

Esperança de Variáveis Aleatórias Discretas

L. Cioletti

Agosto de 2026

Resumo

Estas notas estudam dois temas centrais da teoria das variáveis aleatórias discretas: as funções de variáveis aleatórias e a esperança. Mostramos como a função de probabilidade de $Y = g(X)$ pode ser calculada a partir da função de probabilidade de X , com exemplos concretos como o caso em que g é afim ou $g(x) = x^2$. Em seguida, definimos a esperança de uma variável aleatória discreta, discutimos sua interpretação como valor médio, média ponderada e como centro de gravidade, e demonstramos a Fórmula da Mudança de Variáveis, que permite calcular $\mathbb{E}(g(X))$ diretamente, bem como as propriedades básicas da esperança. Introduzimos também a variância como medida de dispersão em torno da esperança e obtemos a fórmula $\text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$. O texto inclui exemplos envolvendo as distribuições de Poisson e geométrica e exercícios que complementam a exposição. O texto segue de perto as Seções 2.3–2.4 do Capítulo 2 de Grimmett e Welsh [1].

Estas notas dão continuidade ao desenvolvimento da teoria da probabilidade iniciado nas notas *Espaços de Probabilidade e Variáveis Aleatórias Discretas*. Nas primeiras foram introduzidos os ingredientes básicos do modelo probabilístico: o espaço amostral, a σ -álgebra de eventos e a medida de probabilidade; nas segundas, o conceito de variável aleatória discreta e o de função de probabilidade. Aqui estudamos, primeiro, como descrever variáveis aleatórias da forma $Y = g(X)$, obtidas aplicando-se uma função a uma variável aleatória discreta X , e, depois, a noção de *esperança* de X , que é, sem dúvida, um dos conceitos mais importantes de toda a teoria das probabilidades, junto com o de *variância*, que mede o grau de dispersão de X em torno de sua esperança. Seguimos de perto a exposição de [1], que recomendamos como leitura complementar.

1. Funções de Variáveis Aleatórias Discretas

Seja X uma variável aleatória discreta definida sobre um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$ e seja $g : \mathbb{R} \rightarrow \mathbb{R}$ uma função arbitrária. A composição

$$\omega \mapsto Y(\omega) \equiv g(X(\omega)) \quad \forall \omega \in \Omega$$

toma valores em $g(\text{Im } X)$, que é enumerável, e satisfaz $\{Y \in B\} = \{X \in g^{-1}(B)\} \in \mathcal{F}$ para todo boreliano $B \subseteq \mathbb{R}$; portanto $Y \equiv g \circ X$ define uma variável aleatória discreta sobre $(\Omega, \mathcal{F}, \mathbb{P})$. Veja a Figura 1.




Figura 1: Diagrama da composição $Y = g \circ X$: a variável aleatória $X : \Omega \rightarrow \mathbb{R}$ associa cada ponto do espaço amostral $\omega \in \Omega$ ao $X(\omega)$ e este por sua vez é levado por $g : \mathbb{R} \rightarrow \mathbb{R}$ no valor $Y(\omega) = g(X(\omega))$. Em particular, os pontos assinalados satisfazem $y_i = g(x_i) = g(X(\omega_i))$, para $i = 1, 2, 3$.

São exemplos simples de funções de uma variável aleatória:

$$\text{se } g(x) = ax + b, \quad \text{então } g(X) = aX + b,$$

$$\text{se } g(x) = cx^2, \quad \text{então } g(X) = cX^2.$$

A proposição abaixo, embora seja um resultado bastante simples, vai acabar se revelando uma poderosa ferramenta quando estivermos interessados em calcular o valor médio ou a esperança de uma função de uma variável aleatória. Observe que ela fornece uma maneira de representar a função de probabilidade de uma função de uma variável aleatória em termos da função de probabilidade da variável aleatória original.

Proposição 1. Seja X uma variável aleatória discreta sobre um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$ e $Y = g(X)$, onde $g : \mathbb{R} \rightarrow \mathbb{R}$ é uma função arbitrária. Então a função de probabilidade de Y é dada por

$$p_Y(y) = \sum_{x \in \text{Im } X \cap g^{-1}(y)} \mathbb{P}(X = x). \quad (1)$$

Demonstração. Primeiro lembramos que se $A \subseteq \mathbb{R}$ é um conjunto arbitrário (enumerável ou não-enumerável), então o evento $\{X \in A\}$ pode ser decomposto da seguinte maneira como uma união enumerável de eventos

$$\begin{aligned} \{X \in A\} &= \{X \in A\} \cap \Omega \\ &= \{X \in A\} \cap \bigcup_{x \in \text{Im } X} \{X = x\} \\ &= \bigcup_{x \in \text{Im } X} \{X \in A\} \cap \{X = x\} \\ &= \bigcup_{x \in \text{Im } X \cap A} \{X = x\}. \end{aligned}$$

Fixe $y \in \mathbb{R}$ e tome $A = g^{-1}(y)$ na identidade acima. Como os eventos $\{X = x\}$, $x \in \text{Im } X$, são dois a dois disjuntos, temos da definição de função de probabilidade de Y e da σ -aditividade de $\mathbb{P}$ que

$$\begin{aligned} p_Y(y) &= \mathbb{P}(Y = y) = \mathbb{P}(g(X) = y) \\ &= \mathbb{P}(X \in g^{-1}(y)) \\ &= \sum_{x \in \text{Im } X \cap g^{-1}(y)} \mathbb{P}(X = x). \end{aligned}$$

Isso encerra a prova da proposição. ■

Em alguns casos mais simples é possível exibir explicitamente os pontos da imagem inversa de uma função g , isto é, o conjunto de pontos formado por $g^{-1}(y)$, para $y \in \mathbb{R}$. Abaixo vamos mostrar como isto é feito para dois casos particulares de escolhas da função $g : \mathbb{R} \rightarrow \mathbb{R}$.

Seja $g : \mathbb{R} \rightarrow \mathbb{R}$ uma função afim da forma $g(x) = ax + b$. Considere $Y \equiv aX + b$ com $a \neq 0$. Neste caso $g : \mathbb{R} \rightarrow \mathbb{R}$ é uma bijeção e consequentemente uma função invertível. Assim, a imagem inversa de qualquer ponto é um conjunto unitário e neste caso temos

$$\mathbb{P}(Y = y) = \mathbb{P}(aX + b = y) = \mathbb{P}\left(X = \frac{1}{a}(y - b)\right) \quad \text{para qualquer } y \in \mathbb{R}.$$

Vamos considerar agora outro exemplo. Seja $g : \mathbb{R} \rightarrow \mathbb{R}$ dada por $g(x) = x^2$ e considere a variável aleatória $Y = X^2$. Para todo $y > 0$ temos que $g^{-1}(y) = \{-\sqrt{y}, \sqrt{y}\}$, para $y = 0$ temos $g^{-1}(0) = \{0\}$ e para todo $y < 0$ temos $g^{-1}(y) = \emptyset$. Logo, segue da expressão (1) que

$$\mathbb{P}(Y = y) = \begin{cases} \mathbb{P}(X = \sqrt{y}) + \mathbb{P}(X = -\sqrt{y}) & \text{se } y > 0, \\ \mathbb{P}(X = 0) & \text{se } y = 0, \\ 0 & \text{se } y < 0. \end{cases}$$

Exercício 1. Seja X uma variável aleatória discreta com distribuição de Poisson de parâmetro λ , e seja $Y = \left\lfloor \sin\left(\frac{1}{2}\pi X\right) \right\rfloor$. Determine a função de probabilidade de Y .

2. Esperança

Considere um dado honesto. Se ele for lançado um grande número de vezes, cada um dos resultados possíveis $1, 2, \dots, 6$ aparecerá em cerca de um sexto dos lançamentos, e a média dos números observados seria aproximadamente

$$\frac{1}{6} \cdot 1 + \frac{1}{6} \cdot 2 + \dots + \frac{1}{6} \cdot 6 = \frac{7}{2},$$

que chamamos de *valor médio*. Essa noção de valor médio estende-se facilmente a distribuições mais gerais da seguinte forma.

Definição 2 (Esperança). Se X é uma variável aleatória discreta, a *esperança* de X é denotada por $\mathbb{E}(X)$ e definida por

$$\mathbb{E}(X) = \sum_{x \in \text{Im } X} x \mathbb{P}(X = x) \quad (2)$$

sempre que essa soma convergir absolutamente, isto é, sempre que

$$\sum_{x \in \text{Im } X} |x \mathbb{P}(X = x)| < \infty.$$

A equação (2) é frequentemente escrita como

$$\mathbb{E}(X) = \sum_x x \mathbb{P}(X = x) = \sum_x x p_X(x),$$

e a esperança de X é frequentemente chamada de *valor esperado* ou *média* de X . A razão para exigir convergência absoluta em (2) é que a imagem $\text{Im } X$ pode ser um conjunto infinito, e precisamos que a soma em (2) assuma o mesmo valor independentemente da ordem em que somamos seus termos: sem a convergência absoluta, o rearranjo dos termos de uma série condicionalmente convergente poderia alterar o valor da soma.

Uma analogia física para *esperança* é a ideia de *centro de gravidade*. Se massas com pesos $\pi_1, \pi_2, \dots$ são colocadas nos pontos $x_1, x_2, \dots$ de $\mathbb{R}$, então a posição do centro de gravidade é $\sum \pi_i x_i / \sum \pi_i$, ou $\sum x_i p_i$, onde $p_i = \pi_i / \sum_j \pi_j$ é a proporção do peso total alocada à posição x_i .

Se X é uma variável aleatória discreta (em algum espaço de probabilidade) e $g : \mathbb{R} \rightarrow \mathbb{R}$, então $Y = g(X)$ também é uma variável aleatória discreta. De acordo com a definição acima, precisamos conhecer a função de probabilidade de Y antes de calcular sua esperança. O seguinte teorema fornece uma maneira útil de evitar esse cálculo tedioso.

Teorema 3 (Lei do estatístico subconsciente). Se X é uma variável aleatória discreta e $g : \mathbb{R} \rightarrow \mathbb{R}$, então

$$\mathbb{E}(g(X)) = \sum_{x \in \text{Im } X} g(x) \mathbb{P}(X = x),$$

sempre que essa soma convergir absolutamente.

Intuitivamente, esse resultado é bastante claro, pois $g(X)$ assume o valor $g(x)$ quando X assume o valor x , um evento com probabilidade $\mathbb{P}(X = x)$. Uma prova mais formal é a seguinte.

Demonstração. Escrevendo I para a imagem de X , temos que $Y = g(X)$ tem imagem $g(I)$. Assim,

$$\begin{aligned} \mathbb{E}(Y) &= \sum_{y \in g(I)} y \mathbb{P}(Y = y) \\ &= \sum_{y \in g(I)} y \sum_{\substack{x \in I \\ g(x) = y}} \mathbb{P}(X = x) \quad \text{pela equação (1)} \\ &= \sum_{x \in I} g(x) \mathbb{P}(X = x) \end{aligned}$$

se a última soma convergir absolutamente. ■

Duas propriedades simples, mas úteis, da esperança são as seguintes.

Teorema 4. Seja X uma variável aleatória discreta e sejam $a, b \in \mathbb{R}$.

- (a) Se $\mathbb{P}(X \geq 0) = 1$ e $\mathbb{E}(X) = 0$, então $\mathbb{P}(X = 0) = 1$.
- (b) Temos que $\mathbb{E}(aX + b) = a\mathbb{E}(X) + b$.

Demonstração.

- (a) Suponha que as hipóteses sejam satisfeitas. Como $\mathbb{P}(X \geq 0) = 1$, todos os termos $x \mathbb{P}(X = x)$, com $x \in \text{Im } X$, são não negativos. Pela definição (2) de $\mathbb{E}(X)$, a soma desses termos é nula; logo, cada termo deve ser nulo. Portanto, $\mathbb{P}(X = x) = 0$ para $x \neq 0$, e a afirmação segue.
- (b) Esta é uma consequência simples do Teorema 3 aplicado a $g(x) = ax + b$.

■

Vejamos um exemplo de aplicação do Teorema 3.

Exemplo 5. Suponha que X seja uma variável aleatória com distribuição de Poisson de parâmetro λ , e desejamos encontrar o valor esperado de $Y = e^X$. Sem o Teorema 3, teríamos que encontrar a função de probabilidade de Y . Na verdade, isso não é difícil, mas é ainda mais fácil aplicar o teorema para obter

$$\begin{aligned} \mathbb{E}(Y) &= \mathbb{E}(e^X) \\ &= \sum_{k=0}^{\infty} e^k \mathbb{P}(X = k) = \sum_{k=0}^{\infty} e^k \frac{1}{k!} \lambda^k e^{-\lambda} \\ &= e^{-\lambda} \sum_{k=0}^{\infty} \frac{1}{k!} (\lambda e)^k = e^{\lambda(e-1)}. \end{aligned}$$

A esperança $\mathbb{E}(X)$ de uma variável aleatória discreta X é uma indicação do “centro” da distribuição de X . Outra quantidade importante associada a X é a *variância* de X , que é uma medida do grau de dispersão de X em torno de sua esperança $\mathbb{E}(X)$.

Definição 6 (Variância). A *variância* $\text{var}(X)$ de uma variável aleatória discreta X é definida por

$$\text{var}(X) = \mathbb{E}([X - \mathbb{E}(X)]^2). \quad (3)$$

Observamos que, pelo Teorema 3,

$$\text{var}(X) = \sum_{x \in \text{Im } X} (x - \mu)^2 \mathbb{P}(X = x), \quad (4)$$

onde $\mu = \mathbb{E}(X)$. Uma motivação aproximada para essa definição é a seguinte. Se a dispersão de X em torno de sua esperança é muito pequena, então $|X - \mu|$ tende a ser pequeno, fazendo com que $\text{var}(X) = \mathbb{E}(|X - \mu|^2)$ também seja pequena; por outro lado, se há frequentemente uma diferença considerável entre X e sua média, então $|X - \mu|$ pode ser grande, fazendo com que $\text{var}(X)$ também seja grande.

A equação (4) não é sempre a maneira mais conveniente de calcular a variância de uma variável aleatória discreta. Podemos expandir o termo $(x - \mu)^2$ em (4) para obter

$$\begin{aligned}\text{var}(X) &= \sum_x (x^2 - 2\mu x + \mu^2) \mathbb{P}(X = x) \\ &= \sum_x x^2 \mathbb{P}(X = x) - 2\mu \sum_x x \mathbb{P}(X = x) + \mu^2 \sum_x \mathbb{P}(X = x) \\ &= \mathbb{E}(X^2) - 2\mu^2 + \mu^2 \quad \text{pela definição (2) e pelo fato de que } \sum_x \mathbb{P}(X = x) = 1 \\ &= \mathbb{E}(X^2) - \mu^2,\end{aligned}$$

onde $\mu = \mathbb{E}(X)$ como antes. Assim, obtemos a fórmula útil

$$\text{var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2. \quad (5)$$

Exemplo 7. Se X tem distribuição geométrica com parâmetro p ($= 1 - q$), a média de X é

$$\begin{aligned}\mathbb{E}(X) &= \sum_{k=1}^{\infty} k p q^{k-1} \\ &= \frac{p}{(1-q)^2} = \frac{1}{p},\end{aligned}$$

e a variância de X é

$$\text{var}(X) = \sum_{k=1}^{\infty} k^2 p q^{k-1} - \frac{1}{p^2}$$

pela fórmula (5). Agora,

$$\begin{aligned}\sum_{k=1}^{\infty} k^2 q^{k-1} &= q \sum_{k=1}^{\infty} k(k-1) q^{k-2} + \sum_{k=1}^{\infty} k q^{k-1} \\ &= \frac{2q}{(1-q)^3} + \frac{1}{(1-q)^2},\end{aligned}$$

usando a técnica de diferenciação de séries de potências¹, o que dá

$$\begin{aligned}\text{var}(X) &= p \left(\frac{2q}{p^3} + \frac{1}{p^2} \right) - \frac{1}{p^2} \\ &= q p^{-2}.\end{aligned}$$

Exercício 2. Se X tem distribuição binomial com parâmetros n e $p = 1 - q$, mostre que

$$\mathbb{E}(X) = np, \quad \mathbb{E}(X^2) = npq + n^2 p^2,$$

e deduza a variância de X .

Exercício 3. Mostre que $\text{var}(aX + b) = a^2 \text{var}(X)$ para $a, b \in \mathbb{R}$.

Exercício 4. Encontre $\mathbb{E}(X)$ e $\mathbb{E}(X^2)$ quando X tem distribuição de Poisson com parâmetro λ , e mostre que a distribuição de Poisson tem variância igual à sua média.

¹Para somar uma série como $\sum_{k=0}^{\infty} kx^{k-1}$, basta observar que, se $|x| < 1$, então $\sum_k kx^{k-1} = \frac{d}{dx} \sum_k x^k$ e, portanto, $\sum_{k=0}^{\infty} kx^{k-1} = \frac{d}{dx} (1-x)^{-1} = (1-x)^{-2}$. A propriedade relevante das séries de potências é que elas podem ser diferenciadas termo a termo dentro de seu círculo de convergência; diferenciações repetidas de $(1-x)^{-1}$ fornecem fórmulas para $\sum_k k(k-1)x^{k-2}$ e expressões análogas.

Referências

- [1] Geoffrey Grimmett and Dominic Welsh. *Probability—an introduction*. Oxford University Press, Oxford, second edition, 2014.