

A Esperança de Variáveis Aleatórias Discretas

L. Cioletti

Agosto de 2026

Resumo

Nestas notas abordamos dois temas centrais da teoria das variáveis aleatórias discretas: as funções de variáveis aleatórias e a esperança. Mostramos como a função de probabilidade de $Y = g(X)$ pode ser determinada a partir da função de probabilidade de X e apresentamos também alguns exemplos concretos de como este cálculo pode ser feito. Em seguida, definimos a esperança de uma variável aleatória discreta, discutimos sua interpretação como valor médio, média ponderada e como centro de gravidade, e demonstramos o Teorema da Mudança de Variáveis, que permite calcular $\mathbb{E}[g(X)]$ diretamente. Introduzimos também a variância como medida de dispersão em torno do valor médio de X e mostramos a validade da seguinte identidade $\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$. O texto inclui exemplos envolvendo as distribuições de Poisson e geométrica e vários exercícios que complementam a apresentação do material. A exposição segue de perto as Seções 2.3 e 2.4 do Capítulo 2 da referência [1].

1. Funções de Variáveis Aleatórias Discretas

Seja X uma variável aleatória discreta definida sobre um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$ e seja $g : \mathbb{R} \rightarrow \mathbb{R}$ uma função arbitrária. A composição

$$\omega \mapsto Y(\omega) \equiv g(X(\omega)) \quad \forall \omega \in \Omega$$

toma valores em $g(\text{Im } X)$, que é enumerável, e satisfaz $\{Y \in B\} = \{X \in g^{-1}(B)\} \in \mathcal{F}$ para todo boreliano $B \subseteq \mathbb{R}$; portanto $Y \equiv g \circ X$ define uma variável aleatória discreta sobre $(\Omega, \mathcal{F}, \mathbb{P})$. Veja a Figura 1.



CC BY-NC-SA 4.0- Attribution-NonCommercial-ShareAlike 4.0 International




Figura 1: Diagrama da composição $Y = g \circ X$: a variável aleatória $X : \Omega \rightarrow \mathbb{R}$ associa cada ponto do espaço amostral $\omega \in \Omega$ ao $X(\omega)$ e este por sua vez é levado por $g : \mathbb{R} \rightarrow \mathbb{R}$ no valor $Y(\omega) = g(X(\omega))$. Em particular, os pontos assinalados satisfazem $y_i = g(x_i) = g(X(\omega_i))$, para $i = 1, 2, 3$.

São exemplos simples de funções de uma variável aleatória:

$$\text{se } g(x) = ax + b, \quad \text{então } g(X) = aX + b,$$

$$\text{se } g(x) = cx^2, \quad \text{então } g(X) = cX^2.$$

A proposição abaixo, embora seja um resultado bastante simples, vai acabar se revelando uma poderosa ferramenta quando estivermos interessados em calcular o valor médio ou a esperança de uma função de uma variável aleatória. Observe que ela fornece uma maneira de representar a função de probabilidade de uma função de uma variável aleatória em termos da função de probabilidade da variável aleatória original.

Proposição 1. Seja X uma variável aleatória discreta sobre um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$ e $Y = g(X)$, onde $g : \mathbb{R} \rightarrow \mathbb{R}$ é uma função arbitrária. Então a função de probabilidade de Y é dada por

$$p_Y(y) \equiv \mathbb{P}(Y = y) = \sum_{x \in \text{Im } X \cap g^{-1}(y)} \mathbb{P}(X = x). \quad (1)$$

Prova. Primeiro lembramos que se $A \subseteq \mathbb{R}$ é um conjunto arbitrário (enumerável ou não-enumerável), então o evento $\{X \in A\}$ pode ser decomposto da seguinte maneira como uma união enumerável de eventos

$$\begin{aligned} \{X \in A\} &= \{X \in A\} \cap \Omega \\ &= \{X \in A\} \cap \bigcup_{x \in \text{Im } X} \{X = x\} \\ &= \bigcup_{x \in \text{Im } X} \{X \in A\} \cap \{X = x\} \\ &= \bigcup_{x \in \text{Im } X \cap A} \{X = x\}. \end{aligned}$$

Fixe $y \in \mathbb{R}$ e tome $A = g^{-1}(y)$ na identidade acima. Como os eventos $\{X = x\}$, $x \in \text{Im } X$, são dois a dois disjuntos, temos da definição de função de probabilidade de Y e da σ -aditividade de $\mathbb{P}$ que

$$\begin{aligned} p_Y(y) &= \mathbb{P}(Y = y) = \mathbb{P}(g(X) = y) = \mathbb{P}(X \in g^{-1}(y)) \\ &= \sum_{x \in \text{Im } X \cap g^{-1}(y)} \mathbb{P}(X = x). \end{aligned}$$

Isso encerra a prova da proposição. ■

Em alguns casos mais simples é possível exibir explicitamente os pontos da imagem inversa de uma função g , isto é, o conjunto de pontos formado por $g^{-1}(y)$, para $y \in \mathbb{R}$. Abaixo vamos mostrar como isto é feito para dois casos particulares de escolhas da função $g : \mathbb{R} \rightarrow \mathbb{R}$.

Seja $g : \mathbb{R} \rightarrow \mathbb{R}$ uma função afim da forma $g(x) = ax + b$. Considere $Y \equiv aX + b$ com $a \neq 0$. Neste caso $g : \mathbb{R} \rightarrow \mathbb{R}$ é uma bijeção e consequentemente uma função invertível. Assim, a imagem inversa de qualquer ponto é um conjunto unitário e neste caso temos

$$\mathbb{P}(Y = y) = \mathbb{P}(aX + b = y) = \mathbb{P}\left(X = \frac{1}{a}(y - b)\right) \quad \text{para qualquer } y \in \mathbb{R}.$$

Vamos considerar agora outro exemplo. Seja $g : \mathbb{R} \rightarrow \mathbb{R}$ dada por $g(x) = x^2$ e considere a variável aleatória $Y = X^2$. Para todo $y > 0$ temos que $g^{-1}(y) = \{-\sqrt{y}, \sqrt{y}\}$, para $y = 0$ temos $g^{-1}(0) = \{0\}$ e para todo $y < 0$ temos $g^{-1}(y) = \emptyset$. Logo, segue da expressão (1) que

$$\mathbb{P}(Y = y) = \begin{cases} \mathbb{P}(X = \sqrt{y}) + \mathbb{P}(X = -\sqrt{y}) & \text{se } y > 0, \\ \mathbb{P}(X = 0) & \text{se } y = 0, \\ 0 & \text{se } y < 0. \end{cases}$$

Exercício 1. Seja X uma variável aleatória discreta com distribuição de Poisson de parâmetro λ , e seja $Y = \left|\sin\left(\frac{1}{2}\pi X\right)\right|$. Determine a função de probabilidade de Y .




Figura 2: A pré-imagem $g^{-1}(y)$: abscissas dos pontos em que a reta horizontal na altura y corta o gráfico de g .

2. Esperança Matemática ou Valor Esperado

Considere um dado honesto. Se ele for lançado um número muito grande de vezes é natural esperar que cada um dos resultados possíveis $1, 2, \dots, 6$ apareça em cerca de um sexto dos lançamentos. Além do mais a média aritmética dos números observados seria aproximadamente

$$\frac{1}{6} \cdot 1 + \frac{1}{6} \cdot 2 + \dots + \frac{1}{6} \cdot 6 = \frac{7}{2}.$$

Neste contexto o número $7/2$, calculado acima, é às vezes chamado de *valor médio*. Essa noção de valor médio estende-se facilmente a distribuições mais gerais da seguinte forma.

Definição 2 (Esperança). Se X é uma variável aleatória discreta, definida sobre um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$ a *esperança* de X é denotada por $\mathbb{E}[X]$ e definida por

$$\mathbb{E}[X] = \sum_{x \in \text{Im } X} x \mathbb{P}(X = x) \quad (2)$$

sempre que essa soma convergir absolutamente, isto é, sempre que

$$\sum_{x \in \text{Im } X} |x| \mathbb{P}(X = x) < \infty.$$

Se a expressão que aparece em (2) não for absolutamente convergente dizemos que X não possui esperança bem-definida.

A equação (2) é frequentemente escrita de forma mais reduzida (omitindo que a soma é realizada sobre o conjunto enumerável $\text{Im } X$)

$$\mathbb{E}[X] = \sum_x x \mathbb{P}(X = x) = \sum_x x p_X(x),$$

e a esperança de X é às vezes chamada de *valor esperado* ou *média* ou *valor médio* de X . A razão para exigir convergência absoluta em (2) é que a imagem $\text{Im } X$ pode ser um conjunto infinito, e precisamos que a soma em (2) assumo o mesmo valor independentemente da ordem em que somamos seus termos: sem a convergência absoluta, o rearranjo dos termos de uma série condicionalmente convergente poderia alterar o valor da soma.

Exemplo 3. Sejam $(\Omega, \mathcal{F}, \mathbb{P})$ um espaço de probabilidade e $E \in \mathcal{F}$ um evento arbitrário. Então a esperança da variável aleatória $X = \mathbb{1}_E$ é dada por

$$\begin{aligned} \mathbb{E}[X] &= \mathbb{E}[\mathbb{1}_E] = \sum_{x \in \text{Im}(\mathbb{1}_E)} x \mathbb{P}(\mathbb{1}_E = x) \\ &= 0 \cdot \mathbb{P}(\mathbb{1}_E = 0) + 1 \cdot \mathbb{P}(\mathbb{1}_E = 1) \\ &= \mathbb{P}(\mathbb{1}_E = 1) \\ &= \mathbb{P}(E). \end{aligned}$$

Observe que a variável aleatória do **Exemplo 3** é a indicadora do evento E . Esta variável aleatória é também uma variável aleatória de Bernoulli de parâmetro $p = \mathbb{P}(E)$, ou seja, $\mathbb{1}_E \sim \text{Bernoulli}(p)$.

Exemplo 4. Seja X uma variável aleatória com distribuição zeta de parâmetro $s > 1$, isto é, $\text{Im } X = \{1, 2, 3, \dots\}$ e

$$\mathbb{P}(X = n) = \frac{1}{n^s \zeta(s)}, \quad n = 1, 2, 3, \dots,$$

onde $\zeta(s) = \sum_{n=1}^{\infty} \frac{1}{n^s}$ é a função zeta de Riemann, cuja série é convergente precisamente quando $s > 1$. A esperança de X é dada por

$$\begin{aligned} \mathbb{E}[X] &= \sum_{n=1}^{\infty} n \mathbb{P}(X = n) \\ &= \frac{1}{\zeta(s)} \sum_{n=1}^{\infty} \frac{n}{n^s} = \frac{1}{\zeta(s)} \sum_{n=1}^{\infty} \frac{1}{n^{s-1}}. \end{aligned}$$

A última série é uma p -série com $p = s - 1$, de modo que esta série é absolutamente convergente se, e somente se, o expoente $p = s - 1 > 1$, ou seja, $s > 2$. Concluimos que $\mathbb{E}[X]$ existe e é finito precisamente quando $s > 2$, caso em que

$$\mathbb{E}[X] = \frac{\zeta(s-1)}{\zeta(s)}.$$

Para $1 < s \leq 2$ a última série diverge e, portanto, X não possui esperança bem definida no sentido da **Definição 2**. Observamos, ainda, que o parâmetro s não poderia ser tomado menor ou igual a 1: nesses casos a própria função $\zeta(s)$ diverge e portanto a expressão

$$\mathbb{P}(X = n) = \frac{1}{n^s \zeta(s)}$$

nem sequer define uma distribuição de probabilidade.

Uma observação muito importante é que se X e Y são variáveis aleatórias arbitrárias (que podem ser completamente distintas e definidas em espaços de probabilidade distintos também), com a mesma função de probabilidade, então suas esperanças coincidem, desde que existam. De fato, a existência de uma delas implica a existência da outra, e nesse caso $\mathbb{E}[X] = \mathbb{E}[Y]$. Esta observação enfatiza que a função de probabilidade determina completamente o valor médio de uma variável aleatória, independentemente de quaisquer outras particularidades da variável aleatória em questão.

Uma analogia física para *esperança* de uma variável aleatória X é a ideia de *centro de gravidade*. Se massas com pesos $\pi_1, \pi_2, \dots$ são colocadas nos pontos $x_1, x_2, \dots$ de $\mathbb{R}$, então a posição do centro de gravidade é

$$\frac{\sum_i \pi_i x_i}{\sum_i \pi_i} = \sum_i x_i p_i, \quad p_i = \frac{\pi_i}{\sum_j \pi_j},$$

desde que $0 < \sum_i \pi_i < \infty$ e que a série do numerador convirja absolutamente. Aqui, p_i é a proporção do peso total alocada à posição x_i .

Se X é uma variável aleatória discreta (em algum espaço de probabilidade) e $g : \mathbb{R} \rightarrow \mathbb{R}$, então $Y = g(X)$ também é uma variável aleatória discreta. De acordo com a definição

acima, só precisamos conhecer a função de probabilidade de Y para calcular sua esperança. O próximo teorema fornece uma maneira útil de evitar esse cálculo tedioso e muitas vezes inviável. Este resultado mostra também que valores médios mesmo de expressões muito complicadas envolvendo uma variável aleatória X dependem essencialmente da função de probabilidade de X .

Teorema 5 (Teorema da Mudança de Variáveis). Se X é uma variável aleatória discreta e $g : \mathbb{R} \rightarrow \mathbb{R}$, então

$$\mathbb{E}[g(X)] = \sum_{x \in \text{Im } X} g(x) \mathbb{P}(X = x), \quad (3)$$

sempre que essa soma convergir absolutamente.

Este resultado é também conhecido como *lei do estatístico subconsciente* (do inglês *law of the unconscious statistician*).

Prova. Para obter a igualdade acima, escreva

$$I = \text{Im } X, \quad J = g(I), \quad Y = g(X).$$

Para cada $y \in J$, considere o seguinte conjunto

$$I_y = I \cap g^{-1}(\{y\}).$$

Pelas propriedades elementares da imagem inversa podemos verificar que a coleção de todos os conjuntos definidos acima formam uma partição de I , ou seja,

$$I = \bigcup_{y \in J} I_y \quad (4)$$

e a união é formada por conjuntos dois-a-dois disjuntos.




Figura 3: Exemplos dos conjuntos $I_{y_1} = \{x_1, x_3, x_5\}$ e $I_{y_2} = \{x_2, x_4\}$.

Pela hipótese do teorema,

$$\sum_{x \in I} |g(x)| \mathbb{P}(X = x) < \infty. \quad (5)$$

Note que segue de (1) e da definição de I_y que

$$\mathbb{P}(Y = y) = \sum_{x \in \text{Im } X \cap g^{-1}(y)} \mathbb{P}(X = x) = \sum_{x \in I_y} \mathbb{P}(X = x).$$

Usando a identidade acima, $|g(x)| = |y|$, para todo $x \in I_y$, $I = \cup_{y \in J} I_y$ e (5) concluímos que a seguinte série é convergente

$$\begin{aligned} \sum_{y \in J} |y| \mathbb{P}(Y = y) &= \sum_{y \in J} |y| \sum_{x \in I_y} \mathbb{P}(X = x) \\ &= \sum_{y \in J} \sum_{x \in I_y} |y| \mathbb{P}(X = x) \\ &= \sum_{y \in J} \sum_{x \in I_y} |g(x)| \mathbb{P}(X = x) \\ &= \sum_{x \in I} |g(x)| \mathbb{P}(X = x) < \infty. \end{aligned}$$

Logo, $Y = g(X)$ possui esperança bem definida. A convergência absoluta estabelecida acima, permite agora reagrupar os termos da série que define a esperança de Y e argumentar de maneira análoga a feita acima que

$$\begin{aligned} \mathbb{E}[g(X)] &= \mathbb{E}[Y] = \sum_{y \in J} y \mathbb{P}(Y = y) \\ &= \sum_{y \in J} y \sum_{x \in I_y} \mathbb{P}(X = x) \\ &= \sum_{y \in J} \sum_{x \in I_y} g(x) \mathbb{P}(X = x) \\ &= \sum_{x \in I} g(x) \mathbb{P}(X = x). \end{aligned}$$

O que encerra a demonstração do teorema. ■

Duas propriedades simples, mas úteis, da esperança são as seguintes.

Teorema 6. Seja X uma variável aleatória discreta com esperança bem definida e sejam $a, b \in \mathbb{R}$.

- (a) Se $\mathbb{P}(X \geq 0) = 1$ e $\mathbb{E}[X] = 0$, então $\mathbb{P}(X = 0) = 1$.
- (b) Temos que $\mathbb{E}[aX + b] = a \mathbb{E}[X] + b$.

Prova.

- (a) Por hipótese temos $\mathbb{P}(X \geq 0) = 1$. E já que os eventos $\{X \geq 0\}$ e $\{X < 0\}$ são eventos disjuntos concluímos que $\mathbb{P}(X < 0) = 0$. Desta forma para todo $x < 0$ temos $\{X = x\} \subseteq \{X < 0\}$ e portanto segue da propriedade de monotonicidade da probabilidade que $\mathbb{P}(X = x) = 0$, para todo $x < 0$. Como estamos assumindo que existe esperança de X e que $\mathbb{E}[X] = 0$, então podemos usar a convergência absoluta da série que define a esperança e reorganizar suas parcelas como segue

$$\mathbb{E}[X] = \sum_{x \in \text{Im } X} x \mathbb{P}(X = x) = \sum_{\substack{x \in \text{Im } X \\ x \geq 0}} x \mathbb{P}(X = x) + \sum_{\substack{x \in \text{Im } X \\ x < 0}} x \mathbb{P}(X = x)$$

Como visto acima $\mathbb{P}(X = x) = 0$, para todo $x < 0$. Logo segue da última igualdade que

$$\begin{aligned} \mathbb{E}[X] &= \sum_{x \in \text{Im } X} x \mathbb{P}(X = x) = \sum_{\substack{x \in \text{Im } X \\ x \geq 0}} x \mathbb{P}(X = x) \\ &= 0 \cdot \mathbb{P}(X = 0) + \sum_{\substack{x \in \text{Im } X \\ x > 0}} x \mathbb{P}(X = x) \\ &= \sum_{\substack{x \in \text{Im } X \\ x > 0}} x \mathbb{P}(X = x). \end{aligned}$$

Como estamos assumindo que $\mathbb{E}[X] = 0$, segue da igualdade acima que

$$0 = \mathbb{E}[X] = \sum_{\substack{x \in \text{Im } X \\ x > 0}} x \mathbb{P}(X = x).$$

Como cada parcela da série acima é não-negativa e o somatório inteiro é zero, então concluímos que todas as parcelas devem ser nulas. Portanto $\mathbb{P}(X = x) = 0$, para todo $x > 0$. Usando este fato e lembrando que $\mathbb{P}(X = x) = 0$, para todo $x < 0$ e que

$$\Omega = \{X = 0\} \cup \left(\bigcup_{\substack{x \in \text{Im } X \\ x > 0}} \{X = x\} \right) \cup \left(\bigcup_{\substack{x \in \text{Im } X \\ x < 0}} \{X = x\} \right)$$

Concluímos do fato dos conjuntos acima serem dois-a-dois disjuntos e da σ -aditividade da medida $\mathbb{P}$ que

$$\begin{aligned} 1 = \mathbb{P}(\Omega) &= \mathbb{P}(X = 0) + \mathbb{P} \left(\bigcup_{\substack{x \in \text{Im } X \\ x > 0}} \{X = x\} \right) + \mathbb{P} \left(\bigcup_{\substack{x \in \text{Im } X \\ x < 0}} \{X = x\} \right) \\ &= \mathbb{P}(X = 0) + \sum_{\substack{x \in \text{Im } X \\ x > 0}} \mathbb{P}(X = x) + \sum_{\substack{x \in \text{Im } X \\ x < 0}} \mathbb{P}(X = x) \\ &= \mathbb{P}(X = 0). \end{aligned}$$

O que prova a afirmação.

- (b) A prova é uma aplicação direta do **Teorema 5**. De fato, considere a função $g(x) = ax + b$. Então a variável aleatória $g(X) = aX + b$ e pelo **Teorema 5** temos

$$\begin{aligned}
 \mathbb{E}[aX + b] &= \mathbb{E}[g(X)] = \sum_{x \in \text{Im } X} g(x) \mathbb{P}(X = x) \\
 &= \sum_{x \in \text{Im } X} (ax + b) \mathbb{P}(X = x) \\
 &= \sum_{x \in \text{Im } X} ax \mathbb{P}(X = x) + \sum_{x \in \text{Im } X} b \mathbb{P}(X = x) \\
 &= a \sum_{x \in \text{Im } X} x \mathbb{P}(X = x) + b \sum_{x \in \text{Im } X} \mathbb{P}(X = x) \\
 &= a\mathbb{E}[X] + b.
 \end{aligned}$$

■

Vejamos um exemplo de aplicação do **Teorema 5**.

Exemplo 7. Suponha que X seja uma variável aleatória com distribuição de Poisson de parâmetro $\lambda \geq 0$, e desejamos encontrar o valor esperado de $Y = e^X$. Sem o **Teorema 5**, teríamos que encontrar a função de probabilidade de Y . Na verdade, isso não é difícil, mas é ainda mais fácil aplicar o teorema. Primeiro, verificamos que a série do lado direito do teorema converge:

$$\begin{aligned}
 \sum_{k=0}^{\infty} e^k \mathbb{P}(X = k) &= \sum_{k=0}^{\infty} e^k \frac{1}{k!} \lambda^k e^{-\lambda} \\
 &= e^{-\lambda} \sum_{k=0}^{\infty} \frac{1}{k!} (\lambda e)^k = e^{\lambda(e-1)}.
 \end{aligned}$$

Portanto, pelo **Teorema 5**,

$$\mathbb{E}[Y] = \mathbb{E}[e^X] = e^{\lambda(e-1)}.$$

O próximo exemplo ilustra uma situação em que o Teorema da Mudança de Variáveis permite calcular uma esperança sem determinar previamente a função de probabilidade da variável transformada.

Exemplo 8. Suponha que X seja uma variável aleatória com distribuição de Poisson de parâmetro $\lambda \geq 0$, e defina

$$Y = \left| \sin \left(\frac{\pi}{2} X \right) \right|.$$

Como X assume apenas valores inteiros, então Y assume apenas valores da forma

$$\left| \sin \left(\frac{1}{2} \pi k \right) \right| = \begin{cases} 1, & \text{se } k \text{ é ímpar,} \\ 0, & \text{se } k \text{ é par.} \end{cases}$$

Assim, $Y = \mathbb{1}_{\{X \text{ é ímpar}\}}$. Pelo Teorema 5,

$$\begin{aligned}\mathbb{E}[Y] &= \sum_{k=0}^{\infty} \left| \sin\left(\frac{1}{2}\pi k\right) \right| \mathbb{P}(X = k) \\ &= \mathbb{P}(X \text{ é ímpar}) \\ &= e^{-\lambda} \sum_{j=0}^{\infty} \frac{\lambda^{2j+1}}{(2j+1)!} \\ &= e^{-\lambda} \sinh(\lambda) = \frac{1 - e^{-2\lambda}}{2}.\end{aligned}$$

Portanto,

$$\mathbb{E}\left[\left|\sin\left(\frac{1}{2}\pi X\right)\right|\right] = \frac{1 - e^{-2\lambda}}{2}.$$

Proposição 9. Sejam X e Y variáveis aleatórias definidas sobre um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$. Assuma que ambas possuem esperança finita.

- (a) se $\mathbb{P}(X \geq 0) = 1$, então $\mathbb{E}[X] \geq 0$;
- (b) se $\mathbb{P}(X \leq Y) = 1$, então $\mathbb{E}[X] \leq \mathbb{E}[Y]$.

Prova. Suponhamos que as esperanças envolvidas estejam bem definidas.

- (a) Como estamos assumindo que $\mathbb{P}(X \geq 0) = 1$ e como os eventos $\{X \geq 0\}$ e $\{X < 0\}$ são disjuntos, podemos concluir que $\mathbb{P}(X < 0) = 0$. Desta forma, para todo $x < 0$, como $\{X = x\} \subseteq \{X < 0\}$, segue da monotonicidade da probabilidade que $\mathbb{P}(X = x) = 0$. Usando a convergência absoluta da série que define a esperança para separar suas parcelas conforme o sinal de x , obtemos

$$\begin{aligned}\mathbb{E}[X] &= \sum_{x \in \text{Im } X} x \mathbb{P}(X = x) = \sum_{\substack{x \in \text{Im } X \\ x < 0}} x \mathbb{P}(X = x) + \sum_{\substack{x \in \text{Im } X \\ x \geq 0}} x \mathbb{P}(X = x) \\ &= \sum_{\substack{x \in \text{Im } X \\ x \geq 0}} x \mathbb{P}(X = x),\end{aligned}$$

onde a primeira soma do lado direito da primeira igualdade é nula, pois todas as suas probabilidades são nulas. Como cada parcela da última soma é não-negativa, concluímos que $\mathbb{E}[X] \geq 0$.

- (b) Escrevemos $\mathbb{P}(X = x, Y = y)$ como abreviação para $\mathbb{P}(\{X = x\} \cap \{Y = y\})$, onde $x \in \text{Im } X$ e $y \in \text{Im } Y$. Os eventos $\{X = x\} \cap \{Y = y\}$ formam uma família dois a dois disjunta, indexada pelo conjunto enumerável $\text{Im } X \times \text{Im } Y$, cuja união é Ω . Logo, da σ -aditividade de $\mathbb{P}$,

$$\mathbb{P}(Y = y) = \sum_{x \in \text{Im } X} \mathbb{P}(X = x, Y = y) \quad \text{e} \quad \mathbb{P}(X = x) = \sum_{y \in \text{Im } Y} \mathbb{P}(X = x, Y = y).$$

De fato, vamos provar a primeira das igualdades acima já que em ambos os casos os argumentos são completamente análogos

$$\begin{aligned}\sum_{x \in \text{Im } X} \mathbb{P}(X = x, Y = y) &= \mathbb{P}\left(\bigcup_{x \in \text{Im } X} \{X = x\} \cap \{Y = y\}\right) \\ &= \mathbb{P}(\Omega \cap \{Y = y\}) \\ &= \mathbb{P}(Y = y).\end{aligned}$$

Além disso,

$$\begin{aligned}\sum_{\substack{x \in \text{Im } X \\ y \in \text{Im } Y}} |y| \mathbb{P}(X = x, Y = y) &= \sum_{y \in \text{Im } Y} \sum_{x \in \text{Im } X} |y| \mathbb{P}(X = x, Y = y) \\ &= \sum_{y \in \text{Im } Y} |y| \sum_{x \in \text{Im } X} \mathbb{P}(X = x, Y = y) \\ &= \sum_{y \in \text{Im } Y} |y| \mathbb{P}\left(\bigcup_{x \in \text{Im } X} \{X = x\} \cap \{Y = y\}\right) \\ &= \sum_{y \in \text{Im } Y} |y| \mathbb{P}(Y = y) < \infty,\end{aligned}$$

de modo que podemos usar a convergência absoluta para reagrupar as parcelas das séries que definem $\mathbb{E}[X]$ e $\mathbb{E}[Y]$, obtendo

$$\mathbb{E}[Y] = \sum_{y \in \text{Im } Y} y \mathbb{P}(Y = y) = \sum_{\substack{x \in \text{Im } X \\ y \in \text{Im } Y}} y \mathbb{P}(X = x, Y = y)$$

e, analogamente,

$$\mathbb{E}[X] = \sum_{x \in \text{Im } X} x \mathbb{P}(X = x) = \sum_{\substack{x \in \text{Im } X \\ y \in \text{Im } Y}} x \mathbb{P}(X = x, Y = y).$$

Por hipótese, $\mathbb{P}(X \leq Y) = 1$. Como

$$\{X > Y\} = \bigcup_{\substack{x \in \text{Im } X \\ y \in \text{Im } Y \\ x > y}} \{X = x\} \cap \{Y = y\}$$

é uma união enumerável de eventos dois a dois disjuntos com probabilidade nula, concluímos que $\mathbb{P}(X = x, Y = y) = 0$, sempre que $x > y$. Portanto, subtraindo as duas últimas igualdades e descartando as parcelas de probabilidade nula,

$$\begin{aligned}\mathbb{E}[Y] - \mathbb{E}[X] &= \sum_{\substack{x \in \text{Im } X \\ y \in \text{Im } Y}} (y - x) \mathbb{P}(X = x, Y = y) \\ &= \sum_{\substack{x \in \text{Im } X \\ y \in \text{Im } Y \\ x \leq y}} (y - x) \mathbb{P}(X = x, Y = y) \geq 0,\end{aligned}$$

pois cada parcela da última soma é produto de dois fatores não negativos. Logo, $\mathbb{E}[X] \leq \mathbb{E}[Y]$. ■

Lema 10. Seja X uma variável aleatória discreta tal que $\mathbb{E}[X^2] < +\infty$. Então $|X|$ possui esperança bem definida e

$$\mathbb{E}[|X|] \leq 1 + \mathbb{E}[X^2].$$

Prova. Inicialmente, observamos que vale a desigualdade pontual

$$|x| \leq 1 + x^2, \quad x \in \mathbb{R}.$$

De fato, se $|x| \leq 1$, então $|x| \leq 1 \leq 1 + x^2$; já se $|x| > 1$, então $|x| < x^2 \leq 1 + x^2$. Em particular, para todo $x \in \text{Im } X$, temos

$$|x| \mathbb{P}(X = x) \leq (1 + x^2) \mathbb{P}(X = x).$$

Somando as desigualdades acima sobre $x \in \text{Im } X$, usando que $\sum_{x \in \text{Im } X} \mathbb{P}(X = x) = 1$ e o Teorema da Mudança de Variáveis concluímos que

$$\begin{aligned} \sum_{x \in \text{Im } X} |x| \mathbb{P}(X = x) &\leq \sum_{x \in \text{Im } X} (1 + x^2) \mathbb{P}(X = x) \\ &= \sum_{x \in \text{Im } X} \mathbb{P}(X = x) + \sum_{x \in \text{Im } X} x^2 \mathbb{P}(X = x) \\ &= 1 + \mathbb{E}[X^2] < +\infty. \end{aligned}$$

Como todas as parcelas $|x| \mathbb{P}(X = x)$ são não-negativas segue do teste de comparação de séries não-negativas que a série do lado esquerdo da desigualdade acima é absolutamente convergente. Portanto a série que define a esperança de $|X|$ é absolutamente convergente, isto é, $|X|$ possui esperança bem definida e

$$\mathbb{E}[|X|] \leq 1 + \mathbb{E}[X^2],$$

o que conclui a demonstração. ■

Observação 11. Uma observação sobre a demonstração acima é pertinente. À primeira vista, seria tentador obter a estimativa diretamente do item (b) da Proposição anterior, afinal $\mathbb{P}(|X| \leq 1 + X^2) = 1$. Ocorre, porém, que o item (b) compara apenas esperanças já bem definidas, enquanto a existência de $\mathbb{E}[|X|]$ é precisamente o que queremos estabelecer. A estimação termo a termo feita acima contorna esse problema: ela estabelece a existência da esperança de $|X|$ e a estimativa simultaneamente.

A esperança $\mathbb{E}[X]$ de uma variável aleatória discreta X pode ser pensada como uma noção mais vaga de “centro” de como estão distribuídos os valores de X . Outra quantidade importante associada a X é a *variância* de X , que é uma medida do grau de dispersão de X em torno de sua esperança $\mathbb{E}[X]$.

Definição 12 (Variância). A *variância* $\text{Var}(X)$ de uma variável aleatória discreta X tal que $\mathbb{E}[X^2] < \infty$ é definida por

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]. \quad (6)$$

Observamos que, pelo **Teorema 5**,

$$\text{Var}(X) = \sum_{x \in \text{Im } X} (x - \mu)^2 \mathbb{P}(X = x), \quad (7)$$

onde $\mu = \mathbb{E}[X]$. Uma motivação aproximada para essa definição é a seguinte. Se a dispersão de X em torno de sua esperança é muito pequena, então $|X - \mu|$ é tipicamente pequeno, fazendo com que $\text{Var}(X) = \mathbb{E}[|X - \mu|^2]$ também seja pequena; por outro lado, se há frequentemente uma diferença considerável entre X e sua média, então $|X - \mu|$ pode ser grande, fazendo com que $\text{Var}(X)$ também seja grande.

A equação (7) não é sempre a maneira mais conveniente de calcular a variância de uma variável aleatória discreta. Podemos expandir o termo $(x - \mu)^2$ em (7) para obter

$$\begin{aligned} \text{Var}(X) &= \sum_{x \in \text{Im } X} (x^2 - 2\mu x + \mu^2) \mathbb{P}(X = x) \\ &= \sum_{x \in \text{Im } X} x^2 \mathbb{P}(X = x) - 2\mu \sum_{x \in \text{Im } X} x \mathbb{P}(X = x) + \mu^2 \sum_{x \in \text{Im } X} \mathbb{P}(X = x) \\ &= \mathbb{E}[X^2] - 2\mu^2 + \mu^2 \quad \text{pela definição (2) e pelo fato de que } \sum_{x \in \text{Im } X} \mathbb{P}(X = x) = 1 \\ &= \mathbb{E}[X^2] - \mu^2, \end{aligned}$$

onde $\mu = \mathbb{E}[X]$ como antes. Assim, obtemos a fórmula útil

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2. \quad (8)$$

Exemplo 13. Considere novamente o dado honesto da introdução e seja X o número obtido em um lançamento. Como X assume cada um dos valores $1, \dots, 6$ com probabilidade $1/6$, temos

$$\mathbb{E}[X^2] = \frac{1}{6}(1^2 + 2^2 + \dots + 6^2) = \frac{91}{6},$$

e segue da fórmula (8) que

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{91}{6} - \left(\frac{7}{2}\right)^2 = \frac{182 - 147}{12} = \frac{35}{12} \approx 2,92.$$

A raiz quadrada da variância é chamada de *desvio padrão* de X e denotada por σ_X . No caso de um dado honesto,

$$\sigma_X = \sqrt{\frac{35}{12}} \approx 1,71,$$

que se interpreta como a escala típica das flutuações de X em torno de sua média $7/2$.

Observação 14. A variância, e não o desvio padrão, constitui-se em uma medida de dispersão “aditiva”, no seguinte sentido. Para variáveis aleatórias independentes com variâncias finitas, vamos mostrar que é válida a seguinte identidade

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y).$$

A definição formal de variáveis aleatórias independentes será apresentada em aula posterior; aqui, basta a ideia intuitiva de que conhecer o valor de uma das variáveis não altera as

probabilidades da outra. Por exemplo, se X e Y são os resultados de dois lançamentos do dado honesto da introdução, o **Exemplo 13** dá

$$\text{Var}(X + Y) = \frac{35}{12} + \frac{35}{12} = \frac{35}{6}.$$

Os desvios padrões, porém, *não* se somam: na mesma situação,

$$\sigma_{X+Y} = \sqrt{\frac{35}{6}} \approx 2,42 \quad \text{enquanto} \quad \sigma_X + \sigma_Y = 2\sqrt{\frac{35}{12}} \approx 3,42,$$

pois, para $a, b \geq 0$, $\sqrt{a^2 + b^2} \leq a + b$, com igualdade apenas quando $a = 0$ ou $b = 0$. Este é um erro comum: para medir a dispersão de uma soma o correto é somar as *variâncias*, e não desvios padrões. O desvio padrão permanece útil por sua interpretação, já que possui a mesma unidade de medida de X .

Exemplo 15. A hipótese $\mathbb{E}[X^2] < \infty$ da **Definição 12** não é automática: ela é estritamente mais forte do que a existência de $\mathbb{E}[X]$. De fato, retomando a distribuição zeta do **Exemplo 4**, se $X \sim \text{Zeta}(3)$, então

$$\mathbb{E}[X] = \frac{\zeta(2)}{\zeta(3)} < \infty.$$

Porém

$$\mathbb{E}[X^2] = \frac{1}{\zeta(3)} \sum_{n=1}^{\infty} \frac{n^2}{n^3} = \frac{1}{\zeta(3)} \sum_{n=1}^{\infty} \frac{1}{n} = +\infty,$$

uma vez que a última série é a série harmônica. Logo, $\text{Var}(X)$ não está definida para $X \sim \text{Zeta}(3)$, apesar de $\mathbb{E}[X]$ existir e ser finito. Em particular, o **Lema 10** não pode ser revertido: $\mathbb{E}[|X|] < \infty$ não implica $\mathbb{E}[X^2] < \infty$.

Exemplo 16. Se X tem distribuição geométrica, com suporte $\{1, 2, \dots\}$, e parâmetro $0 < p \leq 1$, escreva $q = 1 - p$. No caso degenerado $p = 1$, temos $\mathbb{P}(X = 1) = 1$. Para calcular a esperança e a variância de X , precisaremos de duas identidades obtidas por derivação sucessiva da fórmula da soma de uma série geométrica

$$\sum_{k=0}^{\infty} x^k = \frac{1}{1-x}, \quad \forall x \in (-1, 1)$$

Estas identidades são:

$$\sum_{k=1}^{\infty} kx^{k-1} = \frac{1}{(1-x)^2}, \quad \sum_{k=2}^{\infty} k(k-1)x^{k-2} = \frac{2}{(1-x)^3}.$$

Para $0 < p < 1$, o valor médio de X é dado por

$$\mathbb{E}[X] = \sum_{k=1}^{\infty} k p q^{k-1} = p \sum_{k=1}^{\infty} k q^{k-1} = \frac{p}{(1-q)^2} = \frac{1}{p},$$

A fórmula obtida abaixo também vale no caso $p = 1$, fornecendo $\mathbb{E}[X] = 1/p = 1$ e $\text{Var}(X) = q/p^2 = 0$. A variância de X , pela fórmula (8), é dada por

$$\text{Var}(X) = \sum_{k=1}^{\infty} k^2 p q^{k-1} - \frac{1}{p^2}. \quad (9)$$

Observando que $k^2 = k(k-1) + k$ e colocando um fator de q em evidência no primeiro somatório e depois usando as identidades acima, concluímos que

$$\begin{aligned}\sum_{k=1}^{\infty} k^2 q^{k-1} &= q \sum_{k=2}^{\infty} k(k-1) q^{k-2} + \sum_{k=1}^{\infty} k q^{k-1} \\ &= \frac{2q}{(1-q)^3} + \frac{1}{(1-q)^2}.\end{aligned}$$

Substituindo a igualdade acima em (9) concluímos finalmente que

$$\text{Var}(X) = p \left(\frac{2q}{p^3} + \frac{1}{p^2} \right) - \frac{1}{p^2} = \frac{q}{p^2}.$$

Exercício 2. Se X tem distribuição binomial com parâmetros $n \in \mathbb{N}$ e $0 \leq p \leq 1$, escreva $q = 1 - p$ e mostre que

$$\mathbb{E}[X] = np, \quad \mathbb{E}[X^2] = npq + n^2 p^2,$$

e deduza a variância de X .

Exercício 3. Supondo que X tenha variância finita, mostre que $\text{Var}(aX + b) = a^2 \text{Var}(X)$ para $a, b \in \mathbb{R}$.

Exercício 4. Encontre $\mathbb{E}[X]$ e $\mathbb{E}[X^2]$ quando X tem distribuição de Poisson com parâmetro $\lambda \geq 0$, e mostre que a distribuição de Poisson tem variância igual à sua média.

Exercício 5. Seja X uma variável aleatória discreta cuja variância está bem-definida e igual a zero. Mostre que existe alguma constante $c \in \mathbb{R}$ tal que $\mathbb{P}(X = c) = 1$.

Referências

- [1] Geoffrey Grimmett and Dominic Welsh. *Probability—an introduction*. Oxford University Press, Oxford, second edition, 2014.