

Funções de Distribuição

L. Cioletti

Setembro de 2026

Resumo

Estas notas dão continuidade ao estudo das variáveis aleatórias iniciado nas notas sobre variáveis aleatórias discretas. Introduzimos a noção geral de variável aleatória e a função de distribuição, estudamos suas propriedades gerais e apresentamos os primeiros exemplos. Em seguida definimos as variáveis aleatórias contínuas por meio de suas funções densidade de probabilidade e mostramos como a densidade se relaciona com a função de distribuição. Reunimos também as densidades usuais, a saber, a uniforme, a exponencial, a normal, a de Cauchy, a gama, a beta e a qui-quadrado, verificando as suas normalizações e a relação entre as funções gama e beta. O texto segue de perto as Seções 5.1–5.4 do Capítulo 5 de Grimmett e Welsh [1] e conta com uma lista de exercícios ao final.

1. Funções de Distribuição

Até aqui trabalhamos com variáveis aleatórias discretas, que assumem apenas uma quantidade enumerável de valores. Essa condição é restritiva demais para muitas situações e, por isso, vamos adotar uma definição mais ampla.

Definição 1 (Variável aleatória). Seja $(\Omega, \mathcal{F}, \mathbb{P})$ um espaço de probabilidade. Dizemos que X é uma *variável aleatória* se X é uma função $X : \Omega \rightarrow \mathbb{R}$ tal que

$$\{\omega \in \Omega : X(\omega) \leq x\} \in \mathcal{F} \quad \text{para todo } x \in \mathbb{R}. \quad (1)$$

Quando (1) vale, dizemos que X é $\mathcal{F}$ -mensurável. Daqui em diante, abreviamos o evento $\{\omega \in \Omega : X(\omega) \leq x\}$ pela expressão mais simples $\{X \leq x\}$.

Exigimos que as variáveis aleatórias satisfaçam (1) pela mesma razão pela qual exigimos uma condição análoga na definição de variável aleatória discreta. Estamos interessados nos valores assumidos por X e nas probabilidades associadas a esses valores. Uma maneira conveniente de estudá-los é fixar $x \in \mathbb{R}$ e calcular a probabilidade de que X assumira um valor no intervalo $(-\infty, x]$. Essa probabilidade só está definida quando a pré-imagem $X^{-1}((-\infty, x]) = \{X \leq x\}$ pertence ao espaço de eventos $\mathcal{F}$, e é por isso que postulamos que essa condição vale para todo $x \in \mathbb{R}$.



Observe que toda variável aleatória discreta é uma variável aleatória. De fato, se X é discreta, então

$$\{X \leq x\} = \bigcup_{y \in \text{Im } X: y \leq x} \{X = y\},$$

que é uma união enumerável de eventos em $\mathcal{F}$ e, portanto, também pertence a $\mathcal{F}$.

Enquanto as variáveis aleatórias discretas eram estudadas por meio de suas funções de probabilidade, as variáveis aleatórias no sentido mais amplo são estudadas por meio de suas funções de distribuição, definidas a seguir.

Definição 2 (Função de distribuição). Seja X uma variável aleatória em $(\Omega, \mathcal{F}, \mathbb{P})$. A *função de distribuição* de X é a função $F_X : \mathbb{R} \rightarrow [0, 1]$ definida por

$$F_X(x) = \mathbb{P}(X \leq x). \quad (2)$$

A função de distribuição de X também é chamada, em alguns textos, de função de distribuição acumulada de X .

Exemplo 3 (Função de distribuição de uma variável discreta). Suponha que X seja uma variável aleatória discreta que assume valores inteiros não negativos, com função de probabilidade

$$\mathbb{P}(X = k) = p_k \quad \text{para } k = 0, 1, 2, \dots$$

Para $x \in \mathbb{R}$, temos que $X \leq x$ se, e somente se, X assume um dos valores $0, 1, 2, \dots, \lfloor x \rfloor$, onde $\lfloor x \rfloor$ denota o maior inteiro que não supera x . Logo

$$F_X(x) = \begin{cases} 0, & \text{se } x < 0, \\ p_0 + p_1 + \dots + p_{\lfloor x \rfloor}, & \text{se } x \geq 0. \end{cases}$$

Um esboço dessa função, no caso em que X assume valores no conjunto $\{0, 1, 2, 3, 4, 5\}$, é apresentado na [Figura 1](#).




Figura 1: A função de distribuição de uma variável aleatória que assume valores no conjunto $\{0, 1, 2, 3, 4, 5\}$. Os degraus são crescentes e a função é contínua à direita, mas descontínua à esquerda em cada ponto do suporte.

A função de distribuição F_X possui várias propriedades gerais e elementares, reunidas a seguir.

Proposição 4 (Propriedades da função de distribuição). Seja X uma variável aleatória em $(\Omega, \mathcal{F}, \mathbb{P})$ e seja F_X a sua função de distribuição. Então:

(i) F_X é monótona não decrescente, isto é,

$$F_X(x) \leq F_X(y) \quad \text{se } x \leq y; \quad (3)$$

(ii) os limites nas extremidades são

$$\lim_{x \rightarrow -\infty} F_X(x) = 0 \quad \text{e} \quad \lim_{x \rightarrow +\infty} F_X(x) = 1; \quad (4)$$

(iii) F_X é contínua à direita, isto é,

$$F_X(x + \epsilon) \rightarrow F_X(x) \quad \text{quando } \epsilon \downarrow 0, \quad (5)$$

onde o limite é tomado com ϵ tendendo a 0 apenas por valores positivos.

A monotonicidade expressa em (3) decorre da inclusão

$$\{X \leq x\} \subseteq \{X \leq y\}$$

sempre que $x \leq y$, pois se X assume um valor que não excede x , então esse valor também não excede y .

As demais propriedades elementares de F_X dizem respeito ao seu comportamento quando x se aproxima de $-\infty$ ou de $+\infty$. Intuitivamente é claro que

$$F_X(x) \rightarrow 0 \quad \text{quando } x \rightarrow -\infty, \quad \text{e} \quad F_X(x) \rightarrow 1 \quad \text{quando } x \rightarrow +\infty,$$

uma vez que, no primeiro caso, à medida que x diminui, o evento de que X seja menor do que x torna-se cada vez menos provável; no segundo caso, à medida que x cresce, esse evento torna-se cada vez mais provável. No plano intuitivo, as igualdades em (4) são evidentes, pois lembram as afirmações

$$\mathbb{P}(X \leq -\infty) = 0, \quad \mathbb{P}(X \leq +\infty) = 1,$$

mas a verificação formal de (4) depende da continuidade da medida de probabilidade $\mathbb{P}$.

Para tornar essa verificação formal, considere os eventos $A_n = \{X \leq -n\}$. Eles formam uma sequência decrescente e $\bigcap_{n \geq 1} A_n = \emptyset$, pois nenhum número real é menor ou igual a $-n$ para todo n . Pela continuidade por cima da probabilidade,

$$F_X(-n) = \mathbb{P}(A_n) \rightarrow 0.$$

Analogamente, se $B_n = \{X \leq n\}$, então B_n cresce para Ω e, pela continuidade por baixo,

$$F_X(n) = \mathbb{P}(B_n) \rightarrow 1.$$

Como F_X é monótona, esses dois limites ao longo dos inteiros implicam os limites em (4).

A continuidade da medida de probabilidade também é necessária para demonstrar a continuidade à direita em (5). De fato, se $(x_n)_{n \geq 1}$ é uma sequência decrescente com $x_n \rightarrow x$, então os eventos $\{X \leq x_n\}$ decrescem para $\{X \leq x\}$ e a continuidade por cima de $\mathbb{P}$ dá

$$F_X(x_n) = \mathbb{P}(X \leq x_n) \rightarrow \mathbb{P}(X \leq x) = F_X(x).$$

Observando a [Figura 1](#), vemos que as funções de distribuição não precisam ser contínuas à esquerda: em cada ponto do suporte ocorre um salto.

Observação 5. As três propriedades reunidas na [Proposição 4](#), isto é, a monotonicidade (3), os limites (4) e a continuidade à direita (5), caracterizam completamente as funções de distribuição. Isso significa que, se F é uma função que satisfaz essas três condições, então existem um espaço de probabilidade e uma variável aleatória X nesse espaço cuja função de distribuição é F . A prova desse fato é omitida nestas notas, mas convém registrá-lo, pois em muitas situações ele nos permite evitar o trabalho de exibir explicitamente o espaço de probabilidade e a variável aleatória.

Antes de apresentarmos exemplos de funções de distribuição, vejamos uma última propriedade. A probabilidade $F_X(x) = \mathbb{P}(X \leq x)$ é a probabilidade de que X assumira um valor no intervalo ilimitado $(-\infty, x]$. Para encontrarmos a probabilidade de que X assumira um valor em um intervalo limitado $(a, b]$, procedemos da seguinte maneira. Para $a < b$,

$$\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a). \quad (6)$$

De fato,

$$\begin{aligned} \mathbb{P}(a < X \leq b) &= \mathbb{P}(\{X \leq b\} \setminus \{X \leq a\}) \\ &= \mathbb{P}(X \leq b) - \mathbb{P}(X \leq a), \end{aligned}$$

pois o evento $\{X \leq a\}$ está contido no evento $\{X \leq b\}$.

2. Exemplos de Funções de Distribuição

Na seção anterior introduzimos a definição de função de distribuição e reunimos as suas propriedades gerais na [Proposição 4](#). O [Exemplo 3](#) foi o nosso primeiro exemplo: a função de distribuição de uma variável aleatória discreta, constante por partes e com saltos exatamente nos pontos com probabilidade positiva. Vale a pena observar as características gerais daquela função: ela é não decrescente, contínua à direita, tende a 0 quando $x \rightarrow -\infty$ e tende a 1 quando $x \rightarrow \infty$. Existem, contudo, funções de distribuição que contrastam de modo acentuado com aquele exemplo, por serem contínuas em toda a reta. O próximo exemplo é de uma dessas funções.

Exemplo 6 (Distribuição uniforme). Sejam $a, b \in \mathbb{R}$ com $a < b$. Considere a função

$$F(x) = \begin{cases} 0, & \text{se } x < a, \\ \frac{x-a}{b-a}, & \text{se } a \leq x \leq b, \\ 1, & \text{se } x > b, \end{cases}$$

cujos gráficos estão esboçados na [Figura 2](#). Ela possui as propriedades gerais descritas na [Proposição 4](#) e, portanto, é uma função de distribuição. Dizemos que uma variável aleatória com essa função de distribuição tem *distribuição uniforme* no intervalo (a, b) ; alguns autores preferem dizer que a distribuição é uniforme no intervalo $[a, b]$.

O fato de chamarmos a distribuição de uniforme em (a, b) ou em $[a, b]$ não altera a lei, pois os extremos têm probabilidade zero. Os valores de F nesses pontos, contudo, são determinados pela própria função de distribuição. Em particular, a fórmula define uma função de distribuição para quaisquer escolhas de $a < b$, e a equação (6) se aplica diretamente.

Exemplo 7 (Distribuição exponencial). Seja $\lambda > 0$ e defina F por

$$F(x) = \begin{cases} 0, & \text{se } x \leq 0, \\ 1 - e^{-\lambda x}, & \text{se } x > 0, \end{cases} \quad (7)$$

cujo gráfico esboçamos na **Figura 3**. Vemos que F é claramente uma função de distribuição. Dizemos que uma variável aleatória com essa distribuição tem *distribuição exponencial* com parâmetro λ .

As duas funções de distribuição acima são muito importantes na teoria da probabilidade. As duas são, além disso, casos particulares de uma família maior. Pela caracterização da **Observação 5**, qualquer função F não negativa, contínua e não decrescente que satisfaz

$$\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow \infty} F(x) = 1$$

é uma função de distribuição.




Figura 2: Função de distribuição uniforme no intervalo (a, b) . A função vale 0 à esquerda de a , cresce linearmente de 0 a 1 em $[a, b]$ e vale 1 à direita de b .




Figura 3: Função de distribuição exponencial com parâmetro λ . A função é identicamente nula em $(-\infty, 0]$ e tende assintoticamente a 1 quando $x \rightarrow \infty$.

3. Variáveis Aleatórias Contínuas

As variáveis aleatórias aparecem em muitas formas, mas há duas classes que desempenham um papel central no curso:

- I. as variáveis aleatórias discretas;

II. as variáveis aleatórias contínuas.

Uma variável aleatória discreta assume apenas uma quantidade enumerável de valores e sua função de distribuição tem, em geral, o aspecto de uma função em degraus, como ilustra a [Figura 1](#). No extremo oposto encontram-se variáveis aleatórias cuja função de distribuição é bastante suave, como nos casos uniforme e exponencial discutidos na [Seção 2](#) (veja as [Figuras 2 e 3](#)). É essa segunda classe que passamos a estudar e que chamaremos de *contínua*.

Definição 8 (Variável aleatória contínua). Dizemos que uma variável aleatória X é *contínua* se existir uma função não negativa e mensurável f_X tal que sua função de distribuição F_X possa ser escrita na forma

$$F_X(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f_X(u) du \quad \text{para todo } x \in \mathbb{R}. \quad (8)$$

Nesse caso, dizemos que X tem *função densidade de probabilidade* (ou simplesmente *densidade*) f_X , abreviada por *fdp*.

A identidade (8) diz que a probabilidade de o evento $\{X \leq x\}$ ocorrer é a área sob o gráfico de f_X à esquerda de x . Assim, F_X acumula a densidade desde $-\infty$ até x , e é por isso que F_X também é chamada de função de distribuição acumulada.

Observação 9. Textos mais avançados chamam as variáveis aleatórias descritas na [Definição 8](#) de *absolutamente contínuas*, reservando a palavra “contínua” para uma classe mais ampla. Neste curso não faremos essa distinção e usaremos “contínua” no sentido da definição acima.

Exemplo 10. Se X tem distribuição exponencial de parâmetro $\lambda > 0$, então, como vimos no [Exemplo 7](#),

$$F_X(x) = \begin{cases} 0, & \text{se } x \leq 0, \\ 1 - e^{-\lambda x}, & \text{se } x > 0. \end{cases}$$

Uma densidade para X é obtida derivando F_X nos pontos em que a derivada existe. Para $x > 0$,

$$\frac{d}{dx}(1 - e^{-\lambda x}) = \lambda e^{-\lambda x},$$

e para $x < 0$ a derivada é 0. Logo

$$f_X(x) = \begin{cases} 0, & \text{se } x \leq 0, \\ \lambda e^{-\lambda x}, & \text{se } x > 0. \end{cases}$$

De modo geral, se X é contínua e F_X tem bom comportamento, podemos tomar como densidade de X a função

$$f_X(x) = \begin{cases} \frac{d}{dx}F_X(x), & \text{se essa derivada existe em } x, \\ 0, & \text{caso contrário.} \end{cases} \quad (9)$$

Seguiremos essa receita na maioria dos exemplos. Vale registrar que há algumas dificuldades de rigor matemático nessa passagem: nem toda função de distribuição é derivável, e a

derivada pode não ser uma densidade no sentido da identidade (8). Para os fins deste curso, porém, a fórmula (9) é suficiente, e dificilmente encontraremos problemas ao aplicá-la para determinar a densidade de uma variável aleatória contínua.

As densidades desempenham para as variáveis contínuas um papel análogo ao das funções de probabilidade para as variáveis discretas, e não é surpreendente que as propriedades gerais de umas e de outras sejam muito parecidas.

Propriedade. Se X é uma variável aleatória contínua com densidade f_X , então

$$f_X(x) \geq 0 \quad \text{para todo } x \in \mathbb{R}, \quad \int_{-\infty}^{\infty} f_X(x) dx = 1.$$

Essas duas propriedades são as análogas de $p_X(x) \geq 0$ e $\sum_x p_X(x) = 1$ no caso discreto. A analogia, no entanto, pode ser perigosa, pois $f_X(x)$ *não* é uma probabilidade e pode muito bem assumir valores maiores que 1. No exemplo exponencial, por exemplo, se $\lambda > 1$, então f_X assume valores maiores que 1 na vizinhança de $x = 0$, ainda que $\mathbb{P}(X = 0) = 0$.

O que $f_X(x)$ mede é a densidade de probabilidade nas proximidades de x . Se, além disso, f_X é contínua em x e δx é pequeno e positivo, então, grosso modo, a probabilidade de X estar “perto” de x satisfaz

$$\begin{aligned} \mathbb{P}(x < X \leq x + \delta x) &= F_X(x + \delta x) - F_X(x) \quad \text{por (6)} \\ &= \int_x^{x+\delta x} f_X(u) du \quad \text{por (8)} \\ &\approx f_X(x) \delta x \quad \text{para } \delta x \text{ pequeno.} \end{aligned} \tag{10}$$

A última aproximação usa a continuidade de f_X em x : em um intervalo curto, a área sob f_X é aproximadamente a área de um retângulo de base δx e altura $f_X(x)$.

Portanto, a analogia correta não é entre a densidade $f_X(x)$ e a função de probabilidade $p_X(x)$, mas sim entre $f_X(x) \delta x$ e $p_X(x)$. Essa leitura fica clara ao compararmos a normalização da densidade com a da função de probabilidade: os valores de uma função de probabilidade são substituídos por $f_X(x) \delta x$, e a soma, que no caso discreto percorre apenas os valores positivos (necessariamente em quantidade enumerável), é substituída pela integral. Uma diferença marcante entre os dois casos é dada pela primeira parte do teorema a seguir.

Teorema 11 (Propriedades da densidade). Se X é contínua com densidade f_X , então

$$\mathbb{P}(X = x) = 0 \quad \text{para todo } x \in \mathbb{R}, \tag{11}$$

e

$$\mathbb{P}(a \leq X \leq b) = \int_a^b f_X(u) du \quad \text{para } a, b \in \mathbb{R} \text{ com } a \leq b. \tag{12}$$

Demonstração. Vamos provar primeiro (11). Para isso, observamos que os eventos $\{x - \epsilon < X \leq x\}$ diminuem para $\{X = x\}$ quando ϵ decresce para 0, de modo que, pela continuidade da probabilidade,

$$\mathbb{P}(X = x) = \lim_{\epsilon \downarrow 0} \mathbb{P}(x - \epsilon < X \leq x).$$

A partir daí, usando sucessivamente (6) e (8), obtemos

$$\begin{aligned} \mathbb{P}(X = x) &= \lim_{\epsilon \downarrow 0} [F_X(x) - F_X(x - \epsilon)] \\ &= \lim_{\epsilon \downarrow 0} \int_{x-\epsilon}^x f_X(u) du \\ &= 0. \end{aligned}$$

A última igualdade segue do fato de que a integral sobre um intervalo de comprimento ϵ tende a 0 quando $\epsilon \downarrow 0$.

Para a segunda parte, seja $a \leq b$. Como $\{X = a\}$ tem probabilidade 0 por (11), os eventos $\{a \leq X \leq b\}$ e $\{a < X \leq b\}$ têm a mesma probabilidade. Logo, por (6) e (8),

$$\begin{aligned}\mathbb{P}(a \leq X \leq b) &= \mathbb{P}(a < X \leq b) \\ &= F_X(b) - F_X(a) \\ &= \int_{-\infty}^b f_X(u) du - \int_{-\infty}^a f_X(u) du \\ &= \int_a^b f_X(u) du.\end{aligned}$$

■

O teorema acima mostra que, em uma variável aleatória contínua, a probabilidade de qualquer valor isolado é nula. Consequentemente, para variáveis contínuas, incluir ou excluir os extremos de um intervalo não altera sua probabilidade:

$$\mathbb{P}(a \leq X \leq b) = \mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X < b) = \mathbb{P}(a < X < b).$$

Isso contrasta com o caso discreto, em que um único ponto pode concentrar toda a probabilidade.

Recapitulando o que vimos até aqui: toda variável aleatória possui uma função de distribuição, conforme a Definição 2. No caso discreto, essa informação é codificada por uma função de probabilidade p_X ; no caso contínuo, por uma densidade f_X . Essas duas classes não esgotam, contudo, todas as possibilidades: existem variáveis aleatórias que não são nem discretas nem contínuas, ou seja, cuja função de distribuição não é uma escada nem pode ser escrita como a integral de uma densidade. Tais casos, embora existam, ficam fora do escopo destas notas.

4. Algumas Funções Densidade Usuais

Nas seções anteriores vimos que uma variável aleatória contínua X fica descrita por sua função de distribuição F_X e que, quando F_X é derivável, sua derivada f_X é a função densidade de probabilidade (fdp) associada, conforme a Definição 8. Cabe agora perguntar o contrário: dada uma função f , quando ela é a densidade de alguma variável aleatória? A resposta é simples e vale a pena enunciá-la antes de listarmos os exemplos que ocorrem com mais frequência.

Se $f : \mathbb{R} \rightarrow [0, \infty)$ é mensurável e satisfaz

$$f(x) \geq 0 \quad \text{para todo } x \in \mathbb{R} \tag{13}$$

e

$$\int_{-\infty}^{\infty} f(x) dx = 1, \tag{14}$$

então f é a função densidade de probabilidade de alguma variável aleatória. Para confirmar isso, basta definir

$$F(x) = \int_{-\infty}^x f(u) du$$

e verificar que F satisfaz as três propriedades reunidas na **Proposição 4**, a saber, F é não decrescente, contínua à direita, $\lim_{x \rightarrow -\infty} F(x) = 0$ e $\lim_{x \rightarrow \infty} F(x) = 1$. Pela caracterização da **Observação 5**, existe uma variável aleatória X cuja função de distribuição é F . Como $F(x) = \int_{-\infty}^x f(u) du$, concluímos que f é uma densidade de X .

Mostramos abaixo as densidades mais usadas, cada uma acompanhada de seus parâmetros e de sua região de positividade. Em todos os casos a não negatividade (13) é imediata, e a verificação da normalização (14) é o ponto que merece atenção. Resumimos a lista em forma de tabela no final desta seção (**Tabela 1**).

Distribuição uniforme.

Dizemos que X tem *distribuição uniforme* no intervalo (a, b) , com $a < b$, quando sua densidade é

$$f(x) = \begin{cases} \frac{1}{b-a}, & \text{se } a < x < b, \\ 0, & \text{caso contrário.} \end{cases} \quad (15)$$

Aqui a integral é elementar:

$$\int_{-\infty}^{\infty} f(x) dx = \int_a^b \frac{1}{b-a} dx = \frac{b-a}{b-a} = 1.$$

A densidade é constante sobre o intervalo: não há posição privilegiada dentro de (a, b) , o que justifica o nome.

Distribuição exponencial.

Dizemos que X tem *distribuição exponencial* de parâmetro $\lambda > 0$ quando

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{se } x > 0, \\ 0, & \text{se } x \leq 0. \end{cases} \quad (16)$$

Novamente a normalização sai de uma primitiva imediata, pois $\frac{d}{dx}(-e^{-\lambda x}) = \lambda e^{-\lambda x}$ e $e^{-\lambda x} \rightarrow 0$ quando $x \rightarrow \infty$:

$$\int_{-\infty}^{\infty} f(x) dx = \int_0^{\infty} \lambda e^{-\lambda x} dx = \left[-e^{-\lambda x}\right]_0^{\infty} = 1.$$

Distribuição normal (gaussiana).

Dizemos que X tem *distribuição normal* (ou *gaussiana*) de parâmetros $\mu \in \mathbb{R}$ e $\sigma > 0$, e escrevemos $X \sim N(\mu, \sigma^2)$, quando

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right), \quad x \in \mathbb{R}. \quad (17)$$

Para verificar que a integral vale 1, usamos a integral gaussiana

$$\int_{-\infty}^{\infty} e^{-x^2} dx = \sqrt{\pi}. \quad (18)$$

Com efeito, a mudança de variáveis $x = \mu + \sigma\sqrt{2}z$ dá $dx = \sigma\sqrt{2}dz$ e

$$\int_{-\infty}^{\infty} e^{-\frac{1}{2\sigma^2}(x-\mu)^2} dx = \sigma\sqrt{2} \int_{-\infty}^{\infty} e^{-z^2} dz = \sigma\sqrt{2\pi},$$

onde usamos (18). Dividindo pelo fator $\sqrt{2\pi\sigma^2}$ obtemos exatamente 1. A constante de normalização foi escolhida justamente para isso.

Distribuição de Cauchy.

Dizemos que X tem *distribuição de Cauchy* quando

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad x \in \mathbb{R}. \quad (19)$$

A normalização segue da derivada da função arco-tangente, pois $\frac{d}{dx} \arctan x = \frac{1}{1+x^2}$ e $\lim_{x \rightarrow \pm\infty} \arctan x = \pm\frac{\pi}{2}$:

$$\int_{-\infty}^{\infty} \frac{1}{\pi(1+x^2)} dx = \frac{1}{\pi} \left[\arctan x \right]_{-\infty}^{\infty} = \frac{1}{\pi} \left(\frac{\pi}{2} + \frac{\pi}{2} \right) = 1.$$

Distribuição gama.

Dizemos que X tem *distribuição gama* de parâmetros $w > 0$ e $\lambda > 0$ quando

$$f(x) = \begin{cases} \frac{1}{\Gamma(w)} \lambda^w x^{w-1} e^{-\lambda x}, & \text{se } x > 0, \\ 0, & \text{se } x \leq 0, \end{cases} \quad (20)$$

onde Γ é a *função gama*, definida por

$$\Gamma(w) = \int_0^{\infty} x^{w-1} e^{-x} dx. \quad (21)$$

A integral em (21) converge para todo $w > 0$: perto de 0, o integrando é comparável a x^{w-1} , cuja integral converge para $w > 0$, enquanto, no infinito, o fator e^{-x} garante a convergência. Para checar a normalização de (20), fazemos a mudança $y = \lambda x$, de modo que $dx = dy/\lambda$:

$$\int_{-\infty}^{\infty} f(x) dx = \frac{\lambda^w}{\Gamma(w)} \int_0^{\infty} x^{w-1} e^{-\lambda x} dx = \frac{1}{\Gamma(w)} \int_0^{\infty} y^{w-1} e^{-y} dy = \frac{\Gamma(w)}{\Gamma(w)} = 1.$$

Ou seja, a distribuição gama integra 1 *por definição* de Γ .

Observamos ainda que, para inteiro positivo $w = n$, a função gama recupera o fatorial. De fato, integrando por partes, $\Gamma(w) = (w-1)\Gamma(w-1)$ para $w > 1$, e como $\Gamma(1) = 1$ segue que

$$\Gamma(n) = (n-1)! \quad \text{para } n = 1, 2, 3, \dots$$

Este é o conteúdo do [Exercício 12](#), ao qual remetemos o leitor para os detalhes da indução.

Distribuição beta.

Dizemos que X tem *distribuição beta* de parâmetros $s > 0$ e $t > 0$ quando

$$f(x) = \begin{cases} \frac{1}{B(s,t)} x^{s-1} (1-x)^{t-1}, & \text{se } 0 < x < 1, \\ 0, & \text{caso contrário,} \end{cases} \quad (22)$$

onde B é a *função beta*,

$$B(s,t) = \int_0^1 x^{s-1} (1-x)^{t-1} dx. \quad (23)$$

Aqui a normalização é tautológica: a constante $B(s, t)$ foi escolhida exatamente para que a integral de f em (22) seja

$$\frac{1}{B(s, t)} \int_0^1 x^{s-1} (1-x)^{t-1} dx = \frac{B(s, t)}{B(s, t)} = 1.$$

No caso particular $s = t = 1$, a densidade vale 1 em $(0, 1)$ e 0 fora desse intervalo. Os valores nos extremos são irrelevantes, e obtemos a distribuição uniforme em $[0, 1]$, o que concorda com (15) tomando $a = 0$ e $b = 1$.

Distribuição qui-quadrado.

Dizemos que X tem *distribuição qui-quadrado com n graus de liberdade*, e escrevemos $X \sim \chi_n^2$, quando

$$f(x) = \begin{cases} \frac{1}{2\Gamma(\frac{n}{2})} \left(\frac{x}{2}\right)^{\frac{n}{2}-1} e^{-\frac{x}{2}}, & \text{se } x > 0, \\ 0, & \text{se } x \leq 0. \end{cases} \quad (24)$$

Comparando (24) com (20), vemos que esta é precisamente a distribuição gama com parâmetros $w = \frac{n}{2}$ e $\lambda = \frac{1}{2}$. Logo a normalização já foi verificada no caso gama, e listamos a distribuição separadamente apenas porque ela aparece com muita frequência em estatística.

A tabela abaixo reúne as densidades discutidas acima. A coluna final registra a região de positividade, isto é, o conjunto onde f é estritamente positiva. Ela não deve ser confundida com o suporte topológico, que também contém pontos de fronteira.

Distribuição	Parâmetros	Densidade $f(x)$	Região de positividade
Uniforme	$a < b$	$\frac{1}{b-a}$	$a < x < b$
Exponencial	$\lambda > 0$	$\lambda e^{-\lambda x}$	$x > 0$
Normal	$\mu \in \mathbb{R}, \sigma > 0$	$\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	$x \in \mathbb{R}$
Cauchy	nenhum	$\frac{1}{\pi(1+x^2)}$	$x \in \mathbb{R}$
Gama	$w > 0, \lambda > 0$	$\frac{1}{\Gamma(w)} \lambda^w x^{w-1} e^{-\lambda x}$	$x > 0$
Beta	$s > 0, t > 0$	$\frac{1}{B(s, t)} x^{s-1} (1-x)^{t-1}$	$0 < x < 1$
Qui-quadrado	$n \in \mathbb{N}$	$\frac{1}{2\Gamma(\frac{n}{2})} \left(\frac{x}{2}\right)^{\frac{n}{2}-1} e^{-\frac{x}{2}}$	$x > 0$

Tabela 1: As densidades usuais, com seus parâmetros e regiões de positividade. Cada constante de normalização foi escolhida para que a integral da densidade sobre $\mathbb{R}$ seja igual a 1.

A lista apresentada na [Seção 4](#) é um compêndio de algumas das densidades mais comuns, e não esperamos que ela, sozinha, seja inspiradora. É difícil motivar adequadamente cada uma dessas densidades neste momento, mas vamos precisar retomá-las mais adiante, quando as encontrarmos em ação.

Não é sempre trivial verificar que as funções da lista são realmente densidades. A condição de não negatividade não oferece dificuldade; o cuidado está em conferir que a integral vale 1. Para a densidade normal, por exemplo, precisamos da integral definida padrão

$$\int_{-\infty}^{\infty} e^{-x^2} dx = \sqrt{\pi}.$$

Um esboço da prova dessa identidade, por meio de coordenadas polares, está no [Exercício 13](#).

Os fatores constantes que aparecem nas densidades usuais foram escolhidos apenas para que as funções resultantes tenham integral 1. Considere, por exemplo, a função

$$g(x) = \frac{1}{1+x^2} \quad \text{para } x \in \mathbb{R}.$$

Como

$$\int_{-\infty}^{\infty} g(x) dx = \pi,$$

g não é uma densidade. No entanto, a função normalizada

$$f(x) = \frac{1}{\pi} g(x)$$

é uma densidade, a qual corresponde à distribuição de Cauchy apresentada na [Seção 4](#).

Resta uma relação entre as funções gama e beta que simplifica o cálculo com a densidade beta e que usaremos mais adiante. Ela expressa $B(s, t)$ em termos de Γ .

Proposição 12. Para todos $s > 0$ e $t > 0$ vale

$$B(s, t) = \frac{\Gamma(s)\Gamma(t)}{\Gamma(s+t)}.$$

Demonstração. Partimos do produto das duas integrais que definem $\Gamma(s)$ e $\Gamma(t)$. Como os integrandos são não negativos, podemos escrever o produto como uma integral dupla sobre o quadrante $(0, \infty)^2$, sem qualquer preocupação com convergência:

$$\Gamma(s)\Gamma(t) = \int_0^{\infty} \int_0^{\infty} e^{-(u+v)} u^{s-1} v^{t-1} du dv.$$

Fazemos agora a mudança de variáveis

$$u = r \cos^2 \theta, \quad v = r \sin^2 \theta,$$

com $r > 0$ e $\theta \in (0, \pi/2)$. Essa mudança é sugerida pela identidade $\cos^2 \theta + \sin^2 \theta = 1$: ela transforma a soma $u + v$ na variável radial r , de modo que o fator $e^{-(u+v)}$ passa a depender apenas de r . O determinante jacobiano é

$$J = \det \begin{pmatrix} \cos^2 \theta & -2r \sin \theta \cos \theta \\ \sin^2 \theta & 2r \sin \theta \cos \theta \end{pmatrix} = 2r \sin \theta \cos \theta,$$

que é positivo no domínio considerado, logo $|J| = J$. Além disso, $u + v = r$ e

$$u^{s-1} v^{t-1} = r^{s+t-2} \cos^{2(s-1)} \theta \sin^{2(t-1)} \theta.$$

Substituindo na integral dupla, obtemos

$$\begin{aligned}\Gamma(s)\Gamma(t) &= \int_0^{\pi/2} \int_0^\infty e^{-r} r^{s+t-2} \cos^{2(s-1)} \theta \sin^{2(t-1)} \theta 2r \sin \theta \cos \theta dr d\theta \\ &= \left(\int_0^\infty e^{-r} r^{s+t-1} dr \right) \left(2 \int_0^{\pi/2} \cos^{2s-1} \theta \sin^{2t-1} \theta d\theta \right),\end{aligned}$$

onde separamos as variáveis porque o domínio é um produto e o integrando é um produto de um fator que depende só de r por outro que depende só de θ . A integral em r é exatamente a definição de $\Gamma(s+t)$.

Resta identificar a integral em θ com $B(s, t)$. Para isso, pomos $x = \cos^2 \theta$. Então $dx = -2 \cos \theta \sin \theta d\theta$ e, quando θ vai de 0 a $\pi/2$, x vai de 1 a 0. Escrevendo

$$\cos^{2s-1} \theta = x^{s-1} \cos \theta, \quad \sin^{2t-1} \theta = (1-x)^{t-1} \sin \theta,$$

segue que

$$\begin{aligned}2 \int_0^{\pi/2} \cos^{2s-1} \theta \sin^{2t-1} \theta d\theta &= 2 \int_1^0 x^{s-1} (1-x)^{t-1} \cos \theta \sin \theta \frac{-dx}{2 \cos \theta \sin \theta} \\ &= \int_0^1 x^{s-1} (1-x)^{t-1} dx,\end{aligned}$$

que é $B(s, t)$ por (23). Juntando os dois fatores,

$$\Gamma(s)\Gamma(t) = \Gamma(s+t) B(s, t),$$

e como $\Gamma(s+t) > 0$, dividindo por esse valor chegamos a $B(s, t) = \frac{\Gamma(s)\Gamma(t)}{\Gamma(s+t)}$, como queríamos. ■

A **Proposição 12** mostra, em particular, que a constante de normalização da densidade beta também pode ser escrita em termos da função gama: $B(s, t) = \Gamma(s)\Gamma(t)/\Gamma(s+t)$. Com isso encerramos a lista das densidades usuais, que retomaremos quando essas distribuições aparecerem em situações concretas.

5. Exercícios propostos

Os exercícios a seguir retomam os conceitos e exemplos desenvolvidos ao longo da nota: funções de distribuição, densidades e as distribuições usuais. Salvo indicação em contrário, X denota uma variável aleatória em um espaço de probabilidade fixado.

Funções de distribuição

1. Seja X uma variável aleatória que assume valores inteiros e satisfaz $\mathbb{P}(X = k) = p_k$ para $k = \dots, -1, 0, 1, \dots$. Mostre que a função de distribuição de X satisfaz

$$F_X(b) - F_X(a) = p_{a+1} + p_{a+2} + \dots + p_b$$

para todos os inteiros a, b com $a < b$.

2. Seja X uma variável aleatória e seja c um número real tal que $\mathbb{P}(X = c) > 0$. Mostre que a função de distribuição $F_X(x)$ de X é descontínua no ponto $x = c$. A recíproca é verdadeira?

3. Expresse a função de distribuição de $Y = \max\{0, X\}$ em termos da função de distribuição F_X de X .
4. Dizemos que o número real m é uma *mediana* da variável aleatória X se

$$\mathbb{P}(X < m) \leq \frac{1}{2} \leq \mathbb{P}(X \leq m).$$

Mostre que toda variável aleatória possui pelo menos uma mediana.

Exemplos de funções de distribuição

5. Mostre que se F_1 e F_2 são funções de distribuição, então também é função de distribuição a função

$$F(x) = \alpha F_1(x) + (1 - \alpha) F_2(x)$$

para qualquer α satisfazendo $0 \leq \alpha \leq 1$.

6. Seja

$$F(x) = c \int_{-\infty}^x e^{-|u|} du \quad \text{para } x \in \mathbb{R}.$$

Para qual valor de c a função F é uma função de distribuição?

Variáveis aleatórias contínuas

7. Uma variável aleatória X tem função densidade de probabilidade

$$f(x) = \begin{cases} 2x & \text{se } 0 < x < 1, \\ 0 & \text{caso contrário.} \end{cases}$$

Determine a função de distribuição de X .

8. Se X tem função densidade de probabilidade

$$f(x) = \frac{1}{2} e^{-|x|} \quad \text{para } x \in \mathbb{R},$$

determine a função de distribuição de X . Esta distribuição é chamada de distribuição *exponencial bilateral* (ou *dupla*).

9. Se X tem função de distribuição

$$F(x) = \begin{cases} \frac{1}{2(1+x^2)} & \text{para } -\infty < x \leq 0, \\ \frac{1+2x^2}{2(1+x^2)} & \text{para } 0 < x < \infty, \end{cases}$$

mostre que X é contínua e determine a sua função densidade de probabilidade.

10. Determine a função de distribuição da chamada densidade de “valor extremo”

$$f(x) = \exp(-x - e^{-x}) \quad \text{para } x \in \mathbb{R}.$$

Densidades usuais

11. Para quais valores dos seus parâmetros a distribuição gama é também uma distribuição exponencial?

12. Mostre que a função gama $\Gamma(w)$ satisfaz

$$\Gamma(w) = (w-1)\Gamma(w-1)$$

para $w > 1$, e deduza que

$$\Gamma(n) = (n-1)!$$

para $n = 1, 2, 3, \dots$

13. Seja

$$I = \int_{-\infty}^{\infty} e^{-x^2} dx.$$

Passando a coordenadas polares, mostre que

$$I^2 = \iint_{\mathbb{R}^2} e^{-x^2-y^2} dx dy = \int_{\theta=0}^{2\pi} \int_{r=0}^{\infty} e^{-r^2} r dr d\theta,$$

e deduza que $I = \sqrt{\pi}$.

14. Mostre que a função densidade

$$f(x) = \begin{cases} \frac{1}{\pi\sqrt{x(1-x)}} & \text{se } 0 < x < 1, \\ 0 & \text{caso contrário,} \end{cases}$$

tem função de distribuição da forma

$$F(x) = c \arcsen \sqrt{x} \quad \text{se } 0 < x < 1,$$

e determine a constante c .

Referências

- [1] Geoffrey Grimmett and Dominic Welsh. *Probability—an introduction*. Oxford University Press, Oxford, second edition, 2014.