

Funções de Distribuição

L. Cioletti

Setembro de 2026

Resumo

Estas notas dão continuidade ao estudo das variáveis aleatórias iniciado nas notas sobre variáveis aleatórias discretas. Vamos apresentar a noção geral de variável aleatória, de sua função de distribuição e de suas propriedades elementares. Apresentamos um resultado que caracteriza as funções de distribuição e, consequentemente, permite provar a existência de variáveis aleatórias com determinadas propriedades. Em seguida, definimos as variáveis aleatórias absolutamente contínuas e as chamadas funções de densidade de probabilidade. Mostramos em detalhes como é possível construir um exemplo de uma variável aleatória cuja função de distribuição é contínua, mas que não é absolutamente contínua. Para finalizar, fornecemos diversos exemplos clássicos de variáveis aleatórias absolutamente contínuas. O texto segue de perto as Seções 5.1–5.4 do Capítulo 5 de Grimmett e Welsh [2] e conta com uma lista de exercícios ao final.

1. Funções de Distribuição

1.1. Definição e exemplo discreto

Até aqui trabalhamos com variáveis aleatórias discretas. Esse modelo é natural quando observamos uma contagem, como o número de chamadas recebidas por uma central ou o número de peças defeituosas em um lote: os valores possíveis são isolados e podem ser listados, ao menos em princípio. Muitas quantidades de interesse, porém, não são contagens. O tempo de espera por um ônibus, a vida útil de um componente, a temperatura de uma sala ou a posição de uma partícula são grandezas medidas numa escala contínua e, no modelo matemático, podem assumir qualquer valor real em determinado intervalo. Arredondar essas quantidades para obter um modelo discreto pode ser útil em uma aplicação; entretanto, preservar a possibilidade de variação contínua dessas grandezas nos permite utilizar as poderosas ferramentas do cálculo diferencial e integral. Por isso, exigir que elas assumam, desde o início, valores em um conjunto apenas enumerável nos privaria justamente dos recursos que desejamos empregar.

Precisamos, portanto, conservar a ideia básica de que cada resultado ω determina uma observação numérica $X(\omega)$, sem impor que o conjunto de valores possíveis de X seja enumerável. Ao mesmo tempo, as perguntas que fazemos sobre essa observação precisam corresponder a eventos cuja probabilidade esteja definida. Entre essas perguntas, as mais simples

e flexíveis são as do tipo: qual é a probabilidade de a observação não exceder um nível x ? Isso nos leva a considerar os eventos da forma $\{\omega \in \Omega : X(\omega) \leq x\}$, para cada $x \in \mathbb{R}$, e motiva a definição mais ampla de variável aleatória a seguir.

Definição 1 (Variável aleatória). Seja $(\Omega, \mathcal{F}, \mathbb{P})$ um espaço de probabilidade. Dizemos que X é uma *variável aleatória* se X é uma função $X : \Omega \rightarrow \mathbb{R}$ tal que

$$\{\omega \in \Omega : X(\omega) \leq x\} \in \mathcal{F} \quad \text{para todo } x \in \mathbb{R}. \quad (1)$$




Figura 1: O evento $\{X \leq x\} \equiv \{\omega \in \Omega : X(\omega) \leq x\}$

A **Figura 1** representa o evento $\{X \leq x\}$ e o intervalo $(-\infty, x]$ no contradomínio. Quando (1) vale, dizemos que X é $\mathcal{F}$ -mensurável. Daqui em diante, vamos denotar o evento $\{\omega \in \Omega : X(\omega) \leq x\}$ pela expressão mais simples $\{X \leq x\}$. Como mencionado anteriormente, esta notação não exige que se fixe um espaço de probabilidade particular, o que confere à teoria maior flexibilidade.

Exigimos que as variáveis aleatórias satisfaçam (1) pela mesma razão pela qual exigimos uma condição análoga na definição de variável aleatória discreta. Estamos interessados nos valores assumidos por X e nas probabilidades associadas a esses valores. Uma maneira conveniente de estudá-los é fixar $x \in \mathbb{R}$ e calcular a probabilidade de que X assumira um valor no intervalo $(-\infty, x]$. Essa probabilidade só está definida quando a pré-imagem $X^{-1}((-\infty, x]) = \{X \leq x\}$ pertence ao espaço de eventos $\mathcal{F}$, e é por isso que postulamos que essa condição seja válida para todo $x \in \mathbb{R}$.

Observe que toda variável aleatória discreta é também uma variável aleatória no sentido amplo da **Definição 1**. De fato, se X é discreta, então

$$\{X \leq x\} = \bigcup_{y \in \text{Im } X : y \leq x} \{X = y\},$$

que é uma união enumerável de eventos em $\mathcal{F}$ e, portanto, também pertence a $\mathcal{F}$.

Enquanto as variáveis aleatórias discretas eram estudadas por meio de suas funções de probabilidade, as variáveis aleatórias no sentido mais amplo são estudadas por meio das chamadas *funções de distribuição*, definidas a seguir.

Definição 2 (Função de distribuição). Seja X uma variável aleatória em $(\Omega, \mathcal{F}, \mathbb{P})$. A *função de distribuição* de X é a função $F_X : \mathbb{R} \rightarrow [0, 1]$ definida por

$$F_X(x) = \mathbb{P}(X \leq x). \quad (2)$$

Exemplo 3 (Função de distribuição de uma variável aleatória discreta). Suponha que X seja uma variável aleatória discreta que assume valores inteiros não negativos, com função de probabilidade

$$\mathbb{P}(X = k) = p_k \quad \text{para } k = 0, 1, 2, \dots$$

Para $x \in \mathbb{R}$ com $x \geq 0$, o evento $X \leq x$ ocorre se, e somente se, X assume um dos valores $0, 1, \dots, \lfloor x \rfloor$, em que $\lfloor x \rfloor$ denota o maior inteiro menor ou igual a x ; se $x < 0$, o evento é impossível, pois X não assume valores negativos. Logo,

$$F_X(x) = \begin{cases} 0, & \text{se } x < 0, \\ \sum_{k=0}^{\lfloor x \rfloor} p_k, & \text{se } x \geq 0. \end{cases}$$

Um esboço dessa função, no caso em que X assume valores no conjunto $\{0, 1, 2, 3, 4, 5\}$, é apresentado na [Figura 2](#).




Figura 2: A função de distribuição de uma variável aleatória que assume valores no conjunto $\{0, 1, 2, 3, 4, 5\}$. O salto em $x = 2$, por exemplo, é exatamente o valor de p_2 .

A função de distribuição F_X possui várias propriedades gerais e elementares, reunidas a seguir.

1.2. Propriedades fundamentais

Proposição 4 (Propriedades da função de distribuição). Seja X uma variável aleatória em $(\Omega, \mathcal{F}, \mathbb{P})$ e seja F_X a sua função de distribuição. Então:

- (i) F_X é monótona não decrescente, isto é,

$$F_X(x) \leq F_X(y) \quad \text{se } x \leq y; \quad (3)$$

(ii) os limites de F_X em $-\infty$ e em $+\infty$ existem e são dados por

$$\lim_{x \rightarrow -\infty} F_X(x) = 0 \quad \text{e} \quad \lim_{x \rightarrow +\infty} F_X(x) = 1; \quad (4)$$

(iii) F_X é contínua à direita, isto é,

$$F_X(x + \epsilon) \rightarrow F_X(x) \quad \text{quando } \epsilon \downarrow 0, \quad (5)$$

onde o limite é tomado com ϵ tendendo a 0 apenas por valores positivos.

A monotonicidade expressa em (3) decorre da inclusão

$$\{X \leq x\} \subseteq \{X \leq y\}$$

sempre que $x \leq y$, pois, se X assume um valor que não excede x , esse valor também não excede y .

As demais propriedades elementares de F_X dizem respeito ao seu comportamento quando x se aproxima de $-\infty$ ou de $+\infty$. Intuitivamente, é claro que

$$F_X(x) \rightarrow 0 \quad \text{quando } x \rightarrow -\infty, \quad \text{e} \quad F_X(x) \rightarrow 1 \quad \text{quando } x \rightarrow +\infty,$$

uma vez que, no primeiro caso, à medida que x diminui, o evento de que X não exceda x torna-se cada vez menos provável; no segundo caso, à medida que x cresce, esse evento torna-se cada vez mais provável. No plano intuitivo, essas conclusões correspondem à ideia de que um limiar muito à esquerda captura probabilidade quase nula, enquanto um limiar muito à direita captura quase toda a probabilidade. A verificação formal de (4), entretanto, depende da continuidade da medida de probabilidade $\mathbb{P}$.

Para tornar essa verificação formal, considere os eventos $A_n = \{X \leq -n\}$. Eles formam uma sequência decrescente e $\bigcap_{n \geq 1} A_n = \emptyset$, pois nenhum número real é menor ou igual a $-n$ para todo n . Pela continuidade por cima da probabilidade,

$$F_X(-n) = \mathbb{P}(A_n) \rightarrow 0.$$

Analogamente, se $B_n = \{X \leq n\}$, então B_n cresce para Ω e, pela continuidade por baixo,

$$F_X(n) = \mathbb{P}(B_n) \rightarrow 1.$$

Como F_X é monótona, esses dois limites ao longo dos inteiros implicam os limites em (4).

A continuidade da medida de probabilidade também é usada para estabelecer a continuidade à direita em (5). De fato, se $(x_n)_{n \geq 1}$ é uma sequência decrescente com $x_n \rightarrow x$, então os eventos $\{X \leq x_n\}$ decrescem para $\{X \leq x\}$ e a continuidade por cima de $\mathbb{P}$ fornece

$$F_X(x_n) = \mathbb{P}(X \leq x_n) \rightarrow \mathbb{P}(X \leq x) = F_X(x).$$

Observando a **Figura 2**, vemos que uma função de distribuição não precisa ser contínua à esquerda: em cada ponto k com $p_k > 0$ há um salto de tamanho p_k .

1.3. Espaços de medida, átomos e probabilidades em intervalos

Antes de relacionarmos os saltos de uma função de distribuição com probabilidades de pontos, precisamos fixar a linguagem dos espaços de medida. Essa é a estrutura que permite falar simultaneamente sobre os conjuntos que podem ser medidos e sobre o tamanho que atribuímos a esses conjuntos.

Definição 5 (Espaço de medida). Um *espaço de medida* é uma terna ordenada $(S, \mathcal{A}, \mu)$ formada por:

- (i) um conjunto S ;
- (ii) uma σ -álgebra $\mathcal{A}$ de subconjuntos de S , isto é, uma coleção que contém S , é fechada por complementos relativos a S e por uniões enumeráveis;
- (iii) uma função $\mu : \mathcal{A} \rightarrow [0, +\infty]$, chamada de *medida*, tal que $\mu(\emptyset) = 0$ e, para toda sequência $(A_n)_{n \geq 1}$ de conjuntos dois a dois disjuntos em $\mathcal{A}$,

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n).$$

Os elementos de $\mathcal{A}$ são chamados de *conjuntos mensuráveis*. Quando $\mu(S) = 1$, o espaço de medida é um espaço de probabilidade; nesse caso, costumamos escrever a medida como $\mathbb{P}$.

Assim, o espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$ estudado até aqui é um caso particular de espaço de medida. Outro exemplo importante para estas notas é $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \lambda)$, onde $\mathcal{B}(\mathbb{R})$ é a menor σ -álgebra de subconjuntos de $\mathbb{R}$ que contém todos os intervalos abertos. Ela é chamada de *σ -álgebra de Borel*. A medida λ é a medida de Lebesgue; uma de suas propriedades fundamentais é

$$\lambda((a, b]) = b - a, \quad a < b.$$

Em particular, todo intervalo é Lebesgue-mensurável e tem medida igual ao seu comprimento.

Podemos agora definir precisamente o que significa um conjunto ser indivisível do ponto de vista da medida.

Definição 6 (Átomo de uma medida). Seja $(S, \mathcal{A}, \mu)$ um espaço de medida. Um conjunto mensurável $A \in \mathcal{A}$ é chamado *átomo de μ* quando $\mu(A) > 0$ e, para todo $B \in \mathcal{A}$ com $B \subseteq A$, vale

$$\mu(B) = 0 \quad \text{ou} \quad \mu(A \setminus B) = 0.$$

Em outras palavras, um átomo é um conjunto de medida positiva que não pode ser decomposto em dois subconjuntos mensuráveis de medida positiva.

Se X é uma variável aleatória, chamamos de lei de X a medida de probabilidade μ_X definida nos borelianos $A \subseteq \mathbb{R}$ por

$$\mu_X(A) = \mathbb{P}(X \in A).$$

Para justificar que essa definição faz sentido para todo boreliano, considere a coleção

$$\mathcal{A}_X = \{A \subseteq \mathbb{R} : X^{-1}(A) \in \mathcal{F}\}.$$

Essa coleção é uma σ -álgebra de subconjuntos de $\mathbb{R}$. Pela definição de variável aleatória, ela contém todos os intervalos da forma $(-\infty, x]$; como esses intervalos geram $\mathcal{B}(\mathbb{R})$, segue que todo boreliano A satisfaz $X^{-1}(A) \in \mathcal{F}$. A verificação de que μ_X é de fato uma medida de probabilidade fica proposta na lista de exercícios ao final destas notas (**Exercício 1**).

Vamos dizer que um ponto $x \in \mathbb{R}$ é um *átomo da lei de X* quando o conjunto unitário $\{x\}$ é um átomo de μ_X ou, equivalentemente, quando

$$\mu_X(\{x\}) = \mathbb{P}(X = x) > 0.$$

É nesse sentido que usaremos a palavra “átomo” ao estudar funções de distribuição.

Observação 7. Para toda função de distribuição F_X e todo $x \in \mathbb{R}$, o limite à esquerda $F_X(x^-) := \lim_{\epsilon \downarrow 0} F_X(x - \epsilon)$ existe e

$$\mathbb{P}(X = x) = F_X(x) - F_X(x^-).$$

Em particular, F_X é descontínua em x se, e somente se, $\mathbb{P}(X = x) > 0$, ou seja, $\{x\}$ é um átomo da lei de X .

Antes de apresentarmos exemplos concretos de funções de distribuição, vamos mostrar mais uma propriedade válida para qualquer função de distribuição.

A probabilidade $F_X(x) = \mathbb{P}(X \leq x)$ é a probabilidade de que X assuma um valor no intervalo ilimitado $(-\infty, x]$. Logo, segue das propriedades elementares das medidas de probabilidade que a probabilidade de X assumir um valor em um intervalo limitado $(a, b]$, com $a < b$, é dada por

$$\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a). \quad (6)$$

De fato, já que o evento $\{X \leq a\}$ está contido no evento $\{X \leq b\}$, segue das propriedades elementares da medida de probabilidade $\mathbb{P}$ que

$$\begin{aligned} \mathbb{P}(a < X \leq b) &= \mathbb{P}(\{X \leq b\} \setminus \{X \leq a\}) \\ &= \mathbb{P}(X \leq b) - \mathbb{P}(X \leq a) \\ &= F_X(b) - F_X(a). \end{aligned}$$

2. Exemplos de Funções de Distribuição

O exemplo discreto mostrou uma função de distribuição constante por partes e com saltos nos pontos que são átomos. Agora veremos duas funções de distribuição que contrastam com aquele exemplo por serem contínuas em toda a reta. Em cada caso, verificaremos diretamente as propriedades fundamentais; a seção seguinte mostrará que essas propriedades são também suficientes.

2.1. A distribuição uniforme

Exemplo 8 (Distribuição uniforme). Sejam $a, b \in \mathbb{R}$ com $a < b$. Considere a função

$$F(x) = \begin{cases} 0, & \text{se } x < a, \\ \frac{x-a}{b-a}, & \text{se } a \leq x \leq b, \\ 1, & \text{se } x > b, \end{cases} \quad (7)$$

cujo gráfico está esboçado na **Figura 3**. Ela é não decrescente, contínua, vale 0 à esquerda de a e vale 1 à direita de b . Portanto, satisfaz as propriedades fundamentais que serão caracterizadas na próxima seção. Dizemos que uma variável aleatória com essa função de distribuição tem *distribuição uniforme* no intervalo (a, b) ; alguns autores preferem dizer que a distribuição é uniforme no intervalo $[a, b]$.

O fato de chamarmos a distribuição de uniforme em (a, b) ou em $[a, b]$ não altera a lei, pois os extremos têm probabilidade zero: $F(a) = 0$ e $F(b) = 1$, e a função é contínua nesses pontos. Assim, para X com essa função de distribuição, $\mathbb{P}(X = a) = \mathbb{P}(X = b) = 0$ e, por (6), $\mathbb{P}(a < X \leq b) = F(b) - F(a) = 1$.




Figura 3: Função de distribuição uniforme no intervalo (a, b) . A função vale 0 à esquerda de a , cresce linearmente de 0 a 1 em $[a, b]$ e vale 1 à direita de b .

2.2. A distribuição exponencial

Exemplo 9 (Distribuição exponencial). Seja $\lambda > 0$ e defina F por

$$F(x) = \begin{cases} 0, & \text{se } x \leq 0, \\ 1 - e^{-\lambda x}, & \text{se } x > 0, \end{cases} \quad (8)$$

cujo gráfico esboçamos na **Figura 4**. De fato, F é não decrescente, tem limites 0 e 1 quando $x \rightarrow -\infty$ e $x \rightarrow +\infty$, e é contínua à direita em 0, pois $F(0) = 0 = \lim_{x \downarrow 0} (1 - e^{-\lambda x})$. Logo, ela satisfaz as propriedades fundamentais. Dizemos que uma variável aleatória com essa distribuição tem *distribuição exponencial* com parâmetro λ .




Figura 4: Função de distribuição exponencial com parâmetro λ . A função é identicamente nula em $(-\infty, 0]$ e tende assintoticamente a 1 quando $x \rightarrow +\infty$.

3. Caracterização das Funções de Distribuição

Os dois exemplos anteriores motivam uma pergunta natural: as propriedades fundamentais que verificamos são apenas necessárias, ou também garantem que uma função seja uma função de distribuição de alguma variável aleatória X ? A resposta é afirmativa.

Teorema 10 (Caracterização das funções de distribuição). Seja $F : \mathbb{R} \rightarrow \mathbb{R}$ uma função que satisfaz as três condições a seguir:

(i) F é uma função monótona não decrescente, isto é,

$$F(x) \leq F(y) \quad \text{sempre que } x \leq y;$$

(ii) os limites de F em $-\infty$ e em $+\infty$ existem e são dados por

$$\lim_{x \rightarrow -\infty} F(x) = 0 \quad \text{e} \quad \lim_{x \rightarrow +\infty} F(x) = 1;$$

(iii) F é contínua à direita, isto é, para todo $x \in \mathbb{R}$,

$$F(x + \epsilon) \rightarrow F(x) \quad \text{quando } \epsilon \downarrow 0,$$

onde o limite é tomado com ϵ tendendo a 0 apenas por valores positivos.

Então F toma valores no intervalo $[0, 1]$ e existem um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$ e uma variável aleatória $X : \Omega \rightarrow \mathbb{R}$ nesse espaço tais que

$$\mathbb{P}(X \leq x) = F(x) \quad \text{para todo } x \in \mathbb{R},$$

isto é, F é a função de distribuição de X .

A **Proposição 4** fornece a recíproca do **Teorema 10**: a função de distribuição de qualquer variável aleatória satisfaz as três condições do enunciado. Logo, essas condições são necessárias e suficientes para que uma função seja a função de distribuição de alguma variável aleatória. Na prática, dada uma função F que se deseja exibir como função de distribuição, basta verificar as três condições do enunciado e invocar o teorema; não é preciso construir explicitamente o espaço de probabilidade nem a variável aleatória. A prova é omitida nestas notas e pode ser encontrada na referência [1].

4. Variáveis Aleatórias Absolutamente Contínuas

4.1. Densidades e variáveis absolutamente contínuas

As variáveis aleatórias aparecem em muitas formas, mas há duas classes que desempenham um papel central no curso:

- I. as variáveis aleatórias discretas;
- II. as variáveis aleatórias absolutamente contínuas.

Uma variável aleatória discreta assume apenas uma quantidade enumerável de valores e sua função de distribuição tem, em geral, o aspecto de uma função em degraus, como ilustra a [Figura 2](#). No extremo oposto encontram-se variáveis aleatórias cuja função de distribuição é bastante suave, como nos casos uniforme e exponencial discutidos na [Seção 2](#) (veja as [Figuras 3 e 4](#)). É essa segunda classe que passamos a estudar e cujos elementos chamaremos de *variáveis aleatórias absolutamente contínuas*.

Definição 11 (Variável aleatória absolutamente contínua). Vamos dizer que uma variável aleatória X é *absolutamente contínua* se existir uma função não negativa e Lebesgue-mensurável¹ $f_X : \mathbb{R} \rightarrow [0, +\infty)$ tal que sua função de distribuição F_X possa ser escrita na forma

$$F_X(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f_X(u) du \quad \text{para todo } x \in \mathbb{R}. \quad (9)$$

Nesse caso, dizemos que X tem *função densidade de probabilidade* f_X (ou simplesmente *densidade* f_X).

Quando uma variável aleatória é absolutamente contínua, a identidade (9) diz que a probabilidade do evento $\{X \leq x\}$ ocorrer é a área sob o gráfico de f_X à esquerda de x . Assim, F_X acumula a densidade desde $-\infty$ até x , e é por isso que F_X também é chamada de função de distribuição acumulada.

Observação 12. Uma boa parte dos textos de Teoria de Probabilidade, principalmente os mais avançados, chama as variáveis aleatórias descritas na [Definição 11](#) de *absolutamente contínuas*, reservando a expressão “variável aleatória contínua” para uma classe mais ampla de variáveis aleatórias. Entretanto, em algumas referências, como, por exemplo, [\[2\]](#), o leitor encontrará variáveis aleatórias como as da [Definição 11](#) sendo chamadas simplesmente de “contínuas”.

Nestas notas, o símbolo λ terá dois usos distintos: nesta observação e no estudo do conjunto de Cantor ele denota a medida de Lebesgue; nas distribuições exponencial e gama, denota um parâmetro. O contexto deixará claro qual uso está em jogo.

Exemplo 13. Se X tem distribuição exponencial de parâmetro $\lambda > 0$, então, como vimos no [Exemplo 9](#),

$$F_X(x) = \begin{cases} 0, & \text{se } x \leq 0, \\ 1 - e^{-\lambda x}, & \text{se } x > 0. \end{cases}$$

Uma maneira de investigar se X possui uma função de densidade f_X seria simplesmente calcular formalmente a derivada de F_X , isto é, F'_X , e, em seguida, mostrar que esta derivada pode ser usada para construir uma função de densidade para X . Neste caso em particular, temos para todo $x > 0$,

$$\frac{d}{dx}(1 - e^{-\lambda x}) = \lambda e^{-\lambda x},$$

e para $x < 0$ a derivada é 0. Desta forma, a função

$$f_X(x) = \begin{cases} 0, & \text{se } x \leq 0, \\ \lambda e^{-\lambda x}, & \text{se } x > 0. \end{cases}$$

¹“Lebesgue-mensurável” é uma condição técnica que garante que a integral esteja bem definida; ela não terá papel relevante no curso.

se apresenta como uma candidata natural a ser uma densidade para X . Neste caso mais simples, uma aplicação direta do Teorema Fundamental do Cálculo confirma nossas suspeitas.

Observe que, no ponto $x = 0$, a derivada de F_X não existe. Mesmo assim, podemos atribuir a f_X qualquer valor nesse ponto sem alterar sua integral.

4.2. Medida de Lebesgue e propriedades quase em todo ponto

Observação 14 (Medida de Lebesgue e propriedades em quase todo ponto). A medida de Lebesgue, que será denotada por λ , formaliza a ideia de comprimento na reta. Ela está definida na chamada σ -álgebra de Lebesgue $\mathcal{L}$ que é uma σ -álgebra de subconjuntos de $\mathbb{R}$ que contém a σ -álgebra de Borel $\mathcal{B}(\mathbb{R})$. Portanto, todo intervalo é Lebesgue-mensurável e, para $a < b$,

$$\lambda((a, b]) = b - a, \quad a < b.$$

Em particular, a medida de Lebesgue de um intervalo coincide com a noção intuitiva que temos de comprimento de um intervalo. Diremos que uma propriedade $P(x)$ vale em quase todo ponto, com respeito à medida de Lebesgue, quando o conjunto excepcional

$$N_P \equiv \{x \in \mathbb{R} : P(x) \text{ não vale}\}$$

é mensurável e tem medida nula, isto é, $\lambda(N_P) = 0$.

Pode ser trabalhoso, em geral, mostrar que um determinado subconjunto da reta tem medida de Lebesgue nula; entretanto, para nossos propósitos, será suficiente saber que um ponto (ou um conjunto unitário) tem medida nula, isto é, para todo $x \in \mathbb{R}$ temos $\lambda(\{x\}) = 0$. Deste fato e da σ -aditividade da medida de Lebesgue, podemos concluir que todo conjunto enumerável $E \subseteq \mathbb{R}$ também tem medida nula. No entanto, é importante estar atento ao fato de que é possível construir subconjuntos de $\mathbb{R}$ não-enumeráveis, como o conjunto ternário de Cantor $\mathbb{K} \subseteq [0, 1]$, que possui medida de Lebesgue nula, isto é, $\lambda(\mathbb{K}) = 0$. A construção deste conjunto é apresentada em detalhes adiante.

Vamos dizer que uma função $f : \mathbb{R} \rightarrow \mathbb{R}$ é derivável em quase todo ponto quando o conjunto

$$N_f \equiv \{x \in \mathbb{R} : f'(x) \text{ não existe}\}$$

tem medida de Lebesgue nula. Neste caso, se o conjunto N_f é não-vazio então quer dizer que a derivada de f deixa de existir em um conjunto excepcional.

Embora conjuntos de medida zero sejam “desprezíveis” com respeito à operação de integração, devemos tomar cuidado com o que este “desprezível” significa. Por exemplo, se sabemos apenas que $f'(x) = 0$ em quase todo ponto, isto não implica que seja fácil recuperar f a partir de f' por um processo elementar de integração. Mais adiante, vamos fornecer um exemplo de como este problema pode ser complicado. Este exemplo será baseado na chamada função de Cantor, que, como veremos, é uma função contínua, não-decrescente e não-constante, mas possui derivada nula em quase todo ponto.

Para uma variável aleatória absolutamente contínua no sentido da **Definição 11**, um resultado fundamental, que usaremos sem demonstrar, afirma que F_X é derivável em quase todo ponto. Além disso, sua derivada, estendida no conjunto excepcional pela regra abaixo, é uma versão de uma densidade de X :

$$f_X(x) = \begin{cases} \frac{d}{dx} F_X(x), & \text{se essa derivada existe em } x, \\ 0, & \text{caso contrário.} \end{cases} \quad (10)$$

O valor 0 no caso em que a derivada não existe é apenas uma escolha conveniente. Como o conjunto excepcional tem medida de Lebesgue nula, essa escolha não altera integrais nem probabilidades calculadas a partir da densidade.

Observação 15. Nos exemplos abordados nestas notas, a fórmula expressa em (10) fornecerá a função de densidade. No entanto, é importante saber que nem toda função de distribuição que é derivável em quase todo ponto possui uma função de densidade. Observamos também que a mera continuidade da função de distribuição implica apenas que X não possui átomos. A condição de ser absolutamente contínua exige algo muito mais forte: que as probabilidades dos intervalos possam ser recuperadas por integração de uma densidade em relação à medida de Lebesgue.

4.3. Consequências básicas da existência da função densidade

Observação 16. Se f e g são densidades de uma mesma variável aleatória X , então $f = g$ em quase todo ponto. Em particular, o valor atribuído a f_X em um ponto isolado é irrelevante.

As densidades desempenham para as variáveis aleatórias absolutamente contínuas um papel análogo ao das funções de probabilidade para as variáveis aleatórias discretas. Por isso, é natural começar registrando suas propriedades: não negatividade e normalização.

Propriedade. Se X é uma variável aleatória absolutamente contínua com densidade f_X , então

$$f_X(x) \geq 0 \quad \text{para todo } x \in \mathbb{R}, \quad \int_{-\infty}^{\infty} f_X(x) dx = 1.$$

Essas duas propriedades são análogas às condições $p_X(x) \geq 0$ e $\sum_x p_X(x) = 1$ no caso discreto. A analogia, no entanto, pode ser perigosa, pois $f_X(x)$ não é uma probabilidade e pode assumir valores maiores que 1. No exemplo exponencial, se $\lambda > 1$, então f_X assume valores maiores que 1 na vizinhança de $x = 0$, embora $\mathbb{P}(X = 0) = 0$.

O que $f_X(x)$ mede é a densidade de probabilidade nas vizinhanças de x . Se, além disso, f_X é contínua em x e δx é positivo e suficientemente pequeno, então, grosso modo,

$$\begin{aligned} \mathbb{P}(x < X \leq x + \delta x) &= F_X(x + \delta x) - F_X(x) \quad \text{por (6)} \\ &= \int_x^{x+\delta x} f_X(u) du \quad \text{por (9)} \\ &\approx f_X(x) \delta x \quad \text{para } \delta x \text{ pequeno.} \end{aligned} \tag{11}$$

A última aproximação usa a continuidade da função de densidade no ponto x : em um intervalo curto, a área sob f_X é aproximadamente a área de um retângulo de base δx e altura $f_X(x)$.

Portanto, a analogia correta não é entre $f_X(x)$ e a função de probabilidade $p_X(x)$, mas entre $f_X(x) \delta x$ e $p_X(x)$. No caso absolutamente contínuo, pontos isolados têm probabilidade nula; isso será demonstrado mais adiante.

4.4. O Teorema da Convergência Dominada

Como de costume, se $I \in \mathcal{B}(\mathbb{R})$ e $f : \mathbb{R} \rightarrow \mathbb{R}$ é uma função integrável, usaremos a notação

$$\int_I f(x) dx \equiv \int_{-\infty}^{+\infty} \mathbf{1}_I(x) f(x) dx.$$

O resultado que permite trocar limite e integral, e que será usado na prova seguinte, é o Teorema da Convergência Dominada de Lebesgue.

Teorema 17 (Teorema da Convergência Dominada de Lebesgue). Seja $(f_n)_{n \in \mathbb{N}}$ uma sequência de funções Lebesgue-mensuráveis $f_n : \mathbb{R} \rightarrow \mathbb{R}$. Suponha que exista uma função Lebesgue-mensurável $g : \mathbb{R} \rightarrow [0, +\infty)$ tal que

$$|f_n(x)| \leq g(x) \quad \text{para todo } n \in \mathbb{N} \text{ e para quase todo } x \in \mathbb{R}, \quad \int_{-\infty}^{+\infty} g(x) dx < +\infty.$$

Se, além disso, $f_n(x) \rightarrow f(x)$ em quase todo ponto $x \in \mathbb{R}$, sendo f uma função Lebesgue-mensurável, então f é integrável e

$$\lim_{n \rightarrow \infty} \int_{-\infty}^{+\infty} f_n(x) dx = \int_{-\infty}^{+\infty} f(x) dx.$$

Corolário 18. Para cada $n \in \mathbb{N}$, seja $I_n \in \mathcal{B}(\mathbb{R})$ um boreliano. Suponha que exista algum $I \in \mathcal{B}(\mathbb{R})$ tal que $\mathbb{1}_{I_n}(x) \rightarrow \mathbb{1}_I(x)$ em quase todo ponto $x \in \mathbb{R}$. Seja $f : \mathbb{R} \rightarrow \mathbb{R}$ uma função Lebesgue-mensurável tal que

$$\int_{-\infty}^{+\infty} |f(x)| dx < +\infty.$$

Então

$$\lim_{n \rightarrow \infty} \int_{I_n} f(x) dx = \int_I f(x) dx.$$

4.5. Um critério para construir densidades

Até aqui vimos que uma variável aleatória absolutamente contínua X fica descrita por sua função de distribuição F_X e que, quando F_X é derivável, sua derivada f_X é a função densidade de probabilidade associada, conforme a **Definição 11**. Cabe agora perguntar o contrário: dada uma função f , quando ela é a função de densidade de alguma variável aleatória? A resposta é simples e a registramos a seguir.

Se $f : \mathbb{R} \rightarrow [0, \infty)$ é Lebesgue-mensurável e satisfaz

$$f(x) \geq 0 \quad \text{para todo } x \in \mathbb{R} \tag{12}$$

e

$$\int_{-\infty}^{\infty} f(x) dx = 1, \tag{13}$$

então f é a função densidade de probabilidade de alguma variável aleatória X . Para verificar este fato, vamos mostrar que valem as hipóteses do **Teorema 10** para a função $F : \mathbb{R} \rightarrow \mathbb{R}$ definida por

$$F(x) = \int_{-\infty}^x f(u) du.$$

Primeiro observamos que a hipótese (13), de integrabilidade de f , garante que $F(x)$ está bem-definida e finita para todo $x \in \mathbb{R}$. A monotonicidade da função F segue do Teorema Fundamental do Cálculo e da hipótese (12) de não-negatividade de f . A continuidade à direita e os limites em $\pm\infty$ seguem do Teorema da Convergência Dominada (**Teorema 17**).

De fato, para cada $x \in \mathbb{R}$ fixado e cada sequência $\{\varepsilon_n\}_{n \in \mathbb{N}}$ com $\varepsilon_n \geq 0$ e $\varepsilon_n \rightarrow 0$ quando $n \rightarrow \infty$, temos:

$$\begin{aligned} F(x + \varepsilon_n) - F(x) &= \int_{-\infty}^{x+\varepsilon_n} f(t) dt - \int_{-\infty}^x f(t) dt \\ &= \int_x^{x+\varepsilon_n} f(t) dt = \int_{-\infty}^{+\infty} \mathbb{1}_{[x, x+\varepsilon_n]}(t) f(t) dt. \end{aligned}$$

Tomando $f_n \equiv \mathbb{1}_{[x, x+\varepsilon_n]} \cdot f$, temos que $f_n(t) \rightarrow 0$ em quase todo ponto. Mais precisamente, $f_n(t)$ só não converge no ponto $t = x$. Como $|f_n| = |\mathbb{1}_{[x, x+\varepsilon_n]} \cdot f| \leq f$ e a função f é integrável em toda a reta, segue da aplicação direta do Teorema da Convergência Dominada que existe o seguinte limite e vale a seguinte igualdade

$$\begin{aligned} \lim_{n \rightarrow \infty} [F(x + \varepsilon_n) - F(x)] &= \lim_{n \rightarrow \infty} \int_{-\infty}^{+\infty} \mathbb{1}_{[x, x+\varepsilon_n]}(t) f(t) dt = \int_{-\infty}^{+\infty} \lim_{n \rightarrow \infty} \mathbb{1}_{[x, x+\varepsilon_n]}(t) f(t) dt \\ &= \int_{-\infty}^{+\infty} 0 dt = 0. \end{aligned}$$

Como $\{\varepsilon_n\}_{n \in \mathbb{N}}$ é uma sequência arbitrária que converge para zero, por valores não negativos, segue da igualdade acima que

$$\lim_{\varepsilon \rightarrow 0^+} F(x + \varepsilon) = F(x).$$

De maneira análoga, mostramos que

$$\lim_{x \rightarrow -\infty} \int_{-\infty}^x f(t) dt = 0 \quad \text{e} \quad \lim_{x \rightarrow +\infty} \int_{-\infty}^x f(t) dt = 1,$$

onde, na segunda igualdade, usamos, além do Teorema da Convergência Dominada de Lebesgue, a hipótese (13).

Portanto, pelo **Teorema 10**, existe uma variável aleatória X cuja função de distribuição é F . Como $F(x) = \int_{-\infty}^x f(u) du$, concluímos que f é uma função densidade de X .

4.6. Probabilidades de pontos e intervalos

Teorema 19 (Propriedades da densidade). Se X é uma variável aleatória absolutamente contínua com densidade f_X , então

$$\mathbb{P}(X = x) = 0 \quad \text{para todo } x \in \mathbb{R}, \quad (14)$$

e

$$\mathbb{P}(a \leq X \leq b) = \int_a^b f_X(u) du \quad \text{para } a, b \in \mathbb{R} \text{ com } a \leq b. \quad (15)$$

Demonstração. Vamos provar primeiro (14). Para isso, observamos que os eventos

$$E_n \equiv \left\{ x - \frac{1}{n} < X \leq x \right\}$$

decrecem para $\{X = x\}$ quando $n \rightarrow \infty$. Pela continuidade da probabilidade,

$$\mathbb{P}(X = x) = \lim_{n \rightarrow \infty} \mathbb{P}\left(x - \frac{1}{n} < X \leq x\right).$$


Usando as propriedades elementares (6) e (9), obtemos

$$\begin{aligned}\mathbb{P}(X = x) &= \lim_{n \rightarrow \infty} \left[F_X(x) - F_X\left(x - \frac{1}{n}\right) \right] \\ &= \lim_{n \rightarrow \infty} \int_{x - \frac{1}{n}}^x f_X(u) du \\ &= 0,\end{aligned}$$

onde a última igualdade segue do **Corolário 18**, aplicado a $I_n = [x - 1/n, x]$ e $I = \{x\}$.

Para a segunda parte, seja $a \leq b$. Como $\{X = a\}$ tem probabilidade 0 pela primeira parte, os eventos $\{a \leq X \leq b\}$ e $\{a < X \leq b\}$ têm a mesma probabilidade. Logo, por (6) e (9),

$$\begin{aligned}\mathbb{P}(a \leq X \leq b) &= \mathbb{P}(a < X \leq b) \\ &= F_X(b) - F_X(a) \\ &= \int_{-\infty}^b f_X(u) du - \int_{-\infty}^a f_X(u) du \\ &= \int_a^b f_X(u) du.\end{aligned}$$



■

O teorema mostra que, para uma variável aleatória absolutamente contínua, a probabilidade de qualquer valor isolado é nula. Consequentemente, incluir ou excluir os extremos de um intervalo não altera sua probabilidade, ou seja,

$$\begin{aligned}\mathbb{P}(a \leq X \leq b) &= \mathbb{P}(a < X \leq b) \\ &= \mathbb{P}(a \leq X < b) \\ &= \mathbb{P}(a < X < b).\end{aligned}$$

Isso contrasta com o caso discreto, em que um único ponto pode concentrar toda a probabilidade.

5. Distribuições Contínuas sem Densidade

Até aqui estudamos duas classes de variáveis aleatórias: as discretas e as absolutamente contínuas. Essas duas classes, porém, não esgotam as possibilidades. Nesta seção construímos o exemplo clássico de uma variável aleatória que não pertence a nenhuma delas: sua função de distribuição é contínua, de modo que não há átomos, mas não pode ser escrita como a integral de uma densidade, com respeito à medida de Lebesgue.

O percurso descreve o mesmo objeto de dois pontos de vista. Primeiro definimos a função de Cantor $\mathcal{C} : [0, 1] \rightarrow \mathbb{R}$ como o limite de um processo iterativo de aproximações. Como veremos, a construção já deixa claro que esta função é contínua e não decrescente em todo intervalo fechado $[0, 1]$. Em seguida, construímos uma variável aleatória X cuja função de distribuição é exatamente a função $\mathcal{C}$. Vamos mostrar que X toma valores apenas no conjunto ternário de Cantor, que tem medida de Lebesgue nula, conforme será demonstrado no [Exercício 16](#), e também que X tem distribuição contínua, mas não admite densidade.

5.1. A função de Cantor

Começamos com a função identidade

$$f_0(x) = x, \quad 0 \leq x \leq 1.$$

Em seguida, prosseguimos com a construção recursivamente. Supondo que f_n já tenha sido construída, definimos f_{n+1} como sendo a seguinte função

$$f_{n+1}(x) \equiv \begin{cases} \frac{1}{2}f_n(3x), & \text{se } 0 \leq x \leq \frac{1}{3}, \\ \frac{1}{2}, & \text{se } \frac{1}{3} \leq x \leq \frac{2}{3}, \\ \frac{1}{2} + \frac{1}{2}f_n(3x - 2), & \text{se } \frac{2}{3} \leq x \leq 1. \end{cases}$$

O que essa fórmula faz com o gráfico? Ela copia o gráfico de f_n para o terço esquerdo, comprimindo-o verticalmente até a altura $1/2$. Mantém a função constante e igual a $1/2$ ao longo do terço central. Por último, copia novamente o gráfico para o terço direito, comprimindo-o verticalmente por um fator de $1/2$, e o resultado disso é colocado entre as alturas $1/2$ e 1 . Assim, em cada etapa aparece um novo trecho horizontal no terço médio de cada intervalo que ainda não havia sido achatado. As primeiras etapas da construção descrita acima podem ser visualizadas nos gráficos da [Figura 5](#).




Figura 5: As primeiras seis aproximações da função de Cantor. O primeiro quadro corresponde a f_0 , e cada quadro seguinte é obtido do anterior pela regra descrita no texto; em cada etapa, o gráfico é achatado no terço médio de cada intervalo restante.

A sequência de funções definida recursivamente acima converge uniformemente para uma função contínua e monótona não decrescente $\mathcal{C} : [0, 1] \rightarrow [0, 1]$, chamada função de Cantor:

$$\mathcal{C}(x) = \lim_{n \rightarrow \infty} f_n(x).$$

A taxa uniforme da convergência de f_n para $\mathcal{C}$ é produzida pela regra de construção, já que a cada etapa reduzimos pela metade as diferenças entre duas funções aproximantes consecutivas definidas por esta transformação. O significado preciso dessa afirmação é apresentado nos itens do [Exercício 17](#), que está no final das notas.

Em particular, os intervalos abertos que recebem trechos horizontais na construção são precisamente os intervalos removidos na construção do conjunto ternário de Cantor. Por isso, no limite, $\mathcal{C}$ é constante em cada um desses intervalos, embora continue sendo uma função contínua no intervalo todo. Como o complemento de $\mathbb{K}$ em $[0, 1]$ é a união desses intervalos e $\lambda(\mathbb{K}) = 0$, segue que $\mathcal{C}'(x) = 0$ em quase todo ponto de $[0, 1]$. A verificação dessa identificação fica proposta no [Exercício 17](#).

5.2. A distribuição de Cantor

Até aqui, a função de Cantor apareceu como um objeto construído por meio de aproximações sucessivas de funções. Vamos agora olhar para ela de outro ponto de vista: como a função de distribuição de uma variável aleatória.

Essa interpretação responde a uma pergunta que pode parecer estranha à primeira vista. O conjunto de Cantor $\mathbb{K}$ tem medida de Lebesgue nula, mas a função $\mathcal{C}$ cresce de 0 a 1 em $[0, 1]$. Será possível construir uma variável aleatória que esteja sempre em $\mathbb{K}$ e, ainda assim, tenha uma função de distribuição contínua? A resposta é sim. Mais do que isso: essa variável aleatória não terá uma função de densidade. O exemplo é importante porque mostra concretamente que “distribuição contínua” e “distribuição absolutamente contínua” são noções diferentes.

5.2.1. A ideia do experimento aleatório

Recordemos a construção de $\mathbb{K}$. Começamos com o intervalo $[0, 1]$. Na primeira etapa, retiramos o terço médio e permanecem os dois intervalos laterais. Na etapa seguinte, repetimos o mesmo procedimento em cada um deles, e assim por diante. Os primeiros passos estão representados na [Figura 6](#); os segmentos coloridos são os intervalos que permanecem em cada etapa.




Figura 6: As primeiras etapas da construção do conjunto de Cantor. Os segmentos coloridos representam os intervalos que permanecem.

Agora fazemos uma escolha aleatória em cada etapa: escolhemos o intervalo da esquerda ou o intervalo da direita, sempre com probabilidade $1/2$. As escolhas feitas em etapas diferentes são independentes. Portanto, uma sequência prescrita de n escolhas, por exemplo

esquerda, direita, esquerda, $\dots$, direita,

tem probabilidade $(1/2)^n = 2^{-n}$. Essa é a única propriedade da independência que usaremos explicitamente.

Para registrar as escolhas, definimos variáveis aleatórias B_n , com distribuição de Bernoulli, dadas por

$$B_n = \begin{cases} 0, & \text{se, na etapa } n, \text{ escolhemos o intervalo da esquerda,} \\ 1, & \text{se, na etapa } n, \text{ escolhemos o intervalo da direita.} \end{cases}$$

Assim, cada B_n assume os valores 0 e 1 com a mesma probabilidade:

$$\mathbb{P}(B_n = 0) = \mathbb{P}(B_n = 1) = \frac{1}{2}.$$

Formalmente, podemos pensar que um resultado do experimento é uma sequência infinita $(B_1, B_2, B_3, \dots)$ de zeros e uns. Não será necessário construir em detalhes o espaço de probabilidade dessas sequências. Para todos os cálculos abaixo, basta saber que os eventos que determinam os primeiros n valores $B_1, \dots, B_n$ têm probabilidade 2^{-n} .

5.2.2. O ponto escolhido e sua expansão ternária

Depois de n etapas, as escolhas $B_1, \dots, B_n$ determinam um único intervalo fechado de comprimento 3^{-n} . Seu extremo esquerdo é

$$X_n = \frac{2B_1}{3} + \frac{2B_2}{3^2} + \dots + \frac{2B_n}{3^n} = \sum_{k=1}^n \frac{2B_k}{3^k}.$$

Por exemplo, se as duas primeiras escolhas forem esquerda e direita, então $B_1 = 0$, $B_2 = 1$, e o intervalo escolhido na segunda etapa é

$$\left[\frac{2}{9}, \frac{1}{3}\right].$$

O caminho dessas duas escolhas pode ser visualizado na [Figura 7](#). Em cada linha estão representados os intervalos que permanecem depois da etapa correspondente. O intervalo escolhido fica destacado, e as setas indicam o caminho esquerda–direita determinado por $B_1 = 0$ e $B_2 = 1$.




Figura 7: O caminho correspondente às escolhas $B_1 = 0$ (esquerda) e $B_2 = 1$ (direita).

De fato, nesse caso $X_2 = 2/9$ e o comprimento do intervalo é $3^{-2} = 1/9$. Em geral, o intervalo determinado pelas primeiras n escolhas é

$$I_n = \left[X_n, X_n + \frac{1}{3^n} \right].$$

Os intervalos I_n são encaixados: cada um está contido no anterior. Além disso, seus comprimentos tendem a zero. Pelo Teorema dos intervalos encaixados de Cantor, a interseção de todos estes intervalos determina um único ponto. Podemos vê-lo diretamente pela série. Como $0 \leq B_k \leq 1$, temos

$$\begin{aligned} 0 \leq X - X_n &\equiv \sum_{k=n+1}^{\infty} \frac{2B_k}{3^k} \\ &\leq \sum_{k=n+1}^{\infty} \frac{2}{3^k} = \frac{1}{3^n}. \end{aligned}$$

Consequentemente, a série

$$X \equiv \sum_{k=1}^{\infty} \frac{2B_k}{3^k} \tag{16}$$

converge e seu valor pertence a todos os intervalos I_n . Em particular,

$$X \in \bigcap_{n=1}^{\infty} K_n = \mathbb{K} \quad \text{com probabilidade 1.}$$

Na verdade, nesta construção, a inclusão vale para todo resultado do experimento, e não apenas quase certamente. Portanto, também podemos escrever $\mathbb{P}(X \in \mathbb{K}) = 1$; a expressão “com probabilidade 1” registra essa conclusão no vocabulário usual da teoria da probabilidade.

A expressão (16) também explica o nome “expansão ternária”. Uma expansão ternária comum permite os algarismos 0, 1 e 2. Aqui, porém, todos os algarismos são iguais a 0 ou a 2, pois o algarismo na posição k é $2B_k$. Essa é precisamente a característica dos pontos do conjunto ternário de Cantor.

Como acontece com expansões em qualquer base, alguns números possuem duas representações ternárias diferentes. Isso ocorre, por exemplo, com os extremos dos intervalos

retirados. Essa ambiguidade não afeta a construção: para os pontos de $\mathbb{K}$, escolhemos a representação que utiliza somente os algarismos 0 e 2, isto é, a representação produzida pelas escolhas $B_1, B_2, \dots$.

5.2.3. A condição de continuidade

Se $x \notin \mathbb{K}$, então $\mathbb{P}(X = x) = 0$, pois X sempre pertence a $\mathbb{K}$. Consideremos agora $x \in \mathbb{K}$. Em cada etapa n , o ponto x pertence a uma única componente de K_n , isto é, a um dos intervalos fechados que formam K_n . É claro que estes intervalos são disjuntos. Para que ocorra $X = x$, as primeiras n escolhas precisam ser exatamente as escolhas que conduzem a esse intervalo. Como essa sequência de escolhas tem probabilidade 2^{-n} , obtemos

$$\mathbb{P}(X = x) \leq 2^{-n} \quad \text{para todo } n \in \mathbb{N}.$$

Como $2^{-n} \rightarrow 0$, segue que

$$\mathbb{P}(X = x) = 0 \quad \text{para todo } x \in \mathbb{R}. \quad (17)$$

Portanto, a distribuição de X não concentra probabilidade positiva em nenhum ponto. Pela relação entre saltos da função de distribuição e massas atômicas, discutida na [Observação 7](#), a função de distribuição de X é contínua.

5.2.4. A função de distribuição e sua recursão

Seja

$$F_X(x) = \mathbb{P}(X \leq x)$$

a função de distribuição de X . Para identificar essa função, vamos separar a primeira escolha das escolhas seguintes. Defina a variável aleatória formada pelas escolhas a partir da segunda etapa por

$$Y \equiv \sum_{k=1}^{\infty} \frac{2B_{k+1}}{3^k}.$$

A sequência $B_2, B_3, \dots$ tem, em conjunto, as mesmas probabilidades que a sequência $B_1, B_2, \dots$. Além disso, ela é independente de B_1 . Logo, Y tem a mesma distribuição que X e é independente de B_1 . Separando, na série (16), o primeiro termo, encontramos

$$X = \begin{cases} \frac{1}{3}Y, & \text{se } B_1 = 0, \\ \frac{2}{3} + \frac{1}{3}Y, & \text{se } B_1 = 1. \end{cases}$$

Essa identidade é a tradução probabilística da primeira etapa da construção do conjunto de Cantor: com probabilidade $1/2$, o ponto está no terço esquerdo e, com probabilidade $1/2$, está no terço direito.

Vamos calcular F_X separando esses dois casos.

- i) Se $0 \leq x \leq 1/3$, o evento $\{X \leq x\}$ só pode ocorrer quando $B_1 = 0$. Nesse caso, $X = Y/3$ e, portanto,

$$\begin{aligned} F_X(x) &= \mathbb{P}(B_1 = 0, Y \leq 3x) \\ &= \mathbb{P}(B_1 = 0) \mathbb{P}(Y \leq 3x) \\ &= \frac{1}{2} F_X(3x). \end{aligned}$$

- ii) Se $1/3 \leq x \leq 2/3$, todos os pontos escolhidos no terço esquerdo já satisfazem $X \leq x$, enquanto nenhum ponto do terço direito satisfaz essa desigualdade, exceto possivelmente o extremo $2/3$. Esse único ponto tem probabilidade zero por (17). Assim,

$$F_X(x) = \mathbb{P}(B_1 = 0) = \frac{1}{2}.$$

- iii) Se $2/3 \leq x \leq 1$, todos os pontos do terço esquerdo são menores ou iguais a x . No terço direito, a desigualdade $2/3 + Y/3 \leq x$ equivale a $Y \leq 3x - 2$. Logo,

$$\begin{aligned} F_X(x) &= \mathbb{P}(B_1 = 0) + \mathbb{P}(B_1 = 1, Y \leq 3x - 2) \\ &= \frac{1}{2} + \frac{1}{2} F_X(3x - 2). \end{aligned}$$

Reunindo os três casos, vemos que F_X satisfaz a equação

$$F_X(x) = \begin{cases} \frac{1}{2} F_X(3x), & \text{se } 0 \leq x \leq \frac{1}{3}, \\ \frac{1}{2}, & \text{se } \frac{1}{3} \leq x \leq \frac{2}{3}, \\ \frac{1}{2} + \frac{1}{2} F_X(3x - 2), & \text{se } \frac{2}{3} \leq x \leq 1. \end{cases} \quad (18)$$

Compare essa relação com a regra que definiu as aproximações f_n . Como f_n converge uniformemente para $\mathcal{C}$, podemos passar ao limite em cada uma das três fórmulas que definem f_{n+1} e concluímos que $\mathcal{C}$ satisfaz exatamente a mesma relação (18), com F_X substituída por $\mathcal{C}$.

Para deixar claro por que essa identificação é legítima, vamos verificar que só existe uma função contínua que satisfaz (18). Suponha que $G, H : [0, 1] \rightarrow \mathbb{R}$ sejam duas funções contínuas que satisfazem a relação (18), com F_X substituída por G e por H , respectivamente. Seja

$$D = \sup_{0 \leq x \leq 1} |G(x) - H(x)|.$$

Como G e H são contínuas em um intervalo compacto, esse supremo é finito. Além disso, a própria relação recursiva, avaliada em 0 e em 1, impõe $G(0) = H(0) = 0$ e $G(1) = H(1) = 1$.

Observe que, nos terços da esquerda e da direita, a relação recursiva multiplica a diferença por $1/2$; no terço central, as duas funções têm o mesmo valor $1/2$. Portanto, para todo $x \in [0, 1]$,

$$|G(x) - H(x)| \leq \frac{1}{2} D.$$

Tomando o supremo em x , obtemos $D \leq D/2$. Como $D \geq 0$, isso só é possível quando $D = 0$. Logo $G = H$. Em particular,

$$F_X(x) = \mathcal{C}(x), \quad 0 \leq x \leq 1. \quad (19)$$

Fora de $[0, 1]$, temos $F_X(x) = 0$ para $x < 0$ e $F_X(x) = 1$ para $x \geq 1$, pois $X \in \mathbb{K} \subseteq [0, 1]$. A relação recursiva também mostra que $\mathcal{C}(1) = 1$. Portanto, se estendermos $\mathcal{C}$ por 0 à esquerda de 0 e por 1 à direita de 1, essa extensão será exatamente a função de distribuição da variável aleatória X construída em (16).

5.2.5. Por que essa distribuição não tem densidade?

Já sabemos que $X \in \mathbb{K}$ com probabilidade 1, ao passo que $\lambda(\mathbb{K}) = 0$. Podemos mostrar a impossibilidade de uma densidade usando a relação entre densidade e derivada apresentada acima. Suponha, por contradição, que X tivesse uma densidade f_X . A função de distribuição de X é a extensão de $\mathcal{C}$ por 0 à esquerda e por 1 à direita. Ela é constante em cada componente do complemento de $\mathbb{K}$; logo, sua derivada é nula fora de $\mathbb{K}$. Como $\lambda(\mathbb{K}) = 0$, essa derivada é nula em quase todo ponto. Pela relação (10), a densidade f_X coincide com essa derivada em quase todo ponto. Portanto, $f_X = 0$ em quase todo ponto, o que daria

$$\int_{-\infty}^{\infty} f_X(x) dx = 0,$$

em contradição com a normalização $\int_{-\infty}^{\infty} f_X(x) dx = 1$.

Portanto, X tem uma função de distribuição contínua, mas não possui uma função de densidade de Lebesgue. Dizemos que sua distribuição é uma *distribuição singular contínua*: ela é contínua porque $\mathbb{P}(X = x) = 0$ para todo ponto x , mas é singular porque toda a sua probabilidade está concentrada no conjunto $\mathbb{K}$, que tem medida de Lebesgue nula. Assim, para utilizar uma densidade e as ferramentas do cálculo integral, é necessário assumir explicitamente que a distribuição é absolutamente contínua.

5.3. Resumo

Antes de prosseguir, recapitulamos o percurso feito até o momento. Vimos que toda variável aleatória possui uma função de distribuição conforme a Definição 2. No caso discreto, a função de distribuição é codificada pela função de probabilidade p_X . No caso absolutamente contínuo, pela função densidade f_X . Essas duas classes, como acabamos de ver, não esgotam todas as possibilidades: a distribuição de Cantor fornece um exemplo da existência de uma variável aleatória contínua cuja função de distribuição não pode ser escrita como a integral de uma densidade.

Para diversas aplicações, as funções densidade acabam sendo um instrumento mais útil. Na seção seguinte, apresentamos alguns exemplos que aparecem com mais frequência.

6. Exemplos de Funções Densidade

Mostramos abaixo as densidades mais usadas, cada uma acompanhada de seus parâmetros e de sua região de positividade. Em todos os casos a não negatividade (12) é imediata, e a verificação da normalização (13) é o ponto que merece atenção. Resumimos a lista na Tabela 1.


6.1. Densidades básicas

Distribuição uniforme.

Dizemos que X tem *distribuição uniforme* no intervalo (a, b) , com $a < b$, quando sua densidade é

$$f(x) = \begin{cases} \frac{1}{b-a}, & \text{se } a < x < b, \\ 0, & \text{caso contrário.} \end{cases} \quad (20)$$

O gráfico desta função de densidade é esboçado na figura abaixo.



Neste caso, a verificação da condição de normalização (13) é elementar, já que valem as seguintes igualdades:

$$\int_{-\infty}^{\infty} f(x) dx = \int_a^b \frac{1}{b-a} dx = \frac{b-a}{b-a} = 1.$$

A densidade é constante sobre o intervalo: não há posição privilegiada dentro de (a, b) , o que justifica o nome.

Distribuição exponencial.

Dizemos que X tem *distribuição exponencial* de parâmetro $\lambda > 0$ quando

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{se } x > 0, \\ 0, & \text{se } x \leq 0. \end{cases} \quad (21)$$

Para verificar que f está normalizada como em (13), basta aplicar o Teorema Fundamental do Cálculo. De fato, já que $\frac{d}{dx}(-e^{-\lambda x}) = \lambda e^{-\lambda x}$ e $e^{-\lambda x} \rightarrow 0$ quando $x \rightarrow +\infty$, temos

$$\int_{-\infty}^{\infty} f(x) dx = \int_0^{\infty} \lambda e^{-\lambda x} dx = -e^{-\lambda x} \Big|_0^{\infty} = 1.$$

6.2. Distribuições normal e de Cauchy

Distribuição normal (gaussiana).

Dizemos que X tem *distribuição normal* (ou *gaussiana*) de parâmetros $\mu \in \mathbb{R}$ e $\sigma > 0$, e escrevemos $X \sim N(\mu, \sigma^2)$, quando X possui função de densidade dada por

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right), \quad x \in \mathbb{R}. \quad (22)$$

Como veremos mais à frente, o parâmetro μ será o valor esperado de X . Note que, ao variar este parâmetro, deslocamos o centro da curva ao longo do eixo x , enquanto o

parâmetro σ (que será o desvio-padrão de X ou a raiz quadrada de sua variância) controla sua dispersão (veja o efeito da variação deste parâmetro nos gráficos da [Figura 9](#)). Dizemos que X tem distribuição normal padrão se $\mu = 0$ e $\sigma = 1$, e usaremos a notação $X \sim N(0, 1)$.




Figura 8: Densidade da normal padrão $N(0, 1)$.

Para observar simultaneamente os efeitos dos dois parâmetros, considere agora o exemplo $\mu = 2$ e $\sigma = \frac{3}{2}$. O centro da curva está em μ , enquanto a comparação com a normal padrão mostra a mudança de posição do máximo e o aumento da abertura causado por $\sigma > 1$. As marcações $\mu - \sigma$, μ e $\mu + \sigma$ destacam no eixo x a posição da média e os pontos situados a um desvio-padrão dela.




Figura 9: Densidade normal $N(\mu, \sigma^2)$ no caso $\mu = 2$ e $\sigma = \frac{3}{2}$ (curva contínua), comparada com a densidade da normal padrão $N(0, 1)$ (curva cinza pontilhada).

Para verificar que a integral vale 1, usamos a integral gaussiana

$$\int_{-\infty}^{\infty} e^{-x^2} dx = \sqrt{\pi}. \quad (23)$$

A demonstração dessa identidade é esboçada no [Exercício 14](#). Com efeito, a mudança de variáveis $x = \mu + \sigma\sqrt{2}z$ dá $dx = \sigma\sqrt{2}dz$ e

$$\int_{-\infty}^{\infty} e^{-\frac{1}{2\sigma^2}(x-\mu)^2} dx = \sigma\sqrt{2} \int_{-\infty}^{\infty} e^{-z^2} dz = \sigma\sqrt{2\pi},$$

onde usamos (23). Dividindo pelo fator $\sqrt{2\pi\sigma^2}$ obtemos exatamente 1. A constante de normalização foi escolhida justamente para isso.

Distribuição de Cauchy.

Dizemos que X tem *distribuição de Cauchy* quando

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad x \in \mathbb{R}. \quad (24)$$

A normalização segue da derivada da função arco-tangente, pois $\frac{d}{dx} \arctan x = \frac{1}{1+x^2}$ e $\lim_{x \rightarrow \pm\infty} \arctan x = \pm \frac{\pi}{2}$:

$$\int_{-\infty}^{\infty} \frac{1}{\pi(1+x^2)} dx = \frac{1}{\pi} \arctan x \Big|_{-\infty}^{\infty} = \frac{1}{\pi} \left(\frac{\pi}{2} + \frac{\pi}{2} \right) = 1.$$

6.3. Famílias gama, beta e qui-quadrado

Distribuição gama.

Dizemos que X tem *distribuição gama* de parâmetros $w > 0$ e $\lambda > 0$ quando

$$f(x) = \begin{cases} \frac{1}{\Gamma(w)} \lambda^w x^{w-1} e^{-\lambda x}, & \text{se } x > 0, \\ 0, & \text{se } x \leq 0, \end{cases} \quad (25)$$

onde Γ é a *função gama*, definida por

$$\Gamma(w) = \int_0^{\infty} x^{w-1} e^{-x} dx. \quad (26)$$

A integral em (26) converge para todo $w > 0$: perto de 0, o integrando é comparável a x^{w-1} , cuja integral converge para $w > 0$, enquanto, no infinito, o fator e^{-x} garante a convergência. Para checar a normalização de (25), fazemos a mudança $y = \lambda x$, de modo que $dx = dy/\lambda$:

$$\int_{-\infty}^{\infty} f(x) dx = \frac{\lambda^w}{\Gamma(w)} \int_0^{\infty} x^{w-1} e^{-\lambda x} dx = \frac{1}{\Gamma(w)} \int_0^{\infty} y^{w-1} e^{-y} dy = \frac{\Gamma(w)}{\Gamma(w)} = 1.$$

Ou seja, a distribuição gama integra 1 *por definição* de Γ .

Observamos ainda que, para um inteiro positivo $w = n$, a função gama recupera o fatorial. De fato, integrando por partes, obtém-se $\Gamma(w) = (w-1)\Gamma(w-1)$ para $w > 1$; e, como $\Gamma(1) = 1$, segue que

$$\Gamma(n) = (n-1)! \quad \text{para } n = 1, 2, 3, \dots$$

Este é o conteúdo do [Exercício 13](#), ao qual remetemos o leitor para os detalhes da indução.

Distribuição beta.

Dizemos que X tem *distribuição beta* de parâmetros $s > 0$ e $t > 0$ quando

$$f(x) = \begin{cases} \frac{1}{B(s, t)} x^{s-1} (1-x)^{t-1}, & \text{se } 0 < x < 1, \\ 0, & \text{caso contrário,} \end{cases} \quad (27)$$

onde B é a *função beta*,

$$B(s, t) = \int_0^1 x^{s-1} (1-x)^{t-1} dx. \quad (28)$$

A integral em (28) converge para $s > 0$ e $t > 0$: perto de $x = 0$ o integrando é comparável a x^{s-1} e perto de $x = 1$ a $(1-x)^{t-1}$. Aqui a normalização é imediata: a constante $B(s, t)$ foi escolhida exatamente para que a integral de f em (27) seja

$$\frac{1}{B(s, t)} \int_0^1 x^{s-1} (1-x)^{t-1} dx = \frac{B(s, t)}{B(s, t)} = 1.$$

No caso particular $s = t = 1$, a densidade vale 1 em $(0, 1)$ e 0 fora desse intervalo. Os valores nos extremos são irrelevantes, e obtemos a distribuição uniforme em $[0, 1]$, o que concorda com (20) tomando $a = 0$ e $b = 1$.

Distribuição qui-quadrado.

Dizemos que X tem *distribuição qui-quadrado com n graus de liberdade* ($n = 1, 2, 3, \dots$), e escrevemos $X \sim \chi_n^2$, quando

$$f(x) = \begin{cases} \frac{1}{2\Gamma(\frac{n}{2})} \left(\frac{x}{2}\right)^{\frac{n}{2}-1} e^{-\frac{x}{2}}, & \text{se } x > 0, \\ 0, & \text{se } x \leq 0. \end{cases} \quad (29)$$

Comparando (29) com (25), vemos que esta é precisamente a distribuição gama com parâmetros $w = \frac{n}{2}$ e $\lambda = \frac{1}{2}$. Com efeito, tomando esses valores em (25),

$$\frac{1}{\Gamma(\frac{n}{2})} \left(\frac{1}{2}\right)^{\frac{n}{2}} x^{\frac{n}{2}-1} e^{-\frac{x}{2}} = \frac{1}{2\Gamma(\frac{n}{2})} \left(\frac{x}{2}\right)^{\frac{n}{2}-1} e^{-\frac{x}{2}},$$

pois $(1/2)^{n/2} = \frac{1}{2}(1/2)^{n/2-1}$. Logo, a normalização já foi verificada no caso gama, e listamos a distribuição separadamente apenas porque ela aparece com muita frequência em estatística.

A tabela abaixo reúne as densidades discutidas acima. A coluna final registra a região de positividade, isto é, o conjunto em que f é estritamente positiva. Ela não deve ser confundida com o suporte topológico, que também contém pontos de fronteira.

Distribuição	Parâmetros	Densidade $f(x)$	Região de positividade
Uniforme	$a < b$	$\frac{1}{b-a}$	$a < x < b$
Exponencial	$\lambda > 0$	$\lambda e^{-\lambda x}$	$x > 0$
Normal	$\mu \in \mathbb{R}, \sigma > 0$	$\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	$x \in \mathbb{R}$
Cauchy	nenhum	$\frac{1}{\pi(1+x^2)}$	$x \in \mathbb{R}$
Gama	$w > 0, \lambda > 0$	$\frac{1}{\Gamma(w)} \lambda^w x^{w-1} e^{-\lambda x}$	$x > 0$
Beta	$s > 0, t > 0$	$\frac{1}{B(s, t)} x^{s-1} (1-x)^{t-1}$	$0 < x < 1$
Qui-quadrado	$n \geq 1$	$\frac{1}{2\Gamma(\frac{n}{2})} \left(\frac{x}{2}\right)^{\frac{n}{2}-1} e^{-\frac{x}{2}}$	$x > 0$

Tabela 1: As densidades usuais, com seus parâmetros e regiões de positividade. Cada constante de normalização foi escolhida para que a integral da densidade sobre $\mathbb{R}$ seja igual a 1.

6.4. Observações sobre normalização

A lista apresentada nesta seção é um compêndio de algumas das densidades mais comuns, e não esperamos que ela, sozinha, seja inspiradora. É difícil motivar adequadamente cada uma dessas densidades neste momento, mas vamos precisar retomá-las mais adiante, quando as encontrarmos em ação.

Nem sempre é trivial verificar que as funções da lista são realmente densidades. A condição de não negatividade não oferece dificuldade; o cuidado está em conferir que a integral vale 1. Para a densidade normal, por exemplo, precisamos da integral definida padrão

$$\int_{-\infty}^{\infty} e^{-x^2} dx = \sqrt{\pi}.$$

Um esboço da prova dessa identidade, por meio de coordenadas polares, está no [Exercício 14](#).

Os fatores constantes que aparecem nas densidades usuais foram escolhidos apenas para que as funções resultantes tenham integral 1. Considere, por exemplo, a função

$$g(x) = \frac{1}{1+x^2} \quad \text{para } x \in \mathbb{R}.$$

Como

$$\int_{-\infty}^{\infty} g(x) dx = \pi,$$

g não é uma densidade. No entanto, a função normalizada

$$f(x) = \frac{1}{\pi} g(x)$$

é uma densidade, a qual corresponde à distribuição de Cauchy discutida acima.

6.5. A relação beta–gama

Resta uma relação entre as funções gama e beta que simplifica o cálculo com a densidade beta e que usaremos mais adiante. Ela expressa $B(s, t)$ em termos de Γ .

Proposição 20. Para quaisquer $s > 0$ e $t > 0$, vale

$$B(s, t) = \frac{\Gamma(s)\Gamma(t)}{\Gamma(s+t)}.$$

Demonstração. Partimos do produto das duas integrais que definem $\Gamma(s)$ e $\Gamma(t)$. Como os integrandos são não negativos, podemos escrever o produto como uma integral dupla sobre o quadrante $(0, \infty)^2$, sem qualquer preocupação com convergência:

$$\Gamma(s)\Gamma(t) = \int_0^\infty \int_0^\infty e^{-(u+v)} u^{s-1} v^{t-1} du dv.$$

Fazemos agora a mudança de variáveis

$$u = r \cos^2 \theta, \quad v = r \sin^2 \theta,$$

com $r > 0$ e $\theta \in (0, \pi/2)$. Essa aplicação é uma bijeção de $(0, \infty) \times (0, \pi/2)$ sobre $(0, \infty)^2$: dado (u, v) no quadrante, basta tomar $r = u + v$ e $\theta = \arccos \sqrt{u/(u+v)}$. A mudança é

sugerida pela identidade $\cos^2 \theta + \sin^2 \theta = 1$: ela transforma a soma $u + v$ na variável radial r , de modo que o fator $e^{-(u+v)}$ passa a depender apenas de r . O determinante jacobiano é

$$J = \det \begin{pmatrix} \cos^2 \theta & -2r \sin \theta \cos \theta \\ \sin^2 \theta & 2r \sin \theta \cos \theta \end{pmatrix} = 2r \sin \theta \cos \theta,$$

que é positivo no domínio considerado, logo $|J| = J$. Além disso, $u + v = r$ e

$$u^{s-1} v^{t-1} = r^{s+t-2} \cos^{2(s-1)} \theta \sin^{2(t-1)} \theta.$$

Substituindo na integral dupla, obtemos

$$\begin{aligned} \Gamma(s)\Gamma(t) &= \int_0^{\pi/2} \int_0^\infty e^{-r} r^{s+t-2} \cos^{2(s-1)} \theta \sin^{2(t-1)} \theta 2r \sin \theta \cos \theta dr d\theta \\ &= \left(\int_0^\infty e^{-r} r^{s+t-1} dr \right) \left(2 \int_0^{\pi/2} \cos^{2s-1} \theta \sin^{2t-1} \theta d\theta \right). \end{aligned}$$

Como o integrando é não negativo, o teorema de Tonelli justifica a separação das variáveis: o domínio é um produto e o integrando é um produto de um fator que depende só de r por outro que depende só de θ . A integral em r é exatamente a definição de $\Gamma(s+t)$.

Resta identificar a integral em θ com $B(s, t)$. Para isso, pomos $x = \cos^2 \theta$. Então $dx = -2 \cos \theta \sin \theta d\theta$ e, quando θ vai de 0 a $\pi/2$, x vai de 1 a 0. Escrevendo

$$\cos^{2s-1} \theta = x^{s-1} \cos \theta, \quad \sin^{2t-1} \theta = (1-x)^{t-1} \sin \theta,$$

segue que

$$\begin{aligned} 2 \int_0^{\pi/2} \cos^{2s-1} \theta \sin^{2t-1} \theta d\theta &= 2 \int_1^0 x^{s-1} (1-x)^{t-1} \cos \theta \sin \theta \frac{-dx}{2 \cos \theta \sin \theta} \\ &= \int_0^1 x^{s-1} (1-x)^{t-1} dx, \end{aligned}$$

que é $B(s, t)$ por (28). Juntando os dois fatores,

$$\Gamma(s)\Gamma(t) = \Gamma(s+t) B(s, t),$$

e, como $\Gamma(s+t) > 0$, dividindo por esse valor, concluímos que

$$B(s, t) = \frac{\Gamma(s)\Gamma(t)}{\Gamma(s+t)},$$

como queríamos demonstrar. ■

A **Proposição 20** mostra que a constante de normalização da densidade beta também pode ser escrita em termos da função gama: $B(s, t) = \Gamma(s)\Gamma(t)/\Gamma(s+t)$. Essas distribuições serão retomadas adiante, quando aparecerem em situações concretas.

7. Exercícios propostos

Os exercícios a seguir retomam os conceitos e exemplos desenvolvidos ao longo destas notas: funções de distribuição, densidades, as distribuições usuais e a função de Cantor. Nos exercícios abaixo, X denota sempre uma variável aleatória em um espaço de probabilidade fixado.

Medidas e leis de probabilidade

1. Sejam $(\Omega, \mathcal{F}, \mathbb{P})$ um espaço de probabilidade e X uma variável aleatória definida sobre este espaço. Considere o espaço mensurável $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Mostre que a lei de X , definida por

$$\mu_X(A) = \mathbb{P}(X \in A), \quad A \in \mathcal{B}(\mathbb{R}),$$

é uma medida de probabilidade no sentido dos axiomas de Kolmogorov.

Funções de distribuição

2. Seja X uma variável aleatória que assume valores inteiros e satisfaz $\mathbb{P}(X = k) = p_k$ para $k = \dots, -1, 0, 1, \dots$. Mostre que a função de distribuição de X satisfaz

$$F_X(b) - F_X(a) = p_{a+1} + p_{a+2} + \dots + p_b$$

para todos os inteiros a, b com $a < b$.

3. Seja X uma variável aleatória e seja c um número real tal que $\mathbb{P}(X = c) > 0$. Mostre que a função de distribuição F_X é descontínua no ponto c . A recíproca é verdadeira? *Sugestão:* use a **Observação 7**.

4. Expresse a função de distribuição de $Y = \max\{0, X\}$ em termos da função de distribuição F_X de X .

5. Dizemos que o número real m é uma *mediana* da variável aleatória X se

$$\mathbb{P}(X < m) \leq \frac{1}{2} \leq \mathbb{P}(X \leq m).$$

Mostre que toda variável aleatória possui pelo menos uma mediana. *Sugestão:* considere $m = \inf\{t \in \mathbb{R} : F_X(t) \geq 1/2\}$.

6. Seja

$$F(x) = c \int_{-\infty}^x e^{-|u|} du \quad \text{para } x \in \mathbb{R}.$$

Para qual valor de c a função F é uma função de distribuição?

Exemplos de funções de distribuição

7. Mostre que, se F_1 e F_2 são funções de distribuição, então a função

$$F(x) = \alpha F_1(x) + (1 - \alpha) F_2(x)$$

também é uma função de distribuição, para qualquer α satisfazendo $0 \leq \alpha \leq 1$.

Variáveis aleatórias absolutamente contínuas

8. Uma variável aleatória X tem função densidade de probabilidade

$$f(x) = \begin{cases} 2x & \text{se } 0 < x < 1, \\ 0 & \text{caso contrário.} \end{cases}$$

Determine a função de distribuição de X .

9. Se X tem função densidade de probabilidade

$$f(x) = \frac{1}{2}e^{-|x|} \quad \text{para } x \in \mathbb{R},$$

determine a função de distribuição de X . Esta distribuição é chamada de distribuição *exponencial bilateral* (ou *dupla*).

10. Se X tem função de distribuição

$$F(x) = \begin{cases} \frac{1}{2(1+x^2)} & \text{para } -\infty < x \leq 0, \\ \frac{1+2x^2}{2(1+x^2)} & \text{para } 0 < x < \infty, \end{cases},$$

mostre que X é absolutamente contínua e determine a sua função densidade de probabilidade.

11. Determine a função de distribuição da chamada densidade de “valor extremo”

$$f(x) = \exp(-x - e^{-x}) \quad \text{para } x \in \mathbb{R}.$$

Densidades usuais

12. Mostre que a distribuição gama com parâmetros $w > 0$ e $\lambda > 0$, (25), coincide com a distribuição exponencial de parâmetro λ , (21), se, e somente se, $w = 1$.

13. Mostre que a função gama $\Gamma(w)$ satisfaz

$$\Gamma(w) = (w-1)\Gamma(w-1)$$

para $w > 1$, e deduza que

$$\Gamma(n) = (n-1)!$$

para $n = 1, 2, 3, \dots$

14. Seja

$$I = \int_{-\infty}^{\infty} e^{-x^2} dx.$$

Passando a coordenadas polares, mostre que

$$I^2 = \iint_{\mathbb{R}^2} e^{-x^2-y^2} dx dy = \int_0^{2\pi} \int_0^{\infty} e^{-r^2} r dr d\theta,$$

e deduza que $I = \sqrt{\pi}$.

15. Mostre que a função de distribuição associada à densidade

$$f(x) = \begin{cases} \frac{1}{\pi\sqrt{x(1-x)}} & \text{se } 0 < x < 1, \\ 0 & \text{caso contrário,} \end{cases}$$

é da forma

$$F(x) = \begin{cases} 0, & \text{se } x \leq 0, \\ c \arcsen \sqrt{x}, & \text{se } 0 < x < 1, \\ 1, & \text{se } x \geq 1, \end{cases}$$

e determine a constante c .

A função e a distribuição de Cantor

16. Considere a construção do conjunto ternário de Cantor. Começamos com $K_0 = [0, 1]$ e, em cada etapa, retiramos o terço médio de cada intervalo que permanece. O conjunto de Cantor é o conjunto dos pontos que nunca são retirados:

$$\mathbb{K} = \bigcap_{n=0}^{\infty} K_n.$$

Os primeiros passos estão representados abaixo; os segmentos coloridos são os intervalos que permanecem em cada etapa.




Figura 10: *As etapas da construção do Conjunto de Cantor.*

Responda às perguntas seguintes, usando apenas propriedades elementares da medida de Lebesgue.

- Escreva explicitamente K_1 e K_2 . Quantos intervalos permanecem em K_0 , K_1 , K_2 e K_3 ? Qual é o comprimento de cada intervalo em cada uma dessas etapas?
- Mostre, por indução, que K_n é a união de 2^n intervalos fechados, cada um deles com comprimento 3^{-n} .
- Para $n \geq 1$, denote por $R_n \equiv K_{n-1} \setminus K_n$ a união dos intervalos abertos retirados na n -ésima etapa; os extremos desses intervalos permanecem em K_n . Mostre que R_n é a união de 2^{n-1} intervalos abertos, cada um com comprimento 3^{-n} , e conclua que

$$\lambda(R_n) = 2^{n-1} 3^{-n} = \frac{1}{3} \left(\frac{2}{3}\right)^{n-1}.$$

- Mostre que os conjuntos R_n são dois a dois disjuntos e que

$$[0, 1] \setminus \mathbb{K} = \bigcup_{n=1}^{\infty} R_n.$$

Use a σ -aditividade da medida e a fórmula da série geométrica para calcular a medida do complemento:

$$\lambda([0, 1] \setminus \mathbb{K}) = \sum_{n=1}^{\infty} \lambda(R_n) = \frac{1}{3} \sum_{n=0}^{\infty} \left(\frac{2}{3}\right)^n = 1.$$

- Finalmente, levando em conta que os extremos dos intervalos retirados não são removidos, decomponha $[0, 1]$ como a união disjunta de $\mathbb{K}$ e seu complemento. Sabendo que $\lambda([0, 1]) = 1$, conclua que $\lambda(\mathbb{K}) = 0$.

*** 17 Construção formal da função de Cantor.** Considere o conjunto

$$V \equiv \{f \in C([0, 1], \mathbb{R}) : f(0) = 0, f(1) = 1, 0 \leq f(x) \leq 1 \text{ para todo } x \in [0, 1]\}$$

munido da distância induzida pela norma do supremo,

$$\|f\|_\infty \equiv \sup\{|f(x)| : x \in [0, 1]\}.$$

Para $f \in V$, defina $Tf : [0, 1] \rightarrow \mathbb{R}$ por

$$Tf(x) = \begin{cases} \frac{1}{2}f(3x), & \text{se } 0 \leq x \leq \frac{1}{3}, \\ \frac{1}{2}, & \text{se } \frac{1}{3} \leq x \leq \frac{2}{3}, \\ \frac{1}{2} + \frac{1}{2}f(3x - 2), & \text{se } \frac{2}{3} \leq x \leq 1. \end{cases}$$

Recorde que $C([0, 1], \mathbb{R})$, munido da norma do supremo, é um espaço métrico completo. A função identidade pertence a V , de modo que V não é vazio.

- a) Mostre que V é um subconjunto fechado de $C([0, 1], \mathbb{R})$ e, portanto, é completo. Em seguida, mostre que Tf está bem definida nos pontos $x = 1/3$ e $x = 2/3$, é contínua, satisfaz $(Tf)(0) = 0$, $(Tf)(1) = 1$ e $0 \leq (Tf)(x) \leq 1$. Conclua que $T : V \rightarrow V$ está bem definida.
- b) Mostre que $T : V \rightarrow V$ é uma contração, isto é, para quaisquer $f, g \in V$,

$$\|Tf - Tg\|_\infty \leq \frac{1}{2}\|f - g\|_\infty.$$

- c) Use o Teorema do Ponto Fixo para Contrações de Banach para concluir que existe uma função contínua $\mathcal{C} : [0, 1] \rightarrow [0, 1]$ tal que $\mathcal{C} \in V$ e $T\mathcal{C} = \mathcal{C}$.
- d) Seja $f_0 : [0, 1] \rightarrow [0, 1]$ a função identidade, $f_0(x) = x$. Mostre que $f_0 \in V$ e que a sequência definida por $f_n \equiv Tf_{n-1}$ está bem definida para todo $n \in \mathbb{N}$, verificando por indução que $f_n \in V$.
- e) O Teorema do Ponto Fixo para Contrações de Banach afirma, em particular, que $\mathcal{C} = \lim_{n \rightarrow \infty} T^n h$ para todo $h \in V$. Mostre primeiro que T preserva a monotonicidade: se $f \in V$ é monótona não decrescente, então Tf também é monótona não decrescente. Use esse fato e o item anterior para mostrar, por indução, que cada f_n é monótona não decrescente. Finalmente, use a convergência uniforme de f_n para concluir que $\mathcal{C}$ é contínua e monótona não decrescente.
- f) Mostre que $\mathcal{C}$ é constante em cada intervalo aberto removido na construção de $\mathbb{K}$ e que esses intervalos são precisamente os trechos horizontais do gráfico de $\mathcal{C}$.

Referências

- [1] P. Billingsley. *Probability and measure*. Wiley Series in Probability and Statistics. John Wiley & Sons, Inc., Hoboken, NJ, anniversary edition, 2012. With a foreword by Steve Lalley and a brief biography of Billingsley by Steve Koppes.
- [2] Geoffrey Grimmett and Dominic Welsh. *Probability—an introduction*. Oxford University Press, Oxford, second edition, 2014.