

Funções de Distribuição

L. Cioletti

Setembro de 2026

Resumo

Estas notas dão continuidade ao estudo das variáveis aleatórias iniciado nas notas sobre variáveis aleatórias discretas. Vamos apresentar a noção geral de variável aleatória, de sua função de distribuição e suas propriedades elementares. Apresentamos um resultado que caracteriza as funções de distribuição e conseqüentemente permite provar a existência de variáveis aleatórias com determinadas propriedades. Em seguida, definimos as variáveis aleatórias absolutamente contínuas e as chamadas funções de densidade de probabilidade. Mostramos em detalhes como é possível construir um exemplo de uma variável aleatória contínua que não é absolutamente contínua. Para finalizar fornecemos diversos exemplos clássicos de variáveis aleatórias absolutamente contínuas. O texto segue de perto as Seções 5.1–5.4 do Capítulo 5 de Grimmett e Welsh [2] e conta com uma lista de exercícios ao final.

1. Funções de Distribuição

Até aqui trabalhamos com variáveis aleatórias discretas. Esse modelo é natural quando observamos uma contagem, como o número de chamadas recebidas por uma central ou o número de peças defeituosas em um lote: os valores possíveis são isolados e podem ser listados, ao menos em princípio. Muitas quantidades de interesse, porém, não são contagens. O tempo de espera por um ônibus, a vida útil de um componente, a temperatura de uma sala ou a posição de uma partícula são grandezas medidas numa escala contínua e, no modelo matemático, podem assumir qualquer valor real em determinado intervalo. Arredondar essas quantidades para obter um modelo discreto pode ser útil em uma aplicação; entretanto, preservar a possibilidade de variação contínua dessas grandezas nos permite utilizar as poderosas ferramentas do cálculo diferencial e integral. Por isso, exigir que elas assumam desde o início somente um conjunto enumerável de valores nos privaria justamente dos recursos que desejamos empregar.

Precisamos, portanto, conservar a ideia básica de que cada resultado ω determina uma observação numérica $X(\omega)$, sem impor que o conjunto de valores possíveis de X seja enumerável. Ao mesmo tempo, as perguntas que fazemos sobre essa observação precisam corresponder a eventos cuja probabilidade esteja definida. Entre essas perguntas, as mais simples e flexíveis são as do tipo: qual é a probabilidade de a observação não exceder um nível x ? Isso nos leva a considerar os eventos da forma $\{\omega \in \Omega : X(\omega) \leq x\}$, para cada $x \in \mathbb{R}$, e motiva a definição mais ampla de variável aleatória a seguir.

Definição 1 (Variável aleatória). Seja $(\Omega, \mathcal{F}, \mathbb{P})$ um espaço de probabilidade. Dizemos que X é uma *variável aleatória* se X é uma função $X : \Omega \rightarrow \mathbb{R}$ tal que

$$\{\omega \in \Omega : X(\omega) \leq x\} \in \mathcal{F} \quad \text{para todo } x \in \mathbb{R}. \quad (1)$$




Figura 1: O evento $\{X \leq x\} \equiv \{\omega \in \Omega : X(\omega) \leq x\}$

Quando (1) vale, dizemos que X é $\mathcal{F}$ -mensurável. Daqui em diante, vamos denotar o evento $\{\omega \in \Omega : X(\omega) \leq x\}$ pela expressão mais simples $\{X \leq x\}$. Como mencionado anteriormente, esta notação não exige que se fixe um espaço de probabilidade particular, o que confere à teoria maior flexibilidade.

Exigimos que as variáveis aleatórias satisfaçam (1) pela mesma razão pela qual exigimos uma condição análoga na definição de variável aleatória discreta. Estamos interessados nos valores assumidos por X e nas probabilidades associadas a esses valores. Uma maneira conveniente de estudá-los é fixar $x \in \mathbb{R}$ e calcular a probabilidade de que X assumira um valor no intervalo $(-\infty, x]$. Essa probabilidade só está definida quando a pré-imagem $X^{-1}((-\infty, x]) = \{X \leq x\}$ pertence ao espaço de eventos $\mathcal{F}$, e é por isso que postulamos que essa condição seja válida para todo $x \in \mathbb{R}$.

Observe que toda variável aleatória discreta é também uma variável aleatória no sentido amplo da **Definição 1**. De fato, se X é discreta, então

$$\{X \leq x\} = \bigcup_{y \in \text{Im } X : y \leq x} \{X = y\},$$

que é uma união enumerável de eventos em $\mathcal{F}$ e, portanto, também pertence a $\mathcal{F}$.

Enquanto as variáveis aleatórias discretas eram estudadas por meio de suas funções de probabilidade, as variáveis aleatórias no sentido mais amplo são estudadas por meio das chamadas *funções de distribuição*, definidas a seguir.

Definição 2 (Função de distribuição). Seja X uma variável aleatória em $(\Omega, \mathcal{F}, \mathbb{P})$. A *função de distribuição* de X é a função $F_X : \mathbb{R} \rightarrow [0, 1]$ definida por

$$F_X(x) = \mathbb{P}(X \leq x). \quad (2)$$

A função de distribuição de X também é chamada, em alguns textos, de função de distribuição acumulada de X .

Exemplo 3 (Função de distribuição de uma variável aleatória discreta). Suponha que X seja uma variável aleatória discreta que assume valores inteiros não negativos, com função de probabilidade

$$\mathbb{P}(X = k) = p_k \quad \text{para } k = 0, 1, 2, \dots$$

Para $x \in \mathbb{R}$ com $x \geq 0$, o evento $X \leq x$ ocorre se, e somente se, X assume um dos valores $0, 1, \dots, \lfloor x \rfloor$, em que $\lfloor x \rfloor$ denota o maior inteiro menor ou igual a x ; se $x < 0$ o evento é impossível, pois X não assume valores negativos. Logo

$$F_X(x) = \begin{cases} 0, & \text{se } x < 0, \\ \sum_{k=0}^{\lfloor x \rfloor} p_k, & \text{se } x \geq 0. \end{cases}$$

Um esboço dessa função, no caso em que X assume valores no conjunto $\{0, 1, 2, 3, 4, 5\}$, é apresentado na [Figura 2](#).




Figura 2: A função de distribuição de uma variável aleatória que assume valores no conjunto $\{0, 1, 2, 3, 4, 5\}$. O salto, por exemplo, em $x = 2$ é exatamente o valor de p_2 .

A função de distribuição F_X possui várias propriedades gerais e elementares, reunidas a seguir.

Proposição 4 (Propriedades da função de distribuição). Seja X uma variável aleatória em $(\Omega, \mathcal{F}, \mathbb{P})$ e seja F_X a sua função de distribuição. Então:

- (i) F_X é monótona não decrescente, isto é,

$$F_X(x) \leq F_X(y) \quad \text{se } x \leq y; \quad (3)$$

- (ii) os limites de F_X em $-\infty$ e em $+\infty$ existem e são dados por

$$\lim_{x \rightarrow -\infty} F_X(x) = 0 \quad \text{e} \quad \lim_{x \rightarrow +\infty} F_X(x) = 1; \quad (4)$$

(iii) F_X é contínua à direita, isto é,

$$F_X(x + \epsilon) \rightarrow F_X(x) \quad \text{quando } \epsilon \downarrow 0, \quad (5)$$

onde o limite é tomado com ϵ tendendo a 0 apenas por valores positivos.

A monotonicidade expressa em (3) decorre da inclusão

$$\{X \leq x\} \subseteq \{X \leq y\}$$

sempre que $x \leq y$, pois se X assume um valor que não excede x , então esse valor também não excede y .

As demais propriedades elementares de F_X dizem respeito ao seu comportamento quando x se aproxima de $-\infty$ ou de $+\infty$. Intuitivamente é claro que

$$F_X(x) \rightarrow 0 \quad \text{quando } x \rightarrow -\infty, \quad \text{e} \quad F_X(x) \rightarrow 1 \quad \text{quando } x \rightarrow +\infty,$$

uma vez que, no primeiro caso, à medida que x diminui, o evento de que X não exceda x torna-se cada vez menos provável; no segundo caso, à medida que x cresce, esse evento torna-se cada vez mais provável. No plano intuitivo, essas conclusões correspondem à ideia de que um limiar muito à esquerda captura probabilidade quase nula, enquanto um limiar muito à direita captura quase toda a probabilidade. A verificação formal de (4), entretanto, depende da continuidade da medida de probabilidade $\mathbb{P}$.

Para tornar essa verificação formal, considere os eventos $A_n = \{X \leq -n\}$. Eles formam uma sequência decrescente e $\bigcap_{n \geq 1} A_n = \emptyset$, pois nenhum número real é menor ou igual a $-n$ para todo n . Pela continuidade por cima da probabilidade,

$$F_X(-n) = \mathbb{P}(A_n) \rightarrow 0.$$

Analogamente, se $B_n = \{X \leq n\}$, então B_n cresce para Ω e, pela continuidade por baixo,

$$F_X(n) = \mathbb{P}(B_n) \rightarrow 1.$$

Como F_X é monótona, esses dois limites ao longo dos inteiros implicam os limites em (4).

A continuidade da medida de probabilidade também é usada para estabelecer a continuidade à direita em (5). De fato, se $(x_n)_{n \geq 1}$ é uma sequência decrescente com $x_n \rightarrow x$, então os eventos $\{X \leq x_n\}$ decrescem para $\{X \leq x\}$ e a continuidade por cima de $\mathbb{P}$ dá

$$F_X(x_n) = \mathbb{P}(X \leq x_n) \rightarrow \mathbb{P}(X \leq x) = F_X(x).$$

Observando a Figura 2, vemos que uma função de distribuição não precisa ser contínua à esquerda: em cada ponto k com $p_k > 0$ há um salto de tamanho p_k .

Observação 5. Para toda função de distribuição F_X e todo $x \in \mathbb{R}$, o limite à esquerda $F_X(x^-) := \lim_{\epsilon \downarrow 0} F_X(x - \epsilon)$ existe e

$$\mathbb{P}(X = x) = F_X(x) - F_X(x^-).$$

Em particular, F_X é descontínua em x se, e somente se, $\mathbb{P}(X = x) > 0$.

Teorema 6 (Caracterização das funções de distribuição). Seja $F : \mathbb{R} \rightarrow \mathbb{R}$ uma função que satisfaz as três condições a seguir:

(i) F é uma função monótona não decrescente, isto é,

$$F(x) \leq F(y) \quad \text{sempre que } x \leq y;$$

(ii) os limites de F em $-\infty$ e em $+\infty$ existem e são dados por

$$\lim_{x \rightarrow -\infty} F(x) = 0 \quad \text{e} \quad \lim_{x \rightarrow +\infty} F(x) = 1;$$

(iii) F é contínua à direita, isto é, para todo $x \in \mathbb{R}$,

$$F(x + \epsilon) \rightarrow F(x) \quad \text{quando } \epsilon \downarrow 0,$$

onde o limite é tomado com ϵ tendendo a 0 apenas por valores positivos.

Então F toma valores no intervalo $[0, 1]$ e existem um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$ e uma variável aleatória $X : \Omega \rightarrow \mathbb{R}$ nesse espaço tais que

$$\mathbb{P}(X \leq x) = F(x) \quad \text{para todo } x \in \mathbb{R},$$

isto é, F é a função de distribuição de X .

A **Proposição 4** fornece a recíproca do **Teorema 6**: a função de distribuição de qualquer variável aleatória satisfaz as três condições do enunciado. Logo essas três condições são necessárias e suficientes para que uma função seja a função de distribuição de alguma variável aleatória. Na prática, dada uma função F que se deseja exibir como função de distribuição, basta verificar as três condições do enunciado e invocar o **Teorema 6**; não é preciso construir explicitamente o espaço de probabilidade nem a variável aleatória. A prova do teorema é omitida nestas notas e pode ser encontrada na referência [1].

Antes de apresentarmos exemplos de funções de distribuição, vejamos uma última propriedade. A probabilidade $F_X(x) = \mathbb{P}(X \leq x)$ é a probabilidade de que X assumo um valor no intervalo ilimitado $(-\infty, x]$. Para encontrarmos a probabilidade de que X assumo um valor em um intervalo limitado $(a, b]$, procedemos da seguinte maneira. Para $a < b$,

$$\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a). \quad (6)$$

De fato,

$$\begin{aligned} \mathbb{P}(a < X \leq b) &= \mathbb{P}(\{X \leq b\} \setminus \{X \leq a\}) \\ &= \mathbb{P}(X \leq b) - \mathbb{P}(X \leq a), \end{aligned}$$

pois o evento $\{X \leq a\}$ está contido no evento $\{X \leq b\}$.

2. Exemplos de Funções de Distribuição

Na seção anterior introduzimos a definição de função de distribuição e reunimos as suas propriedades gerais na **Proposição 4**. O **Exemplo 3** foi o nosso primeiro exemplo: a função de distribuição de uma variável aleatória discreta, constante por partes e com saltos exatamente nos pontos com probabilidade positiva. Vale a pena observar as características gerais daquela função: ela é não decrescente, contínua à direita, tende a 0 quando $x \rightarrow -\infty$ e tende a 1 quando $x \rightarrow +\infty$. Existem, contudo, funções de distribuição que contrastam de modo acentuado com aquele exemplo, por serem contínuas em toda a reta. O próximo exemplo é de uma dessas funções.

Exemplo 7 (Distribuição uniforme). Sejam $a, b \in \mathbb{R}$ com $a < b$. Considere a função

$$F(x) = \begin{cases} 0, & \text{se } x < a, \\ \frac{x-a}{b-a}, & \text{se } a \leq x \leq b, \\ 1, & \text{se } x > b, \end{cases} \quad (7)$$

cujo gráfico está esboçado na **Figura 3**. Ela satisfaz as três condições do **Teorema 6** e, portanto, é uma função de distribuição. Dizemos que uma variável aleatória com essa função de distribuição tem *distribuição uniforme* no intervalo (a, b) ; alguns autores preferem dizer que a distribuição é uniforme no intervalo $[a, b]$.

O fato de chamarmos a distribuição de uniforme em (a, b) ou em $[a, b]$ não altera a lei, pois os extremos têm probabilidade zero: $F(a) = 0$ e $F(b) = 1$, e a função é contínua nesses pontos. Assim, para X com essa função de distribuição, $\mathbb{P}(X = a) = \mathbb{P}(X = b) = 0$ e, por (6), $\mathbb{P}(a < X \leq b) = F(b) - F(a) = 1$.




Figura 3: Função de distribuição uniforme no intervalo (a, b) . A função vale 0 à esquerda de a , cresce linearmente de 0 a 1 em $[a, b]$ e vale 1 à direita de b .

Exemplo 8 (Distribuição exponencial). Seja $\lambda > 0$ e defina F por

$$F(x) = \begin{cases} 0, & \text{se } x \leq 0, \\ 1 - e^{-\lambda x}, & \text{se } x > 0, \end{cases} \quad (8)$$

cujo gráfico esboçamos na **Figura 4**. De fato, F é não decrescente, tem limites 0 e 1 quando $x \rightarrow -\infty$ e $x \rightarrow +\infty$, e é contínua à direita em 0, pois $F(0) = 0 = \lim_{x \downarrow 0} (1 - e^{-\lambda x})$; logo F é uma função de distribuição. Dizemos que uma variável aleatória com essa distribuição tem *distribuição exponencial* com parâmetro λ .

As duas funções de distribuição acima são muito importantes na teoria da probabilidade. As duas são, além disso, casos particulares de uma família maior. Pelo **Teorema 6**, qualquer função F não decrescente e contínua à direita que satisfaz

$$\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow +\infty} F(x) = 1$$

é uma função de distribuição.




Figura 4: Função de distribuição exponencial com parâmetro λ . A função é identicamente nula em $(-\infty, 0]$ e tende assintoticamente a 1 quando $x \rightarrow +\infty$.

3. Variáveis Aleatórias Absolutamente Contínuas

As variáveis aleatórias aparecem em muitas formas, mas há duas classes que desempenham um papel central no curso:

- I. as variáveis aleatórias discretas;
- II. as variáveis aleatórias absolutamente contínuas.

Uma variável aleatória discreta assume apenas uma quantidade enumerável de valores e sua função de distribuição tem, em geral, o aspecto de uma função em degraus, como ilustra a [Figura 2](#). No extremo oposto encontram-se variáveis aleatórias cuja função de distribuição é bastante suave, como nos casos uniforme e exponencial discutidos na [Seção 2](#) (veja as [Figuras 3 e 4](#)). É essa segunda classe que passamos a estudar e cujos elementos chamaremos de *variáveis aleatórias absolutamente contínuas*.

Definição 9 (Variável aleatória absolutamente contínua). Vamos dizer que uma variável aleatória X é *absolutamente contínua* se existir uma função não negativa e Lebesgue-mensurável¹ $f_X : \mathbb{R} \rightarrow [0, +\infty)$ tal que sua função de distribuição F_X possa ser escrita na forma

$$F_X(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f_X(u) du \quad \text{para todo } x \in \mathbb{R}. \quad (9)$$

Nesse caso, dizemos que X tem *função densidade de probabilidade* f_X (ou simplesmente *densidade* f_X).

Quando uma variável aleatória é absolutamente contínua, a identidade (9) diz que a probabilidade do evento $\{X \leq x\}$ ocorrer é a área sob o gráfico de f_X à esquerda de x . Assim, F_X acumula a densidade desde $-\infty$ até x , e é por isso que F_X também é chamada de função de distribuição acumulada.

Observação 10. Uma boa parte dos textos de Teoria de Probabilidade, principalmente os mais avançados, chama as variáveis aleatórias descritas na [Definição 9](#) de *absolutamente contínuas*, reservando a expressão “variável aleatória contínua” para uma classe mais ampla

¹“Lebesgue-Mensurável” é uma condição técnica que garante que a integral esteja bem definida; ela não terá papel relevante no curso.

de variáveis aleatórias. Entretanto, o leitor encontrará em algumas referências como, por exemplo, [2] variáveis aleatórias como as da **Definição 9** sendo chamadas simplesmente de variáveis aleatórias “contínuas”.

Nesta nota, o símbolo λ terá dois usos distintos: nesta observação e no estudo do conjunto de Cantor ele denota a medida de Lebesgue; nas distribuições exponencial e gama, denota um parâmetro. O contexto deixará claro qual uso está em jogo.

Exemplo 11. Se X tem distribuição exponencial de parâmetro $\lambda > 0$, então, como vimos no **Exemplo 8**,

$$F_X(x) = \begin{cases} 0, & \text{se } x \leq 0, \\ 1 - e^{-\lambda x}, & \text{se } x > 0. \end{cases}$$

Uma maneira de investigar se X possui uma função de densidade f_X seria simplesmente tentar calcular formalmente a derivada de F_X , isto é, F'_X e tentar mostrar que esta derivada pode ser usada para construir uma função de densidade para X . Neste caso em particular, temos para todo $x > 0$,

$$\frac{d}{dx}(1 - e^{-\lambda x}) = \lambda e^{-\lambda x},$$

e para $x < 0$ a derivada é 0. Desta forma, a função

$$f_X(x) = \begin{cases} 0, & \text{se } x \leq 0, \\ \lambda e^{-\lambda x}, & \text{se } x > 0. \end{cases}$$

se apresenta como uma candidata natural a ser uma densidade para X . Aqui, neste caso mais simples, uma aplicação direta do Teorema Fundamental do Cálculo confirma nossas suspeitas.

Observe que, no ponto $x = 0$, a derivada de F_X não existe. Mesmo assim, podemos atribuir a f_X qualquer valor nesse ponto sem alterar sua integral. A noção de medida de Lebesgue torna precisa essa ideia e explica a expressão “quase todo ponto”.

Observação 12 (Medida de Lebesgue e propriedades em quase todo ponto). A medida de Lebesgue λ formaliza a ideia de comprimento na reta. Ela é definida nos conjuntos Lebesgue-mensuráveis e satisfaz

$$\lambda((a, b]) = b - a, \quad a < b.$$

Diremos que uma propriedade $P(x)$ vale em quase todo ponto, com respeito à medida de Lebesgue, quando o conjunto excepcional

$$N_P \equiv \{x \in \mathbb{R} : P(x) \text{ não vale}\}$$

é mensurável e tem medida nula, isto é, $\lambda(N_P) = 0$.

Para o que faremos neste curso, basta lembrar que um ponto tem medida nula, $\lambda(\{x\}) = 0$, e que, pela σ -aditividade, todo conjunto enumerável $E \subseteq \mathbb{R}$ também tem medida nula. A recíproca é falsa: o conjunto ternário de Cantor $\mathbb{K} \subseteq [0, 1]$, que construiremos mais adiante, é não enumerável e ainda assim satisfaz $\lambda(\mathbb{K}) = 0$.

Em particular, uma função $f : \mathbb{R} \rightarrow \mathbb{R}$ é derivável em quase todo ponto quando

$$N_f \equiv \{x \in \mathbb{R} : f'(x) \text{ não existe}\}$$

tem medida de Lebesgue nula. Assim, a derivada pode deixar de existir em um conjunto excepcional, mas esse conjunto é irrelevante para integrais.

É importante não confundir essa afirmação com a ideia de que a derivada determina sempre a função. Sem hipóteses adicionais, $f'(x) = 0$ em quase todo ponto não implica que f seja constante. A função de Cantor, apresentada a seguir, é contínua e não decrescente, não é constante e, apesar disso, tem derivada nula em quase todo ponto.

Para uma variável aleatória absolutamente contínua no sentido da [Definição 9](#), um resultado fundamental, que usaremos sem demonstrar, afirma que F_X é derivável em quase todo ponto. Além disso, sua derivada, completada no conjunto excepcional pela regra abaixo, é uma versão de uma densidade de X :

$$f_X(x) = \begin{cases} \frac{d}{dx}F_X(x), & \text{se essa derivada existe em } x, \\ 0, & \text{caso contrário.} \end{cases} \quad (10)$$

O valor 0 no caso em que a derivada não existe é apenas uma escolha conveniente. Como o conjunto excepcional tem medida de Lebesgue nula, essa escolha não altera integrais nem probabilidades calculadas a partir da densidade.

Nos exemplos abordados nestas notas, o procedimento descrito acima irá fornecer a função de densidade. Entretanto, vale ressaltar que a questão da existência da densidade de uma variável aleatória X , no caso geral, pode ser muito delicada. A discussão fica mais complicada na direção oposta: existem funções de distribuição contínuas, mas que não são obtidas integrando uma densidade. O exemplo clássico é a função de Cantor, que é constante em cada intervalo removido na construção de $\mathbb{K}$. Como $\mathbb{K}$ tem medida nula, sua derivada é nula em quase todo ponto. Assim, a função definida em (10) é nula quase todo ponto e sua integral é zero, embora a função de Cantor varie de 0 a 1 em $[0, 1]$; portanto, ela não pode ser recuperada por essa fórmula. Variáveis com esse comportamento são ditas variáveis aleatórias singulares contínuas. Não desenvolveremos sua teoria geral; usaremos a função de Cantor apenas como exemplo e a construiremos a seguir por meio de um processo iterativo simples.

Começamos com a função identidade

$$f_0(x) = x, \quad 0 \leq x \leq 1.$$

Se f_n já foi construída, obtemos a próxima aproximação aplicando a mesma regra em cada um dos três terços do intervalo:

$$f_{n+1}(x) = Tf_n(x) = \begin{cases} \frac{1}{2}f_n(3x), & \text{se } 0 \leq x \leq \frac{1}{3}, \\ \frac{1}{2}, & \text{se } \frac{1}{3} \leq x \leq \frac{2}{3}, \\ \frac{1}{2} + \frac{1}{2}f_n(3x-2), & \text{se } \frac{2}{3} \leq x \leq 1. \end{cases}$$

O que essa fórmula faz com o gráfico? Ela copia o gráfico de f_n para o terço esquerdo, comprimindo-o verticalmente até a altura $1/2$; mantém o terço central na altura $1/2$; e copia novamente o gráfico para o terço direito, agora entre as alturas $1/2$ e 1 . Assim, em cada etapa aparece um novo trecho horizontal no terço médio de cada intervalo que ainda não havia sido achatado.




Figura 5: As primeiras seis aproximações da função de Cantor. O quadro f_0 é o inicial, e cada quadro seguinte é obtido do anterior pela regra descrita no texto; em cada etapa, o gráfico é achatado no terço médio de cada intervalo restante.

A sequência de funções definida recursivamente acima converge uniformemente para uma função contínua e monótona não decrescente $\mathcal{C}$, chamada função de Cantor:

$$\mathcal{C}(x) = \lim_{n \rightarrow \infty} f_n(x).$$

A ideia por trás da convergência uniforme é que a regra de construção reduz pela metade as diferenças entre duas funções que recebem a mesma transformação. A verificação formal dessa estimativa fica reunida na lista de exercícios avançados ao final das notas.

Em particular, os intervalos abertos que recebem trechos horizontais na construção são precisamente os intervalos removidos na construção do conjunto ternário de Cantor. Por isso, no limite, $\mathcal{C}$ é constante em cada um desses intervalos, embora continue sendo uma função contínua no intervalo todo. Como o complemento de $\mathbb{K}$ em $[0, 1]$ é a união desses intervalos e $\lambda(\mathbb{K}) = 0$, segue que $\mathcal{C}'(x) = 0$ em quase todo ponto de $[0, 1]$. A identificação precisa desses intervalos fica reunida na lista de exercícios avançados no final das notas.

Exemplo 13 (A distribuição de Cantor: uma distribuição sem densidade). Até aqui, a função de Cantor apareceu como um objeto construído por meio de aproximações sucessivas de funções. Vamos agora olhar para ela de outro ponto de vista: como a função de distribuição de uma variável aleatória.

Essa interpretação responde a uma pergunta que pode parecer estranha à primeira vista. O conjunto de Cantor $\mathbb{K}$ tem medida de Lebesgue nula, mas a função $\mathcal{C}$ cresce de 0 a 1 em $[0, 1]$. Será possível construir uma variável aleatória que esteja sempre em $\mathbb{K}$ e, ainda assim, tenha uma função de distribuição contínua? A resposta é sim. Mais do que isso: essa variável aleatória não terá uma função de densidade de Lebesgue. O exemplo é importante porque mostra concretamente que “distribuição contínua” e “distribuição absolutamente contínua” são noções diferentes.

A ideia do experimento aleatório.

Recordemos a construção de $\mathbb{K}$. Começamos com o intervalo $[0, 1]$. Na primeira etapa, retiramos o terço médio e permanecem os dois intervalos laterais. Na etapa seguinte, repetimos o mesmo procedimento em cada um deles, e assim por diante. Os primeiros passos estão representados na figura; os segmentos coloridos são os intervalos que permanecem em cada etapa.




Figura 6: As primeiras etapas da construção do conjunto de Cantor. Os segmentos coloridos representam os intervalos que permanecem.

Agora fazemos uma escolha aleatória em cada etapa: escolhemos o intervalo da esquerda ou o intervalo da direita, sempre com probabilidade $1/2$. As escolhas feitas em etapas diferentes são independentes. Portanto, uma sequência prescrita de n escolhas, por exemplo

esquerda, direita, esquerda, ..., direita,

tem probabilidade $(1/2)^n = 2^{-n}$. Essa é a única propriedade da independência que usaremos explicitamente.

Para registrar as escolhas, definimos variáveis aleatórias B_n por

$$B_n = \begin{cases} 0, & \text{se na etapa } n \text{ escolhemos o intervalo da esquerda,} \\ 1, & \text{se na etapa } n \text{ escolhemos o intervalo da direita.} \end{cases}$$

Assim, cada B_n assume os valores 0 e 1 com a mesma probabilidade:

$$\mathbb{P}(B_n = 0) = \mathbb{P}(B_n = 1) = \frac{1}{2}.$$

Formalmente, podemos pensar que um resultado do experimento é uma sequência infinita $(B_1, B_2, B_3, \dots)$ de zeros e uns. Não será necessário construir em detalhes o espaço de probabilidade dessas sequências. Para todos os cálculos abaixo, basta saber que os eventos que fixam os primeiros n valores de $B_1, \dots, B_n$ têm probabilidade 2^{-n} .

O ponto escolhido e sua expansão ternária.

Depois de n etapas, as escolhas $B_1, \dots, B_n$ determinam um único intervalo fechado de comprimento 3^{-n} . Seu extremo esquerdo é

$$X_n = \frac{2B_1}{3} + \frac{2B_2}{3^2} + \dots + \frac{2B_n}{3^n} = \sum_{k=1}^n \frac{2B_k}{3^k}.$$

Por exemplo, se as duas primeiras escolhas forem esquerda e direita, então $B_1 = 0$, $B_2 = 1$, e o intervalo escolhido na segunda etapa é

$$\left[\frac{2}{9}, \frac{1}{3}\right].$$

O caminho dessas duas escolhas pode ser visualizado na figura abaixo. Em cada linha estão representados os intervalos que permanecem depois da etapa correspondente. O intervalo escolhido fica destacado em teal, e as setas indicam o caminho esquerda–direita determinado por $B_1 = 0$ e $B_2 = 1$.




Figura 7: O caminho correspondente às escolhas $B_1 = 0$ (esquerda) e $B_2 = 1$ (direita).

De fato, nesse caso $X_2 = 2/9$ e o comprimento do intervalo é $3^{-2} = 1/9$. Em geral, o intervalo determinado pelas primeiras n escolhas é

$$I_n = \left[X_n, X_n + \frac{1}{3^n} \right].$$

Os intervalos I_n são encaixados: cada um está contido no anterior. Além disso, seus comprimentos tendem a zero. Isso sugere que eles determinam um único ponto. Podemos vê-lo diretamente pela série. Como $0 \leq B_k \leq 1$, temos

$$\begin{aligned} 0 \leq X - X_n &\equiv \sum_{k=n+1}^{\infty} \frac{2B_k}{3^k} \\ &\leq \sum_{k=n+1}^{\infty} \frac{2}{3^k} = \frac{1}{3^n}. \end{aligned}$$

Consequentemente, a série

$$X \equiv \sum_{k=1}^{\infty} \frac{2B_k}{3^k} \tag{11}$$

converge e seu valor pertence a todos os intervalos I_n . Em particular,

$$X \in \bigcap_{n=1}^{\infty} K_n = \mathbb{K} \quad \text{com probabilidade 1.}$$

Na verdade, nesta construção a inclusão vale para todo resultado do experimento, e não apenas quase certamente. Portanto, também podemos escrever $\mathbb{P}(X \in \mathbb{K}) = 1$; a expressão “com probabilidade 1” registra essa conclusão no vocabulário usual da teoria da probabilidade.

A expressão (11) também explica o nome “expansão ternária”. Uma expansão ternária comum permite os algarismos 0, 1 e 2. Aqui, porém, todos os algarismos são iguais a 0 ou a 2, pois o algarismo na posição k é $2B_k$. Essa é precisamente a característica dos pontos do conjunto ternário de Cantor.

Como acontece com expansões em qualquer base, alguns números possuem duas representações ternárias diferentes. Isso ocorre, por exemplo, com os extremos dos intervalos retirados. Essa ambiguidade não afeta a construção: para os pontos de $\mathbb{K}$, escolhemos a representação que utiliza somente os algarismos 0 e 2, isto é, a representação produzida pelas escolhas $B_1, B_2, \dots$.

A condição de continuidade

Se $x \notin \mathbb{K}$, então $\mathbb{P}(X = x) = 0$, pois X sempre pertence a $\mathbb{K}$. Consideremos agora $x \in \mathbb{K}$. Em cada etapa n , o ponto x pertence a um único componente de K_n , isto é, a um dos intervalos fechados que formam K_n ; esses componentes são disjuntos. Para que ocorra $X = x$, as primeiras n escolhas precisam ser exatamente as escolhas que conduzem a esse intervalo. Como essa sequência de escolhas tem probabilidade 2^{-n} , obtemos

$$\mathbb{P}(X = x) \leq 2^{-n} \quad \text{para todo } n \in \mathbb{N}.$$

Como $2^{-n} \rightarrow 0$, segue que

$$\mathbb{P}(X = x) = 0 \quad \text{para todo } x \in \mathbb{R}. \tag{12}$$

Portanto, a distribuição de X não concentra probabilidade positiva em nenhum ponto. Pela relação entre saltos da função de distribuição e massas atômicas, discutida na [Observação 5](#), a função de distribuição de X é contínua.

A função de distribuição e sua recursão.

Seja

$$F_X(x) = \mathbb{P}(X \leq x)$$

a função de distribuição de X . Para identificar essa função, vamos separar a primeira escolha das escolhas seguintes. Defina a variável aleatória formada pelas escolhas a partir da segunda etapa por

$$Y \equiv \sum_{k=1}^{\infty} \frac{2B_{k+1}}{3^k}.$$

A sequência $B_2, B_3, \dots$ tem, em conjunto, as mesmas probabilidades que a sequência $B_1, B_2, \dots$. Além disso, ela é independente de B_1 . Logo, Y tem a mesma distribuição que X e é independente de B_1 . Separando na série (11) o primeiro termo, encontramos

$$X = \begin{cases} \frac{1}{3}Y, & \text{se } B_1 = 0, \\ \frac{2}{3} + \frac{1}{3}Y, & \text{se } B_1 = 1. \end{cases}$$

Essa identidade é a tradução probabilística da primeira etapa da construção do conjunto de Cantor: com probabilidade $1/2$ o ponto está no terço esquerdo e com probabilidade $1/2$ está no terço direito.

Vamos calcular F_X separando esses dois casos.

- i) Se $0 \leq x \leq 1/3$, o evento $\{X \leq x\}$ só pode ocorrer quando $B_1 = 0$. Nesse caso, $X = Y/3$, e portanto

$$\begin{aligned} F_X(x) &= \mathbb{P}(B_1 = 0, Y \leq 3x) \\ &= \mathbb{P}(B_1 = 0) \mathbb{P}(Y \leq 3x) \\ &= \frac{1}{2} F_X(3x). \end{aligned}$$

- ii) Se $1/3 \leq x \leq 2/3$, todos os pontos escolhidos no terço esquerdo já satisfazem $X \leq x$, enquanto nenhum ponto do terço direito satisfaz essa desigualdade, exceto possivelmente o extremo $2/3$. Esse único ponto tem probabilidade zero por (12). Assim,

$$F_X(x) = \mathbb{P}(B_1 = 0) = \frac{1}{2}.$$

- iii) Se $2/3 \leq x \leq 1$, todos os pontos do terço esquerdo são menores ou iguais a x . No terço direito, a desigualdade $2/3 + Y/3 \leq x$ equivale a $Y \leq 3x - 2$. Logo,

$$\begin{aligned} F_X(x) &= \mathbb{P}(B_1 = 0) + \mathbb{P}(B_1 = 1, Y \leq 3x - 2) \\ &= \frac{1}{2} + \frac{1}{2} F_X(3x - 2). \end{aligned}$$

Reunindo os três casos, vemos que F_X satisfaz a equação

$$F_X(x) = \begin{cases} \frac{1}{2}F_X(3x), & \text{se } 0 \leq x \leq \frac{1}{3}, \\ \frac{1}{2}, & \text{se } \frac{1}{3} \leq x \leq \frac{2}{3}, \\ \frac{1}{2} + \frac{1}{2}F_X(3x-2), & \text{se } \frac{2}{3} \leq x \leq 1. \end{cases} \quad (13)$$

Compare essa relação com a regra que definiu as aproximações f_n . Como f_n converge uniformemente para $\mathcal{C}$, podemos passar ao limite em cada uma das três fórmulas que definem f_{n+1} e concluímos que $\mathcal{C}$ satisfaz exatamente a mesma relação (13), com F_X substituída por $\mathcal{C}$.

Para deixar claro por que essa identificação é legítima, vamos verificar que só existe uma função contínua que satisfaz (13). Suponha que $G, H : [0, 1] \rightarrow \mathbb{R}$ sejam duas funções contínuas que satisfazem a relação (13), com F_X substituída por G e por H , respectivamente. Seja

$$D = \sup_{0 \leq x \leq 1} |G(x) - H(x)|.$$

Como G e H são contínuas em um intervalo compacto, esse supremo é finito. Além disso, a própria relação recursiva, avaliada em 0 e em 1, impõe $G(0) = H(0) = 0$ e $G(1) = H(1) = 1$.

Observe que nos terços da esquerda e da direita, a relação recursiva multiplica a diferença por 1/2; no terço central, as duas funções têm o mesmo valor 1/2. Portanto, para todo $x \in [0, 1]$,

$$|G(x) - H(x)| \leq \frac{1}{2}D.$$

Tomando o supremo em x , obtemos $D \leq D/2$. Como $D \geq 0$, isso só é possível quando $D = 0$. Logo $G = H$. Em particular,

$$F_X(x) = \mathcal{C}(x), \quad 0 \leq x \leq 1. \quad (14)$$

Fora de $[0, 1]$, temos $F_X(x) = 0$ para $x < 0$ e $F_X(x) = 1$ para $x \geq 1$, pois $X \in \mathbb{K} \subseteq [0, 1]$. A relação recursiva também mostra que $\mathcal{C}(1) = 1$. Portanto, se estendermos $\mathcal{C}$ por 0 à esquerda de 0 e por 1 à direita de 1, essa extensão será exatamente a função de distribuição da variável aleatória X construída em (11).

Por que essa distribuição não tem densidade?

Já sabemos que $X \in \mathbb{K}$ com probabilidade 1, ao passo que $\lambda(\mathbb{K}) = 0$. Como $\mathbb{K}$ é uma interseção de conjuntos fechados, ele é Lebesgue-mensurável. Se X tivesse uma densidade f_X com respeito à medida de Lebesgue, a probabilidade de um conjunto Lebesgue-nulo seria dada pela integral de f_X nesse conjunto. Em particular, teríamos

$$1 = \mathbb{P}(X \in \mathbb{K}) = \int_{\mathbb{K}} f_X(x) dx = 0,$$

o que é impossível. A última igualdade decorre da propriedade básica de que a integral de uma função não negativa sobre um conjunto de medida de Lebesgue nula é zero.

Portanto, X tem uma função de distribuição contínua, mas não possui uma função de densidade de Lebesgue. Dizemos que sua distribuição é uma *distribuição singular contínua*: ela é contínua porque $\mathbb{P}(X = x) = 0$ para todo ponto x , mas é singular porque toda

a sua probabilidade está concentrada no conjunto $\mathbb{K}$, que tem medida de Lebesgue nula. Assim, para utilizar uma densidade e as ferramentas do cálculo integral, é necessário assumir explicitamente que a distribuição é absolutamente contínua.

Observação 14. Se f e g são densidades de uma mesma variável aleatória X , então $f = g$ em quase todo ponto. Em particular, o valor atribuído a f_X em um ponto isolado é irrelevante.

As densidades desempenham para as variáveis absolutamente contínuas um papel análogo ao das funções de probabilidade para as variáveis discretas, e não é surpreendente que as propriedades gerais de umas e de outras sejam muito parecidas.

Propriedade. Se X é uma variável aleatória absolutamente contínua com densidade f_X , então

$$f_X(x) \geq 0 \quad \text{para todo } x \in \mathbb{R}, \quad \int_{-\infty}^{\infty} f_X(x) dx = 1.$$

Essas duas propriedades são análogas às condições $p_X(x) \geq 0$ e $\sum_x p_X(x) = 1$ no caso discreto. A analogia, no entanto, pode ser perigosa, pois $f_X(x)$ *não* é uma probabilidade e pode muito bem assumir valores maiores que 1. No exemplo exponencial, se $\lambda > 1$, então f_X assume valores maiores que 1 na vizinhança de $x = 0$, ainda que $\mathbb{P}(X = 0) = 0$.

O que $f_X(x)$ mede é a densidade de probabilidade nas vizinhanças de x . Se, além disso, f_X é contínua em x e δx é um número real positivo e suficientemente pequeno, então, grosso modo, a probabilidade de X estar “próximo” do valor x satisfaz

$$\begin{aligned} \mathbb{P}(x < X \leq x + \delta x) &= F_X(x + \delta x) - F_X(x) \quad \text{por (6)} \\ &= \int_x^{x+\delta x} f_X(u) du \quad \text{por (9)} \\ &\approx f_X(x) \delta x \quad \text{para } \delta x \text{ pequeno.} \end{aligned} \tag{15}$$

A última aproximação usa a continuidade da função de densidade f_X no ponto x : em um intervalo curto, a área sob f_X é aproximadamente a área de um retângulo de base δx e altura $f_X(x)$.

Portanto, a analogia correta não é entre a densidade $f_X(x)$ e a função de probabilidade $p_X(x)$, mas sim entre $f_X(x) \delta x$ e $p_X(x)$. Essa leitura fica clara ao compararmos a normalização da densidade com a da função de probabilidade: os valores de uma função de probabilidade são substituídos por $f_X(x) \delta x$, e a soma, que no caso discreto percorre apenas os valores positivos (necessariamente em quantidade enumerável), é substituída pela integral. Uma diferença marcante entre os dois casos é que, no caso absolutamente contínuo, pontos isolados têm probabilidade nula; veremos isso no teorema sobre as propriedades da densidade mais adiante.

Como de costume, se $I \in \mathcal{B}(\mathbb{R})$ e $f : \mathbb{R} \rightarrow \mathbb{R}$ é uma função integrável, vamos usar a notação

$$\int_I f(x) dx \equiv \int_{-\infty}^{+\infty} \mathbf{1}_I(x) f(x) dx.$$

O resultado que permite trocar limite e integral, e que será usado logo abaixo, é o Teorema da Convergência Dominada de Lebesgue.

Teorema 15 (Teorema da Convergência Dominada de Lebesgue). Seja $(f_n)_{n \in \mathbb{N}}$ uma sequência de funções Lebesgue-mensuráveis $f_n : \mathbb{R} \rightarrow \mathbb{R}$. Suponha que exista uma função Lebesgue-mensurável $g : \mathbb{R} \rightarrow [0, +\infty)$ tal que

$$|f_n(x)| \leq g(x) \quad \text{para todo } n \in \mathbb{N} \text{ e para quase todo } x \in \mathbb{R}, \quad \text{e} \quad \int_{-\infty}^{\infty} g(x) dx < +\infty.$$

Se, além disso, $f_n(x) \rightarrow f(x)$ para quase todo $x \in \mathbb{R}$, para alguma função Lebesgue-mensurável f , então f é integrável e

$$\lim_{n \rightarrow \infty} \int_{-\infty}^{\infty} f_n(x) dx = \int_{-\infty}^{\infty} f(x) dx.$$

Corolário 16. Para cada $n \in \mathbb{N}$ seja $I_n \in \mathcal{B}(\mathbb{R})$ um boreliano. Suponha que existe algum $I \in \mathcal{B}(\mathbb{R})$ tal que $\mathbb{1}_{I_n}(x) \rightarrow \mathbb{1}_I(x)$ quase todo $x \in \mathbb{R}$. Seja $f : \mathbb{R} \rightarrow \mathbb{R}$ uma função Lebesgue-mensurável tal que

$$\int_{-\infty}^{\infty} |f(x)| dx < +\infty$$

Então

$$\lim_{n \rightarrow \infty} \int_{I_n} f(x) dx = \int_I f(x) dx.$$

Teorema 17 (Propriedades da densidade). Se X é absolutamente contínua com densidade f_X , então

$$\mathbb{P}(X = x) = 0 \quad \text{para todo } x \in \mathbb{R}, \quad (16)$$

e

$$\mathbb{P}(a \leq X \leq b) = \int_a^b f_X(u) du \quad \text{para } a, b \in \mathbb{R} \text{ com } a \leq b. \quad (17)$$

Demonstração. Vamos provar primeiro (16). Para isso, observamos que os eventos

$$E_n \equiv \left\{ x - \frac{1}{n} < X \leq x \right\}$$

decrecem para $\{X = x\}$, quando $n \rightarrow \infty$, de modo que, pela continuidade da probabilidade,

$$\mathbb{P}(X = x) = \lim_{n \rightarrow \infty} \mathbb{P}\left(x - \frac{1}{n} < X \leq x\right).$$

Destas observações e das identidades (6) e (9), concluímos que

$$\begin{aligned} \mathbb{P}(X = x) &= \lim_{n \rightarrow \infty} \left[F_X(x) - F_X\left(x - \frac{1}{n}\right) \right] \\ &= \lim_{n \rightarrow \infty} \int_{x - \frac{1}{n}}^x f_X(u) du \\ &= 0, \end{aligned}$$

A função f_X é Lebesgue-mensurável e integrável, pois é não negativa. Além disso, satisfaz $\int_{-\infty}^{\infty} f_X(u) du = 1$. Assim, a última igualdade segue do **Corolário 16**, que é uma aplicação do Teorema da Convergência Dominada de Lebesgue, com

$$I_n = \left[x - \frac{1}{n}, x \right] \quad \text{e} \quad I = \{x\}.$$

Para a segunda parte, seja $a \leq b$. Como $\{X = a\}$ tem probabilidade 0 pela primeira parte, os eventos $\{a \leq X \leq b\}$ e $\{a < X \leq b\}$ têm a mesma probabilidade. Logo, por (6) e (9),

$$\begin{aligned}\mathbb{P}(a \leq X \leq b) &= \mathbb{P}(a < X \leq b) \\ &= F_X(b) - F_X(a) \\ &= \int_{-\infty}^b f_X(u) du - \int_{-\infty}^a f_X(u) du \\ &= \int_a^b f_X(u) du.\end{aligned}$$

■

O teorema acima mostra que, em uma variável aleatória absolutamente contínua, a probabilidade de qualquer valor isolado é nula. Consequentemente, para variáveis absolutamente contínuas, incluir ou excluir os extremos de um intervalo não altera sua probabilidade:

$$\mathbb{P}(a \leq X \leq b) = \mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X < b) = \mathbb{P}(a < X < b).$$

Isso contrasta com o caso discreto, em que um único ponto pode concentrar toda a probabilidade.

Recapitulando o que vimos até aqui: toda variável aleatória possui uma função de distribuição, conforme a **Definição 2**. No caso discreto, essa informação é codificada por uma função de probabilidade p_X ; no caso absolutamente contínuo, por uma densidade f_X . Essas duas classes não esgotam, contudo, todas as possibilidades: existem variáveis aleatórias que não são nem discretas nem absolutamente contínuas, ou seja, cuja função de distribuição não é uma escada nem pode ser escrita como a integral de uma densidade. Tais casos, embora existam, ficam fora do escopo destas notas.

4. Algumas Funções de Densidade Usuais

Nas seções anteriores vimos que uma variável aleatória absolutamente contínua X fica descrita por sua função de distribuição F_X e que, quando F_X é derivável, sua derivada f_X é a função densidade de probabilidade associada, conforme a **Definição 9**. Cabe agora perguntar o contrário: dada uma função f , quando ela é a densidade de alguma variável aleatória? A resposta é simples e vale a pena enunciá-la antes de listarmos os exemplos que ocorrem com mais frequência.

Se $f : \mathbb{R} \rightarrow [0, \infty)$ é Lebesgue-mensurável e satisfaz

$$f(x) \geq 0 \quad \text{para todo } x \in \mathbb{R} \tag{18}$$

e

$$\int_{-\infty}^{\infty} f(x) dx = 1, \tag{19}$$

então f é a função densidade de probabilidade de alguma variável aleatória. Para confirmar isso, basta definir

$$F(x) = \int_{-\infty}^x f(u) du$$

Note que (19) garante $f \in L^1(\mathbb{R})$, de modo que a integral que define F é finita para todo x ; a monotonicidade segue de (18), e a continuidade à direita e os limites em $\pm\infty$ seguem da continuidade da integral. Verifica-se assim que F satisfaz as propriedades reunidas na **Proposição 4**. Pelo **Teorema 6**, existe uma variável aleatória X cuja função de distribuição é F . Como $F(x) = \int_{-\infty}^x f(u) du$, concluímos que f é uma densidade de X .

Mostramos abaixo as densidades mais usadas, cada uma acompanhada de seus parâmetros e de sua região de positividade. Em todos os casos a não negatividade (18) é imediata, e a verificação da normalização (19) é o ponto que merece atenção. Resumimos a lista em forma de tabela no final desta seção (**Tabela 1**).

Distribuição uniforme.

Dizemos que X tem *distribuição uniforme* no intervalo (a, b) , com $a < b$, quando sua densidade é

$$f(x) = \begin{cases} \frac{1}{b-a}, & \text{se } a < x < b, \\ 0, & \text{caso contrário.} \end{cases} \quad (20)$$

Aqui a integral é elementar:

$$\int_{-\infty}^{\infty} f(x) dx = \int_a^b \frac{1}{b-a} dx = \frac{b-a}{b-a} = 1.$$

A densidade é constante sobre o intervalo: não há posição privilegiada dentro de (a, b) , o que justifica o nome.

Distribuição exponencial.

Dizemos que X tem *distribuição exponencial* de parâmetro $\lambda > 0$ quando

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{se } x > 0, \\ 0, & \text{se } x \leq 0. \end{cases} \quad (21)$$

Novamente a normalização sai de uma primitiva imediata, pois $\frac{d}{dx}(-e^{-\lambda x}) = \lambda e^{-\lambda x}$ e $e^{-\lambda x} \rightarrow 0$ quando $x \rightarrow +\infty$:

$$\int_{-\infty}^{\infty} f(x) dx = \int_0^{\infty} \lambda e^{-\lambda x} dx = -e^{-\lambda x} \Big|_0^{\infty} = 1.$$

Distribuição normal (gaussiana).

Dizemos que X tem *distribuição normal* (ou *gaussiana*) de parâmetros $\mu \in \mathbb{R}$ e $\sigma > 0$, e escrevemos $X \sim N(\mu, \sigma^2)$, quando X possui função de densidade dada por

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right), \quad x \in \mathbb{R}. \quad (22)$$

Como veremos mais à frente, o parâmetro μ será o valor esperado de X e este parâmetro desloca o centro da curva ao longo do eixo x , enquanto o parâmetro σ (que será o desvio padrão de X ou a raiz quadrada de sua variância) controla sua dispersão. Dizemos que X tem distribuição normal padrão se $\mu = 0$ e $\sigma = 1$ e usaremos a notação $X \sim N(0, 1)$.




Figura 8: Densidade da normal padrão $N(0, 1)$.

Para observar simultaneamente os efeitos dos dois parâmetros, considere agora o exemplo $\mu = 2$ e $\sigma = \frac{3}{2}$. O centro da curva está em μ , enquanto a comparação com a normal padrão mostra a mudança de posição do máximo e o aumento da abertura causado por $\sigma > 1$. As marcações $\mu - \sigma$, μ e $\mu + \sigma$ destacam no eixo x a posição da média e os pontos situados a um desvio-padrão dela.




Figura 9: Densidade normal $N(\mu, \sigma^2)$ no caso $\mu = 2$ e $\sigma = \frac{3}{2}$ (curva contínua), comparada com a densidade da normal padrão $N(0, 1)$ (curva cinza pontilhada).

Para verificar que a integral vale 1, usamos a integral gaussiana

$$\int_{-\infty}^{\infty} e^{-x^2} dx = \sqrt{\pi}. \quad (23)$$

cuja demonstração é esboçada no **Exercício 13**. Com efeito, a mudança de variáveis $x = \mu + \sigma\sqrt{2}z$ dá $dx = \sigma\sqrt{2}dz$ e

$$\int_{-\infty}^{\infty} e^{-\frac{1}{2\sigma^2}(x-\mu)^2} dx = \sigma\sqrt{2} \int_{-\infty}^{\infty} e^{-z^2} dz = \sigma\sqrt{2\pi},$$

onde usamos (23). Dividindo pelo fator $\sqrt{2\pi\sigma^2}$ obtemos exatamente 1. A constante de normalização foi escolhida justamente para isso.

Distribuição de Cauchy.

Dizemos que X tem *distribuição de Cauchy* quando

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad x \in \mathbb{R}. \quad (24)$$

A normalização segue da derivada da função arco-tangente, pois $\frac{d}{dx} \arctan x = \frac{1}{1+x^2}$ e $\lim_{x \rightarrow \pm\infty} \arctan x = \pm \frac{\pi}{2}$:

$$\int_{-\infty}^{\infty} \frac{1}{\pi(1+x^2)} dx = \frac{1}{\pi} \arctan x \Big|_{-\infty}^{\infty} = \frac{1}{\pi} \left(\frac{\pi}{2} + \frac{\pi}{2} \right) = 1.$$

Distribuição gama.

Dizemos que X tem *distribuição gama* de parâmetros $w > 0$ e $\lambda > 0$ quando

$$f(x) = \begin{cases} \frac{1}{\Gamma(w)} \lambda^w x^{w-1} e^{-\lambda x}, & \text{se } x > 0, \\ 0, & \text{se } x \leq 0, \end{cases} \quad (25)$$

onde Γ é a *função gama*, definida por

$$\Gamma(w) = \int_0^{\infty} x^{w-1} e^{-x} dx. \quad (26)$$

A integral em (26) converge para todo $w > 0$: perto de 0, o integrando é comparável a x^{w-1} , cuja integral converge para $w > 0$, enquanto, no infinito, o fator e^{-x} garante a convergência. Para checar a normalização de (25), fazemos a mudança $y = \lambda x$, de modo que $dx = dy/\lambda$:

$$\int_{-\infty}^{\infty} f(x) dx = \frac{\lambda^w}{\Gamma(w)} \int_0^{\infty} x^{w-1} e^{-\lambda x} dx = \frac{1}{\Gamma(w)} \int_0^{\infty} y^{w-1} e^{-y} dy = \frac{\Gamma(w)}{\Gamma(w)} = 1.$$

Ou seja, a distribuição gama integra 1 *por definição* de Γ .

Observamos ainda que, para inteiro positivo $w = n$, a função gama recupera o fatorial. De fato, integrando por partes, $\Gamma(w) = (w-1)\Gamma(w-1)$ para $w > 1$, e como $\Gamma(1) = 1$ segue que

$$\Gamma(n) = (n-1)! \quad \text{para } n = 1, 2, 3, \dots$$

Este é o conteúdo do [Exercício 12](#), ao qual remetemos o leitor para os detalhes da indução.

Distribuição beta.

Dizemos que X tem *distribuição beta* de parâmetros $s > 0$ e $t > 0$ quando

$$f(x) = \begin{cases} \frac{1}{B(s, t)} x^{s-1} (1-x)^{t-1}, & \text{se } 0 < x < 1, \\ 0, & \text{caso contrário,} \end{cases} \quad (27)$$

onde B é a *função beta*,

$$B(s, t) = \int_0^1 x^{s-1} (1-x)^{t-1} dx. \quad (28)$$

A integral em (28) converge para $s > 0$ e $t > 0$: perto de $x = 0$ o integrando é comparável a x^{s-1} e perto de $x = 1$ a $(1-x)^{t-1}$. Aqui a normalização é imediata: a constante $B(s, t)$ foi escolhida exatamente para que a integral de f em (27) seja

$$\frac{1}{B(s, t)} \int_0^1 x^{s-1} (1-x)^{t-1} dx = \frac{B(s, t)}{B(s, t)} = 1.$$

No caso particular $s = t = 1$, a densidade vale 1 em $(0, 1)$ e 0 fora desse intervalo. Os valores nos extremos são irrelevantes, e obtemos a distribuição uniforme em $[0, 1]$, o que concorda com (20) tomando $a = 0$ e $b = 1$.

Distribuição qui-quadrado.

Dizemos que X tem *distribuição qui-quadrado com n graus de liberdade* ($n = 1, 2, 3, \dots$), e escrevemos $X \sim \chi_n^2$, quando

$$f(x) = \begin{cases} \frac{1}{2\Gamma(\frac{n}{2})} \left(\frac{x}{2}\right)^{\frac{n}{2}-1} e^{-\frac{x}{2}}, & \text{se } x > 0, \\ 0, & \text{se } x \leq 0. \end{cases} \quad (29)$$

Comparando (29) com (25), vemos que esta é precisamente a distribuição gama com parâmetros $w = \frac{n}{2}$ e $\lambda = \frac{1}{2}$. Com efeito, tomando esses valores em (25),

$$\frac{1}{\Gamma(\frac{n}{2})} \left(\frac{1}{2}\right)^{\frac{n}{2}} x^{\frac{n}{2}-1} e^{-\frac{x}{2}} = \frac{1}{2\Gamma(\frac{n}{2})} \left(\frac{x}{2}\right)^{\frac{n}{2}-1} e^{-\frac{x}{2}},$$

pois $(1/2)^{n/2} = \frac{1}{2}(1/2)^{n/2-1}$. Logo a normalização já foi verificada no caso gama, e listamos a distribuição separadamente apenas porque ela aparece com muita frequência em estatística.

A tabela abaixo reúne as densidades discutidas acima. A coluna final registra a região de positividade, isto é, o conjunto em que f é estritamente positiva. Ela não deve ser confundida com o suporte topológico, que também contém pontos de fronteira.

Distribuição	Parâmetros	Densidade $f(x)$	Região de positividade
Uniforme	$a < b$	$\frac{1}{b-a}$	$a < x < b$
Exponencial	$\lambda > 0$	$\lambda e^{-\lambda x}$	$x > 0$
Normal	$\mu \in \mathbb{R}, \sigma > 0$	$\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	$x \in \mathbb{R}$
Cauchy	nenhum	$\frac{1}{\pi(1+x^2)}$	$x \in \mathbb{R}$
Gama	$w > 0, \lambda > 0$	$\frac{1}{\Gamma(w)} \lambda^w x^{w-1} e^{-\lambda x}$	$x > 0$
Beta	$s > 0, t > 0$	$\frac{1}{B(s,t)} x^{s-1} (1-x)^{t-1}$	$0 < x < 1$
Qui-quadrado	$n \geq 1$	$\frac{1}{2\Gamma(\frac{n}{2})} \left(\frac{x}{2}\right)^{\frac{n}{2}-1} e^{-\frac{x}{2}}$	$x > 0$

Tabela 1: As densidades usuais, com seus parâmetros e regiões de positividade. Cada constante de normalização foi escolhida para que a integral da densidade sobre $\mathbb{R}$ seja igual a 1.

A lista apresentada nesta seção é um compêndio de algumas das densidades mais comuns, e não esperamos que ela, sozinha, seja inspiradora. É difícil motivar adequadamente cada uma dessas densidades neste momento, mas vamos precisar retomá-las mais adiante, quando as encontrarmos em ação.

Nem sempre é trivial verificar que as funções da lista são realmente densidades. A condição de não negatividade não oferece dificuldade; o cuidado está em conferir que a

integral vale 1. Para a densidade normal, por exemplo, precisamos da integral definida padrão

$$\int_{-\infty}^{\infty} e^{-x^2} dx = \sqrt{\pi}.$$

Um esboço da prova dessa identidade, por meio de coordenadas polares, está no **Exercício 13**.

Os fatores constantes que aparecem nas densidades usuais foram escolhidos apenas para que as funções resultantes tenham integral 1. Considere, por exemplo, a função

$$g(x) = \frac{1}{1+x^2} \quad \text{para } x \in \mathbb{R}.$$

Como

$$\int_{-\infty}^{\infty} g(x) dx = \pi,$$

g não é uma densidade. No entanto, a função normalizada

$$f(x) = \frac{1}{\pi} g(x)$$

é uma densidade, a qual corresponde à distribuição de Cauchy discutida acima.

Resta uma relação entre as funções gama e beta que simplifica o cálculo com a densidade beta e que usaremos mais adiante. Ela expressa $B(s, t)$ em termos de Γ .

Proposição 18. Para quaisquer $s > 0$ e $t > 0$, vale

$$B(s, t) = \frac{\Gamma(s)\Gamma(t)}{\Gamma(s+t)}.$$

Demonstração. Partimos do produto das duas integrais que definem $\Gamma(s)$ e $\Gamma(t)$. Como os integrandos são não negativos, podemos escrever o produto como uma integral dupla sobre o quadrante $(0, \infty)^2$, sem qualquer preocupação com convergência:

$$\Gamma(s)\Gamma(t) = \int_0^\infty \int_0^\infty e^{-(u+v)} u^{s-1} v^{t-1} du dv.$$

Fazemos agora a mudança de variáveis

$$u = r \cos^2 \theta, \quad v = r \sin^2 \theta,$$

com $r > 0$ e $\theta \in (0, \pi/2)$. Essa aplicação é uma bijeção de $(0, \infty) \times (0, \pi/2)$ sobre $(0, \infty)^2$: dado (u, v) no quadrante, basta tomar $r = u + v$ e $\theta = \arccos \sqrt{u/(u+v)}$. A mudança é sugerida pela identidade $\cos^2 \theta + \sin^2 \theta = 1$: ela transforma a soma $u + v$ na variável radial r , de modo que o fator $e^{-(u+v)}$ passa a depender apenas de r . O determinante jacobiano é

$$J = \det \begin{pmatrix} \cos^2 \theta & -2r \sin \theta \cos \theta \\ \sin^2 \theta & 2r \sin \theta \cos \theta \end{pmatrix} = 2r \sin \theta \cos \theta,$$

que é positivo no domínio considerado, logo $|J| = J$. Além disso, $u + v = r$ e

$$u^{s-1} v^{t-1} = r^{s+t-2} \cos^{2(s-1)} \theta \sin^{2(t-1)} \theta.$$

Substituindo na integral dupla, obtemos

$$\begin{aligned}\Gamma(s)\Gamma(t) &= \int_0^{\pi/2} \int_0^\infty e^{-r} r^{s+t-2} \cos^{2(s-1)} \theta \sin^{2(t-1)} \theta 2r \sin \theta \cos \theta dr d\theta \\ &= \left(\int_0^\infty e^{-r} r^{s+t-1} dr \right) \left(2 \int_0^{\pi/2} \cos^{2s-1} \theta \sin^{2t-1} \theta d\theta \right),\end{aligned}$$

Como o integrando é não negativo, o teorema de Tonelli justifica a separação das variáveis: o domínio é um produto e o integrando é um produto de um fator que depende só de r por outro que depende só de θ . A integral em r é exatamente a definição de $\Gamma(s+t)$.

Resta identificar a integral em θ com $B(s, t)$. Para isso, pomos $x = \cos^2 \theta$. Então $dx = -2 \cos \theta \sin \theta d\theta$ e, quando θ vai de 0 a $\pi/2$, x vai de 1 a 0. Escrevendo

$$\cos^{2s-1} \theta = x^{s-1} \cos \theta, \quad \sin^{2t-1} \theta = (1-x)^{t-1} \sin \theta,$$

segue que

$$\begin{aligned}2 \int_0^{\pi/2} \cos^{2s-1} \theta \sin^{2t-1} \theta d\theta &= 2 \int_1^0 x^{s-1} (1-x)^{t-1} \cos \theta \sin \theta \frac{-dx}{2 \cos \theta \sin \theta} \\ &= \int_0^1 x^{s-1} (1-x)^{t-1} dx,\end{aligned}$$

que é $B(s, t)$ por (28). Juntando os dois fatores,

$$\Gamma(s)\Gamma(t) = \Gamma(s+t) B(s, t),$$

e como $\Gamma(s+t) > 0$, dividindo por esse valor chegamos a $B(s, t) = \frac{\Gamma(s)\Gamma(t)}{\Gamma(s+t)}$, como queríamos. ■

A **Proposição 18** mostra que a constante de normalização da densidade beta também pode ser escrita em termos da função gama: $B(s, t) = \Gamma(s)\Gamma(t)/\Gamma(s+t)$. Com isso encerramos a lista das densidades usuais, que retomaremos quando essas distribuições aparecerem em situações concretas.

5. Exercícios propostos

Os exercícios a seguir retomam os conceitos e exemplos desenvolvidos ao longo da nota: funções de distribuição, densidades e as distribuições usuais. Salvo indicação em contrário, X denota uma variável aleatória em um espaço de probabilidade fixado.

Funções de distribuição

1. Seja X uma variável aleatória que assume valores inteiros e satisfaz $\mathbb{P}(X = k) = p_k$ para $k = \dots, -1, 0, 1, \dots$. Mostre que a função de distribuição de X satisfaz

$$F_X(b) - F_X(a) = p_{a+1} + p_{a+2} + \dots + p_b$$

para todos os inteiros a, b com $a < b$.

2. Seja X uma variável aleatória e seja c um número real tal que $\mathbb{P}(X = c) > 0$. Mostre que a função de distribuição F_X é descontínua no ponto c . A recíproca é verdadeira? *Sugestão:* use a **Observação 5**.

3. Expresse a função de distribuição de $Y = \max\{0, X\}$ em termos da função de distribuição F_X de X .
4. Dizemos que o número real m é uma *mediana* da variável aleatória X se

$$\mathbb{P}(X < m) \leq \frac{1}{2} \leq \mathbb{P}(X \leq m).$$

Mostre que toda variável aleatória possui pelo menos uma mediana. *Sugestão:* considere $m = \inf\{t \in \mathbb{R} : F_X(t) \geq 1/2\}$.

Exemplos de funções de distribuição

5. Mostre que se F_1 e F_2 são funções de distribuição, então também é função de distribuição a função

$$F(x) = \alpha F_1(x) + (1 - \alpha) F_2(x)$$

para qualquer α satisfazendo $0 \leq \alpha \leq 1$.

6. Seja

$$F(x) = c \int_{-\infty}^x e^{-|u|} du \quad \text{para } x \in \mathbb{R}.$$

Para qual valor de c a função F é uma função de distribuição?

Variáveis aleatórias absolutamente contínuas

7. Uma variável aleatória X tem função densidade de probabilidade

$$f(x) = \begin{cases} 2x & \text{se } 0 < x < 1, \\ 0 & \text{caso contrário.} \end{cases}$$

Determine a função de distribuição de X .

8. Se X tem função densidade de probabilidade

$$f(x) = \frac{1}{2} e^{-|x|} \quad \text{para } x \in \mathbb{R},$$

determine a função de distribuição de X . Esta distribuição é chamada de distribuição *exponencial bilateral* (ou *dupla*).

9. Se X tem função de distribuição

$$F(x) = \begin{cases} \frac{1}{2(1+x^2)} & \text{para } -\infty < x \leq 0, \\ \frac{1+2x^2}{2(1+x^2)} & \text{para } 0 < x < \infty, \end{cases}$$

mostre que X é absolutamente contínua e determine a sua função densidade de probabilidade.

10. Determine a função de distribuição da chamada densidade de “valor extremo”

$$f(x) = \exp(-x - e^{-x}) \quad \text{para } x \in \mathbb{R}.$$

Densidades usuais

11. Mostre que a distribuição gama com parâmetros $w > 0$ e $\lambda > 0$, (25), coincide com a distribuição exponencial de parâmetro λ , (21), se, e somente se, $w = 1$.

12. Mostre que a função gama $\Gamma(w)$ satisfaz

$$\Gamma(w) = (w-1)\Gamma(w-1)$$

para $w > 1$, e deduza que

$$\Gamma(n) = (n-1)!$$

para $n = 1, 2, 3, \dots$

13. Seja

$$I = \int_{-\infty}^{\infty} e^{-x^2} dx.$$

Passando a coordenadas polares, mostre que

$$I^2 = \iint_{\mathbb{R}^2} e^{-x^2-y^2} dx dy = \int_0^{2\pi} \int_0^{\infty} e^{-r^2} r dr d\theta,$$

e deduza que $I = \sqrt{\pi}$.

14. Mostre que a função densidade

$$f(x) = \begin{cases} \frac{1}{\pi\sqrt{x(1-x)}} & \text{se } 0 < x < 1, \\ 0 & \text{caso contrário,} \end{cases}$$

tem função de distribuição da forma

$$F(x) = \begin{cases} 0, & \text{se } x \leq 0, \\ c \arcsen \sqrt{x}, & \text{se } 0 < x < 1, \\ 1, & \text{se } x \geq 1, \end{cases}$$

e determine a constante c .

15 A Medida de Lebesgue do Conjunto de Cantor. Considere a construção do conjunto ternário de Cantor. Começamos com $K_0 = [0, 1]$ e, em cada etapa, retiramos o terço médio de cada intervalo que permaneceu. O conjunto de Cantor é o conjunto dos pontos que nunca são retirados:

$$\mathbb{K} = \bigcap_{n=0}^{\infty} K_n.$$

Os primeiros passos estão representados abaixo; os segmentos coloridos são os intervalos que permanecem em cada etapa.




Figura 10: A cada etapa, cada intervalo restante dá origem a dois intervalos com um terço do comprimento anterior.

Responda às perguntas seguintes, usando apenas propriedades elementares da medida de Lebesgue.

- a) Escreva explicitamente K_1 e K_2 . Quantos intervalos permanecem em K_0 , K_1 , K_2 e K_3 ? Qual é o comprimento de cada intervalo em cada uma dessas etapas?
- b) Mostre, por indução, que K_n é a união de 2^n intervalos fechados, cada um deles com comprimento 3^{-n} .
- c) Para $n \geq 1$, denote por

$$R_n \equiv K_{n-1} \setminus K_n$$

a união dos intervalos abertos retirados na n -ésima etapa; os extremos desses intervalos permanecem em K_n . Mostre que R_n é a união de 2^{n-1} intervalos abertos, cada um com comprimento 3^{-n} , e conclua que

$$\lambda(R_n) = 2^{n-1} 3^{-n} = \frac{1}{3} \left(\frac{2}{3}\right)^{n-1}.$$

- d) Mostre que os conjuntos R_n são dois a dois disjuntos e que

$$[0, 1] \setminus \mathbb{K} = \bigcup_{n=1}^{\infty} R_n.$$

Use a σ -aditividade da medida e a fórmula da série geométrica para calcular a medida do complemento:

$$\lambda([0, 1] \setminus \mathbb{K}) = \sum_{n=1}^{\infty} \lambda(R_n) = \frac{1}{3} \sum_{n=0}^{\infty} \left(\frac{2}{3}\right)^n = 1.$$

- e) Finalmente, levando em conta que os extremos dos intervalos retirados não são removidos, decomponha $[0, 1]$ como a união disjunta de $\mathbb{K}$ e seu complemento. Sabendo que $\lambda([0, 1]) = 1$, conclua que $\lambda(\mathbb{K}) = 0$.

*** 16 Construção formal da função de Cantor.** Considere o conjunto

$$V \equiv \{f \in C([0, 1], \mathbb{R}) : f(0) = 0, f(1) = 1, 0 \leq f(x) \leq 1 \text{ para todo } x \in [0, 1]\}$$

munido da distância induzida pela norma do supremo,

$$\|f\|_{\infty} \equiv \sup\{|f(x)| : x \in [0, 1]\}.$$

Para $f \in V$, defina $Tf : [0, 1] \rightarrow \mathbb{R}$ por

$$Tf(x) = \begin{cases} \frac{1}{2}f(3x), & \text{se } 0 \leq x \leq \frac{1}{3}, \\ \frac{1}{2}, & \text{se } \frac{1}{3} \leq x \leq \frac{2}{3}, \\ \frac{1}{2} + \frac{1}{2}f(3x - 2), & \text{se } \frac{2}{3} \leq x \leq 1. \end{cases}$$

Recorde que $C([0, 1], \mathbb{R})$, munido da norma do supremo, é um espaço métrico completo. A função identidade pertence a V , de modo que V não é vazio.

a) Mostre que V é um subconjunto fechado de $C([0, 1], \mathbb{R})$ e, portanto, é completo. Em seguida, mostre que Tf está bem definida nos pontos $x = 1/3$ e $x = 2/3$, é contínua, satisfaz $(Tf)(0) = 0$, $(Tf)(1) = 1$ e $0 \leq (Tf)(x) \leq 1$. Conclua que $T : V \rightarrow V$ está bem definida.

b) Mostre que $T : V \rightarrow V$ é uma contração, isto é, para quaisquer $f, g \in V$,

$$\|Tf - Tg\|_{\infty} \leq \frac{1}{2}\|f - g\|_{\infty}.$$

c) Use o Teorema do Ponto Fixo para Contrações de Banach para concluir que existe uma função contínua $\mathcal{C} : [0, 1] \rightarrow [0, 1]$ tal que $\mathcal{C} \in V$ e $T\mathcal{C} = \mathcal{C}$.

d) Seja $f_0 : [0, 1] \rightarrow [0, 1]$ a função identidade, $f_0(x) = x$. Mostre que $f_0 \in V$ e que a sequência definida por $f_n \equiv Tf_{n-1}$ está bem definida para todo $n \in \mathbb{N}$, verificando por indução que $f_n \in V$.

e) O Teorema do Ponto Fixo para Contrações de Banach afirma, em particular, que $\mathcal{C} = \lim_{n \rightarrow \infty} T^n h$ para todo $h \in V$. Mostre primeiro que T preserva a monotonicidade: se $f \in V$ é monótona não decrescente, então Tf também é monótona não decrescente. Use esse fato e o item anterior para mostrar, por indução, que cada f_n é monótona não decrescente. Finalmente, use a convergência uniforme de f_n para concluir que $\mathcal{C}$ é contínua e monótona não decrescente.

Referências

- [1] P. Billingsley. *Probability and measure*. Wiley Series in Probability and Statistics. John Wiley & Sons, Inc., Hoboken, NJ, anniversary edition, 2012. With a foreword by Steve Lalley and a brief biography of Billingsley by Steve Koppes.
- [2] Geoffrey Grimmett and Dominic Welsh. *Probability—an introduction*. Oxford University Press, Oxford, second edition, 2014.