UnB | Departamento de Matemática

Momentos e Funções Geradoras de Momentos

L. Cioletti

Outubro de 2026

Resumo

Nestas notas estudamos os momentos de uma variável aleatória e as funções geradoras de momentos. Começamos com uma nota geral sobre o tratamento de variáveis aleatórias sem supor que sejam discretas ou absolutamente contínuas, com a regra de conversão que troca $f_X(x)\,dx$ por $p_X(x)$ e a integral pela soma. Definimos os momentos $\mathbb{E}[X^k]$, calculamos os momentos da distribuição exponencial, observamos que a distribuição de Cauchy não possui momentos e discutimos em que sentido a sequência de momentos determina a distribuição, com a distribuição log-normal como contraexemplo. Em seguida estudamos a variância, a covariância e o coeficiente de correlação $\rho(X,Y)$, mostramos que $|\rho(X,Y)| \leqslant 1$ a partir da desigualdade de Cauchy-Schwarz e caracterizamos os casos $\rho(X,Y) = \pm 1$. Por fim, introduzimos a função geradora de momentos $M_X(t) = \mathbb{E}[e^{tX}]$, mostramos que os momentos se recuperam das derivadas de M_X na origem, que $M_{aX+b}(t) = e^{tb}M_X(at)$ e que a geradora da soma de variáveis aleatórias independentes é o produto das geradoras. Com o teorema de unicidade, mostramos que a soma de duas variáveis normais independentes é normal. A exposição segue de perto as Seções 7.1 a 7.4 do Capítulo 7 da referência [1].

1. Introdução

Nas notas anteriores estudamos as variáveis aleatórias discretas e, em notas separadas, as absolutamente contínuas. No caso discreto descrevemos a distribuição por uma função de probabilidade p_X e calculamos esperanças por meio de somas; no caso absolutamente contínuo descrevemos a distribuição por uma densidade f_X e calculamos as mesmas grandezas por meio de integrais. Essa separação tem a vantagem de manter cada dedução próxima das ferramentas disponíveis no momento, mas sugere que existem duas teorias distintas, quando a estrutura por trás das duas é a mesma: em ambos os casos somamos valores da variável contra pesos, e é a aditividade da esperança sobre eventos dois a dois disjuntos que organiza as contas. Além disso, mal tocamos na existência de variáveis aleatórias que não são de nenhum dos dois tipos, questão que retomamos ao final desta seção. A Figura 1 dá uma visão geral do percurso feito até aqui e do lugar ocupado pelas duas classes estudadas.

CC BY-NC-SA 4.0- Attribution-NonCommercial-ShareAlike 4.0 International

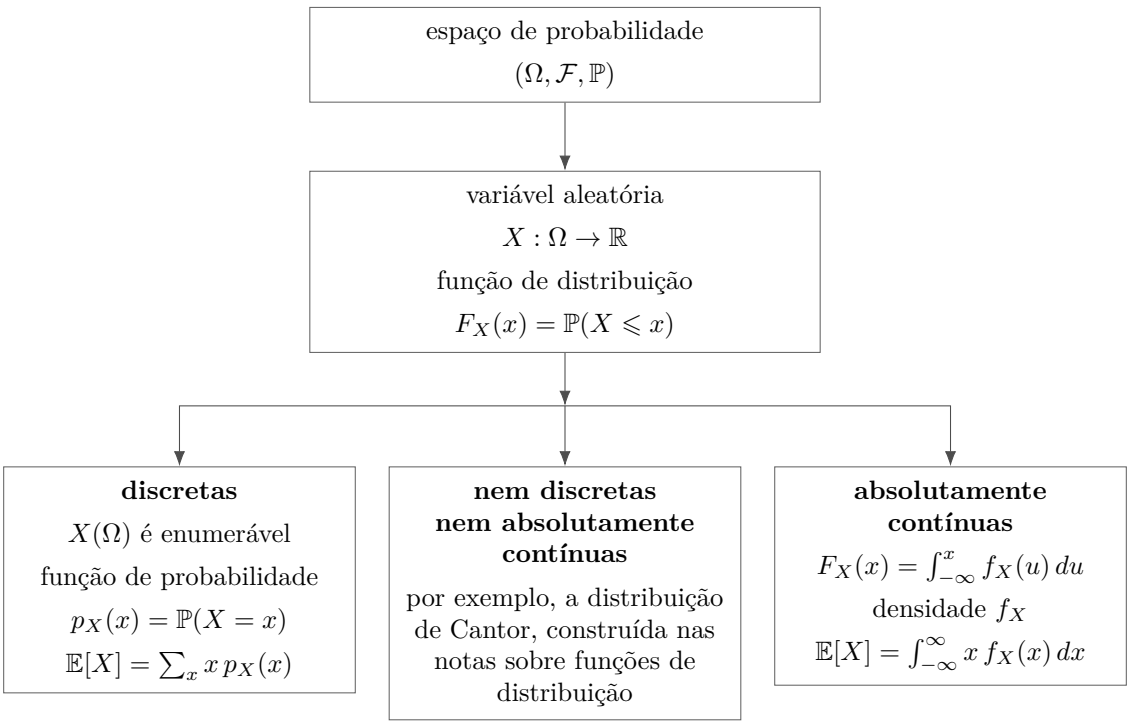


Figura 1: As classes de distribuições estudadas até aqui. Toda variável aleatória é um mapa $X : \Omega \to \mathbb{R}$ e induz uma função de distribuição F_X. As distribuições discretas e as absolutamente contínuas foram estudadas em notas anteriores; a distribuição de Cantor, também estudada antes, mostra que essas duas classes não esgotam todas as possibilidades.

Não podemos continuar tratando o caso discreto e o caso absolutamente contínuo separadamente e os demais casos de modo algum. O que se deve fazer neste ponto é estudar as variáveis aleatórias em sua generalidade. O tratamento rigoroso desse problema, porém, exigiria definir a esperança de uma variável aleatória arbitrária, o que se faz com as ideias e as técnicas da teoria da medida e da integração, e esse caminho está além do que supomos conhecido até aqui. Somos levados, portanto, a adotar uma estratégia intermediária. Vamos enunciar e demonstrar os resultados de modo que eles não mencionem explicitamente o tipo (discreto, absolutamente contínuo ou outro) das variáveis envolvidas. Em alguns pontos, um enunciado geral será usado como guia e verificado apenas no caso particular que sabemos tratar com as ferramentas já desenvolvidas; quando isso acontecer, diremos com clareza qual caso está sendo verificado. Algumas vezes teremos de examinar um caso particular, e então trataremos normalmente o caso *absolutamente contínuo*. O caso discreto é em geral análogo e mais simples, e uma regra prática para converter um argumento sobre variáveis absolutamente contínuas em um argumento sobre variáveis discretas é substituir $f_X(x)\,dx$ por $p_X(x)$ e a integral pela soma:

$$f_X(x)\,dx \;\longmapsto\; p_X(x), \qquad \int \;\longmapsto\; \sum. \tag{1}$$

A correspondência em (1) não é um teorema, e sim um guia de leitura: ela diz que, nos argumentos que faremos, o caso discreto se obtém do caso contínuo trocando a densidade pela função de probabilidade e o símbolo de integração pelo de soma, sem que a estrutura da dedução mude.

Uma última observação, que pode ser lida como um comentário à parte. Para quem quiser conhecer uma variável aleatória que não é discreta nem absolutamente contínua, o exemplo padrão é a distribuição de Cantor, construída nas notas sobre funções de distribuição: sua função de distribuição é contínua, mas ela não concentra massa em pontos e tampouco admite densidade, trata-se de uma distribuição singular. Esse fato mostra que as duas classes estudadas até aqui não esgotam todas as possibilidades, e é justamente por isso que os resultados desta nota são enunciados sem referência ao tipo das variáveis. Com esse panorama, passamos ao estudo dos momentos, que permitem descrever aspectos da distribuição de uma variável aleatória sem restringir o seu tipo.

2. Momentos

2.1. Definição e Primeiros Exemplos

A média de uma variável aleatória X é apenas o primeiro de uma família de números que descrevem sua distribuição. Nesta nota vamos estudar os *momentos* de X, isto é, as esperanças de suas potências, e ver como essa sequência de números permite extrair informações sobre a distribuição. Começamos pelos cálculos diretos, que mostram o que a definição exige e o que ela pode falhar em fornecer.

Definição 1 (Momento de ordem k)**.** Seja X uma variável aleatória e seja $k \geqslant 1$ um inteiro. O *momento de ordem* k de X é o número $\mathbb{E}[X^k]$, sempre que essa esperança existir e for finita. Nesse caso dizemos que X possui momento de ordem k; caso contrário, dizemos que o momento de ordem k não existe. Por conveniência, também falamos do momento de ordem 0, que é sempre $\mathbb{E}[X^0] = 1$.

Como a esperança é calculada a partir da distribuição de X, os momentos dependem apenas dela, e não do espaço de probabilidade particular em que X está definida. Por isso também falamos dos momentos de uma distribuição ou de uma densidade.

Vale explicitar o que a Definição 1 pede em cada caso. Se X é discreta, então

$$\mathbb{E}[X^k] = \sum_{x \in \operatorname{Im} X} x^k \, \mathbb{P}(X = x),$$

e a soma deve convergir absolutamente, já que $\mathbb{E}[|X|^k] = \mathbb{E}[X^k]$ somente quando k é par. Se X tem densidade f, então

$$\mathbb{E}[X^k] = \int_{-\infty}^{\infty} x^k f(x)\, dx,$$

e aqui a exigência é a mesma: como vimos nas notas sobre funções de variáveis aleatórias contínuas, a esperança de uma variável aleatória está definida apenas quando ela é integrável, de modo que a integral de $|x|^k f(x)$ precisa ser finita. Em ambos os casos,

$$\mathbb{E}[X^k] \text{ está bem definida} \quad \Longleftrightarrow \quad \mathbb{E}\Big[|X|^k\Big] < \infty.$$

Para k par as duas quantidades coincidem, mas para k ímpar o integrando troca de sinal, e a convergência absoluta não é uma exigência técnica dispensável.

Exemplo 2 (Momentos da distribuição exponencial)**.** Fixe $\lambda > 0$ e suponha que X tenha densidade $f(x) = \lambda e^{-\lambda x}$ para $x > 0$ e $f(x) = 0$ para $x \leqslant 0$. Como $X \geqslant 0$, a integrabilidade

de X^k coincide com a convergência da integral que define $\mathbb{E}[X^k]$, e podemos escrever, para $k \geqslant 1$,

$$\mathbb{E}[X^k] = \int_0^\infty x^k \lambda e^{-\lambda x}\, dx.$$

Vamos calcular essa integral por partes, escolhendo derivar o fator polinomial x^k e integrar o fator exponencial. Tomando $u = x^k$ e $dv = \lambda e^{-\lambda x}\, dx$, temos $du = kx^{k-1}\, dx$ e $v = -e^{-\lambda x}$, logo

$$\mathbb{E}[X^k] = \Big[-x^k e^{-\lambda x}\Big]_0^\infty + \int_0^\infty kx^{k-1} e^{-\lambda x}\, dx.$$

O termo de fronteira se anula nas duas extremidades: em $x = 0$ porque x^k se anula e $e^{-\lambda x}$ vale 1, e em $x \to \infty$ porque a exponencial decai mais rápido do que qualquer polinômio cresce, isto é, $\lim_{x\to\infty} x^k e^{-\lambda x} = 0$. Quanto à integral que sobra,

$$\int_0^\infty kx^{k-1} e^{-\lambda x}\, dx = \frac{k}{\lambda} \int_0^\infty x^{k-1} \lambda e^{-\lambda x}\, dx = \frac{k}{\lambda}\, \mathbb{E}[X^{k-1}],$$

onde a última igualdade usa novamente a definição do momento de ordem $k-1$. Como o integrando é não negativo, a integração por partes pode ser feita em $[0, R]$ e seguida da passagem ao limite $R \to \infty$, de modo que a recorrência abaixo vale em $[0, +\infty]$, isto é, ela é válida mesmo que um dos dois lados seja infinito. Reunindo os dois passos, obtemos a recorrência

$$\mathbb{E}[X^k] = \frac{k}{\lambda}\, \mathbb{E}[X^{k-1}], \qquad k \geqslant 1.$$

Aplicando-a repetidamente,

$$\begin{aligned} \mathbb{E}[X^k] &= \frac{k}{\lambda}\, \mathbb{E}[X^{k-1}] = \frac{k(k-1)}{\lambda^2}\, \mathbb{E}[X^{k-2}] = \cdots \\ &= \frac{k!}{\lambda^k}\, \mathbb{E}[X^0] = \frac{k!}{\lambda^k}, \end{aligned}$$

pois $X^0 = 1$ e a esperança da constante 1 é 1. Para $k = 1$ recuperamos $\mathbb{E}[X] = 1/\lambda$, o valor já conhecido para a média da exponencial. Mais do que isso, como $\mathbb{E}[X^0] = 1$ é finita, a recorrência fornece, por indução, $\mathbb{E}[X^k] < \infty$ para todo k: se $\mathbb{E}[X^{k-1}] < \infty$, então $\mathbb{E}[X^k] = (k/\lambda)\mathbb{E}[X^{k-1}] < \infty$. Logo a distribuição exponencial possui momentos de todas as ordens, dados por $\mathbb{E}[X^k] = k!/\lambda^k$.

Exemplo 3 (A distribuição de Cauchy não possui momentos)**.** Dizemos que X tem distribuição de Cauchy quando sua densidade é

$$f(x) = \frac{1}{\pi(1+x^2)}, \qquad x \in \mathbb{R}.$$

Se X tivesse momento de ordem k, ele seria dado por

$$\mathbb{E}[X^k] = \int_{-\infty}^\infty \frac{x^k}{\pi(1+x^2)}\, dx.$$

Vamos mostrar que essa integral não converge absolutamente para nenhum $k \geqslant 1$, de modo que a distribuição de Cauchy não possui momento algum.

Para $|x| \geqslant 1$ temos $1 + x^2 \leqslant 2x^2$, logo

$$\left|\frac{x^k}{\pi(1+x^2)}\right| = \frac{|x|^k}{\pi(1+x^2)} \geqslant \frac{|x|^k}{2\pi x^2} = \frac{1}{2\pi}\,|x|^{k-2}.$$

Como $k - 2 \geqslant -1$, a integral de $|x|^{k-2}$ em $\{|x| \geqslant 1\}$ diverge, e a comparação garante que

$$\int_{-\infty}^{\infty} \left|\frac{x^k}{\pi(1+x^2)}\right| dx = \infty.$$

Para $k = 1$ vale a pena notar por que isso não é um detalhe técnico. O integrando $x/(\pi(1+x^2))$ é uma função ímpar, e o valor principal simétrico da integral se anula; mas a esperança exige convergência absoluta, e podemos refazer o argumento acima separando $\{|x| \geqslant 1\}$ do intervalo limitado $[-1, 1]$ para ver que a integral de $|x|/(\pi(1+x^2))$ diverge. Concluímos que $\mathbb{E}[X]$ não existe, e o mesmo vale para todo $k \geqslant 1$.

O exemplo anterior sugere que o comportamento da densidade no infinito controla quais momentos existem. Vamos tornar isso preciso com uma família de densidades de cauda polinomial, para as quais os momentos existem apenas até uma certa ordem.

Exemplo 4 (Densidades com cauda polinomial)**.** Fixe um inteiro $m \geqslant 2$ e considere

$$f(x) = \frac{c_m}{1 + |x|^m}, \qquad x \in \mathbb{R},$$

onde a constante

$$c_m = \left(\int_{-\infty}^{\infty} \frac{dx}{1+|x|^m}\right)^{-1}$$

é escolhida de modo que f integre 1. A constante é positiva e finita: o integrando é positivo e contínuo, e para $|x| \geqslant 1$ ele é dominado por $|x|^{-m}$, cuja integral converge em $\{|x| \geqslant 1\}$ porque $m \geqslant 2$. Portanto f é de fato uma densidade de probabilidade.

Vamos determinar para quais k a integral

$$\int_{-\infty}^{\infty} \frac{|x|^k}{1+|x|^m}\,dx$$

converge. O comportamento no infinito é o único ponto delicado, pois o integrando é contínuo e limitado em qualquer intervalo limitado. Para $|x| \geqslant 1$ temos $|x|^m \leqslant 1 + |x|^m \leqslant 2|x|^m$, e portanto

$$\frac{1}{2}\,|x|^{k-m} \leqslant \frac{|x|^k}{1+|x|^m} \leqslant |x|^{k-m}.$$

As duas desigualdades mostram que a integral em $\{|x| \geqslant 1\}$ converge se, e somente se, $\int_1^\infty x^{k-m}\,dx$ converge, o que ocorre exatamente quando $k - m < -1$, isto é, $k < m - 1$. Como k e m são inteiros, essa condição é equivalente a $k \leqslant m - 2$.

Concluímos que a densidade f possui momentos apenas para as ordens $1 \leqslant k \leqslant m - 2$: ela tem momento de ordem k para todo inteiro k nesse intervalo e nenhum momento para $k \geqslant m - 1$. Conforme m aumenta, a cauda fica mais leve e mais momentos passam a existir; para $m = 4$, por exemplo, existem $\mathbb{E}[X]$ e $\mathbb{E}[X^2]$, mas não $\mathbb{E}[X^3]$. No extremo oposto, $m = 2$ dá $f(x) = c_2/(1 + x^2)$, que é a densidade de Cauchy do Exemplo 3, e a condição $k \leqslant 0$ não deixa nenhuma ordem admissível, como já sabíamos.

Conhecida a função de distribuição de X, podemos calcular seus momentos, sempre que eles existirem, pelo menos quando X é discreta ou tem densidade. Cabe então perguntar se vale a recíproca: dada a sequência dos momentos finitos

$$\mathbb{E}[X],\ \mathbb{E}[X^2],\ \mathbb{E}[X^3],\ \ldots,$$

é possível reconstruir a distribuição de X? A resposta geral é não: existem variáveis aleatórias distintas que compartilham toda a sequência de momentos. A resposta passa a ser sim quando acrescentamos alguma informação extra sobre a sequência, e a próxima subseção trata exatamente disso.

2.2. Os Momentos e a Determinação da Distribuição

Os momentos de uma variável aleatória X, isto é, as esperanças $\mathbb{E}[X]$, $\mathbb{E}[X^2]$, $\mathbb{E}[X^3]$, $\ldots$, quando existem, codificam informações sobre a distribuição de X. Uma pergunta natural é se a sequência de momentos determina unicamente essa distribuição. Vamos ver que a resposta é afirmativa sob uma hipótese de convergência, que explicita a relação entre a sequência de momentos e uma função geradora.

Teorema 5 (Unicidade dos momentos)**.** Suponha que todos os momentos $\mathbb{E}[X]$, $\mathbb{E}[X^2]$, $\ldots$ da variável aleatória X existam e que a série

$$\sum_{k=0}^{\infty} \frac{1}{k!}\, t^k\, \mathbb{E}[X^k] \tag{2}$$

seja absolutamente convergente para algum $t > 0$. Então a sequência de momentos determina unicamente a distribuição de X.

A prova não pertence à probabilidade elementar: ela usa argumentos de análise real e complexa, pode ser encontrada em textos de análise, e por isso a omitimos. O ponto de contato com a probabilidade está na forma de (2): essa série é a função geradora exponencial da sequência $(\mathbb{E}[X^k])_{k\geqslant 0}$, e o teorema é o análogo, para momentos, do teorema de unicidade da função geradora de probabilidade, que estudamos nas notas sobre funções geradoras de probabilidade. Assim como lá a função geradora determinava a distribuição, aqui a convergência absoluta da série faz a sequência de momentos determinar a distribuição.

O papel lógico da hipótese é de condição suficiente, e não necessária: a convergência absoluta de (2) para algum $t > 0$ basta para que os momentos determinem a distribuição, mas ela não é indispensável em todo caso. A subseção seguinte mostra que, sem hipótese alguma sobre a convergência da série, os momentos podem deixar de determinar a distribuição.

2.3. Um Contraexemplo: A Distribuição Log-Normal

Vamos construir uma distribuição que não é determinada pelos seus momentos. A partida é a distribuição log-normal: se $X \sim \mathrm{N}(0,1)$, dizemos que $Y = e^X$ tem a distribuição log-normal padrão. Para $x > 0$, a função de distribuição de Y vale $\mathbb{P}(Y \leqslant x) = \mathbb{P}(X \leqslant \log x)$, e derivando em relação a x (ou pela fórmula de mudança de variável para transformações crescentes e diferenciáveis) obtemos a densidade

$$f(x) = \begin{cases} \dfrac{1}{x\sqrt{2\pi}} \exp\Big[-\dfrac{1}{2}(\log x)^2\Big] & \text{se } x > 0, \\[2ex] 0 & \text{se } x \leqslant 0. \end{cases} \tag{3}$$

Exemplo 6 (Momentos que não determinam a distribuição)**.** Fixe a com $-1 \leqslant a \leqslant 1$ e defina

$$f_a(x) = \Big[1 + a\,\mathrm{sen}(2\pi \log x)\Big] f(x) \qquad \text{para } x > 0,$$

com $f_a(x) = 0$ para $x \leqslant 0$. Vamos verificar que (i) f_a é uma densidade, (ii) f tem momentos finitos de todas as ordens, (iii) f_a e f têm momentos iguais de todas as ordens.

Todas as contas usam a mudança de variável $x = e^u$, com $u = \log x$ e $dx = e^u\,du$, que leva a parte principal da densidade à densidade da normal padrão:

$$f(x)\,dx = \frac{1}{x\sqrt{2\pi}}\, e^{-u^2/2}\, e^u\, du = \frac{1}{\sqrt{2\pi}}\, e^{-u^2/2}\, du.$$

Em particular, $\int_0^\infty g(x) f(x)\,dx = \mathbb{E}[g(e^U)]$ quando $U \sim \mathrm{N}(0,1)$ e o lado direito faça sentido; veremos que isso ocorre para $g(x) = x^k$.

(i) Para $x > 0$ temos $|a\,\mathrm{sen}(2\pi \log x)| \leqslant |a| \leqslant 1$, logo $1 + a\,\mathrm{sen}(2\pi \log x) \geqslant 1 - |a| \geqslant 0$ e $f_a(x) \geqslant 0$ em $\mathbb{R}$; a função f_a é contínua em $(0,\infty)$ e nula em $(-\infty, 0]$, logo é mensurável. Para a integral, aplicamos a mudança de variável nos dois termos:

$$\int_0^\infty f_a(x)\,dx = \int_0^\infty f(x)\,dx + a\int_{-\infty}^\infty \mathrm{sen}(2\pi u)\,\frac{1}{\sqrt{2\pi}}\, e^{-u^2/2}\,du = 1.$$

De fato, o primeiro termo vale 1, por ser a integral da densidade de $\mathrm{N}(0,1)$, e o integrando do segundo é ímpar, pois é o produto de $\mathrm{sen}(2\pi u)$, ímpar, por $e^{-u^2/2}$, par; uma função ímpar integrada sobre um intervalo simétrico tem integral nula. Concluímos que f_a é uma densidade.

(ii) Seja $k \geqslant 1$ inteiro. Completando o quadrado em $ku - \frac{u^2}{2} = -\frac{1}{2}(u-k)^2 + \frac{k^2}{2}$, obtemos

$$\begin{aligned}
\int_0^\infty x^k f(x)\,dx &= \int_{-\infty}^\infty e^{ku}\,\frac{1}{\sqrt{2\pi}}\, e^{-u^2/2}\,du \\
&= e^{k^2/2}\int_{-\infty}^\infty \frac{1}{\sqrt{2\pi}}\, e^{-(u-k)^2/2}\,du \\
&= e^{k^2/2} < \infty.
\end{aligned}$$

A última integral vale 1 por ser a integral da densidade de $\mathrm{N}(k,1)$. Assim f tem momentos finitos (e positivos) de todas as ordens, e o momento de ordem k vale $e^{k^2/2}$.

(iii) Resta comparar os momentos de f_a e f. Separamos a perturbação senoidal do termo principal e repetimos as duas etapas anteriores:

$$\begin{aligned}
\int_0^\infty x^k f_a(x)\,dx &= \int_0^\infty x^k f(x)\,dx + a\int_0^\infty x^k\,\mathrm{sen}(2\pi \log x)\, f(x)\,dx \\
&= e^{k^2/2} + \frac{a\, e^{k^2/2}}{\sqrt{2\pi}}\int_{-\infty}^\infty \mathrm{sen}(2\pi u)\, e^{-(u-k)^2/2}\,du.
\end{aligned}$$

Na integral restante a gaussiana está centrada em $u = k$; a translação $v = u - k$, que preserva os limites de $-\infty$ a $+\infty$, dá

$$\int_{-\infty}^\infty \mathrm{sen}(2\pi u)\, e^{-(u-k)^2/2}\,du = \int_{-\infty}^\infty \mathrm{sen}\Big(2\pi(v+k)\Big)\, e^{-v^2/2}\,dv.$$

É aqui que entra a hipótese de k ser inteiro: pela fórmula de adição do seno,

$$\operatorname{sen}\Big(2\pi(v+k)\Big) = \operatorname{sen}(2\pi v)\cos(2\pi k) + \cos(2\pi v)\operatorname{sen}(2\pi k) = \operatorname{sen}(2\pi v),$$

pois $\cos(2\pi k) = 1$ e $\operatorname{sen}(2\pi k) = 0$ para $k \in \mathbb{Z}$. Assim,

$$\int_{-\infty}^{\infty} \operatorname{sen}\Big(2\pi(v+k)\Big)\, e^{-v^2/2}\, dv = \int_{-\infty}^{\infty} \operatorname{sen}(2\pi v)\, e^{-v^2/2}\, dv = 0,$$

porque o novo integrando é ímpar. Note o cuidado com o segundo termo da fórmula de adição: $\int_{-\infty}^{\infty} \cos(2\pi v)\, e^{-v^2/2}\, dv$ é positiva e não se anula por paridade; esse termo desaparece porque a sua amplitude $\operatorname{sen}(2\pi k)$ se anula para k inteiro. Voltando à cadeia de cálculos, concluímos que

$$\int_0^{\infty} x^k f_a(x)\, dx = e^{k^2/2} = \int_0^{\infty} x^k f(x)\, dx \qquad \text{para } k = 1, 2, \ldots$$

(para $k = 0$ a igualdade também vale, pois ambas as integrais são 1).

Finalmente, as densidades f_a são distintas para valores distintos de a: se $a \neq a'$, a diferença $f_a(x) - f_{a'}(x) = (a - a')\operatorname{sen}(2\pi \log x) f(x)$ não se anula quase sempre, pois $\operatorname{sen}(2\pi \log x) f(x)$ é não nula em um conjunto de medida positiva. Portanto $\{f_a : -1 \leqslant a \leqslant 1\}$ é uma família de densidades distintas com os mesmos momentos de todas as ordens.

Concluímos que os momentos não determinam a distribuição quando a hipótese de Teorema 5 falha: as densidades f_a acima são distintas, mas compartilham a sequência de momentos $\big(\mathbb{E}[Y^k]\big)_{k\geqslant 1} = \big(e^{k^2/2}\big)_{k\geqslant 1}$. Para esta família a série (2) diverge para todo $t > 0$: a razão entre termos consecutivos é $\frac{t\, e^{k+1/2}}{k+1}$, que tende a $+\infty$, de modo que os termos gerais nem sequer tendem a zero. Temos assim o contraponto do teorema de unicidade: sem a convergência absoluta em (2), a sequência de momentos pode deixar de determinar a distribuição.

2.4. A Variância e suas Propriedades

A variância de uma variável aleatória já apareceu duas vezes no curso: nas notas sobre esperança de variáveis discretas, onde foi definida por meio da função de probabilidade, e nas notas sobre funções de variáveis contínuas e esperança, onde foi definida por meio da densidade. Naquele momento era necessário escolher uma forma de somar ou integrar segundo o tipo da variável. Agora que dispomos de uma noção de esperança que não depende do tipo, podemos reapresentar a definição de uma só vez e estudar as propriedades da variância de maneira unificada.

Definição 7 (Variância)**.** Seja X uma variável aleatória com $\mathbb{E}[X^2] < \infty$ e escreva $\mu = \mathbb{E}[X]$. A *variância* de X é

$$\operatorname{Var}(X) = \mathbb{E}\Big[(X - \mu)^2\Big]. \tag{4}$$

A exigência $\mathbb{E}[X^2] < \infty$ garante que a esperança em (4) está bem definida: como $X - \mu$ é uma variável aleatória e $(X-\mu)^2 \geqslant 0$, a esperança existe sempre como elemento de $[0, \infty]$, e é finita exatamente quando $\mathbb{E}[(X-\mu)^2] < \infty$, o que ocorre se, e somente se, $\mathbb{E}[X^2] < \infty$ e $\mathbb{E}[X] < \infty$. Trabalharemos sempre nesse regime, de modo que as manipulações abaixo envolvem apenas quantidades reais.

A variância mede a dispersão de X em torno de sua esperança μ. Se X assume com frequência valores consideravelmente distantes de μ, então $|X-\mu|$ é frequentemente grande e $\mathbb{E}[(X-\mu)^2]$ também será grande; se X costuma ficar perto de μ, então $|X-\mu|$ é tipicamente pequena e $\mathbb{E}[(X-\mu)^2]$ é pequena. O caso extremo é o de uma variável *concentrada* em um único ponto, e é isso que caracterizamos a seguir.

Começamos por um critério de anulamento que vale para qualquer variável aleatória quadrado-integrável.

Lema 8 (Anulamento do segundo momento)**.** Para uma variável aleatória Y com $\mathbb{E}[Y^2] < \infty$,

$$\mathbb{E}[Y^2] = 0 \quad \text{se, e somente se,} \quad \mathbb{P}(Y = 0) = 1. \tag{5}$$

Prova. Uma das implicações é imediata. Se $\mathbb{P}(Y=0)=1$, então $Y^2 = 0$ quase certamente e, pela definição de esperança de uma variável que se anula em um evento de probabilidade 1, temos $\mathbb{E}[Y^2] = 0$.

Para a recíproca, suponha que $\mathbb{E}[Y^2] = 0$ e fixe $\varepsilon > 0$. Como Y^2 é não negativa, a definição de esperança fornece diretamente a desigualdade de Markov,

$$\varepsilon^2 \, \mathbb{P}\Big(Y^2 \geqslant \varepsilon^2\Big) \leqslant \mathbb{E}[Y^2] = 0,$$

e portanto $\mathbb{P}(|Y| \geqslant \varepsilon) = 0$ para todo $\varepsilon > 0$. Escrevemos agora o evento $\{Y \neq 0\}$ como união enumerável dos eventos aninhados $\{|Y| \geqslant 1/n\}$, com $n \in \mathbb{N}$:

$$\{Y \neq 0\} = \bigcup_{n \geqslant 1} \{|Y| \geqslant 1/n\}.$$

Pela continuidade por baixo da probabilidade e pela subaditividade enumerável aplicada a essa união,

$$\mathbb{P}(Y \neq 0) = \lim_{n \to \infty} \mathbb{P}\Big(|Y| \geqslant 1/n\Big) \leqslant \sum_{n \geqslant 1} \mathbb{P}\Big(|Y| \geqslant 1/n\Big) = 0.$$

Logo $\mathbb{P}(Y \neq 0) = 0$ e, tomando o complementar, $\mathbb{P}(Y = 0) = 1$. ∎

No caso de uma variável aleatória discreta, a recíproca admite uma leitura puramente somatória, que registramos porque esclarece de onde vem o argumento acima. Escrevendo a esperança como soma sobre a imagem de Y,

$$\mathbb{E}[Y^2] = \sum_{y \in \operatorname{Im} Y} y^2 \, \mathbb{P}(Y = y),$$

vemos que todos os termos dessa soma são não negativos. A soma, portanto, só pode se anular se cada termo for nulo; como $y^2 = 0$ apenas para $y = 0$, concluímos que $\mathbb{P}(Y = y) = 0$ para todo $y \neq 0$ e, somando sobre a parte não nula da imagem, $\mathbb{P}(Y \neq 0) = 0$. O argumento da Lema 8 apenas substitui essa soma por uma estimativa integral, o que permite tratar ao mesmo tempo os casos discreto, contínuo e singular.

Aplicando (5) a $Y = X - \mu$, cuja esperança do quadrado é $\operatorname{Var}(X)$, obtemos a caracterização do caso sem dispersão alguma:

$$\operatorname{Var}(X) = 0 \quad \text{se, e somente se,} \quad \mathbb{P}(X = \mathbb{E}[X]) = 1. \tag{6}$$

Isto é, a variância se anula exatamente quando X é constante com probabilidade 1, de modo que "variância nula" significa "nenhuma dispersão".

Existem outras medidas possíveis de dispersão, como $\mathbb{E}[|X-\mu|]$ ou $\mathbb{E}[|X-\mu|^3]$, mas é com a variância que se trabalha com mais facilidade. O motivo aparece na fórmula a seguir.

Quando calculamos a variância de uma variável concreta, é em geral mais simples usar os momentos de X do que retornar à definição (4). Expandindo o quadrado e usando a linearidade da esperança, obtemos uma identidade que expressa a variância em termos do segundo momento e da média. Como todos os termos envolvidos são integráveis, a expansão é legítima e resulta em

$$\operatorname{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2. \tag{7}$$

De fato, escrevendo $\mu = \mathbb{E}[X]$,

$$\begin{aligned}
\mathbb{E}\Big[(X-\mu)^2\Big] &= \mathbb{E}\Big[X^2 - 2\mu X + \mu^2\Big] \\
&= \mathbb{E}[X^2] - 2\mu\,\mathbb{E}[X] + \mu^2 \\
&= \mathbb{E}[X^2] - 2\mu^2 + \mu^2 = \mathbb{E}[X^2] - \mu^2.
\end{aligned}$$

A vantagem de (7) é que ela separa o cálculo em dois momentos, $\mathbb{E}[X]$ e $\mathbb{E}[X^2]$, que costumam ser obtidos por somas ou integrais diretas, sem que seja preciso lidar com o quadrado de $X - \mathbb{E}[X]$.

A mesma linearidade controla o efeito de uma transformação afim.

Proposição 9 (Variância de uma transformação afim)**.** Sejam X uma variável aleatória com $\mathbb{E}[X^2] < \infty$ e $a, b \in \mathbb{R}$. Então

$$\operatorname{Var}(aX + b) = a^2 \operatorname{Var}(X). \tag{8}$$

Prova. Pela linearidade da esperança, $\mathbb{E}[aX+b] = a\mathbb{E}[X] + b$, de modo que o desvio de $aX+b$ em relação à sua média é $aX + b - \mathbb{E}[aX+b] = a\Big(X - \mathbb{E}[X]\Big)$. Logo

$$\begin{aligned}
\operatorname{Var}(aX+b) &= \mathbb{E}\Big[\Big(aX + b - \mathbb{E}[aX+b]\Big)^2\Big] \\
&= \mathbb{E}\Big[\Big(aX + b - a\mathbb{E}[X] - b\Big)^2\Big] \\
&= \mathbb{E}\Big[a^2\Big(X - \mathbb{E}[X]\Big)^2\Big] = a^2\,\mathbb{E}\Big[\Big(X - \mathbb{E}[X]\Big)^2\Big] \\
&= a^2 \operatorname{Var}(X).
\end{aligned}$$

A penúltima igualdade usa a linearidade da esperança para retirar a constante a^2, que é não negativa e finita. ∎

Como medida de dispersão, a variância tem um inconveniente: ela é quadrática em X e, portanto, não linear. Pela Proposição 9, se $a > 1$, a variância de aX é a^2 vezes a variância de X, e não a vezes; além disso, a variância é medida em unidades ao quadrado das unidades de X. Se, por exemplo, X é um comprimento em metros, $\operatorname{Var}(X)$ é expresso em metros quadrados. Por esse motivo, quem precisa de uma medida de dispersão na mesma escala de X usa o *desvio padrão*

$$\sigma_X = \sqrt{\operatorname{Var}(X)}.$$

O desvio padrão herda a não linearidade apenas no fator de escala: pela Proposição 9, $\sigma_{aX+b} = |a|\,\sigma_X$, o que é compatível com a mudança de unidades descrita por a.

Voltamo-nos agora para a variância de uma soma. A pergunta natural é se $\mathrm{Var}(X+Y)$ se decompõe em $\mathrm{Var}(X)+\mathrm{Var}(Y)$. Veremos que isso não é verdade em geral e que o termo que falta tem significado próprio.

Proposição 10 (Variância de uma soma)**.** Sejam X e Y variáveis aleatórias com $\mathbb{E}[X^2] < \infty$ e $\mathbb{E}[Y^2] < \infty$. Então

$$\mathrm{Var}(X+Y) = \mathrm{Var}(X) + \mathrm{Var}(Y) + 2\,\mathbb{E}\Big[(X-\mathbb{E}[X])(Y-\mathbb{E}[Y])\Big]. \tag{9}$$

Prova. Escreva $\mu_X = \mathbb{E}[X]$ e $\mu_Y = \mathbb{E}[Y]$. Pela linearidade da esperança, $\mathbb{E}[X+Y] = \mu_X + \mu_Y$, de modo que $(X+Y) - \mathbb{E}[X+Y] = (X-\mu_X) + (Y-\mu_Y)$. Expandindo o quadrado dessa soma,

$$\begin{aligned}
\mathrm{Var}(X+Y) &= \mathbb{E}\Big[\big\{(X-\mu_X)+(Y-\mu_Y)\big\}^2\Big] \\
&= \mathbb{E}\Big[(X-\mu_X)^2\Big] + 2\,\mathbb{E}\Big[(X-\mu_X)(Y-\mu_Y)\Big] + \mathbb{E}\Big[(Y-\mu_Y)^2\Big] \\
&= \mathrm{Var}(X) + 2\,\mathbb{E}\Big[(X-\mu_X)(Y-\mu_Y)\Big] + \mathrm{Var}(Y).
\end{aligned}$$

A validade da expansão do quadrado segue da linearidade da esperança: as três parcelas são integráveis, pois $\mathbb{E}[(X-\mu_X)^2] < \infty$, $\mathbb{E}[(Y-\mu_Y)^2] < \infty$ e $|(X-\mu_X)(Y-\mu_Y)| \leqslant \frac{1}{2}\Big[(X-\mu_X)^2 + (Y-\mu_Y)^2\Big]$, o que garante que o termo misto é absolutamente integrável. ■

A Proposição 10 mostra que a variância da soma é a soma das variâncias acrescida de duas vezes o número $\mathbb{E}[(X-\mathbb{E}[X])(Y-\mathbb{E}[Y])]$. Esse número mede o quanto as duas variáveis flutuam conjuntamente em torno de suas médias: ele é positivo quando X e Y tendem a ficar simultaneamente acima ou simultaneamente abaixo de suas médias, e negativo quando tendem a se deslocar em direções opostas. É essa quantidade que se chama *covariância* de X e Y, e é o objeto que estudamos na próxima subseção.

2.5. Covariância

Definição 11 (Covariância)**.** A covariância das variáveis aleatórias X e Y é a quantidade denotada $\mathrm{Cov}(X,Y)$ e dada por

$$\mathrm{Cov}(X,Y) = \mathbb{E}\Big[(X-\mathbb{E}[X])(Y-\mathbb{E}[Y])\Big], \tag{10}$$

sempre que essas esperanças existem.

Note que $\mathrm{Cov}(X,X) = \mathrm{Var}(X)$: a covariância generaliza a variância, que mede a dispersão de uma única variável em torno de sua média, para o caso de duas variáveis.

A expressão em (10) pode ser reescrita de forma mais simples. Vamos expandir o produto e usar a linearidade da esperança; como X e Y têm segundo momento finito, o produto XY é integrável e todas as esperanças abaixo estão bem definidas:

$$\begin{aligned}\operatorname{Cov}(X,Y) &= \mathbb{E}\Big[(X-\mathbb{E}[X])(Y-\mathbb{E}[Y])\Big] \\ &= \mathbb{E}\Big[XY - X\mathbb{E}[Y] - \mathbb{E}[X]\,Y + \mathbb{E}[X]\mathbb{E}[Y]\Big] \\ &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y],\end{aligned} \tag{11}$$

onde usamos que $\mathbb{E}[X]$ e $\mathbb{E}[Y]$ são constantes. Vale a pena guardar a forma final: ela dispensa o cálculo prévio das médias dentro do produto e é, em geral, a mais rápida de calcular.

Voltando à expressão da variância de uma soma, obtida na subseção anterior, o termo do meio é $2\,\mathbb{E}\Big[(X-\mathbb{E}[X])(Y-\mathbb{E}[Y])\Big]$, e portanto

$$\operatorname{Var}(X+Y) = \operatorname{Var}(X) + 2\operatorname{Cov}(X,Y) + \operatorname{Var}(Y), \tag{12}$$

identidade válida para quaisquer X e Y com segundo momento finito, sem hipótese de independência.

Suponhamos agora que X e Y sejam independentes. Nesse caso a esperança do produto se fatora, como vimos nas notas sobre esperança no caso discreto: $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$. Substituindo em (11), obtemos

$$\operatorname{Cov}(X,Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0, \tag{13}$$

ou seja, variáveis independentes não são correlacionadas. Levando esse resultado a (12), recuperamos a fórmula já conhecida

$$\operatorname{Var}(X+Y) = \operatorname{Var}(X) + \operatorname{Var}(Y), \tag{14}$$

válida sempre que as variâncias existem.

A recíproca é falsa: covariância nula não implica independência. Como esse ponto costuma causar confusão, vamos examiná-lo num exemplo com as contas feitas.

Exemplo 12 (Covariância nula não implica independência)**.** Seja X uniforme em $\{-1,0,1\}$, isto é, $\mathbb{P}(X=x)=\frac{1}{3}$ para cada $x\in\{-1,0,1\}$, e defina $Y=X^2$. Como Y é função de X, as variáveis são dependentes: por exemplo, $\mathbb{P}(X=1,\,Y=1)=\frac{1}{3}$, enquanto $\mathbb{P}(X=1)\mathbb{P}(Y=1)=\frac{1}{3}\cdot\frac{2}{3}=\frac{2}{9}$.

Vamos calcular a covariância:

$$\begin{aligned}\mathbb{E}[X] &= \tfrac{1}{3}(-1)+\tfrac{1}{3}\cdot 0+\tfrac{1}{3}\cdot 1 = 0,\\ \mathbb{E}[Y] &= \mathbb{E}[X^2] = \tfrac{1}{3}\cdot 1+\tfrac{1}{3}\cdot 0+\tfrac{1}{3}\cdot 1 = \tfrac{2}{3},\\ \mathbb{E}[XY] &= \mathbb{E}[X^3] = \mathbb{E}[X] = 0,\end{aligned}$$

pois X assume apenas os valores -1, 0 e 1, e nesse conjunto $X^3 = X$ ponto a ponto. Substituindo em (11),

$$\operatorname{Cov}(X,Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0 - 0\cdot\tfrac{2}{3} = 0.$$

Concluímos que X e Y são dependentes e, ainda assim, não correlacionadas. A razão do cancelamento está na simetria: quando X se afasta da média para a direita, Y também se afasta para a direita, mas o mesmo ocorre quando X se afasta para a esquerda, e as duas contribuições se anulam.

Apesar de a recíproca falhar, a covariância é muito usada como medida de dependência, e há uma razão para isso: ela é um único número, e não um objeto complicado como uma densidade conjunta, e ainda assim carrega informação sobre o comportamento conjunto de X e Y. Se $\operatorname{Cov}(X,Y) > 0$, os desvios tendem a ter o mesmo sinal; se $\operatorname{Cov}(X,Y) < 0$, a tendência se inverte.

A covariância tem, porém, uma desvantagem: ela não é invariante por mudança de escala. Se X e Y registram duas grandezas em metros e U e V registram as mesmas grandezas em centímetros, então $U = 100X$, $V = 100Y$ e, pela linearidade da esperança,

$$\operatorname{Cov}(U,V) = 100^2 \operatorname{Cov}(X,Y) = 10\,000 \operatorname{Cov}(X,Y).$$

A covariância muda por um fator 10 000, embora os dois pares descrevam as mesmas quantidades; só a unidade de medida mudou. Para contornar isso, reescalamos a covariância de modo a eliminar as unidades.

2.6. Correlação

Definição 13 (Coeficiente de correlação)**.** O coeficiente de correlação das variáveis aleatórias X e Y é a quantidade $\rho(X,Y)$ dada por

$$\rho(X,Y) = \frac{\operatorname{Cov}(X,Y)}{\sqrt{\operatorname{Var}(X)\operatorname{Var}(Y)}}, \tag{15}$$

sempre que essas quantidades existem e $\operatorname{Var}(X)\operatorname{Var}(Y) \neq 0$.

A condição $\operatorname{Var}(X)\operatorname{Var}(Y) \neq 0$ garante que o denominador não se anule: se uma das variáveis fosse constante, ela não teria dispersão, e não haveria o que medir conjuntamente.

Vejamos que a correlação é invariante por translações e mudanças de escala. Sejam $a, b, c, d \in \mathbb{R}$ com $ac \neq 0$ e considere $aX + b$ e $cY + d$. Desenvolvendo a covariância com a forma (11),

$$\begin{aligned}
\operatorname{Cov}(aX+b,\, cY+d) &= \mathbb{E}[(aX+b)(cY+d)] - \mathbb{E}[aX+b]\,\mathbb{E}[cY+d] \\
&= ac\,\mathbb{E}[XY] + ad\,\mathbb{E}[X] + bc\,\mathbb{E}[Y] + bd - (a\mathbb{E}[X]+b)(c\mathbb{E}[Y]+d) \\
&= ac\operatorname{Cov}(X,Y),
\end{aligned}$$

pois os termos constantes e os termos lineares se cancelam. Para as variâncias, o mesmo desenvolvimento mostra que uma translação não altera a dispersão e que um fator multiplicativo sai ao quadrado:

$$\operatorname{Var}(aX+b) = a^2 \operatorname{Var}(X), \qquad \operatorname{Var}(cY+d) = c^2 \operatorname{Var}(Y).$$

Substituindo em (15),

$$\rho(aX+b,\, cY+d) = \frac{ac\operatorname{Cov}(X,Y)}{\sqrt{a^2c^2\operatorname{Var}(X)\operatorname{Var}(Y)}} = \operatorname{sgn}(ac)\,\rho(X,Y). \tag{16}$$

Em particular, se $ac > 0$, como em qualquer mudança de unidades aplicada às duas coordenadas (metros e centímetros, quilos e gramas), temos $\rho(aX+b, cY+d) = \rho(X,Y)$: a correlação é invariante por escala. Se $ac < 0$, uma das coordenadas é invertida e o sinal

de ρ se inverte, o que é coerente com a interpretação de ρ como medida da tendência de os desvios terem o mesmo sinal.

A correlação tem ainda outra propriedade atraente como medida de dependência: seus valores estão confinados ao intervalo $[-1, 1]$, e os casos extremos admitem interpretação precisa em termos do comportamento conjunto de X e Y.

Teorema 14 (Faixa de variação do coeficiente de correlação)**.** Se X e Y são variáveis aleatórias e $\rho(X, Y)$ existe, então

$$-1 \leqslant \rho(X, Y) \leqslant 1. \tag{17}$$

A prova é uma aplicação direta da desigualdade de Cauchy-Schwarz, que apresentaremos na próxima subseção; por isso a demonstração fica adiada para lá.

2.7. A Desigualdade de Cauchy-Schwarz

Nas notas sobre funções de variáveis aleatórias contínuas, provamos uma desigualdade de Cauchy-Schwarz integrando $(g-\lambda h)^2$ em relação a uma densidade. O argumento não depende de representação alguma da distribuição e vale para variáveis aleatórias arbitrárias; é o que vamos registrar agora. A desigualdade compara o momento de segunda ordem do produto UV com os momentos de segunda ordem de U e V, e não exige nenhuma hipótese de independência entre as variáveis.

Teorema 15 (Desigualdade de Cauchy–Schwarz)**.** Sejam U e V variáveis aleatórias quaisquer. Então, sempre que as esperanças envolvidas existirem,

$$[\mathbb{E}[UV]]^2 \leqslant \mathbb{E}[U^2]\,\mathbb{E}[V^2]. \tag{18}$$

Prova. A ideia é produzir uma função quadrática em uma variável real s que não assume valores negativos e extrair uma restrição sobre seus coeficientes. Para isso, fixe $s \in \mathbb{R}$ e defina a variável aleatória

$$W = sU + V.$$

Como $W^2 \geqslant 0$ em cada ponto de Ω, vale $\mathbb{E}[W^2] \geqslant 0$ e, pela linearidade da esperança,

$$0 \leqslant \mathbb{E}[W^2] = \mathbb{E}[s^2U^2 + 2sUV + V^2] = as^2 + bs + c, \tag{19}$$

com coeficientes

$$a = \mathbb{E}[U^2], \qquad b = 2\mathbb{E}[UV], \qquad c = \mathbb{E}[V^2].$$

Claramente $a \geqslant 0$, pois $U^2 \geqslant 0$. Podemos supor $a > 0$: se $a = \mathbb{E}[U^2] = 0$, então $U = 0$ quase certamente (resultado da subseção anterior), de modo que $\mathbb{E}[UV] = 0$ e (18) vale com igualdade.

Considere então a função quadrática $g(s) = as^2 + bs + c$ com $a > 0$. Por (19), temos $g(s) \geqslant 0$ para todo $s \in \mathbb{R}$. Afimamos que g tem no máximo uma raiz real. De fato, se $g(s_1) = g(s_2) = 0$ com $s_1 \neq s_2$, então, como $a > 0$, vale $g(s) = a(s - s_1)(s - s_2)$, e para s estritamente entre s_1 e s_2 os dois fatores têm sinais opostos, donde $g(s) < 0$, em contradição com (19). As raízes de g são $\dfrac{-b \pm \sqrt{b^2 - 4ac}}{2a}$, de modo que a existência de duas raízes reais distintas equivale a $b^2 - 4ac > 0$. Portanto $b^2 - 4ac \leqslant 0$; o caso $b^2 - 4ac = 0$ ocorre quando g toca o eixo horizontal em uma raiz dupla. Substituindo os coeficientes, concluímos que

$$0 \geqslant b^2 - 4ac = 4[\mathbb{E}[UV]]^2 - 4\,\mathbb{E}[U^2]\,\mathbb{E}[V^2],$$

e, dividindo por 4, obtemos (18). ∎

Vamos agora completar o resultado anunciado na subseção anterior. Sejam X e Y variáveis aleatórias com $\mathrm{Var}(X) > 0$ e $\mathrm{Var}(Y) > 0$, de modo que $\rho(X,Y)$ está definido. Tomando $U = X - \mathbb{E}[X]$ e $V = Y - \mathbb{E}[Y]$ em Teorema 15, notamos que

$$\mathbb{E}[U^2] = \mathrm{Var}(X), \qquad \mathbb{E}[V^2] = \mathrm{Var}(Y), \qquad \mathbb{E}[UV] = \mathrm{Cov}(X,Y),$$

e, portanto,

$$\mathrm{Cov}(X,Y)^2 \leqslant \mathrm{Var}(X)\ \mathrm{Var}(Y).$$

Dividindo por $\mathrm{Var}(X)\,\mathrm{Var}(Y) > 0$ e usando a definição $\rho(X,Y) = \mathrm{Cov}(X,Y)/(\sigma_X\sigma_Y)$, concluímos que $\rho(X,Y)^2 \leqslant 1$, isto é,

$$-1 \leqslant \rho(X,Y) \leqslant 1.$$

2.8. A Caracterização dos Casos Extremos

Os valores $\rho(X,Y) = \pm 1$ só ocorrem em circunstâncias especiais. Para identificá-las, vamos reexaminar a prova de Teorema 15 com as escolhas $U = X - \mathbb{E}[X]$ e $V = Y - \mathbb{E}[Y]$ feitas acima; lembramos que $\mathrm{Var}(X) > 0$ e $\mathrm{Var}(Y) > 0$, pois fora disso $\rho(X,Y)$ não está definido. O polinômio quadrático (19) torna-se $g(s) = as^2 + bs + c$, com

$$a = \mathrm{Var}(X), \qquad b = 2\,\mathrm{Cov}(X,Y), \qquad c = \mathrm{Var}(Y),$$

e, para cada $s \in \mathbb{R}$,

$$g(s) = \mathbb{E}\Big[(s(X - \mathbb{E}[X]) + (Y - \mathbb{E}[Y]))^2\Big] \geqslant 0.$$

Suponha $\rho(X,Y) = \pm 1$. Então $ac = \mathrm{Var}(X)\,\mathrm{Var}(Y) > 0$ e o discriminante se anula:

$$b^2 - 4ac = 4\,\mathrm{Cov}(X,Y)^2 - 4\,\mathrm{Var}(X)\,\mathrm{Var}(Y) = 4\,\mathrm{Var}(X)\,\mathrm{Var}(Y)[\rho(X,Y)^2 - 1] = 0.$$

Como $a > 0$ e $b^2 - 4ac = 0$, a equação $g(s) = 0$ possui uma raiz dupla $s = s_0$, com $s_0 = -b/(2a)$. A variável aleatória

$$W = s_0(X - \mathbb{E}[X]) + (Y - \mathbb{E}[Y])$$

satisfaz $\mathbb{E}[W^2] = g(s_0) = 0$. Além disso, $\mathbb{E}[W] = 0$, de modo que $\mathrm{Var}(W) = \mathbb{E}[W^2] = 0$ e, por (5), concluímos que $\mathbb{P}(W = 0) = 1$. Isso significa que

$$\mathbb{P}(Y = \alpha X + \beta) = 1, \qquad \text{com} \qquad \alpha = -s_0 = \frac{\mathrm{Cov}(X,Y)}{\mathrm{Var}(X)} \quad \text{e} \quad \beta = \mathbb{E}[Y] - \alpha\,\mathbb{E}[X].$$

O sinal de α é o sinal de $\rho(X,Y)$: de fato, como $\mathrm{Var}(Y) = \alpha^2\,\mathrm{Var}(X)$, vale $\sigma_Y = |\alpha|\sigma_X$ e, portanto,

$$\rho(X,Y) = \frac{\mathrm{Cov}(X,Y)}{\sigma_X\sigma_Y} = \frac{\alpha\,\mathrm{Var}(X)}{\sigma_X\,|\alpha|\sigma_X} = \frac{\alpha}{|\alpha|}.$$

Assim, $\alpha > 0$ quando $\rho(X,Y) = 1$ e $\alpha < 0$ quando $\rho(X,Y) = -1$. Reciprocamente, se $\mathbb{P}(Y = \alpha X + \beta) = 1$ com $\alpha \neq 0$, então $\mathrm{Cov}(X,Y) = \alpha\,\mathrm{Var}(X)$ e $\mathrm{Var}(Y) = \alpha^2\,\mathrm{Var}(X)$, e o cálculo acima dá $\rho(X,Y) = \alpha/|\alpha|$. Ficam assim estabelecidas as duas equivalências

$$\rho(X,Y) = 1 \quad \text{se, e somente se,} \quad \mathbb{P}(Y = \alpha X + \beta) = 1 \text{ para algum } \alpha > 0 \text{ e } \beta \in \mathbb{R}, \tag{20}$$

$$\rho(X,Y) = -1 \quad \text{se, e somente se,} \quad \mathbb{P}(Y = \alpha X + \beta) = 1 \text{ para algum } \alpha < 0 \text{ e } \beta \in \mathbb{R}. \tag{21}$$

Recapitulando, quando $\mathrm{Var}(X) > 0$ e $\mathrm{Var}(Y) > 0$, o coeficiente $\rho(X,Y)$ pertence ao intervalo $[-1,1]$ e pode ser lido como uma medida da dependência entre X e Y à luz dos valores -1, 0 e 1:

- se X e Y são independentes, então $\rho(X, Y) = 0$;
- $\rho(X, Y) = 1$ se, e somente se, Y é função linear crescente de X;
- $\rho(X, Y) = -1$ se, e somente se, Y é função linear decrescente de X.

Nos dois últimos casos, a relação linear vale quase certamente, como estabelecem (20) e (21).

Observação 16 (Variáveis não correlacionadas)**.** Dizemos que X e Y são "não correlacionadas" quando $\rho(X, Y) = 0$, o que equivale a $\mathrm{Cov}(X, Y) = 0$. A independência implica não correlação, pois $\mathrm{Cov}(X, Y) = 0$ quando $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$, mas a recíproca é falsa: como mostra Exemplo 12, é possível que $\mathrm{Cov}(X, Y) = 0$ sem que X e Y sejam independentes. A não correlação registra apenas a ausência de relação linear entre as variáveis, enquanto a independência controla toda forma de dependência.

3. Funções Geradoras de Momentos

3.1. Definição e Exemplos

Na nota sobre funções geradoras de probabilidade estudamos, em detalhe, a ferramenta que associa a uma variável aleatória X com valores em $\{0, 1, 2, \ldots\}$ a função

$$G_X(s) = \mathbb{E}\left[s^X\right] = \sum_{k=0}^{\infty} s^k \, \mathbb{P}(X = k), \tag{22}$$

definida para os s reais para os quais a série converge. Lá vimos que G_X determina a distribuição de X, que suas derivadas em $s = 1$ produzem os momentos fatoriais de X e que ela se comporta bem sob somas de variáveis independentes. Recordamos aqui apenas a definição, pois vamos precisar dela para comparar com o objeto novo desta seção.

A limitação de (22) é imediata: a expressão só faz sentido quando X toma valores inteiros não negativos. Se X é, por exemplo, uma variável com densidade ou uma variável discreta que assume valores negativos, não há como escrever s^X como potência inteira de s com expoente aleatório e a construção não se aplica. Para variáveis gerais, o costume é substituir a potência de base livre s pela exponencial de base fixa e, cujo expoente é o produto tX. A vantagem é que e^{tX} está definida para todo x real e todo t real, de modo que a esperança pode ser formada sempre que o integrando ou a série correspondente for absolutamente integrável ou somável.

Definição 17 (Função geradora de momentos)**.** A *função geradora de momentos* da variável aleatória X é a função M_X definida por

$$M_X(t) = \mathbb{E}\left[e^{tX}\right], \tag{23}$$

para todo $t \in \mathbb{R}$ para o qual essa esperança existe e é finita.

Precisamos ser explícitos quanto ao domínio. Em (23) o símbolo $M_X(t)$ só está definido quando $\mathbb{E}\left[e^{tX}\right]$ converge; quando não converge, dizemos que a função geradora de momentos não existe naquele t. Além disso, como $e^{tX} > 0$, a esperança em (23) ou é finita ou é $+\infty$, e não há ambiguidade de sinal. Assim, o domínio de M_X é um subconjunto de $\mathbb{R}$ que contém $t = 0$, pois $M_X(0) = \mathbb{E}[1] = 1$.

Para variáveis que tomam valores em $\{0, 1, 2, \ldots\}$, a definição nova é uma modificação da anterior. De fato, tomando $s = e^t$ em (22) obtemos

$$M_X(t) = \mathbb{E}\Big[e^{tX}\Big] = \mathbb{E}\Big[(e^t)^X\Big] = G_X(e^t), \tag{24}$$

desde que a série em (22) convirja em $s = e^t$, o que ocorre em particular para todo $t \leqslant 0$. Quando o raio de convergência da série é estritamente maior do que 1, a identidade vale também para uma faixa de valores positivos de t: no caso da distribuição de Poisson, por exemplo, a série converge para todo $s \in \mathbb{R}$ e a identidade vale em toda a reta.

Em geral, separando os casos discreto e contínuo, a definição se lê como

$$M_X(t) = \mathbb{E}\Big[e^{tX}\Big] = \begin{cases} \displaystyle\sum_x e^{tx}\,\mathbb{P}(X = x), & \text{se } X \text{ é discreta,} \\ \displaystyle\int_{-\infty}^{\infty} e^{tx}\, f_X(x)\, dx, & \text{se } X \text{ é contínua,} \end{cases} \tag{25}$$

sempre que a soma ou a integral converge absolutamente. A exigência de convergência absoluta não é um detalhe técnico dispensável: é o que garante que a soma ou a integral não dependa da ordem em que seus termos são adicionados, de modo que o valor de $M_X(t)$ esteja bem definido. Como veremos nos exemplos seguintes, a existência de $M_X(t)$ para $t \neq 0$ pode falhar, e falha com frequência suficiente para merecer atenção.

Começamos pelo caso em que a função existe em toda a reta.

Exemplo 18 (A geradora da normal padrão)**.** Seja $X \sim \mathrm{N}(0, 1)$. Vamos calcular $\mathbb{E}\Big[e^{tX}\Big]$ para $t \in \mathbb{R}$ fixado. Como o integrando é não negativo, a integral imprópria está bem definida, ainda que possa valer $+\infty$; vamos calcular e verificar que o valor é finito.

$$\begin{aligned} M_X(t) &= \int_{-\infty}^{\infty} e^{tx}\, \frac{1}{\sqrt{2\pi}}\, e^{-\frac{1}{2}x^2}\, dx \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}\left(x^2 - 2tx\right)}\, dx. \end{aligned}$$

A ideia é completar o quadrado no expoente, escrevendo $x^2 - 2tx = (x - t)^2 - t^2$. Isso separa do integrando um fator que não depende de x e deixa no lugar da exponencial a densidade de uma normal de média t e variância 1. Obtemos

$$\begin{aligned} M_X(t) &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(x-t)^2 + \frac{1}{2}t^2}\, dx \\ &= e^{\frac{1}{2}t^2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}}\, e^{-\frac{1}{2}(x-t)^2}\, dx. \end{aligned} \tag{26}$$

A integral que restou é a integral, sobre toda a reta, da densidade de uma variável normal com média t e variância 1. Por isso ela vale 1, e concluímos que

$$M_X(t) = e^{\frac{1}{2}t^2}, \qquad t \in \mathbb{R}.$$

Em particular, a função geradora de momentos da normal padrão existe para todo t real, o que é o melhor comportamento possível.

Exemplo 19 (A geradora da exponencial)**.** Seja $X \sim \mathrm{Exp}(\lambda)$, com densidade $f_X(x) = \lambda e^{-\lambda x}$ para $x > 0$ e $f_X(x) = 0$ para $x \leqslant 0$. Como $X > 0$ quase certamente, e^{tX} é decrescente em X quando $t < 0$, e a esperança deve ser finita nesse caso; para $t \geqslant 0$ a exponencial cresce e precisamos verificar diretamente. Escrevemos, usando $f_X(x) = 0$ para $x \leqslant 0$,

$$M_X(t) = \int_0^\infty e^{tx}\, \lambda e^{-\lambda x}\, dx = \lambda \int_0^\infty e^{-(\lambda - t)x}\, dx.$$

O integrando é positivo, logo a integral imprópria tem valor bem definido em $[0, +\infty]$, e o cálculo é uma integral exponencial elementar.

Se $t < \lambda$, o expoente $-(\lambda - t)x$ é negativo para $x > 0$ e a integral converge, valendo $1/(\lambda - t)$. Se $t \geqslant \lambda$, o expoente é não negativo; quando $t = \lambda$ o integrando é a constante λ, e quando $t > \lambda$ ele cresce exponencialmente, de modo que em ambos os casos a integral diverge para $+\infty$. Resumindo,

$$M_X(t) = \begin{cases} \dfrac{\lambda}{\lambda - t}, & \text{se } t < \lambda, \\ +\infty, & \text{se } t \geqslant \lambda. \end{cases}$$

Portanto $M_X(t)$ existe apenas para $t < \lambda$, um intervalo semiaberto à esquerda de λ que contém a origem. O domínio é assimétrico: não há simetria entre valores positivos e negativos de t, o que reflete a assimetria da própria distribuição exponencial.

Exemplo 20 (Uma variável sem geradora de momentos)**.** Seja X com densidade $f_X(x) = 1/[\pi(1 + x^2)]$, isto é, X com distribuição de Cauchy. Para $t = 0$ o integrando é a própria densidade e temos $M_X(0) = 1$. Vamos mostrar que, para todo $t \neq 0$, a esperança é infinita.

Suponha primeiro $t > 0$. Então $e^{tx} \to +\infty$ quando $x \to +\infty$ e $e^{tx} \to 0$ quando $x \to -\infty$. Para decidir a convergência, examinamos o comportamento do integrando

$$g_t(x) = \frac{e^{tx}}{\pi(1 + x^2)}$$

quando $x \to +\infty$. Para obter uma cota inferior, observamos que $1 + x^2 \leqslant 2x^2$ para $x \geqslant 1$, de modo que

$$g_t(x) = \frac{e^{tx}}{\pi(1 + x^2)} \geqslant \frac{e^{tx}}{2\pi x^2}, \qquad x \geqslant 1.$$

A função $x \mapsto e^{tx}/x^2$ tende a $+\infty$, pois a exponencial cresce mais rápido do que qualquer polinômio; logo existe $x_0 \geqslant 1$ tal que $e^{tx}/x^2 \geqslant 1$ para todo $x \geqslant x_0$, e portanto $g_t(x) \geqslant 1/(2\pi)$ nesse intervalo. A integral de g_t sobre $[x_0, \infty)$ diverge para $+\infty$, e o mesmo ocorre com $\int_{-\infty}^{\infty} g_t$.

Suponha agora $t < 0$. Desta vez $e^{tx} \to +\infty$ quando $x \to -\infty$. No extremo $x \to -\infty$ escrevemos $u = -x \to +\infty$, e a mesma comparação se aplica: a densidade se comporta como $1/(\pi u^2)$ e $e^{tx} = e^{-|t|u}$, de modo que o integrando é limitado inferiormente por uma constante positiva a partir de algum ponto e a integral diverge para $+\infty$. Reunindo os dois casos,

$$M_X(t) = \begin{cases} 1, & \text{se } t = 0, \\ +\infty, & \text{se } t \neq 0. \end{cases}$$

Assim, M_X existe apenas em $t = 0$. Note ainda que a esperança de X não existe, o que já sugere que a distribuição de Cauchy não pode ter uma geradora de momentos útil.

O último exemplo mostra que a dificuldade com a existência de $\mathbb{E}\left[e^{tX}\right]$ é intrínseca e não se resolve com uma escolha melhor de parametrização. Há uma forma de contorná-la: estudar a função característica $\phi_X(t) = \mathbb{E}\left[e^{itX}\right]$, com $i = \sqrt{-1}$, que envolve números complexos e existe para todo $t \in \mathbb{R}$ porque $|e^{itX}| = 1$. Esse caminho, porém, depende de integração complexa e de argumentos de análise de Fourier que ficam fora do escopo destas notas; ficamos, portanto, com a função geradora de momentos e convivemos com a restrição.

Para o que faremos em seguida isso é suficiente, porque o que realmente importa não é que $M_X(t)$ exista em todos os t, mas que exista em uma vizinhança $(-\delta, \delta)$ da origem, para algum $\delta > 0$. Essa condição é a que permite derivar M_X repetidamente em $t = 0$ e recuperar os momentos de X, e é também a hipótese do teorema de unicidade que garante que a função geradora determina a distribuição. Sempre que usarmos uma geradora de momentos em momentos de t diferentes de zero, ou em vizinhanças de zero, essa existência local será um pressuposto implícito.

Resta explicar o nome. A justificativa é o desenvolvimento, intuitivamente atraente, da exponencial em série de potências:

$$\begin{aligned} M_X(t) = \mathbb{E}\left[e^{tX}\right] &= \mathbb{E}\left(1 + tX + \frac{1}{2!}(tX)^2 + \cdots\right) \\ &= 1 + t\,\mathbb{E}[X] + \frac{1}{2!}\,t^2\,\mathbb{E}\left[X^2\right] + \cdots . \end{aligned} \tag{27}$$

Os coeficientes são, a menos dos fatoriais, os momentos de X: o termo de ordem n em t é $\frac{1}{n!}t^n\mathbb{E}[X^n]$. É nesse sentido que M_X é a função geradora exponencial dos momentos de X.

Devemos ser honestos quanto ao estatuto de (27) neste ponto: o cálculo acima é apenas formal. Trocamos a esperança pela soma infinita e permutamos a soma sobre n com a soma ou a integral que define a esperança, e nenhuma dessas passagens foi justificada. Elas exigem, entre outras coisas, que $\mathbb{E}\left[e^{tX}\right]$ exista em uma vizinhança da origem, o que já sabemos não ser verdadeiro em geral. A justificativa rigorosa será dada pelo teorema de unicidade das funções geradoras de momentos, mais adiante, do qual segue também que derivar (27) termo a termo produz os momentos: $\mathbb{E}[X^n] = M_X^{(n)}(0)$. Por ora, guardamos (27) como a motivação do nome e como um guia para o que esperamos que seja verdadeiro.

3.2. Momentos, Transformações Lineares e Somas

Nas subseções anteriores usamos a função geradora de momentos como um objeto que codifica a distribuição de uma variável aleatória. Vamos agora extrair dela duas consequências operacionais: a recuperação dos momentos por derivação em $t = 0$, e o comportamento da geradora sob transformações lineares e sob somas de variáveis aleatórias independentes.

Antes de enunciar o primeiro resultado, precisamos deixar claro o que significa existir. Como $e^{tX} > 0$, a esperança $\mathbb{E}[e^{tX}]$ está sempre bem definida, eventualmente valendo $+\infty$; dizemos então que $M_X(t)$ *existe* em t quando essa esperança é finita, isto é, quando $M_X(t) < \infty$. Dizemos que $M_X(t)$ existe numa vizinhança de 0 quando existe $\delta > 0$ tal que $M_X(t) < \infty$ para todo $t \in (-\delta, \delta)$. Essa é a hipótese que garante a existência de todos os momentos de X.

Teorema 21 (Momentos por derivação da função geradora)**.** Suponha que $M_X(t)$ existe numa vizinhança de 0. Então $\mathbb{E}[|X|^k]$ é finita para todo $k \geqslant 1$ e

$$\mathbb{E}\Big[X^k\Big] = M_X^{(k)}(0), \tag{28}$$

onde $M_X^{(k)}(0)$ denota a k-ésima derivada de M_X calculada em $t = 0$.

Ideia da prova. O ponto de partida é a definição de derivada aplicada à função $t \mapsto M_X(t) = \mathbb{E}[e^{tX}]$. No caso $k = 1$, para t numa vizinhança de 0,

$$M_X'(t) = \lim_{h\to 0} \frac{M_X(t+h) - M_X(t)}{h} = \lim_{h\to 0} \mathbb{E}\left[\frac{e^{(t+h)X} - e^{tX}}{h}\right].$$

Para cada ω fixado, o quociente de diferenças converge para $X(\omega)e^{tX(\omega)}$, de modo que o limite dentro da esperança é $\mathbb{E}[Xe^{tX}]$. O que falta justificar é a passagem do limite para dentro do operador de esperança. Esse é o ponto delicado da demonstração e é exatamente onde o livro opta por não entrar: é preciso um majorante integrável que não dependa de h, e a existência de $M_X(t)$ numa vizinhança de 0 fornece esse majorante para t próximo de 0. Trata-se do mesmo tipo de argumento de convergência dominada que usamos nas notas sobre densidades condicionais para derivar sob o sinal de esperança; não vamos reproduzi-lo aqui em detalhe, mas registramos que é ele, e não a manipulação formal, que sustenta a identidade

$$\frac{d}{dt} M_X(t) = \mathbb{E}\Big[Xe^{tX}\Big].$$

Uma vez obtida essa identidade para t próximo de 0, podemos repetir o argumento: o lado direito é novamente uma esperança de uma função derivável de t, com a mesma estrutura e o mesmo tipo de majorante, de modo que derivar k vezes sucessivamente conduz a

$$\frac{d^k}{dt^k} M_X(t) = \mathbb{E}\Big[X^k e^{tX}\Big].$$

Fazendo $t = 0$, o fator $e^{0\cdot X}$ se reduz a 1 e obtemos (28). ■

Com o teorema acima, os momentos deixam de ser quantidades que precisam ser calculadas por somas ou integrais separadas: eles ficam armazenados nas derivadas de M_X em 0. Vejamos agora como a geradora se comporta sob duas operações que aparecem o tempo todo em probabilidade.

Transformações lineares. Seja X uma variável aleatória e considere $aX + b$, com $a, b \in \mathbb{R}$. Fixado t, o expoente se decompõe em um fator que depende de X e um fator constante, e podemos usar a linearidade da esperança no fator constante:

$$\begin{aligned} M_{aX+b}(t) &= \mathbb{E}\Big[e^{t(aX+b)}\Big] = \mathbb{E}\Big[e^{atX} e^{tb}\Big] \\ &= e^{tb}\, \mathbb{E}\Big[e^{(at)X}\Big] = e^{tb} M_X(at), \end{aligned}$$

sempre que $M_{aX+b}(t)$ seja finita, o que ocorre precisamente quando $M_X(at)$ é finita. A primeira igualdade é a definição de função geradora de momentos aplicada a $aX + b$; na segunda usamos $e^{u+v} = e^u e^v$; na terceira, que e^{tb} não depende de ω e pode sair da esperança. Concluímos que

$$M_{aX+b}(t) = e^{tb} M_X(at). \tag{29}$$

Assim, uma mudança de escala em X dilata o argumento de M_X, e uma translação multiplica a geradora por uma exponencial. Note que, se $a = 0$, a variável $aX + b$ é a constante b e (29) fornece $e^{tb} M_X(0) = e^{tb}$, como esperado.

Somas de variáveis independentes. Boa parte da teoria da probabilidade gira em torno de somas de variáveis aleatórias. Obter a distribuição de uma soma a partir das distribuições das parcelas costuma ser trabalhoso: nas notas sobre somas de variáveis aleatórias contínuas fizemos isso por convolução, identificando a densidade de $X + Y$ com a convolução das densidades de X e de Y, cálculo que frequentemente envolve integrais desconfortáveis. As funções geradoras de momentos são úteis aqui porque transformam somas em produtos, e produtos são fáceis de manipular.

Teorema 22 (Geradora da soma de duas variáveis independentes)**.** Sejam X e Y variáveis aleatórias independentes e suponha que $M_X(t)$ e $M_Y(t)$ são finitas. Então $M_{X+Y}(t)$ é finita e

$$M_{X+Y}(t) = M_X(t)\, M_Y(t). \tag{30}$$

Prova. Como $t(X + Y) = tX + tY$, podemos escrever o integrando como um produto:

$$M_{X+Y}(t) = \mathbb{E}\Big[e^{t(X+Y)}\Big] = \mathbb{E}\Big[e^{tX} e^{tY}\Big].$$

Aqui entra a independência. Nas notas sobre independência de variáveis aleatórias, e mais geralmente nas notas sobre vetores aleatórios, vimos que, se X e Y são independentes, então $\mathbb{E}[g(X)h(Y)] = \mathbb{E}[g(X)]\mathbb{E}[h(Y)]$ para funções mensuráveis g e h para as quais as esperanças envolvidas façam sentido. Aplicamos esse resultado com $g(x) = e^{tx}$ e $h(y) = e^{ty}$, que são mensuráveis e não negativas, logo fora do caso de indeterminação. Segue que

$$\mathbb{E}\Big[e^{tX} e^{tY}\Big] = \mathbb{E}\Big[e^{tX}\Big]\mathbb{E}\Big[e^{tY}\Big] = M_X(t) M_Y(t).$$

Como as duas geradoras são finitas por hipótese, o produto é finito e portanto $M_{X+Y}(t)$ é finita, o que justifica as passagens acima. Isto prova (30). ∎

O mesmo argumento se estende a qualquer número finito de parcelas independentes. Sejam $X_1, \ldots, X_n$ independentes e $S = X_1 + \cdots + X_n$. Provamos por indução sobre n que

$$M_S(t) = M_{X_1}(t) \cdots M_{X_n}(t), \tag{31}$$

válida em todo t em que todas as geradoras do lado direito sejam finitas. Para $n = 1$ a identidade é a definição de M_{X_1}. Suponha o resultado verdadeiro para $n - 1$ e escreva $S = X_1 + \cdots + X_{n-1} + X_n$. Se $X_1, \ldots, X_n$ são independentes, então o vetor $(X_1, \ldots, X_{n-1})$ é independente de X_n (é o que as notas sobre vetores aleatórios chamam de independência entre um vetor e uma variável). Em particular, a soma $S_{n-1} = X_1 + \cdots + X_{n-1}$ é independente de X_n, pois é função do vetor $(X_1, \ldots, X_{n-1})$. Podemos, portanto, aplicar o caso de duas variáveis, Teorema 22, com $X = S_{n-1}$ e $Y = X_n$, e depois a hipótese de indução:

$$M_S(t) = M_{S_{n-1}}(t)\, M_{X_n}(t) = M_{X_1}(t) \cdots M_{X_{n-1}}(t)\, M_{X_n}(t),$$

o que conclui a indução. A etapa de indução usa explicitamente o teorema para duas variáveis; é ele que faz o trabalho de transformar a soma de n parcelas em um produto de n fatores.

O ganho prático é o seguinte. Para identificar a distribuição de uma soma, podemos calcular o produto das geradoras, que é uma operação algébrica, e depois reconhecer a distribuição cuja geradora é aquele produto. Nada de convoluções: o preço a pagar está na última etapa, que exige saber ler a tabela de geradoras no sentido inverso. Voltaremos a esse ponto quando discutirmos a unicidade da função geradora de momentos.

3.3. O Teorema de Unicidade e a Soma de Duas Normais

O desenvolvimento formal da seção anterior produziu a expansão (27) da função geradora de momentos em série de potências. Para que esse cálculo signifique algo, precisamos saber que a função geradora de momentos determina a distribuição da variável aleatória. O resultado a seguir garante exatamente isso.

Teorema 23 (Unicidade das funções geradoras de momentos)**.** Seja X variável aleatória cuja função geradora de momentos $M_X(t) = \mathbb{E}[e^{tX}]$ satisfaz $M_X(t) < \infty$ para todo t com $|t| < \delta$, em que $\delta > 0$. Então valem as duas conclusões a seguir. (i) Existe uma única distribuição com função geradora de momentos M_X. (ii) Todos os momentos $\mathbb{E}[X^k]$ são finitos, para $k = 1, 2, \ldots$, e vale a expansão em série de potências

$$M_X(t) = \sum_{k \geqslant 0} \frac{t^k}{k!}\, \mathbb{E}[X^k], \qquad |t| < \delta. \tag{32}$$

Não demonstramos este teorema. Ele é, em essência, o teorema de inversão da transformada de Laplace. De fato, quando X é absolutamente contínua, com densidade f_X, vale $M_X(t) = \int_{-\infty}^{+\infty} e^{tx} f_X(x)\, dx$, que é a transformada de Laplace de f_X, a menos do sinal do parâmetro; e o teorema de inversão afirma que, quando essa transformada existe de modo adequado, a densidade f_X pode ser recuperada da transformada por uma fórmula de inversão. A igualdade (32) é a mesma expansão de (27), mas a passagem exige cuidado: é preciso justificar a permutação entre a esperança $\mathbb{E}$ e a soma, como observamos após (27). O teorema é o que dá rigor ao desenvolvimento formal apresentado antes. Existe também uma relação estreita com Teorema 5, o teorema de unicidade dos momentos: trata-se do mesmo fenômeno, visto pelo lado da série de momentos.

Vamos aplicar a parte de unicidade do teorema em um exemplo em que ela é indispensável.

Exemplo 24 (Soma de duas normais independentes)**.** Sejam $X \sim \mathrm{N}(\mu_1, \sigma_1^2)$ e $Y \sim \mathrm{N}(\mu_2, \sigma_2^2)$ variáveis aleatórias independentes. Mostre que a soma $Z = X + Y$ tem distribuição $\mathrm{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

Solução. Começamos calculando a função geradora de momentos de uma normal geral. Seja $U \sim \mathrm{N}(\mu, \sigma^2)$, com $\mu \in \mathbb{R}$ e $\sigma > 0$. Fixado $t \in \mathbb{R}$, vamos calcular $M_U(t) = \mathbb{E}[e^{tU}]$. O integrando $e^{tu} f_U(u)$ é positivo, de modo que a integral converge absolutamente e podemos manipulá-la livremente. A ideia do cálculo é dupla: a substituição $x = (u - \mu)/\sigma$ transfere a integral para a normal padrão, e o completamento de quadrado no expoente absorve o termo

linear em x criado por $e^{\sigma t x}$, restando a massa total de uma densidade normal. Assim,

$$\begin{aligned} M_U(t) &= \int_{-\infty}^{+\infty} e^{tu}\,\frac{1}{\sqrt{2\pi\sigma^2}}\,\exp\!\left(-\frac{(u-\mu)^2}{2\sigma^2}\right) du \\ &= e^{\mu t}\int_{-\infty}^{+\infty} e^{\sigma t x}\,\frac{1}{\sqrt{2\pi}}\,e^{-\frac{1}{2}x^2}\,dx \qquad \text{com } x=\frac{u-\mu}{\sigma} \\ &= e^{\mu t+\frac{1}{2}\sigma^2 t^2}\int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi}}\,e^{-\frac{1}{2}(x-\sigma t)^2}\,dx \\ &= \exp\!\left(\mu t+\frac{\sigma^2 t^2}{2}\right), \end{aligned} \tag{33}$$

para todo $t\in\mathbb{R}$. Na segunda linha usamos $u=\mu+\sigma x$, de modo que $du=\sigma\,dx$ e $e^{tu}=e^{\mu t}e^{\sigma t x}$; na terceira completamos o quadrado,

$$\sigma t x-\frac{x^2}{2}=-\frac{(x-\sigma t)^2}{2}+\frac{\sigma^2 t^2}{2},$$

e, na quarta, a integral restante é a massa total da densidade de $\mathrm{N}(\sigma t,1)$, logo vale 1.

Voltemos a X e Y. Como as duas variáveis são independentes, Teorema 22 nos dá $M_Z(t)=M_X(t)\,M_Y(t)$ para todo t em que as duas geradoras são finitas. Aplicando (33) a cada parcela, obtemos

$$\begin{aligned} M_Z(t) &= M_X(t)\,M_Y(t) \\ &= \exp\!\left(\mu_1 t+\frac{\sigma_1^2 t^2}{2}\right)\exp\!\left(\mu_2 t+\frac{\sigma_2^2 t^2}{2}\right) \\ &= \exp\!\left[(\mu_1+\mu_2)t+\frac{(\sigma_1^2+\sigma_2^2)t^2}{2}\right]. \end{aligned}$$

O lado direito é exatamente (33) com $\mu=\mu_1+\mu_2$ e $\sigma^2=\sigma_1^2+\sigma_2^2$: trata-se da função geradora de momentos de $\mathrm{N}(\mu_1+\mu_2,\sigma_1^2+\sigma_2^2)$, que é finita para todo $t\in\mathbb{R}$. Assim, vale a hipótese de Teorema 23 para qualquer $\delta>0$, e a conclusão de unicidade desse teorema dá que Z tem essa distribuição: se $W\sim\mathrm{N}(\mu_1+\mu_2,\sigma_1^2+\sigma_2^2)$, então $Z\overset{d}{=}W$.

Na nota sobre somas de variáveis aleatórias contínuas, obtivemos a soma de gamas independentes por convolução das densidades; o argumento por funções geradoras é bem mais curto, e a normal é o caso em que essa economia aparece com clareza.

4. Exercícios propostos

Os exercícios a seguir percorrem os três temas centrais desta nota: o cálculo de momentos por integração direta, o estudo da variância e da covariância e o uso das funções geradoras de momentos como instrumento de cálculo e de identificação de distribuições. Alguns deles pedem apenas a execução de uma integral já preparada no texto; outros exigem que você reconheça qual resultado da nota se aplica e verifique suas hipóteses antes de usá-lo. Salvo menção explícita em contrário, todas as variáveis aleatórias têm esperança e variância finitas e as integrais que aparecem convergem absolutamente.

Momentos

1. Uma moeda honesta é lançada indefinidamente. No k-ésimo lançamento, o apostador recebe 0 se o resultado for coroa e $2/3^k$ se o resultado for cara. Seja X o ganho total do apostador na sequência infinita de lançamentos. Mostre que X tem a distribuição de Cantor.

Sugestão: escreva X como soma das contribuições de cada lançamento, usando indicadoras dos eventos "cara no k-ésimo lançamento", e determine a função de distribuição de X. A construção da distribuição de Cantor foi feita nas notas sobre funções de distribuição; reconheça ali o mesmo objeto.

∗ **2.** Mostre que o conjunto de Cantor é não enumerável.

3. Se X é uniformemente distribuída no intervalo (a, b), mostre que

$$\mathbb{E}[X^k] = \frac{b^{k+1} - a^{k+1}}{(b-a)(k+1)} \qquad \text{para } k = 1, 2, \ldots.$$

4. Se X tem distribuição gama com parâmetros w e λ, mostre que

$$\mathbb{E}[X^k] = \frac{\Gamma(w+k)}{\lambda^k\,\Gamma(w)} \qquad \text{para } k = 1, 2, \ldots.$$

Nota: usamos a convenção de densidade adotada nas notas sobre somas de variáveis aleatórias, em que

$$f_X(x) = \frac{\lambda^w}{\Gamma(w)}\, x^{w-1} e^{-\lambda x}, \qquad x > 0,$$

com $w > 0$ o parâmetro de forma e $\lambda > 0$ a taxa. Verifique, antes de começar, que a integral que define $\mathbb{E}[X^k]$ converge para todo $k \geqslant 1$.

5. Se X tem distribuição χ^2 com n graus de liberdade, mostre que

$$\mathbb{E}[X^k] = 2^k\, \frac{\Gamma\left(k + \frac{1}{2}n\right)}{\Gamma\left(\frac{1}{2}n\right)} \qquad \text{para } k = 1, 2, \ldots.$$

Sugestão: observe que a distribuição χ^2 com n graus de liberdade é o caso particular $w = n/2$ e $\lambda = 1/2$ da distribuição gama e aplique o exercício anterior.

Variância e covariância

∗ **6.** Sejam X e Y variáveis aleatórias com distribuição normal bivariada de parâmetros μ_1, μ_2, σ_1, σ_2 e ρ. Mostre que

$$\mathrm{Cov}(X, Y) = \rho\,\sigma_1\sigma_2 \qquad \text{e} \qquad \rho(X, Y) = \rho.$$

Nota: a densidade normal bivariada já foi estudada nas notas sobre densidades condicionais. Use a expressão da densidade lá obtida e, para calcular $\mathrm{Cov}(X, Y)$, comece determinando $\mathbb{E}[X \mid Y]$, tal como fizemos naquelas notas. Este exercício justifica o nome do parâmetro ρ: ele é, de fato, o coeficiente de correlação entre as coordenadas.

7. Sejam $X_1, X_2, \ldots$ variáveis aleatórias não correlacionadas, todas com variância σ^2. Escreva $S_n = X_1 + X_2 + \cdots + X_n$ para $n \geqslant 1$. Mostre que

$$\mathrm{Cov}(S_m, S_n) = \mathrm{Var}(S_m) = m\sigma^2 \qquad \text{se } m < n.$$

Sugestão: use a bilinearidade da covariância e a hipótese de que $\mathrm{Cov}(X_i, X_j) = 0$ para $i \neq j$. Note que a hipótese $m < n$ apenas escolhe as duas somas de modo que S_m seja a menor delas: para $m > n$ a mesma conta dá $\mathrm{Cov}(S_m, S_n) = n\sigma^2$, pois cada parcela de S_n aparece também em S_m.

∗ **8.** Mostre que $\operatorname{Cov}(X, Y) = 1$ quando X e Y têm densidade conjunta

$$f(x,y) = \begin{cases} \dfrac{1}{y}\, e^{-y-x/y}, & \text{se } x, y > 0, \\ 0, & \text{caso contrário.} \end{cases}$$

Sugestão: condicione em Y para calcular $\mathbb{E}[X \mid Y]$ e, depois, $\mathbb{E}[X]$; ou trabalhe diretamente com a densidade conjunta, calculando as integrais iteradas na ordem mais conveniente.

Funções geradoras de momentos

9. Determine a função geradora de momentos de uma variável aleatória com

(a) distribuição gama de parâmetros w e λ;

(b) distribuição de Poisson de parâmetro λ.

Nota: em (a), use a mesma convenção de densidade do exercício 4, com λ como taxa. Em ambos os itens, indique o intervalo de valores de t para os quais a FGM está definida.

10. Se X tem distribuição normal com média μ e variância σ^2, determine $\mathbb{E}[X^3]$.

Sugestão: a FGM da normal foi calculada nesta nota. Derive-a três vezes em t e avalie o resultado em $t = 0$; verifique que a derivação sob o sinal de integral é legítima em uma vizinhança de 0.

11. Mostre que, se X tem distribuição normal, então $aX + b$ também tem distribuição normal, quaisquer que sejam $a, b \in \mathbb{R}$ com $a \neq 0$.

Sugestão: use a unicidade das funções geradoras de momentos, vista nesta nota, e a expressão da FGM da distribuição normal para calcular a FGM de $aX + b$ e reconhecê-la como a FGM de uma normal.

∗ **12.** Sejam $X_1, X_2, \ldots$ variáveis aleatórias independentes e identicamente distribuídas, com função geradora de momentos comum M. Seja N uma variável aleatória que assume valores inteiros não negativos, com função geradora de probabilidade G, e suponha que N seja independente da sequência (X_i). Mostre que a soma aleatória $S = X_1 + X_2 + \cdots + X_N$ tem função geradora de momentos

$$M_S(t) = G\Big(M(t)\Big).$$

Sugestão: condicione no valor de N e use a independência para fatorar a esperança. O resultado é a versão, na linguagem das funções geradoras de momentos, da composição de funções geradoras de probabilidade estudada nas notas sobre funções geradoras de probabilidade, onde a soma de um número aleatório de parcelas foi examinada no caso discreto. A composição obtida aqui também explica por que G precisa assumir valores não negativos no ponto $M(t)$.

Nota: a independência mútua das parcelas X_i é indispensável, e não apenas a independência entre N e a sequência. Sem ela a identidade $M_{X_1+\cdots+X_n}(t) = M(t)^n$ pode falhar, e com ela o resultado deixa de valer. O enunciado impresso do livro que seguimos menciona apenas que as variáveis são identicamente distribuídas; acrescentamos a hipótese que falta para que o enunciado seja verdadeiro.

Referências

[1] Geoffrey Grimmett and Dominic Welsh. *Probability—an introduction*. Oxford University Press, Oxford, second edition, 2014.