

Variáveis Aleatórias Discretas

L. Cioletti

Agosto de 2026

Resumo

Nestas notas introduzimos o conceito de variáveis aleatórias discreta e de função de probabilidade. Como exemplos, apresentamos algumas das famílias mais clássicas de variáveis aleatórias discretas: Bernoulli; binomial; Poisson; geométrica e binomial negativa. Demostramos também um resultado conhecido como a Lei dos Eventos Raros que consiste basicamente em obter uma aproximação da distribuição binomial pela de Poisson. Ao longo do texto mostramos como calcular a função de probabilidade de funções de variáveis aleatórias e discutimos, brevemente, a noção de igualdade em distribuição. O texto segue de perto as Seções 2.1–2.3 do Capítulo 2 de Grimmett e Welsh [1].

1. Variáveis aleatórias discretas

Estas notas dão continuidade ao desenvolvimento da teoria da probabilidade iniciado nas notas *Espaços de Probabilidade*, onde o modelo probabilístico consistindo do espaço amostral, σ -álgebra de eventos e da medida de probabilidade foi introduzido. Aqui vamos apresentar o conceito de variável aleatória discreta e o que é a função de probabilidade associada à uma variável aleatória e algumas de suas propriedades mais básicas.

1.1. Funções de Probabilidade

Dado um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$, frequentemente estamos interessados em situações envolvendo alguma função com valores reais, por exemplo, $X : \Omega \rightarrow \mathbb{R}$. Mais precisamente, seja $\mathcal{E}$ o experimento de lançar um dado honesto uma vez e $\Omega = \{1, 2, 3, 4, 5, 6\}$ o espaço amostral associado a este experimento aleatório. Vamos supor que vamos fazer uma aposta baseada no resultado deste experimento $\mathcal{E}$ de tal modo que de acordo com o resultado do experimento podemos ter lucro ou prejuízo ou nenhum ganho segundo a seguinte tabela

- -1 se o resultado é 1, 2 ou 3,
- 0 se o resultado é 4,
- 2 se o resultado é 5 ou 6,

Podemos pensar em cada resultado do experimento $\mathcal{E}$ como sendo um ponto $\omega \in \Omega$. Assim, se definimos uma função $X : \Omega \rightarrow \mathbb{R}$ dada por

$$X(1) = X(2) = X(3) = -1, \quad X(4) = 0, \quad X(5) = X(6) = 2,$$

então esta função pode ser usada para modelar qual foi o ganho ou perda da realização deste jogo. A função X , como veremos a seguir, é um exemplo de uma *variável aleatória discreta*.

A primeira vista esta definição parece um pouco estranha, pois podemos pensar que uma função, a rigor, é um objeto matemático completamente determinístico. A ideia de que a função X fornece uma noção de variável aleatória é baseada no fato que a associação $\omega \mapsto X(\omega)$ possui algum grau de aleatoriedade devido ao fato da escolha do ponto ω no domínio de X ser aleatória. Mas há, na verdade, uma outra razão que será apresentada após introduzirmos a noção de função de probabilidade e de certas classes de equivalência.

Mais formalmente, uma variável aleatória discreta X no espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$ é definida como uma função $X : \Omega \rightarrow \mathbb{R}$ tal que a imagem $X(\Omega)$ é um subconjunto enumerável de $\mathbb{R}$ ¹ e

$$\{\omega \in \Omega : X(\omega) = x\} \in \mathcal{F} \quad \text{para } x \in \mathbb{R}. \quad (1)$$

A palavra “discreta” aqui se refere à condição de que X assume apenas uma quantidade enumerável de valores em $\mathbb{R}$.² A condição (1) é obscura à primeira vista, e o ponto aqui é o seguinte. Uma variável aleatória discreta X assume valores em $\mathbb{R}$, mas não podemos prever com certeza o valor efetivo de X , uma vez que o experimento subjacente $\mathcal{E}$ envolve o acaso. Em vez disso, gostaríamos de medir a probabilidade de X assumir um dado valor, digamos x . Para isso, observamos que X assume o valor x se, e somente se, o resultado do experimento $\mathcal{E}$ pertence àquele subconjunto de Ω que é mapeado em x , ou seja, o subconjunto

$$X^{-1}(x) = \{\omega \in \Omega : X(\omega) = x\}.$$

A condição (1) postula que todos esses subconjuntos são eventos, no sentido de que pertencem a $\mathcal{F}$, e portanto podemos atribuir a cada um destes conjuntos uma probabilidade segundo a medida de probabilidade $\mathbb{P}$.

O que há de mais interessante em uma variável aleatória discreta são os valores que ela pode assumir e as probabilidades associadas a esses valores. Se X é uma variável aleatória discreta no espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$, então sua *imagem* $\text{Im } X$ é a imagem de Ω por X , isto é, o conjunto dos valores assumidos por X .

De agora em diante, abreviamos eventos da forma $\{\omega \in \Omega : X(\omega) = x\}$ para a forma mais conveniente $\{X = x\}$.

Definição 1. A *função de probabilidade* (ou também conhecida como função de massa de probabilidade) associada à uma variável aleatória discreta X é a função $p_X : \mathbb{R} \rightarrow [0, 1]$ definida por

$$p_X(x) = \mathbb{P}(X = x). \quad (2)$$

¹Se $X : \Omega \rightarrow \mathbb{R}$ e $A \subseteq \Omega$, a imagem de A é o conjunto $X(A) = \{X(\omega) : \omega \in A\}$ dos valores assumidos por X em A .

²Uma definição ligeiramente diferente, mas moralmente equivalente, de variável aleatória discreta é uma função $X : \Omega \rightarrow \mathbb{R}$ tal que existe um subconjunto enumerável $S \subseteq \mathbb{R}$ com $\mathbb{P}(X \in S) = 1$.

Assim, $p_X(x)$ é a probabilidade de a função X assumir o valor x . Note que $\text{Im } X$ é enumerável para qualquer variável aleatória discreta X , e para $x \notin \text{Im } X$ temos que o evento $\{X = x\} = \emptyset$ e portanto

$$p_X(x) = \mathbb{P}(X = x) = \mathbb{P}(\emptyset) = 0 \quad \text{se } x \notin \text{Im } X. \quad (3)$$

Outra observação importante é que é consequência direta das propriedades elementares de imagem inversa de uma função é que se $x \neq x'$ então $\{X = x\} \cap \{X = x'\} = \emptyset$ e

$$\bigcup_{x \in \text{Im } X} \{X = x\} = \Omega$$

e conseqüentemente, temos

$$\sum_{x \in \text{Im } X} p_X(x) = \mathbb{P}\left(\bigcup_{x \in \text{Im } X} \{\omega \in \Omega : X(\omega) = x\}\right) = \mathbb{P}(\Omega) = 1. \quad (4)$$

A equação (4) é às vezes pode ser escrita como

$$\sum_{x \in \mathbb{R}} p_X(x) = 1,$$

tendo em vista que somente uma quantidade enumerável de valores de x dá contribuição não nula para essa soma. A condição (4) caracteriza essencialmente as funções de massa de variáveis aleatórias discretas, no sentido do seguinte teorema.

Teorema 2. Seja $S = \{s_i : i \in I\}$ um conjunto enumerável de números reais distintos, e seja $\{\pi_i : i \in I\}$ uma coleção de números reais satisfazendo

$$\pi_i \geq 0 \quad \text{para } i \in I, \text{ e } \sum_{i \in I} \pi_i = 1.$$

Então existe um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$ e uma variável aleatória discreta X em $(\Omega, \mathcal{F}, \mathbb{P})$ tal que a função de massa de probabilidade de X é dada por

$$\begin{aligned} p_X(s_i) &= \pi_i \quad \text{para } i \in I, \\ p_X(s) &= 0 \quad \text{se } s \notin S. \end{aligned}$$

Prova. Tome $\Omega = S$, seja $\mathcal{F}$ o conjunto das partes de Ω , e

$$\mathbb{P}(A) = \sum_{i: s_i \in A} \pi_i \quad \text{para } A \in \mathcal{F}.,$$

Com a convenção que a soma sobre o conjunto vazio é zero. É imediato verificar que os axiomas de Kolmogorov são satisfeitos e portanto que $(\Omega, \mathcal{F}, \mathbb{P})$ como definidos acima é de fato um espaço de probabilidade.

A variável aleatória desejada é fornecida pela função $X : \Omega \rightarrow \mathbb{R}$ dada por $X(\omega) = \omega$ para $\omega \in \Omega$. De fato, para cada $s \in S$ temos

$$p_X(s_i) \equiv \mathbb{P}\{X = s_i\} = \sum_{j: s_j \in \{s_i\}} \pi_{s_j} = \pi_{s_i}.$$

■

Esse teorema é extremamente muito útil, pois, para muitos fins, ele nos permite esquecer circunstancialmente os espaços amostrais, as σ -álgebras e as medidas de probabilidade. Desta forma podemos trabalhar em um ambiente mais abstrato e simplesmente usar expressões como:

“seja X uma variável aleatória que assume o valor s_i com probabilidade π_i , para cada $i \in I$ ”




Figura 1: Gráfico da função probabilidade definida pela sequência $\pi_i = p_X(s_i)$, com conjunto de índices $I = \{0, 1, 2, 3, \dots\}$.

sabendo que tal variável aleatória existe, sem precisar construí-la explicitamente. Este ponto de vista permite também identificar variáveis aleatórias que tomam mesmos valores e possuem a mesma função de probabilidade. Sugerindo que a maioria das propriedades intrinsecamente probabilísticas de uma variável aleatória estão completamente codificadas na função de probabilidade, fazendo que com menções a qual espaço de probabilidade esta variável está definida, seja uma questão de menor importância na teoria.




Figura 2: Função indicadora $\mathbf{1}_E : \Omega \rightarrow \mathbb{R}$ de um evento $E \subseteq \Omega$, que vale 1 em E e 0 fora de E .

No caso da variável aleatória dada pela função indicadora de um evento E em $(\Omega, \mathcal{F}, \mathbb{P})$ temos que sua função probabilidade é dada por

$$p_{\mathbf{1}_E}(0) = \mathbb{P}(\{\mathbf{1}_E = 0\}) = \mathbb{P}(E^c), \quad p_{\mathbf{1}_E}(1) = \mathbb{P}(\{\mathbf{1}_E = 1\}) = \mathbb{P}(E)$$

e

$$p_{\mathbf{1}_E}(x) = 0, \quad \forall x \in \mathbb{R} \setminus \{0, 1\}.$$

Na próxima seção, apresentamos uma lista de alguns dos tipos mais comuns de variáveis aleatórias discretas.

Exercício 1. Se X e Y são variáveis aleatórias discretas no espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$, mostre que U e V dadas por

$$U(\omega) = X(\omega) + Y(\omega), \quad V(\omega) = X(\omega)Y(\omega), \quad \text{para } \omega \in \Omega.$$

também são variáveis aleatórias discretas nesse espaço de probabilidade.

Exercício 2. Mostre que, se $\mathcal{F}$ é o conjunto das partes de Ω , então todas as funções que mapeiam Ω em um subconjunto enumerável de $\mathbb{R}$ são variáveis aleatórias discretas.

Exercício 3. Se E é um evento do espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$, mostre que a função indicadora de E , definida como a função $\mathbb{1}_E$ em Ω dada por

$$\mathbb{1}_E(\omega) = \begin{cases} 1 & \text{se } \omega \in E, \\ 0 & \text{se } \omega \notin E, \end{cases}$$

é uma variável aleatória discreta.

Exercício 4. Seja X uma variável aleatória discreta no espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$, cuja imagem é o conjunto enumerável $\text{Im } X = \{s_i : i \in I\}$. Mostre que X pode ser escrita como uma soma (possivelmente enumerável) de múltiplos reais de funções indicadoras, mais precisamente,

$$X = \sum_{i \in I} s_i \mathbb{1}_{\{X=s_i\}},$$

no sentido de que, para cada $\omega \in \Omega$, a soma acima converge e é igual a $X(\omega)$. *Dica:* fixe $\omega \in \Omega$ e determine quantos termos da soma são não nulos.

Exercício 5. Seja $(\Omega, \mathcal{F}, \mathbb{P})$ um espaço de probabilidade no qual

$$\Omega = \{1, 2, 3, 4, 5, 6\}, \quad \mathcal{F} = \{\emptyset, \{2, 4, 6\}, \{1, 3, 5\}, \Omega\},$$

e sejam U, V, W funções em Ω definidas por

$$U(\omega) = \omega, \quad V(\omega) = \begin{cases} 1 & \text{se } \omega \text{ é par,} \\ 0 & \text{se } \omega \text{ é ímpar,} \end{cases} \quad \text{e} \quad W(\omega) = \omega^2,$$

para todo $\omega \in \Omega$. Determine quais das funções U , V e W definem variáveis aleatórias discretas nesse espaço de probabilidade.

Exercício 6. Para que valor de c a função p , definida por

$$p(k) = \begin{cases} \frac{c}{k(k+1)} & \text{se } k = 1, 2, \dots, \\ 0 & \text{caso contrário,} \end{cases}$$

é uma função de probabilidade de alguma variável aleatória?

1.2. Exemplos

Certos tipos de variáveis aleatórias discretas ocorrem com frequência, e listamos algumas delas a seguir. Observamos que ao longo desta seção, n denota um inteiro positivo, p é um número em $[0, 1]$ e $q = 1 - p$. Como observado acima será supérfluo por hora descrever o espaço de probabilidade subjacente.

Distribuição de Bernoulli. Esta é a distribuição não trivial mais simples. Dizemos que a variável aleatória discreta X tem a distribuição de Bernoulli com parâmetro p se X assume apenas os valores 0 e 1.

Uma variável aleatória X desse tipo é frequentemente chamada simplesmente de *lançamento de moeda*. Existe $p \in [0, 1]$ tal que

$$\mathbb{P}(X = 0) = q, \quad \mathbb{P}(X = 1) = p, \quad (5)$$

e a função de massa de probabilidade de X é dada por

$$p_X(0) = q, \quad p_X(1) = p, \quad p_X(x) = 0 \text{ se } x \neq 0, 1.$$

Neste caso usamos a notação $X \sim \text{Bernoulli}(p)$.

Lançamentos de moeda são os blocos de construção da teoria da probabilidade. Há um sentido em que toda a teoria pode ser construída a partir de uma sequência infinita de lançamentos de moeda. Note que a função indicadora da [Figura 2](#) fornece uma variável aleatória do tipo Bernoulli.

Distribuição binomial. Dizemos que X tem a distribuição binomial com parâmetros n e p se X assume valores em $\{0, 1, \dots, n\}$ e

$$\mathbb{P}(X = k) = \binom{n}{k} p^k q^{n-k} \quad \text{para } k = 0, 1, 2, \dots, n. \quad (6)$$

Note que (6) dá origem a uma função de probabilidade já ela é não-negativa e satisfaz (4). De fato, pelo teorema binomial, temos

$$\sum_{k=0}^n \binom{n}{k} p^k q^{n-k} = (p + q)^n = 1.$$

Vamos usar a notação $X \sim \text{Bin}(n, p)$, quando X for uma variável aleatória (v.a.) com distribuição binomial de parâmetros n e p .




Figura 3: Função de probabilidade da distribuição binomial com parâmetros $n = 5$ e $p = 0,2$.




Figura 4: Função de probabilidade da distribuição binomial com parâmetros $n = 8$ e $p = 0,3$.




Figura 5: Função de probabilidade da distribuição binomial com parâmetros $n = 20$ e $p = 0,6$.




Figura 6: Função de probabilidade da distribuição binomial com parâmetros $n = 15$ e $p = 0,7$.

Distribuição de Poisson. Dizemos que X tem a distribuição de Poisson com parâmetro λ , onde $\lambda > 0$, se X assume valores em $\{0, 1, 2, \dots\}$ e satisfaz

$$\mathbb{P}(X = k) = \frac{1}{k!} \lambda^k e^{-\lambda} \quad \text{para } k = 0, 1, 2, \dots \quad (7)$$

Novamente, isso dá origem a uma função de probabilidade, pois

$$\sum_{k=0}^{\infty} \frac{1}{k!} \lambda^k e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{1}{k!} \lambda^k = e^{-\lambda} e^{\lambda} = 1.$$

Neste caso usamos a notação $X \sim \text{Poisson}(\lambda)$.




Figura 7: Função de probabilidade de uma Poisson(4).

Distribuição geométrica. Dizemos que X tem a distribuição geométrica com parâmetro $p \in (0, 1)$ se X assume valores em $\{1, 2, 3, \dots\}$ e

$$\mathbb{P}(X = k) = pq^{k-1} \quad \text{para } k = 1, 2, 3, \dots \quad (8)$$

Usando a fórmula da soma de uma progressão geométrica e que p e q somam um temos

$$\sum_{k=1}^{\infty} pq^{k-1} = \frac{p}{1-q} = \frac{p}{p} = 1.$$

Neste caso usamos a notação $X \sim \text{Geom}(p)$.

Distribuição binomial negativa. Dizemos que X tem a distribuição binomial negativa com parâmetros n e $p \in (0, 1)$ se X assume valores em $\{n, n+1, n+2, \dots\}$ e

$$\mathbb{P}(X = k) = \binom{k-1}{n-1} p^n q^{k-n} \quad \text{para } k = n, n+1, n+2, \dots \quad (9)$$

Como antes, note que

$$\begin{aligned} \sum_{k=n}^{\infty} \binom{k-1}{n-1} p^n q^{k-n} &= p^n \sum_{l=0}^{\infty} \binom{n+l-1}{l} q^l \quad \text{com } l = k - n \\ &= p^n \sum_{l=0}^{\infty} \binom{-n}{l} (-q)^l \\ &= p^n (1 - q)^{-n} = 1, \end{aligned}$$

usando a expansão binomial generalizada de $(1 - q)^{-n}$. Neste caso usamos a notação $X \sim \text{BinNeg}(n, p)$.

Para referência futura, resumimos na [Tabela 1](#) as distribuições discretas apresentadas nesta seção, juntamente com a notação usada para cada uma delas.

Tabela 1: Resumo das distribuições discretas desta seção. Em todos os casos, $q = 1 - p$ e a entrada da coluna “Notação” deve ser lida como $X \sim \dots$

Distribuição	Parâmetros	Suporte	$p_X(k)$	Notação
Bernoulli	$p \in [0, 1]$	$\{0, 1\}$	$p^k q^{1-k}$	Bernoulli(p)
Binomial	$n \geq 1, p \in [0, 1]$	$\{0, 1, \dots, n\}$	$\binom{n}{k} p^k q^{n-k}$	Bin(n, p)
Poisson	$\lambda > 0$	$\{0, 1, 2, \dots\}$	$e^{-\lambda} \lambda^k / k!$	Poisson(λ)
Geométrica	$p \in (0, 1)$	$\{1, 2, 3, \dots\}$	$p q^{k-1}$	Geom(p)
Bin. negativa	$n \geq 1, p \in (0, 1)$	$\{n, n+1, \dots\}$	$\binom{k-1}{n-1} p^n q^{k-n}$	BinNeg(n, p)

Exemplo 3. Eis um exemplo de algumas das distribuições acima em ação. Suponha que uma moeda seja lançada n vezes e que a probabilidade de sair cara em cada lançamento seja p . Representando cara por H e coroa por T, o espaço amostral é o conjunto Ω de todas as sequências ordenadas de comprimento n contendo as letras H e T, em que a k -ésima entrada de tal sequência representa o resultado do k -ésimo lançamento. Isto é,

$$\Omega \equiv \underbrace{\{H, T\} \times \{H, T\} \times \dots \times \{H, T\}}_{n \text{ cópias}}$$

O conjunto Ω é finito, e tomamos $\mathcal{F}$ como o conjunto das partes de Ω . Para cada $\omega \in \Omega$, definimos a probabilidade de que ω pela seguinte expressão

$$\mathbb{P}(\omega) = p^{h(\omega)} q^{t(\omega)},$$

onde $h(\omega)$ é o número de caras em ω e $t(\omega) = n - h(\omega)$ é o número de coroas. De maneira natural estendemos a definição de $\mathbb{P}$ para um evento arbitrário $A \in \mathcal{F}$ por

$$\mathbb{P}(A) = \sum_{\omega \in A} \mathbb{P}(\omega).$$

Para $i = 1, 2, \dots, n$, definimos a variável aleatória discreta X_i por

$$X_i(\omega) = \begin{cases} 1 & \text{se a } i\text{-ésima entrada de } \omega \text{ é H,} \\ 0 & \text{se a } i\text{-ésima entrada de } \omega \text{ é T.} \end{cases}$$

Cada X_i assume valores em $\{0, 1\}$ e tem função de probabilidade dada por

$$\mathbb{P}(X_i = 0) = \mathbb{P}(\{\omega \in \Omega : \omega_i = \text{T}\}),$$

onde ω_i é a i -ésima entrada de ω . Assim,

$$\begin{aligned} \mathbb{P}(X_i = 0) &= \sum_{\substack{\omega \in \Omega \\ \omega_i = \text{T}}} p^{h(\omega)} q^{n-h(\omega)} \\ &= \sum_{h=0}^{n-1} \sum_{\substack{\omega \in \Omega : \omega_i = \text{T} \\ h(\omega) = h}} p^h q^{n-h} = \sum_{h=0}^{n-1} \binom{n-1}{h} p^h q^{n-h} q (p+q)^{n-1} = q \end{aligned}$$

e

$$\mathbb{P}(X_i = 1) = 1 - \mathbb{P}(X_i = 0) = p.$$

Portanto, cada X_i tem distribuição do tipo Bernoulli de parâmetro p .

Embora esta dedução seja um pouco trabalhosa, acreditamos que esses detalhes são instrutivos e ilustra várias ideias importantes quando estamos trabalhando em espaços que são do tipo produto cartesiano e que terão um papel importante no estudo de variáveis aleatórias independente, conceito este que será definido mais a frente.

Vamos prosseguir com mais uma observação importante sobre este exemplo. Considere a variável aleatória

$$S_n = X_1 + X_2 + \dots + X_n,$$

ou seja, $S_n(\omega) = X_1(\omega) + X_2(\omega) + \dots + X_n(\omega)$. Claramente, S_n é o número total de caras que ocorrem, e S_n assume valores em $\{0, 1, \dots, n\}$, pois cada X_i é igual a 0 ou 1. Além disso, para cada $k = 0, 1, \dots, n$, temos que

$$\begin{aligned} \mathbb{P}(S_n = k) &= \mathbb{P}(\{\omega \in \Omega : h(\omega) = k\}) \\ &= \sum_{\omega \in \Omega : h(\omega) = k} \mathbb{P}(\omega) \\ &= \binom{n}{k} p^k q^{n-k}, \end{aligned} \tag{10}$$

e assim S_n tem a distribuição binomial de parâmetros n e p .

Se n é muito grande e p é muito pequeno, mas np tem um “tamanho razoável” (digamos, $np = \lambda$), então a distribuição de S_n pode ser aproximada pela distribuição de Poisson com

parâmetro λ , da seguinte forma. Para $k \geq 0$ fixo, escrevemos $p = \lambda/n$ e, supondo que n seja grande, obtemos

$$\begin{aligned}
\mathbb{P}(S_n = k) &= \binom{n}{k} p^k (1-p)^{n-k} \\
&= \frac{n!}{(n-k)! k!} p^k (1-p)^{n-k} \\
&= \frac{n(n-1) \cdots (n-k+1)}{k!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \\
&= \frac{n^k}{k!} \left(\frac{n(n-1) \cdots (n-k+1)}{n^k}\right) \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \\
&\sim \frac{n^k}{k!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-k} \\
&\sim \frac{1}{k!} \lambda^k e^{-\lambda}.
\end{aligned} \tag{11}$$

Essa aproximação pode ser útil na prática. Por exemplo, considere uma única página do jornal Guardian contendo, digamos, 10^6 caracteres, e suponha que o tipógrafo lança uma moeda antes de compor cada caractere e então, deliberadamente, compõe incorretamente esse caractere sempre que a moeda cai em cara. Se a moeda cai em cara com probabilidade 10^{-5} em cada lançamento, então isso equivale a tomar $n = 10^6$ e $p = 10^{-5}$ no exemplo acima, de modo que o número S_n de erros deliberados tem a distribuição binomial com parâmetros 10^6 e 10^{-5} . Pode ser mais fácil (e não muito impreciso) usar (11) em vez de (10) para calcular probabilidades. Nesse caso, $\lambda = np = 10$ e, por exemplo,

$$\mathbb{P}(S_n = 10) \approx \frac{1}{10!} (10e^{-1})^{10} \approx 0,125.$$

O cálculo heurístico que acabamos de fazer no **Exemplo 3** pode ser transformado em um resultado preciso, conhecido como a *lei dos eventos raros* (ou teorema do limite de Poisson).

Teorema 4 (Lei dos eventos raros). Seja $(p_n)_{n \geq 1}$ uma sequência de números em $[0, 1]$ tal que $np_n \rightarrow \lambda$ quando $n \rightarrow \infty$, para algum $\lambda > 0$. Então, para cada $k \in \{0, 1, 2, \dots\}$ fixo,

$$\lim_{n \rightarrow \infty} \binom{n}{k} p_n^k (1-p_n)^{n-k} = e^{-\lambda} \frac{\lambda^k}{k!}.$$

Em outras palavras, se $X_n \sim \text{Bin}(n, p_n)$ com $np_n \rightarrow \lambda$ e $Y \sim \text{Poisson}(\lambda)$, então $\mathbb{P}(X_n = k) \rightarrow \mathbb{P}(Y = k)$ para cada k fixo. Assim, a distribuição binomial com n grande e p pequeno, de modo que np tenha um tamanho moderado, é bem aproximada pela distribuição de Poisson de parâmetro $\lambda = np$.

Prova. Defina $\lambda_n = np_n$, de modo que $p_n = \lambda_n/n$ e $\lambda_n \rightarrow \lambda$. Para $n \geq k$, escrevemos

$$\binom{n}{k} p_n^k (1-p_n)^{n-k} = \frac{n(n-1) \cdots (n-k+1)}{k!} \left(\frac{\lambda_n}{n}\right)^k \left(1 - \frac{\lambda_n}{n}\right)^{n-k}.$$

Separando o fator $\lambda_n^k/k!$, isso pode ser reescrito como

$$\binom{n}{k} p_n^k (1-p_n)^{n-k} = \frac{\lambda_n^k}{k!} \cdot \frac{n(n-1) \cdots (n-k+1)}{n^k} \cdot \left(1 - \frac{\lambda_n}{n}\right)^n \cdot \left(1 - \frac{\lambda_n}{n}\right)^{-k}.$$

Vamos analisar o limite de cada um dos três últimos fatores quando $n \rightarrow \infty$, lembrando que $\lambda_n \rightarrow \lambda$ e que k é fixo. Primeiro,

$$\frac{n(n-1) \cdots (n-k+1)}{n^k} = \prod_{j=0}^{k-1} \left(1 - \frac{j}{n}\right) \rightarrow 1,$$

pois trata-se de um produto finito de fatores, cada um dos quais tende a 1. Segundo,

$$\left(1 - \frac{\lambda_n}{n}\right)^n \rightarrow e^{-\lambda},$$

pelo limite fundamental $\left(1 + \frac{a_n}{n}\right)^n \rightarrow e^a$, válido quando $a_n \rightarrow a$, aplicado aqui com $a_n = -\lambda_n \rightarrow -\lambda$. Terceiro,

$$\left(1 - \frac{\lambda_n}{n}\right)^{-k} \rightarrow 1,$$

pois $\lambda_n/n \rightarrow 0$. Além disso, $\lambda_n^k \rightarrow \lambda^k$. Multiplicando todos os limites, obtemos

$$\lim_{n \rightarrow \infty} \binom{n}{k} p_n^k (1-p_n)^{n-k} = \frac{\lambda^k}{k!} \cdot 1 \cdot e^{-\lambda} \cdot 1 = e^{-\lambda} \frac{\lambda^k}{k!},$$

como queríamos demonstrar. ■

A [Tabela 2](#) ilustra numericamente a convergência obtida acima. Nela comparamos a probabilidade $\mathbb{P}(X = k)$ calculada pela distribuição $\text{Bin}(100, \frac{5}{100})$ com a probabilidade correspondente calculada pela distribuição $\text{Poisson}(5)$. Note que $np = 100 \cdot 0,05 = 5 = \lambda$.

Tabela 2: Comparação entre as distribuições $\text{Bin}(100, \frac{5}{100})$ e $\text{Poisson}(5)$.

k	$\text{Bin}(100, \frac{5}{100})$	$\text{Poisson}(5)$
0	0,0059	0,0067
1	0,0312	0,0337
2	0,0812	0,0842
3	0,1396	0,1404
4	0,1781	0,1755
5	0,1800	0,1755
6	0,1500	0,1462
7	0,1060	0,1044
8	0,0649	0,0653
9	0,0349	0,0363
10	0,0167	0,0181

Observe que as duas colunas são praticamente idênticas, mesmo com $n = 100$ não sendo particularmente grande. Quanto maior for n e menor for p , mantendo $np = \lambda$ fixo, melhor é a aproximação. Este é o conteúdo preciso do cálculo heurístico realizado no [Exemplo 3](#).

Exemplo 5. Suponha que lançamos a moeda do **Exemplo 3** até que a primeira cara apareça, e então paramos. O espaço amostral agora é

$$\Omega = \{H, TH, T^2H, \dots\} \cup \{T^\infty\},$$

onde T^kH representa o resultado de k coroas seguidas de uma cara, e T^∞ representa uma sequência infinita de coroas sem nenhuma cara. Como antes, $\mathcal{F}$ é o conjunto das partes de Ω , e $\mathbb{P}$ é dada pela expressão

$$\begin{aligned} \mathbb{P}(T^kH) &= pq^k \quad \text{para } k = 0, 1, 2, \dots, \\ \mathbb{P}(T^\infty) &= \begin{cases} 1 & \text{se } p = 0, \\ 0 & \text{se } p > 0. \end{cases} \end{aligned}$$

Seja Y o número total de lançamentos neste experimento, de modo que $Y(T^kH) = k + 1$ para $0 \leq k < \infty$ e $Y(T^\infty) = \infty$. Se $p > 0$, então

$$\mathbb{P}(Y = k) = \mathbb{P}(T^{k-1}H) = pq^{k-1} \quad \text{para } k = 1, 2, \dots,$$

mostrando que, para $p \in (0, 1)$, Y tem a distribuição geométrica com parâmetro p .

Exemplo 6. Se continuarmos a lançar a moeda do **Exemplo 5** até que a n -ésima cara tenha aparecido, então um argumento semelhante mostra que, se $p \in (0, 1)$, o número total de lançamentos necessário tem a distribuição binomial negativa com parâmetros n e p .

Exercício 7. Se X é uma variável aleatória discreta com distribuição de Poisson de parâmetro λ , mostre que a probabilidade de que X seja par é $e^{-\lambda} \cosh \lambda$.

Exercício 8. Se X é uma variável aleatória discreta com distribuição geométrica de parâmetro p , mostre que a probabilidade de que X seja maior do que k é $(1 - p)^k$.

1.3. Funções de variáveis aleatórias discretas

Seja X uma variável aleatória discreta no espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$ e seja $g : \mathbb{R} \rightarrow \mathbb{R}$. É fácil verificar que a composição de funções $Y \equiv g \circ X$ também é uma variável aleatória discreta em $(\Omega, \mathcal{F}, \mathbb{P})$, definida por

$$Y(\omega) = g(X(\omega)) \quad \text{para } \omega \in \Omega.$$

Exemplos simples são

$$\begin{aligned} \text{se } g(x) &= ax + b \quad \text{então } g(X) = aX + b, \\ \text{se } g(x) &= cx^2 \quad \text{então } g(X) = cX^2. \end{aligned}$$

Se $Y = g(X)$, a função de probabilidade de Y é dada por

$$\begin{aligned} p_Y(y) &= \mathbb{P}(Y = y) = \mathbb{P}(g(X) = y) \\ &= \mathbb{P}(X \in g^{-1}(y)) \\ &= \sum_{x \in g^{-1}(y)} \mathbb{P}(X = x), \end{aligned} \tag{12}$$

uma vez que essa soma possui apenas uma quantidade enumerável de contribuições não nulas. Assim, se $Y = aX + b$ com $a \neq 0$, então

$$\mathbb{P}(Y = y) = \mathbb{P}(aX + b = y) = \mathbb{P}(X = a^{-1}(y - b)) \quad \text{para } y \in \mathbb{R},$$

enquanto, se $Y = X^2$, então

$$\mathbb{P}(Y = y) = \begin{cases} \mathbb{P}(X = \sqrt{y}) + \mathbb{P}(X = -\sqrt{y}), & \text{se } y > 0; \\ \mathbb{P}(X = 0), & \text{se } y = 0; \\ 0, & \text{se } y < 0. \end{cases}$$

Exercício 9. Seja X uma variável aleatória discreta com distribuição de Poisson de parâmetro λ , e seja $Y = |\sin(\frac{1}{2}\pi X)|$. Determine a função de probabilidade de Y .

2. Equivalência entre Variáveis Aleatórias

Sejam $(\Omega, \mathcal{F}, \mathbb{P})$ um espaço de probabilidade e $X : \Omega \rightarrow S$ uma variável aleatória com função de probabilidade p_X , onde $S = \{s_i : i \in I\}$ é um conjunto enumerável de números reais distintos. Suponha que $(\tilde{\Omega}, \tilde{\mathcal{F}}, \tilde{\mathbb{P}})$ seja um outro espaço de probabilidade e $Y : \tilde{\Omega} \rightarrow S$ uma outra variável aleatória com função de probabilidade p_Y .

Vamos dizer que X e Y possuem a mesma distribuição e escrever $X \stackrel{d}{=} Y$ se a seguinte condição for satisfeita: $p_X(s) = p_Y(s)$ para todo $s \in S$. Neste caso, veremos que as propriedades intrinsecamente probabilísticas destas duas variáveis aleatórias são as mesmas, de modo que tanto faz usar uma ou outra para responder a certos tipos de perguntas. Esta observação motiva a identificar estas duas funções $X : \Omega \rightarrow S$ e $Y : \tilde{\Omega} \rightarrow S$ e considerar a classe de equivalência de tais funções também como uma variável aleatória com função de probabilidade dada, por exemplo, por p_X . Embora este conceito de variável aleatória seja muito mais abstrato, ele pode ser útil quando for conveniente mudar de espaço e de descrição de uma variável aleatória ao longo da solução de um problema. Em particular, escrevendo $\{X = x\}$ em vez da notação de funções e pré-imagens como $\{\omega \in \Omega : X(\omega) = x\}$, temos a vantagem de evitar falar do espaço onde a v.a. é construída e focar apenas nas propriedades resultantes de sua função de probabilidade.

Para tornar essas ideias concretas, vejamos dois exemplos que mostram, com todos os detalhes, o que a igualdade em distribuição afirma e, talvez mais importante, o que ela *não* afirma!

Exemplo 7. Considere o experimento de lançar um dado honesto uma vez. Temos $\Omega = \{1, 2, 3, 4, 5, 6\}$, $\mathcal{F}$ é o conjunto das partes de Ω , e $\mathbb{P}(A) = |A|/6$ para $A \in \mathcal{F}$, onde $|A|$ denota o número de elementos de A . Definimos duas variáveis aleatórias discretas $X, Y : \Omega \rightarrow \mathbb{R}$ por

$$X(\omega) = \omega \quad \text{e} \quad Y(\omega) = 7 - \omega \quad \text{para } \omega \in \Omega.$$

Assim, X registra o resultado do lançamento, enquanto Y registra o número da face oposta à face sorteadas (em um dado padrão, as faces opostas somam 7).

Vamos calcular as funções de probabilidade de X e de Y . Para cada $k \in \{1, 2, 3, 4, 5, 6\}$,

$$p_X(k) = \mathbb{P}(X = k) = \mathbb{P}(\{\omega \in \Omega : \omega = k\}) = \mathbb{P}(\{k\}) = \frac{1}{6},$$

e

$$p_Y(k) = \mathbb{P}(Y = k) = \mathbb{P}(\{\omega \in \Omega : 7 - \omega = k\}) = \mathbb{P}(\{7 - k\}) = \frac{1}{6}.$$

Portanto, $p_X(k) = p_Y(k) = 1/6$ para todo $k \in \{1, \dots, 6\}$, e ambas são nulas fora desse conjunto. Logo, $X \stackrel{d}{=} Y$.

Entretanto, X e Y são funções diferentes. De fato, para todo $\omega \in \Omega$,

$$X(\omega) = \omega \neq 7 - \omega = Y(\omega),$$

pois a igualdade $\omega = 7 - \omega$ implicaria $2\omega = 7$, o que é impossível para ω inteiro. Assim, $X(\omega) \neq Y(\omega)$ para todo $\omega \in \Omega$.

Concluimos que X e Y têm a mesma distribuição, mas são funções distintas. A igualdade em distribuição é, portanto, estritamente mais fraca que a igualdade de funções.

Exemplo 8. A igualdade em distribuição não apenas é mais fraca que a igualdade de funções: ela faz sentido em uma situação em que a igualdade de funções sequer pode ser enunciada, a saber, quando as variáveis estão definidas em espaços amostrais diferentes.

Considere, além do dado do **Exemplo 7**, um segundo experimento: lançar uma moeda honesta, que produz 0 ou 1, e em seguida sortear, com chances iguais, um dos números 0, 1, 2. O espaço amostral deste segundo experimento é

$$\tilde{\Omega} = \{0, 1\} \times \{0, 1, 2\},$$

cujos seis elementos são os pares ordenados (i, j) com $i \in \{0, 1\}$ e $j \in \{0, 1, 2\}$. Tomamos $\tilde{\mathcal{F}}$ como o conjunto das partes de $\tilde{\Omega}$ e definimos $\tilde{\mathbb{P}}$ atribuindo a cada um dos seis resultados a probabilidade $1/6$.

Definimos $Z : \tilde{\Omega} \rightarrow \mathbb{R}$ associando a cada par um número distinto de 1 a 6, conforme a tabela

$\tilde{\omega}$	(0, 0)	(1, 0)	(0, 1)	(1, 1)	(0, 2)	(1, 2)
$Z(\tilde{\omega})$	1	2	3	4	5	6

Como cada ponto de $\tilde{\Omega}$ tem probabilidade $1/6$ e Z é uma bijeção de $\tilde{\Omega}$ em $\{1, \dots, 6\}$, temos, para cada $k \in \{1, \dots, 6\}$,

$$p_Z(k) = \tilde{\mathbb{P}}(Z = k) = \frac{1}{6}.$$

Comparando com a variável X do **Exemplo 7**, obtemos $p_Z(k) = p_X(k)$ para todo k , e portanto $Z \stackrel{d}{=} X$.

Observe, contudo, que X e Z estão definidas em espaços amostrais diferentes: $X : \Omega \rightarrow \mathbb{R}$ e $Z : \tilde{\Omega} \rightarrow \mathbb{R}$, com $\Omega \neq \tilde{\Omega}$. Nesse caso, a expressão “ $X = Z$ ” não tem sentido, pois não se podem comparar funções com domínios distintos. Ainda assim, a afirmação “ $X \stackrel{d}{=} Z$ ” é perfeitamente bem definida. Isso ilustra que a distribuição de uma variável aleatória é uma propriedade que independe do espaço amostral em que ela foi construída.

Os dois exemplos acima são manifestações de um princípio geral: a função de probabilidade determina todas as probabilidades associadas a uma variável aleatória. É o que tornamos preciso a seguir.

Proposição 9. Seja X uma variável aleatória discreta com função de probabilidade p_X . Então, para todo conjunto $A \subseteq \mathbb{R}$,

$$\mathbb{P}(X \in A) = \sum_{s \in A} p_X(s).$$

Prova. O evento $\{X \in A\}$ ocorre exatamente quando X assume algum valor em A . Podemos, portanto, escrevê-lo como a união dos eventos $\{X = s\}$, para s percorrendo os valores que X efetivamente assume em A :

$$\{X \in A\} = \bigcup_{s \in A \cap \text{Im } X} \{X = s\}.$$

Como $\text{Im } X$ é enumerável, esta é uma união enumerável. Além disso, os eventos $\{X = s\}$ são dois a dois disjuntos, pois X não pode assumir dois valores distintos ao mesmo tempo. Pela aditividade enumerável de $\mathbb{P}$,

$$\mathbb{P}(X \in A) = \sum_{s \in A \cap \text{Im } X} \mathbb{P}(X = s) = \sum_{s \in A \cap \text{Im } X} p_X(s).$$

Por fim, como $p_X(s) = 0$ para $s \notin \text{Im } X$, acrescentar os termos com $s \in A \setminus \text{Im } X$ não altera a soma, e obtemos

$$\sum_{s \in A \cap \text{Im } X} p_X(s) = \sum_{s \in A} p_X(s),$$

o que conclui a demonstração. ■

Corolário 10. Se $X \stackrel{d}{=} Y$, então $\mathbb{P}(X \in A) = \mathbb{P}(Y \in A)$ para todo $A \subseteq \mathbb{R}$.

Prova. Pela **Proposição 9**, e usando que $p_X = p_Y$,

$$\mathbb{P}(X \in A) = \sum_{s \in A} p_X(s) = \sum_{s \in A} p_Y(s) = \mathbb{P}(Y \in A).$$
■

Em palavras, o **Corolário 10** diz que duas variáveis com a mesma distribuição atribuem a mesma probabilidade a qualquer evento definido em termos de seus valores. Este é o sentido preciso em que X e Y possuem “as mesmas propriedades probabilísticas”, mencionado no início da seção.

Observação 11. A relação $\stackrel{d}{=}$ é uma relação de equivalência no conjunto de todas as variáveis aleatórias discretas: é reflexiva ($X \stackrel{d}{=} X$), simétrica (se $X \stackrel{d}{=} Y$, então $Y \stackrel{d}{=} X$) e transitiva (se $X \stackrel{d}{=} Y$ e $Y \stackrel{d}{=} Z$, então $X \stackrel{d}{=} Z$). Isso decorre imediatamente de a igualdade de funções ser, ela própria, uma relação de equivalência. Observe que isso permanece válido mesmo quando X , Y e Z estão definidas em espaços amostrais diferentes, pois as funções de probabilidade p_X , p_Y e p_Z são todas funções definidas em $\mathbb{R}$ e, portanto, sempre comparáveis.

Referências

- [1] Geoffrey Grimmett and Dominic Welsh. *Probability—an introduction*. Oxford University Press, Oxford, second edition, 2014.