

Variáveis Aleatórias Discretas

L. Cioletti

Agosto de 2026

Resumo

Nestas notas introduzimos o conceito de variável aleatória discreta e o de função de probabilidade. Como exemplos, apresentamos algumas das famílias clássicas de variáveis aleatórias discretas: Bernoulli, binomial, Poisson, geométrica e binomial negativa. Demonstramos também um resultado conhecido como lei dos eventos raros, que fornece uma aproximação da distribuição binomial pela distribuição de Poisson. Ao longo do texto, mostramos como calcular a função de probabilidade de funções de variáveis aleatórias e discutimos brevemente a noção de igualdade em distribuição. O texto segue de perto as Seções 2.1–2.3 do Capítulo 2 de Grimmett e Welsh [1].

1. Variáveis Aleatórias Discretas

Estas notas dão continuidade ao desenvolvimento da teoria da probabilidade iniciado nas notas *Espaços de Probabilidade*, nas quais foram introduzidos o modelo probabilístico constituído pelo espaço amostral, pela σ -álgebra de eventos e pela medida de probabilidade. Aqui apresentaremos o conceito de variável aleatória discreta, a função de probabilidade associada a ela e algumas de suas propriedades básicas.

1.1. Funções de Probabilidade

Dado um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$, frequentemente estamos interessados em alguma função com valores reais, por exemplo, $X : \Omega \rightarrow \mathbb{R}$. Para tornar essa ideia concreta, seja $\mathcal{E}$ o experimento de lançar um dado honesto uma vez e seja $\Omega = \{1, 2, 3, 4, 5, 6\}$ o espaço amostral associado a esse experimento. Suponha que fazemos uma aposta baseada no resultado de $\mathcal{E}$, com lucro, prejuízo ou nenhum ganho conforme a seguinte tabela:

- -1 se o resultado for 1, 2 ou 3;
- 0 se o resultado for 4;
- 2 se o resultado for 5 ou 6.



Podemos pensar em cada resultado do experimento $\mathcal{E}$ como um ponto $\omega \in \Omega$. Assim, definindo a função $X : \Omega \rightarrow \mathbb{R}$ por

$$X(1) = X(2) = X(3) = -1, \quad X(4) = 0, \quad X(5) = X(6) = 2,$$

essa função pode ser usada para modelar o ganho ou a perda resultante da realização desse jogo. A função X , como veremos a seguir, é um exemplo de uma *variável aleatória discreta*.

À primeira vista, essa definição parece um pouco estranha, pois podemos pensar que uma função, a rigor, é um objeto matemático completamente determinístico. A ideia de que a função X fornece uma noção de variável aleatória baseia-se no fato de que a associação $\omega \mapsto X(\omega)$ adquire um grau de aleatoriedade porque a escolha do ponto ω no domínio de X é aleatória. Mas há, na verdade, outra razão, que será apresentada depois de introduzirmos a noção de função de probabilidade e certas classes de equivalência.

Mais formalmente, uma variável aleatória discreta X no espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$ é definida como uma função $X : \Omega \rightarrow \mathbb{R}$ tal que a imagem $X(\Omega)$ é um subconjunto enumerável de $\mathbb{R}$ ¹ e

$$\{\omega \in \Omega : X(\omega) = x\} \in \mathcal{F} \quad \text{para } x \in \mathbb{R}. \quad (1)$$

A palavra “discreta” aqui se refere à condição de que X assume apenas uma quantidade enumerável de valores em $\mathbb{R}$.² A condição (1) é obscura à primeira vista, e o ponto aqui é o seguinte. Uma variável aleatória discreta X assume valores em $\mathbb{R}$, mas não podemos prever com certeza o valor efetivo de X , uma vez que o experimento subjacente $\mathcal{E}$ envolve o acaso. Em vez disso, gostaríamos de medir a probabilidade de X assumir um dado valor, digamos x . Para isso, observamos que X assume o valor x se, e somente se, o resultado do experimento $\mathcal{E}$ pertence àquele subconjunto de Ω que é mapeado em x , ou seja, o subconjunto

$$X^{-1}(x) = \{\omega \in \Omega : X(\omega) = x\}.$$

A condição (1) postula que todos esses subconjuntos são eventos, no sentido de que pertencem a $\mathcal{F}$, e portanto podemos atribuir a cada um destes conjuntos uma probabilidade segundo a medida de probabilidade $\mathbb{P}$.

O que há de mais interessante em uma variável aleatória discreta são os valores que ela pode assumir e as probabilidades associadas a esses valores. Se X é uma variável aleatória discreta no espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$, então sua *imagem* $\text{Im } X$ é a imagem de Ω por X , isto é, o conjunto dos valores assumidos por X .

De agora em diante, abreviamos eventos da forma $\{\omega \in \Omega : X(\omega) = x\}$ para a forma mais conveniente $\{X = x\}$.

Definição 1. A *função de probabilidade*, também conhecida na literatura como *função de massa de probabilidade*, associada a uma variável aleatória discreta X é a função $p_X : \mathbb{R} \rightarrow [0, 1]$ definida por

$$p_X(x) = \mathbb{P}(X = x). \quad (2)$$

¹Se $X : \Omega \rightarrow \mathbb{R}$ e $A \subseteq \Omega$, a imagem de A é o conjunto $X(A) = \{X(\omega) : \omega \in A\}$ dos valores assumidos por X em A .

²Uma definição ligeiramente diferente, mas moralmente equivalente, de variável aleatória discreta é uma função $X : \Omega \rightarrow \mathbb{R}$ tal que existe um subconjunto enumerável $S \subseteq \mathbb{R}$ com $\mathbb{P}(X \in S) = 1$.

Assim, $p_X(x)$ é a probabilidade de X assumir o valor x . Note que $\text{Im } X$ é enumerável para qualquer variável aleatória discreta X , e para $x \notin \text{Im } X$ temos que o evento $\{X = x\} = \emptyset$ e, portanto,

$$p_X(x) = \mathbb{P}(X = x) = \mathbb{P}(\emptyset) = 0 \quad \text{se } x \notin \text{Im } X. \quad (3)$$

Outra observação importante, consequência direta das propriedades elementares da imagem inversa de uma função, é que, se $x \neq x'$, então $\{X = x\} \cap \{X = x'\} = \emptyset$ e

$$\bigcup_{x \in \text{Im } X} \{X = x\} = \Omega$$

e conseqüentemente, temos

$$\sum_{x \in \text{Im } X} p_X(x) = \mathbb{P}\left(\bigcup_{x \in \text{Im } X} \{\omega \in \Omega : X(\omega) = x\}\right) = \mathbb{P}(\Omega) = 1. \quad (4)$$

A equação (4) às vezes pode ser escrita como

$$\sum_{x \in \mathbb{R}} p_X(x) = 1,$$

tendo em vista que somente os valores de x pertencentes a um conjunto enumerável dão contribuição não nula para essa soma. A condição (4) caracteriza essencialmente as funções de probabilidade de variáveis aleatórias discretas, no sentido do seguinte teorema.

Teorema 2. Seja $S = \{s_i : i \in I\}$ um conjunto enumerável de números reais distintos, e seja $\{\pi_i : i \in I\}$ uma coleção de números reais satisfazendo

$$\pi_i \geq 0 \quad \text{para } i \in I, \text{ e } \sum_{i \in I} \pi_i = 1.$$

Então existe um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$ e uma variável aleatória discreta X em $(\Omega, \mathcal{F}, \mathbb{P})$ tal que a função de probabilidade de X é dada por

$$\begin{aligned} p_X(s_i) &= \pi_i \quad \text{para } i \in I, \\ p_X(s) &= 0 \quad \text{se } s \notin S. \end{aligned}$$

Demonstração. Tome $\Omega = S$, seja $\mathcal{F}$ o conjunto das partes de Ω , e

$$\mathbb{P}(A) = \sum_{i: s_i \in A} \pi_i \quad \text{para } A \in \mathcal{F},$$

com a convenção de que a soma sobre o conjunto vazio é zero. É imediato verificar que os axiomas de Kolmogorov são satisfeitos e, portanto, que o espaço $(\Omega, \mathcal{F}, \mathbb{P})$ definido acima é de fato um espaço de probabilidade.

A variável aleatória desejada é fornecida pela função $X : \Omega \rightarrow \mathbb{R}$ dada por $X(\omega) = \omega$ para $\omega \in \Omega$. De fato, para cada $s \in S$ temos

$$p_X(s_i) = \mathbb{P}\{X = s_i\} = \sum_{j: s_j = s_i} \pi_j = \pi_i.$$

■

Esse teorema é muito útil, pois, em muitos contextos, permite deixar de lado temporariamente os espaços amostrais, as σ -álgebras e as medidas de probabilidade. Dessa forma, podemos trabalhar em um ambiente mais abstrato e simplesmente usar expressões como:

“seja X uma variável aleatória que assume o valor s_i com probabilidade π_i , para cada $i \in I$ ”




Figura 1: Gráfico da função de probabilidade definida pela sequência $\pi_i = p_X(s_i)$, com conjunto de índices $I = \{0, 1, 2, 3, \dots\}$.

sabendo que tal variável aleatória existe, sem precisar construí-la explicitamente. Esse ponto de vista também permite identificar variáveis aleatórias que assumem os mesmos valores e possuem a mesma função de probabilidade. Isso sugere que a maioria das propriedades intrinsecamente probabilísticas de uma variável aleatória está completamente codificada em sua função de probabilidade e torna menos importante mencionar em qual espaço de probabilidade ela está definida.




Figura 2: Função indicadora $\mathbf{1}_E : \Omega \rightarrow \mathbb{R}$ de um evento $E \subseteq \Omega$, que vale 1 em E e 0 fora de E .

No caso da variável aleatória dada pela função indicadora de um evento E em $(\Omega, \mathcal{F}, \mathbb{P})$, sua função de probabilidade é dada por

$$p_{\mathbf{1}_E}(0) = \mathbb{P}(\{\mathbf{1}_E = 0\}) = \mathbb{P}(E^c), \quad p_{\mathbf{1}_E}(1) = \mathbb{P}(\{\mathbf{1}_E = 1\}) = \mathbb{P}(E)$$

e

$$p_{\mathbf{1}_E}(x) = 0, \quad \forall x \in \mathbb{R} \setminus \{0, 1\}.$$

Na próxima seção, apresentamos uma lista de alguns dos tipos mais comuns de variáveis aleatórias discretas.

Exercício 1. Se X e Y são variáveis aleatórias discretas no espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$, mostre que U e V , definidas por

$$U(\omega) = X(\omega) + Y(\omega), \quad V(\omega) = X(\omega)Y(\omega), \quad \text{para } \omega \in \Omega.$$

também são variáveis aleatórias discretas nesse espaço de probabilidade.

Exercício 2. Mostre que, se $\mathcal{F}$ é o conjunto das partes de Ω , então todas as funções que mapeiam Ω em um subconjunto enumerável de $\mathbb{R}$ são variáveis aleatórias discretas.

Exercício 3. Se E é um evento do espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$, mostre que a função indicadora de E , definida como a função $\mathbb{1}_E$ em Ω dada por

$$\mathbb{1}_E(\omega) = \begin{cases} 1 & \text{se } \omega \in E, \\ 0 & \text{se } \omega \notin E, \end{cases}$$

é uma variável aleatória discreta.

Exercício 4. Seja X uma variável aleatória discreta no espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$, cuja imagem é o conjunto enumerável $\text{Im } X = \{s_i : i \in I\}$. Mostre que X pode ser escrita como uma soma (possivelmente enumerável) de múltiplos reais de funções indicadoras, mais precisamente,

$$X = \sum_{i \in I} s_i \mathbb{1}_{\{X=s_i\}},$$

no sentido de que, para cada $\omega \in \Omega$, a soma acima converge e é igual a $X(\omega)$. *Dica:* fixe $\omega \in \Omega$ e determine quantos termos da soma são não nulos.

Exercício 5. Seja $(\Omega, \mathcal{F}, \mathbb{P})$ um espaço de probabilidade no qual

$$\Omega = \{1, 2, 3, 4, 5, 6\}, \quad \mathcal{F} = \{\emptyset, \{2, 4, 6\}, \{1, 3, 5\}, \Omega\},$$

e sejam U, V, W funções em Ω definidas por

$$U(\omega) = \omega, \quad V(\omega) = \begin{cases} 1 & \text{se } \omega \text{ é par,} \\ 0 & \text{se } \omega \text{ é ímpar,} \end{cases} \quad \text{e} \quad W(\omega) = \omega^2,$$

para todo $\omega \in \Omega$. Determine quais das funções U , V e W definem variáveis aleatórias discretas nesse espaço de probabilidade.

Exercício 6. Para que valor de c a função p , definida por

$$p(k) = \begin{cases} \frac{c}{k(k+1)} & \text{se } k = 1, 2, \dots, \\ 0 & \text{caso contrário,} \end{cases}$$

é uma função de probabilidade de alguma variável aleatória?

1.2. Exemplos

Certos tipos de variáveis aleatórias discretas ocorrem com frequência, e listamos algumas delas a seguir. Ao longo desta seção, n denota um inteiro positivo, p é um número em $[0, 1]$ e $q = 1 - p$. Como observado acima, por ora será desnecessário descrever o espaço de probabilidade subjacente.

Distribuição de Bernoulli. Esta é a distribuição não trivial mais simples. Dizemos que a variável aleatória discreta X tem distribuição de Bernoulli com parâmetro p se X assume apenas os valores 0 e 1.

Uma variável aleatória X desse tipo é frequentemente chamada simplesmente de *variável de Bernoulli*; ela pode modelar, por exemplo, um lançamento de moeda. Existe $p \in [0, 1]$ tal que

$$\mathbb{P}(X = 0) = q, \quad \mathbb{P}(X = 1) = p, \quad (5)$$

e a função de probabilidade de X é dada por

$$p_X(0) = q, \quad p_X(1) = p, \quad p_X(x) = 0 \text{ se } x \neq 0, 1.$$

Neste caso usamos a notação $X \sim \text{Bernoulli}(p)$.

Lançamentos de moeda são os blocos de construção da teoria da probabilidade. Há um sentido em que toda a teoria pode ser construída a partir de uma sequência infinita de lançamentos de moeda. Note que a função indicadora da [Figura 2](#) fornece uma variável aleatória do tipo Bernoulli.

Distribuição binomial. Dizemos que X tem distribuição binomial com parâmetros n e p se X assume valores em $\{0, 1, \dots, n\}$ e

$$\mathbb{P}(X = k) = \binom{n}{k} p^k q^{n-k} \quad \text{para } k = 0, 1, 2, \dots, n. \quad (6)$$

Note que (6) define uma função de probabilidade, pois ela é não negativa e satisfaz (4). De fato, pelo teorema binomial, temos

$$\sum_{k=0}^n \binom{n}{k} p^k q^{n-k} = (p + q)^n = 1.$$

Vamos usar a notação $X \sim \text{Bin}(n, p)$, quando X for uma variável aleatória (v.a.) com distribuição binomial de parâmetros n e p .




Figura 3: Função de probabilidade da distribuição binomial com parâmetros $n = 5$ e $p = 0,2$.




Figura 4: Função de probabilidade da distribuição binomial com parâmetros $n = 8$ e $p = 0,3$.




Figura 5: Função de probabilidade da distribuição binomial com parâmetros $n = 20$ e $p = 0,6$.




Figura 6: Função de probabilidade da distribuição binomial com parâmetros $n = 15$ e $p = 0,7$.

Distribuição de Poisson. Dizemos que X tem a distribuição de Poisson com parâmetro λ , onde $\lambda > 0$, se X assume valores em $\{0, 1, 2, \dots\}$ e satisfaz

$$\mathbb{P}(X = k) = \frac{1}{k!} \lambda^k e^{-\lambda} \quad \text{para } k = 0, 1, 2, \dots \quad (7)$$

Novamente, isso dá origem a uma função de probabilidade, pois

$$\sum_{k=0}^{\infty} \frac{1}{k!} \lambda^k e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{1}{k!} \lambda^k = e^{-\lambda} e^{\lambda} = 1.$$

Neste caso usamos a notação $X \sim \text{Poisson}(\lambda)$.




Figura 7: Função de probabilidade de uma Poisson(4).

Distribuição geométrica. Dizemos que X tem distribuição geométrica com parâmetro $p \in (0, 1)$ se X assume valores em $\{1, 2, 3, \dots\}$ e

$$\mathbb{P}(X = k) = pq^{k-1} \quad \text{para } k = 1, 2, 3, \dots \quad (8)$$

Usando a fórmula da soma de uma progressão geométrica e observando que $p + q = 1$, temos

$$\sum_{k=1}^{\infty} pq^{k-1} = \frac{p}{1-q} = \frac{p}{p} = 1.$$

Neste caso usamos a notação $X \sim \text{Geom}(p)$.

Distribuição binomial negativa. Dizemos que X tem distribuição binomial negativa com parâmetros n e $p \in (0, 1)$ se X assume valores em $\{n, n+1, n+2, \dots\}$ e

$$\mathbb{P}(X = k) = \binom{k-1}{n-1} p^n q^{k-n} \quad \text{para } k = n, n+1, n+2, \dots \quad (9)$$

Como antes, note que

$$\begin{aligned} \sum_{k=n}^{\infty} \binom{k-1}{n-1} p^n q^{k-n} &= p^n \sum_{l=0}^{\infty} \binom{n+l-1}{l} q^l \quad \text{com } l = k - n \\ &= p^n \sum_{l=0}^{\infty} \binom{-n}{l} (-q)^l \\ &= p^n (1 - q)^{-n} = 1, \end{aligned}$$

usando a expansão binomial generalizada de $(1 - q)^{-n}$. Neste caso usamos a notação $X \sim \text{BinNeg}(n, p)$.

Para referência futura, resumimos na [Tabela 1](#) as distribuições discretas apresentadas nesta seção, juntamente com a notação usada para cada uma delas.

Tabela 1: Resumo das distribuições discretas desta seção. Em todos os casos, $q = 1 - p$ e a entrada da coluna “Notação” deve ser lida como $X \sim \dots$

Distribuição	Parâmetros	Suporte	$p_X(k)$	Notação
Bernoulli	$p \in [0, 1]$	$\{0, 1\}$	$p^k q^{1-k}$	Bernoulli(p)
Binomial	$n \geq 1, p \in [0, 1]$	$\{0, 1, \dots, n\}$	$\binom{n}{k} p^k q^{n-k}$	Bin(n, p)
Poisson	$\lambda > 0$	$\{0, 1, 2, \dots\}$	$e^{-\lambda} \lambda^k / k!$	Poisson(λ)
Geométrica	$p \in (0, 1)$	$\{1, 2, 3, \dots\}$	$p q^{k-1}$	Geom(p)
Binomial negativa	$n \geq 1, p \in (0, 1)$	$\{n, n+1, \dots\}$	$\binom{k-1}{n-1} p^n q^{k-n}$	BinNeg(n, p)

Exemplo 3. Eis um exemplo de algumas das distribuições acima em ação. Suponha que uma moeda seja lançada n vezes e que a probabilidade de sair cara em cada lançamento seja p . Representando cara por H e coroa por T, o espaço amostral é o conjunto Ω de todas as sequências ordenadas de comprimento n contendo as letras H e T, em que a k -ésima entrada de tal sequência representa o resultado do k -ésimo lançamento. Isto é,

$$\Omega = \underbrace{\{H, T\} \times \{H, T\} \times \dots \times \{H, T\}}_{n \text{ cópias}}$$

O conjunto Ω é finito, e tomamos $\mathcal{F}$ como o conjunto das partes de Ω . Para cada $\omega \in \Omega$, definimos a probabilidade do resultado ω por

$$\mathbb{P}(\omega) := \mathbb{P}(\{\omega\}) = p^{h(\omega)} q^{t(\omega)},$$

onde $h(\omega)$ é o número de caras em ω e $t(\omega) = n - h(\omega)$ é o número de coroas. De maneira natural, estendemos a definição de $\mathbb{P}$ a um evento arbitrário $A \in \mathcal{F}$ por

$$\mathbb{P}(A) = \sum_{\omega \in A} \mathbb{P}(\omega).$$

Para $i = 1, 2, \dots, n$, definimos a variável aleatória discreta X_i por

$$X_i(\omega) = \begin{cases} 1 & \text{se a } i\text{-ésima entrada de } \omega \text{ é H,} \\ 0 & \text{se a } i\text{-ésima entrada de } \omega \text{ é T.} \end{cases}$$

Cada X_i assume valores em $\{0, 1\}$ e tem função de probabilidade dada por

$$\mathbb{P}(X_i = 0) = \mathbb{P}(\{\omega \in \Omega : \omega_i = \text{T}\}),$$

onde ω_i é a i -ésima entrada de ω . Assim,

$$\begin{aligned} \mathbb{P}(X_i = 0) &= \sum_{\substack{\omega \in \Omega \\ \omega_i = \text{T}}} p^{h(\omega)} q^{n-h(\omega)} \\ &= \sum_{h=0}^{n-1} \sum_{\substack{\omega \in \Omega : \omega_i = \text{T} \\ h(\omega) = h}} p^h q^{n-h} \\ &= q \sum_{h=0}^{n-1} \binom{n-1}{h} p^h q^{n-1-h} = q(p+q)^{n-1} = q \end{aligned}$$

e

$$\mathbb{P}(X_i = 1) = 1 - \mathbb{P}(X_i = 0) = p.$$

Portanto, cada X_i tem distribuição do tipo Bernoulli de parâmetro p .

Embora esta dedução seja um pouco trabalhosa, acreditamos que esses detalhes são instrutivos e ilustram várias ideias importantes sobre o trabalho em espaços que são produtos cartesianos. Essas ideias terão um papel importante no estudo de variáveis aleatórias independentes, conceito que será definido mais adiante.

Vamos prosseguir com mais uma observação importante sobre este exemplo. Considere a variável aleatória

$$S_n = X_1 + X_2 + \dots + X_n,$$

ou seja, $S_n(\omega) = X_1(\omega) + X_2(\omega) + \dots + X_n(\omega)$. Claramente, S_n conta o número total de caras que ocorrem e assume valores em $\{0, 1, \dots, n\}$, pois cada X_i é igual a 0 ou 1. Além disso, para cada $k = 0, 1, \dots, n$, temos que

$$\begin{aligned} \mathbb{P}(S_n = k) &= \mathbb{P}(\{\omega \in \Omega : h(\omega) = k\}) \\ &= \sum_{\omega \in \Omega : h(\omega) = k} \mathbb{P}(\omega) \\ &= \binom{n}{k} p^k q^{n-k}, \end{aligned} \tag{10}$$

e assim S_n tem a distribuição binomial de parâmetros n e p .

Se n é muito grande e p é muito pequeno, mas np tem um “tamanho razoável” (digamos, $np = \lambda$), então a distribuição de S_n pode ser aproximada pela distribuição de Poisson com parâmetro λ , da seguinte forma. Para $k \geq 0$ fixo, escrevemos $p = \lambda/n$ e, supondo que n seja grande, obtemos

$$\begin{aligned}
\mathbb{P}(S_n = k) &= \binom{n}{k} p^k (1-p)^{n-k} \\
&= \frac{n!}{(n-k)! k!} p^k (1-p)^{n-k} \\
&= \frac{n(n-1) \cdots (n-k+1)}{k!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \\
&= \frac{n^k}{k!} \left(\frac{n(n-1) \cdots (n-k+1)}{n^k}\right) \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \\
&\sim \frac{n^k}{k!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-k} \\
&\sim \frac{1}{k!} \lambda^k e^{-\lambda}.
\end{aligned} \tag{11}$$

Essa aproximação pode ser útil na prática. Por exemplo, considere uma única página do jornal Guardian contendo, digamos, 10^6 caracteres, e suponha que o tipógrafo lança uma moeda antes de compor cada caractere e então, deliberadamente, compõe incorretamente esse caractere sempre que a moeda cai em cara. Se a moeda cai em cara com probabilidade 10^{-5} em cada lançamento, então isso equivale a tomar $n = 10^6$ e $p = 10^{-5}$ no exemplo acima, de modo que o número S_n de erros deliberados tem a distribuição binomial com parâmetros 10^6 e 10^{-5} . Pode ser mais fácil (e não muito impreciso) usar (11) em vez de (10) para calcular probabilidades. Nesse caso, $\lambda = np = 10$ e, por exemplo,

$$\mathbb{P}(S_n = 10) \approx \frac{1}{10!} (10e^{-1})^{10} \approx 0,125.$$

O cálculo heurístico que acabamos de fazer no **Exemplo 3** pode ser transformado em um resultado preciso, conhecido como a *lei dos eventos raros* (ou teorema do limite de Poisson).

Teorema 4 (Lei dos eventos raros). Seja $(p_n)_{n \geq 1}$ uma sequência de números em $[0, 1]$ tal que $np_n \rightarrow \lambda$ quando $n \rightarrow \infty$, para algum $\lambda > 0$. Então, para cada $k \in \{0, 1, 2, \dots\}$ fixo,

$$\lim_{n \rightarrow \infty} \binom{n}{k} p_n^k (1-p_n)^{n-k} = e^{-\lambda} \frac{\lambda^k}{k!}.$$

Em outras palavras, se $X_n \sim \text{Bin}(n, p_n)$ com $np_n \rightarrow \lambda$ e $Y \sim \text{Poisson}(\lambda)$, então $\mathbb{P}(X_n = k) \rightarrow \mathbb{P}(Y = k)$ para cada k fixo. Assim, a distribuição binomial com n grande e p pequeno, de modo que np tenha um tamanho moderado, é bem aproximada pela distribuição de Poisson de parâmetro $\lambda = np$.

Demonstração. Defina $\lambda_n = np_n$, de modo que $p_n = \lambda_n/n$ e $\lambda_n \rightarrow \lambda$. Para $n \geq k$, escrevemos

$$\binom{n}{k} p_n^k (1 - p_n)^{n-k} = \frac{n(n-1) \cdots (n-k+1)}{k!} \left(\frac{\lambda_n}{n}\right)^k \left(1 - \frac{\lambda_n}{n}\right)^{n-k}.$$

Separando o fator $\lambda_n^k/k!$, isso pode ser reescrito como

$$\binom{n}{k} p_n^k (1 - p_n)^{n-k} = \frac{\lambda_n^k}{k!} \cdot \frac{n(n-1) \cdots (n-k+1)}{n^k} \cdot \left(1 - \frac{\lambda_n}{n}\right)^n \cdot \left(1 - \frac{\lambda_n}{n}\right)^{-k}.$$

Vamos analisar o limite de cada um dos três últimos fatores quando $n \rightarrow \infty$, lembrando que $\lambda_n \rightarrow \lambda$ e que k é fixo. Primeiro,

$$\frac{n(n-1) \cdots (n-k+1)}{n^k} = \prod_{j=0}^{k-1} \left(1 - \frac{j}{n}\right) \rightarrow 1,$$

pois trata-se de um produto finito de fatores, cada um dos quais tende a 1. Segundo,

$$\left(1 - \frac{\lambda_n}{n}\right)^n \rightarrow e^{-\lambda},$$

pelo limite fundamental $\left(1 + \frac{a_n}{n}\right)^n \rightarrow e^a$, válido quando $a_n \rightarrow a$, aplicado aqui com $a_n = -\lambda_n \rightarrow -\lambda$. Terceiro,

$$\left(1 - \frac{\lambda_n}{n}\right)^{-k} \rightarrow 1,$$

pois $\lambda_n/n \rightarrow 0$. Além disso, $\lambda_n^k \rightarrow \lambda^k$. Multiplicando todos os limites, obtemos

$$\lim_{n \rightarrow \infty} \binom{n}{k} p_n^k (1 - p_n)^{n-k} = \frac{\lambda^k}{k!} \cdot 1 \cdot e^{-\lambda} \cdot 1 = e^{-\lambda} \frac{\lambda^k}{k!},$$

como queríamos demonstrar. ■

A **Tabela 2** ilustra numericamente a convergência obtida acima. Nela comparamos a probabilidade $\mathbb{P}(X = k)$ calculada pela distribuição $\text{Bin}(100, \frac{5}{100})$ com a probabilidade correspondente calculada pela distribuição $\text{Poisson}(5)$. Note que $np = 100 \cdot 0,05 = 5 = \lambda$.

Tabela 2: Comparação entre as distribuições $\text{Bin}(100, \frac{5}{100})$ e $\text{Poisson}(5)$.

k	$\text{Bin}(100, \frac{5}{100})$	$\text{Poisson}(5)$
0	0,0059	0,0067
1	0,0312	0,0337
2	0,0812	0,0842
3	0,1396	0,1404
4	0,1781	0,1755
5	0,1800	0,1755
6	0,1500	0,1462
7	0,1060	0,1044
8	0,0649	0,0653
9	0,0349	0,0363
10	0,0167	0,0181

Observe que as duas colunas são praticamente idênticas, mesmo com $n = 100$ não sendo particularmente grande. Quanto maior for n e menor for p , mantendo $np = \lambda$ fixo, melhor é a aproximação. Este é o conteúdo preciso do cálculo heurístico realizado no **Exemplo 3**.

Exemplo 5. Suponha que lançamos a moeda do **Exemplo 3**, com $p \in (0, 1)$, até que a primeira cara apareça, e então paramos. O espaço amostral agora é

$$\Omega = \{H, TH, T^2H, \dots\} \cup \{T^\infty\},$$

onde T^kH representa o resultado de k coroas seguidas de uma cara, e T^∞ representa uma sequência infinita de coroas sem nenhuma cara. Como antes, $\mathcal{F}$ é o conjunto das partes de Ω , e $\mathbb{P}$ é dada pela expressão

$$\begin{aligned}\mathbb{P}(T^kH) &= pq^k \quad \text{para } k = 0, 1, 2, \dots, \\ \mathbb{P}(T^\infty) &= 0\end{aligned}$$

Seja Y o número total de lançamentos neste experimento, de modo que $Y(T^kH) = k + 1$ para $k = 0, 1, 2, \dots$. Definimos $Y(T^\infty) = 0$, um valor arbitrário no evento de probabilidade zero. Então,

$$\mathbb{P}(Y = k) = \mathbb{P}(T^{k-1}H) = pq^{k-1} \quad \text{para } k = 1, 2, \dots,$$

mostrando que Y tem a distribuição geométrica com parâmetro p .

Exemplo 6. Se continuarmos a lançar a moeda do **Exemplo 5** até que a n -ésima cara apareça, então um argumento semelhante mostra que, se $p \in (0, 1)$, o número total de lançamentos necessário tem a distribuição binomial negativa com parâmetros n e p .

Exercício 7. Se X é uma variável aleatória discreta com distribuição de Poisson de parâmetro λ , mostre que a probabilidade de que X seja par é $e^{-\lambda} \cosh \lambda$.

Exercício 8. Se X é uma variável aleatória discreta com distribuição geométrica de parâmetro p , mostre que a probabilidade de que X seja maior do que k , para $k = 0, 1, 2, \dots$, é $(1 - p)^k$.

1.3. Funções de Variáveis Aleatórias Discretas

Seja X uma variável aleatória discreta no espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$ e seja $g : \mathbb{R} \rightarrow \mathbb{R}$. É fácil verificar que a composição $Y := g \circ X$ também é uma variável aleatória discreta em $(\Omega, \mathcal{F}, \mathbb{P})$, definida por

$$Y(\omega) = g(X(\omega)) \quad \text{para } \omega \in \Omega.$$

Exemplos simples são

$$\begin{aligned}\text{se } g(x) &= ax + b \quad \text{então } g(X) = aX + b, \\ \text{se } g(x) &= cx^2 \quad \text{então } g(X) = cX^2.\end{aligned}$$

Se $Y = g(X)$, a função de probabilidade de Y é dada por

$$\begin{aligned}p_Y(y) &= \mathbb{P}(Y = y) = \mathbb{P}(g(X) = y) \\ &= \mathbb{P}(X \in g^{-1}(\{y\})) \\ &= \sum_{x \in g^{-1}(\{y\}) \cap \text{Im } X} \mathbb{P}(X = x),\end{aligned}\tag{12}$$

pois os valores fora de $\text{Im } X$ têm probabilidade zero. Assim, se $Y = aX + b$ com $a \neq 0$, então

$$\mathbb{P}(Y = y) = \mathbb{P}(aX + b = y) = \mathbb{P}\left(X = \frac{y - b}{a}\right) \quad \text{para } y \in \mathbb{R},$$

enquanto, se $Y = X^2$, então

$$\mathbb{P}(Y = y) = \begin{cases} \mathbb{P}(X = \sqrt{y}) + \mathbb{P}(X = -\sqrt{y}), & \text{se } y > 0; \\ \mathbb{P}(X = 0), & \text{se } y = 0; \\ 0, & \text{se } y < 0. \end{cases}$$

Exercício 9. Seja X uma variável aleatória discreta com distribuição de Poisson de parâmetro λ , e seja $Y = |\sin(\frac{1}{2}\pi X)|$. Determine a função de probabilidade de Y .

2. Equivalência entre Variáveis Aleatórias

Seja $(\Omega, \mathcal{F}, \mathbb{P})$ um espaço de probabilidade e seja $X : \Omega \rightarrow S$ uma variável aleatória com função de probabilidade p_X , onde $S = \{s_i : i \in I\}$ é um conjunto enumerável de números reais distintos. Suponha que $(\tilde{\Omega}, \tilde{\mathcal{F}}, \tilde{\mathbb{P}})$ seja outro espaço de probabilidade e que $Y : \tilde{\Omega} \rightarrow S$ seja outra variável aleatória com função de probabilidade p_Y .

Dizemos que X e Y possuem a mesma distribuição, e escrevemos $X \stackrel{d}{=} Y$, quando

$$p_X(s) = p_Y(s) \quad \text{para todo } s \in S.$$

Nesse caso, veremos que as propriedades intrinsecamente probabilísticas dessas duas variáveis aleatórias são as mesmas, de modo que podemos usar qualquer uma delas para responder a certos tipos de perguntas. Essa observação motiva tratar a distribuição, em vez da função específica $X : \Omega \rightarrow S$, como o objeto que representa a variável aleatória para esses fins. Embora essa perspectiva seja mais abstrata, ela pode ser útil quando for conveniente mudar de espaço e de descrição de uma variável aleatória ao longo da solução de um problema. Em particular, escrevendo $\{X = x\}$ em vez da notação de funções e pré-imagens, como $\{\omega \in \Omega : X(\omega) = x\}$, evitamos mencionar o espaço no qual a variável foi construída e nos concentramos nas propriedades resultantes de sua função de probabilidade.

Para tornar essas ideias concretas, vejamos dois exemplos que mostram, com todos os detalhes, o que a igualdade em distribuição afirma e, talvez mais importante, o que ela *não* afirma!

Exemplo 7. Considere o experimento de lançar um dado honesto uma vez. Temos $\Omega = \{1, 2, 3, 4, 5, 6\}$, $\mathcal{F}$ é o conjunto das partes de Ω , e $\mathbb{P}(A) = |A|/6$ para $A \in \mathcal{F}$, onde $|A|$ denota o número de elementos de A . Definimos duas variáveis aleatórias discretas $X, Y : \Omega \rightarrow \mathbb{R}$ por

$$X(\omega) = \omega \quad \text{e} \quad Y(\omega) = 7 - \omega \quad \text{para } \omega \in \Omega.$$

Assim, X registra o resultado do lançamento, enquanto Y registra o número da face oposta à face sorteadada (em um dado padrão, as faces opostas somam 7).

Vamos calcular as funções de probabilidade de X e de Y . Para cada $k \in \{1, 2, 3, 4, 5, 6\}$,

$$p_X(k) = \mathbb{P}(X = k) = \mathbb{P}(\{\omega \in \Omega : \omega = k\}) = \mathbb{P}(\{k\}) = \frac{1}{6},$$

e

$$p_Y(k) = \mathbb{P}(Y = k) = \mathbb{P}(\{\omega \in \Omega : 7 - \omega = k\}) = \mathbb{P}(\{7 - k\}) = \frac{1}{6}.$$

Portanto, $p_X(k) = p_Y(k) = 1/6$ para todo $k \in \{1, \dots, 6\}$, e ambas são nulas fora desse conjunto. Logo, $X \stackrel{d}{=} Y$.

Entretanto, X e Y são funções diferentes. De fato, para todo $\omega \in \Omega$,

$$X(\omega) = \omega \neq 7 - \omega = Y(\omega),$$

pois a igualdade $\omega = 7 - \omega$ implicaria $2\omega = 7$, o que é impossível para ω inteiro. Assim, $X(\omega) \neq Y(\omega)$ para todo $\omega \in \Omega$.

Concluimos que X e Y têm a mesma distribuição, mas são funções distintas. A igualdade em distribuição é, portanto, estritamente mais fraca que a igualdade de funções.

Exemplo 8. A igualdade em distribuição não é apenas mais fraca que a igualdade de funções: ela faz sentido em uma situação em que a igualdade de funções sequer pode ser enunciada, a saber, quando as variáveis estão definidas em espaços amostrais diferentes.

Considere, além do dado do **Exemplo 7**, um segundo experimento: lançar uma moeda honesta, que produz 0 ou 1, e em seguida sortear, com chances iguais, um dos números 0, 1, 2. O espaço amostral deste segundo experimento é

$$\tilde{\Omega} = \{0, 1\} \times \{0, 1, 2\},$$

cujos seis elementos são os pares ordenados (i, j) com $i \in \{0, 1\}$ e $j \in \{0, 1, 2\}$. Tomamos $\tilde{\mathcal{F}}$ como o conjunto das partes de $\tilde{\Omega}$ e definimos $\tilde{\mathbb{P}}$ atribuindo a cada um dos seis resultados a probabilidade $1/6$.

Definimos $Z : \tilde{\Omega} \rightarrow \mathbb{R}$ associando a cada par um número distinto de 1 a 6, conforme a tabela

$\tilde{\omega}$	(0, 0)	(1, 0)	(0, 1)	(1, 1)	(0, 2)	(1, 2)
$Z(\tilde{\omega})$	1	2	3	4	5	6

Como cada ponto de $\tilde{\Omega}$ tem probabilidade $1/6$ e Z é uma bijeção de $\tilde{\Omega}$ em $\{1, \dots, 6\}$, temos, para cada $k \in \{1, \dots, 6\}$,

$$p_Z(k) = \tilde{\mathbb{P}}(Z = k) = \frac{1}{6}.$$

Comparando com a variável X do **Exemplo 7**, obtemos $p_Z(k) = p_X(k)$ para todo k , e portanto $Z \stackrel{d}{=} X$.

Observe, contudo, que X e Z estão definidas em espaços amostrais diferentes: $X : \Omega \rightarrow \mathbb{R}$ e $Z : \tilde{\Omega} \rightarrow \mathbb{R}$, com $\Omega \neq \tilde{\Omega}$. Nesse caso, a expressão “ $X = Z$ ” não tem sentido, pois não se podem comparar funções com domínios distintos. Ainda assim, a afirmação “ $X \stackrel{d}{=} Z$ ” é perfeitamente bem definida. Isso ilustra que a distribuição de uma variável aleatória é uma propriedade que independe do espaço amostral em que ela foi construída.

Os dois exemplos acima são manifestações de um princípio geral: a função de probabilidade determina todas as probabilidades associadas a uma variável aleatória. É o que tornamos preciso a seguir.

Proposição 9. Seja X uma variável aleatória discreta com função de probabilidade p_X . Então, para todo conjunto $A \subseteq \mathbb{R}$,

$$\mathbb{P}(X \in A) = \sum_{s \in A} p_X(s).$$

Demonstração. O evento $\{X \in A\}$ ocorre exatamente quando X assume algum valor em A . Podemos, portanto, escrevê-lo como a união dos eventos $\{X = s\}$, para s percorrendo os valores que X efetivamente assume em A :

$$\{X \in A\} = \bigcup_{s \in A \cap \text{Im } X} \{X = s\}.$$

Como $\text{Im } X$ é enumerável, esta é uma união enumerável. Além disso, os eventos $\{X = s\}$ são dois a dois disjuntos, pois X não pode assumir dois valores distintos ao mesmo tempo. Pela aditividade enumerável de $\mathbb{P}$,

$$\mathbb{P}(X \in A) = \sum_{s \in A \cap \text{Im } X} \mathbb{P}(X = s) = \sum_{s \in A \cap \text{Im } X} p_X(s).$$

Por fim, como $p_X(s) = 0$ para $s \notin \text{Im } X$, acrescentar os termos com $s \in A \setminus \text{Im } X$ não altera a soma, e obtemos

$$\sum_{s \in A \cap \text{Im } X} p_X(s) = \sum_{s \in A} p_X(s),$$

o que conclui a demonstração. ■

Corolário 10. Se $X \stackrel{d}{=} Y$, então $\mathbb{P}(X \in A) = \mathbb{P}(Y \in A)$ para todo $A \subseteq \mathbb{R}$.

Demonstração. Pela **Proposição 9**, e usando que $p_X = p_Y$,

$$\mathbb{P}(X \in A) = \sum_{s \in A} p_X(s) = \sum_{s \in A} p_Y(s) = \mathbb{P}(Y \in A).$$
■

Em palavras, o **Corolário 10** diz que duas variáveis com a mesma distribuição atribuem a mesma probabilidade a qualquer evento definido em termos de seus valores. Este é o sentido preciso em que X e Y possuem “as mesmas propriedades probabilísticas”, mencionado no início da seção.

Observação 11. A relação $\stackrel{d}{=}$ é uma relação de equivalência no conjunto de todas as variáveis aleatórias discretas: é reflexiva ($X \stackrel{d}{=} X$), simétrica (se $X \stackrel{d}{=} Y$, então $Y \stackrel{d}{=} X$) e transitiva (se $X \stackrel{d}{=} Y$ e $Y \stackrel{d}{=} Z$, então $X \stackrel{d}{=} Z$). Isso decorre imediatamente do fato de a igualdade entre as funções p_X , p_Y e p_Z ser uma relação de equivalência. Observe que isso permanece válido mesmo quando X , Y e Z estão definidas em espaços amostrais diferentes, pois as funções de probabilidade p_X , p_Y e p_Z são todas funções definidas em $\mathbb{R}$ e, portanto, sempre comparáveis.

Referências

- [1] Geoffrey Grimmett and Dominic Welsh. *Probability—an introduction*. Oxford University Press, Oxford, second edition, 2014.