

Vetores Contínuos: Densidade Conjunta, Marginais e Independência

L. Cioletti

Setembro de 2026

Resumo

Nestas notas, damos continuidade ao estudo das variáveis aleatórias e iniciamos o estudo dos vetores aleatórios contínuos. Apresentamos a função de distribuição conjunta e suas propriedades, definimos a densidade conjunta e mostramos como calcular probabilidades por meio de integração sobre regiões do plano. Em seguida, introduzimos as densidades marginais, obtidas integrando a densidade conjunta em relação à outra variável, e estudamos o conceito de independência de variáveis aleatórias absolutamente contínuas, caracterizada pela fatoração da densidade conjunta, em quase todo ponto, como produto das densidades marginais. Desenvolvemos três aplicações à inteligência artificial: sorteios com probabilidades softmax por meio de relógios exponenciais, classificação baseada na informação conjunta de duas características e escassez de amostras locais em dimensão alta. A apresentação dos conceitos segue de perto as Seções 6.1 a 6.3 do Capítulo 6 de [1].

1. Vetores aleatórios e independência

Dadas duas variáveis aleatórias X e Y , definidas em um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$, é frequentemente útil pensar nelas conjuntamente como um vetor aleatório (X, Y) que assume valores em $\mathbb{R}^2$. Quando X e Y são discretas, podemos estudar esse vetor aleatório por meio da função de probabilidade conjunta de X e Y , mas, para variáveis aleatórias gerais, essa função pode não determinar a distribuição. Uma ferramenta aplicável em todos esses casos é a *função de distribuição conjunta*, definida a seguir.

Definição 1 (Função de distribuição conjunta). A função de distribuição conjunta do par de variáveis aleatórias X e Y é a função $F_{X,Y} : \mathbb{R}^2 \rightarrow [0, 1]$ dada por

$$F_{X,Y}(x, y) = \mathbb{P}(X \leq x, Y \leq y). \quad (1)$$

A notação $\mathbb{P}(X \leq x, Y \leq y)$ representa a probabilidade da interseção dos seguintes eventos $\{X \leq x\}$ e $\{Y \leq y\}$.

Algumas propriedades elementares das funções de distribuição conjunta são análogas às das funções de distribuição usuais. Por exemplo,

$$\lim_{x, y \rightarrow -\infty} F_{X,Y}(x, y) = 0 \quad (2)$$

e

$$\lim_{x,y \rightarrow \infty} F_{X,Y}(x,y) = 1. \quad (3)$$

Para justificar o primeiro limite, basta observar que $0 \leq F_{X,Y}(x,y) \leq F_X(x)$ e que $F_X(x) \rightarrow 0$ quando $x \rightarrow -\infty$. Para o segundo, usamos a continuidade da probabilidade em sequências crescentes: os eventos $\{X \leq n, Y \leq n\}$ crescem para Ω quando $n \rightarrow \infty$, pois X e Y assumem valores reais. Além disso, $F_{X,Y}(x,y) \geq F_{X,Y}(n,n)$ sempre que $x, y \geq n$.

Da mesma forma, a inclusão dos eventos mostra que $F_{X,Y}$ é não decrescente em cada variável, no sentido de que

$$F_{X,Y}(x_1, y_1) \leq F_{X,Y}(x_2, y_2) \quad \text{se} \quad x_1 \leq x_2 \text{ e } y_1 \leq y_2. \quad (4)$$

A função de distribuição conjunta $F_{X,Y}$ contém, em geral, mais informação do que as duas funções de distribuição usuais F_X e F_Y , uma vez que ela descreve como X e Y se comportam *conjuntamente*. Em particular, as funções de distribuição de X e Y podem ser obtidas a partir de sua função de distribuição conjunta de maneira direta. Para obter $F_X(x)$, fixamos x e deixamos o limiar de Y tender ao infinito. Os eventos $\{X \leq x, Y \leq n\}$ crescem até $\{X \leq x\}$ quando $n \rightarrow \infty$. Pela continuidade da probabilidade em sequências crescentes, e analogamente para Y , temos

$$F_X(x) = \lim_{y \rightarrow \infty} F_{X,Y}(x,y), \quad F_Y(y) = \lim_{x \rightarrow \infty} F_{X,Y}(x,y). \quad (5)$$

Essas funções de distribuição são chamadas de funções de distribuição *marginais* da função de distribuição conjunta $F_{X,Y}$.

A noção de independência das variáveis aleatórias X e Y surge naturalmente dessa discussão.

Definição 2 (Variáveis aleatórias independentes). Dizemos que X e Y são **independentes** se, para quaisquer $x, y \in \mathbb{R}$, os eventos $\{X \leq x\}$ e $\{Y \leq y\}$ forem independentes.

Isto é, X e Y são independentes se, e somente se,

$$\mathbb{P}(X \leq x, Y \leq y) = \mathbb{P}(X \leq x) \mathbb{P}(Y \leq y) \quad \text{para todos } x, y \in \mathbb{R},$$

o que equivale a dizer que a sua função de distribuição conjunta se fatora como o produto das duas funções de distribuição marginais:

$$F_{X,Y}(x,y) = F_X(x) F_Y(y) \quad \text{para todos } x, y \in \mathbb{R}. \quad (6)$$

No caso de variáveis aleatórias *discretas*, essa definição equivale à fatoração da função de probabilidade conjunta como produto das funções de probabilidade marginais. A verificação fica como exercício. Variáveis aleatórias que não são independentes são chamadas de *dependentes*.

Estudamos famílias finitas de variáveis aleatórias da mesma maneira. Se $X_1, X_2, \dots, X_n$ são variáveis aleatórias em $(\Omega, \mathcal{F}, \mathbb{P})$, escrevemos $\mathbf{X} = (X_1, X_2, \dots, X_n)$. A sua *função de distribuição conjunta* é a função $F_{\mathbf{X}} : \mathbb{R}^n \rightarrow [0, 1]$ dada por

$$F_{\mathbf{X}}(\mathbf{x}) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n), \quad \forall \mathbf{x} = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n. \quad (7)$$

Vamos dizer que uma coleção finita de variáveis aleatórias $X_1, X_2, \dots, X_n$ são *independentes* se

$$\mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n) = \mathbb{P}(X_1 \leq x_1) \cdots \mathbb{P}(X_n \leq x_n) \quad \forall \mathbf{x} \in \mathbb{R}^n,$$

ou, equivalentemente, se

$$F_{\mathbf{X}}(\mathbf{x}) = F_{X_1}(x_1) \cdots F_{X_n}(x_n) \quad \forall \mathbf{x} \in \mathbb{R}^n. \quad (8)$$

Exemplo 3 (Função de distribuição conjunta discreta). Suponha que X e Y sejam variáveis aleatórias em um espaço de probabilidade, cada uma assumindo valores no conjunto dos inteiros $\mathbb{Z} = \{\dots, -1, 0, 1, \dots\}$, com função de probabilidade conjunta

$$\mathbb{P}(X = i, Y = j) = p(i, j) \quad \text{para } i, j \in \mathbb{Z}.$$

Somando as probabilidades dos eventos $\{X = i, Y = j\}$, que são dois a dois disjuntos, obtemos

$$F_{X,Y}(x, y) = \sum_{\substack{i, j \in \mathbb{Z} \\ i \leq x, j \leq y}} p(i, j) \quad \text{para todo } (x, y) \in \mathbb{R}^2.$$

Exemplo 4 (Distribuição conjunta e independência de exponenciais). Suponha que X e Y sejam variáveis aleatórias com função de distribuição conjunta

$$F_{X,Y}(x, y) = \begin{cases} 1 - e^{-x} - e^{-y} + e^{-x-y} & \text{se } x, y \geq 0, \\ 0 & \text{caso contrário.} \end{cases}$$

A função de distribuição marginal de X é

$$F_X(x) = \lim_{y \rightarrow \infty} F_{X,Y}(x, y) = \begin{cases} 1 - e^{-x} & \text{se } x \geq 0, \\ 0 & \text{caso contrário,} \end{cases}$$

de modo que X tem distribuição exponencial com parâmetro 1. Um cálculo análogo mostra que Y também possui essa distribuição. Para $x, y \geq 0$, podemos fatorar a expressão inicial:

$$F_{X,Y}(x, y) = (1 - e^{-x})(1 - e^{-y}) = F_X(x) F_Y(y).$$

Se $x < 0$ ou $y < 0$, tanto $F_{X,Y}(x, y)$ quanto $F_X(x) F_Y(y)$ são nulos. Portanto, a fatoração vale para todos $x, y \in \mathbb{R}$, e X e Y são independentes.

1. Mostre que duas variáveis aleatórias X e Y são independentes se, e somente se,

$$\mathbb{P}(X > x, Y > y) = \mathbb{P}(X > x) \mathbb{P}(Y > y) \quad \text{para todos } x, y \in \mathbb{R}.$$

2. Seja (X, Y) um par de variáveis aleatórias com função de distribuição conjunta F . Prove que

$$\mathbb{P}(a < X \leq b, c < Y \leq d) = F(b, d) + F(a, c) - F(a, d) - F(b, c)$$

para quaisquer $a, b, c, d \in \mathbb{R}$ tais que $a < b$ e $c < d$.

3. Prove que duas variáveis aleatórias X e Y são independentes se, e somente se,

$$\mathbb{P}(a < X \leq b, c < Y \leq d) = \mathbb{P}(a < X \leq b) \mathbb{P}(c < Y \leq d)$$

para todos $a, b, c, d \in \mathbb{R}$ satisfazendo $a < b$ e $c < d$.

2. Funções de densidade conjunta

Uma densidade conjunta permitirá calcular a probabilidade de o vetor aleatório pertencer a uma região do plano. Antes de defini-la, vamos especificar quais regiões serão mensuráveis, estendendo ao plano a noção de conjunto boreliano já apresentada na reta.

Dados $a \in \mathbb{R}^2$ e $r > 0$, o disco aberto de centro a e raio r é o conjunto

$$D(a, r) = \{x \in \mathbb{R}^2 : \|x - a\| < r\},$$

isto é, o conjunto dos pontos cuja distância até a é menor que r . Aqui, $\|\cdot\|$ denota a norma euclidiana.




Figura 1: Disco aberto de centro a e raio r em $\mathbb{R}^2$.

Um conjunto $U \subseteq \mathbb{R}^2$ é *aberto* se, para todo ponto $a \in U$, existe algum raio $r > 0$ tal que $D(a, r) \subseteq U$. Denotemos por $\mathcal{C}$ a coleção de todos os discos abertos de $\mathbb{R}^2$, com centros em $\mathbb{R}^2$ e raios positivos. A σ -álgebra de Borel de $\mathbb{R}^2$, denotada por $\mathcal{B}(\mathbb{R}^2)$, é a menor σ -álgebra de subconjuntos de $\mathbb{R}^2$ que contém $\mathcal{C}$. Em outras palavras, é a interseção de todas as σ -álgebras de subconjuntos de $\mathbb{R}^2$ que contêm todos os discos abertos. Seus elementos são chamados de *conjuntos borelianos*, ou simplesmente *borelianos*.

Todo aberto do plano é uma união enumerável de discos abertos com centros em $\mathbb{Q}^2$ e raios racionais positivos. Por isso, a classe dos borelianos contém todos os conjuntos abertos e fechados do plano. Em particular, inclui retângulos, discos e regiões delimitadas por curvas fechadas simples (curvas de Jordan), entre outros conjuntos que aparecem nas aplicações do Cálculo.

Diremos que uma função $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ é *Borel-mensurável* se, para todo $t \in \mathbb{R}$, o conjunto

$$\{(x, y) \in \mathbb{R}^2 : f(x, y) \leq t\}$$

pertencer a $\mathcal{B}(\mathbb{R}^2)$. Como os intervalos $(-\infty, t]$ geram $\mathcal{B}(\mathbb{R})$, essa condição equivale a exigir que a pré-imagem $f^{-1}(C) = \{(x, y) \in \mathbb{R}^2 : f(x, y) \in C\}$ pertença a $\mathcal{B}(\mathbb{R}^2)$ para todo $C \in \mathcal{B}(\mathbb{R})$. Essa condição é análoga à usada na definição de variável aleatória: as pré-imagens dos borelianos da reta devem ser conjuntos mensuráveis no domínio. Na reta, usamos a mesma definição, tomando $\mathcal{B}(\mathbb{R})$ também no domínio. Em particular, toda função contínua é Borel-mensurável, pois a pré-imagem de um aberto por uma função contínua é um conjunto aberto.

Com essas noções, podemos passar das densidades na reta às densidades no plano. Recordamos que uma variável aleatória X é dita *absolutamente contínua* se sua função de distribuição admitir uma representação integral da forma

$$F_X(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f(u) du, \quad \text{para todo } x \in \mathbb{R},$$

para alguma função Borel mensurável e não negativa f .

Definição 5 (Variáveis aleatórias conjuntamente absolutamente contínuas). Dizemos que o par (X, Y) de variáveis aleatórias em $(\Omega, \mathcal{F}, \mathbb{P})$ é (*conjuntamente*) *absolutamente contínuo* se sua função de distribuição conjunta puder ser expressa na forma¹

$$F_{X,Y}(x, y) = \mathbb{P}(X \leq x, Y \leq y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) dv du \quad (9)$$

para quaisquer $x, y \in \mathbb{R}$ e alguma função Borel-mensurável $f : \mathbb{R}^2 \rightarrow [0, \infty)$. Quando essa condição é satisfeita, dizemos que X e Y possuem *função densidade (de probabilidade) conjunta* f , e costumamos denotar essa função por $f_{X,Y}$.

A medida de Lebesgue no plano formaliza a ideia de área, assim como na reta formaliza o comprimento. Um conjunto tem *área zero* se, para todo $\varepsilon > 0$, puder ser coberto por uma união enumerável de retângulos cuja soma das áreas seja menor que ε . Por exemplo, todo segmento de reta tem área zero. Dizemos que uma propriedade vale *quase em todo ponto* do plano quando ela pode falhar apenas em um conjunto de área zero.

Assim como no caso unidimensional, duas densidades representam a mesma distribuição conjunta se, e somente se, coincidem quase em todo ponto. Em particular, a densidade não é única: alterar seus valores em um conjunto de área zero, mantendo a Borel-mensurabilidade e a não negatividade, não altera a representação integral de $F_{X,Y}$.

Sob hipóteses de regularidade, podemos obter uma densidade por derivação. Uma condição suficiente é que o par (X, Y) seja conjuntamente absolutamente contínuo e que $F_{X,Y}$ tenha derivadas parciais de segunda ordem contínuas em um aberto $G \subseteq \mathbb{R}^2$ cujo complemento tenha área zero. Nesse caso, uma densidade conjunta é dada por

$$f_{X,Y}(x, y) = \begin{cases} \frac{\partial^2}{\partial x \partial y} F_{X,Y}(x, y) & \text{se } (x, y) \in G, \\ 0 & \text{caso contrário.} \end{cases} \quad (10)$$

Para entender essa fórmula, observe que a integral da derivada mista sobre um retângulo cujo fecho esteja contido em G é, pelo Teorema Fundamental do Cálculo, a diferença de quatro valores de $F_{X,Y}$ que dá a probabilidade desse retângulo (**Exercício 2**). Isso identifica a derivada mista com uma densidade quase em todo ponto de G . A escolha do valor zero fora de G não altera as integrais, pois esse complemento tem área zero. Nos exemplos em que essa hipótese estiver satisfeita, usaremos (10) para encontrar uma densidade conjunta.

As propriedades elementares da função densidade conjunta $f_{X,Y}$ são a não negatividade, exigida na definição,

$$f_{X,Y}(x, y) \geq 0 \quad \text{para quaisquer } x, y \in \mathbb{R}, \quad (11)$$

e a integral unitária,

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx dy = 1. \quad (12)$$

Esta última igualdade é obtida tomando o limite quando x e y tendem a $+\infty$ na igualdade (9), já que os eventos $\{X \leq n, Y \leq n\}$ crescem para Ω e, pela não negatividade de f , as integrais correspondentes crescem para a integral sobre todo o plano.

¹As integrais são tomadas no sentido de Lebesgue. Nos exemplos do curso, elas podem ser calculadas pelas técnicas usuais do Cálculo. Como o integrando é mensurável e não negativo, o Teorema de Tonelli permite trocar a ordem de integração. Quando sua integral é finita, também se aplica o Teorema de Fubini.

Mais uma vez, observamos uma analogia entre funções densidade conjuntas e funções de probabilidade conjuntas. De modo intuitivo, podemos dizer que, para um ponto (x, y) em que $f_{X,Y}$ seja contínua e para acréscimos positivos pequenos δx e δy , a probabilidade de o vetor aleatório (X, Y) pertencer ao pequeno retângulo com vértice inferior esquerdo em (x, y) e lados de comprimentos δx e δy é dada aproximadamente por

$$\mathbb{P}(x < X \leq x + \delta x, y < Y \leq y + \delta y) \approx f_{X,Y}(x, y) \delta x \delta y. \quad (13)$$

De fato, pela continuidade, a densidade varia pouco nesse retângulo. O erro da aproximação, dividido pela área $\delta x \delta y$, tende a zero quando δx e δy tendem a zero por valores positivos. Essa interpretação sugere que a probabilidade de uma região deve ser obtida integrando a densidade sobre ela, como veremos a seguir.

Teorema 6 (Probabilidade de regiões borelianas). Se A é um boreliano de $\mathbb{R}^2$ e X e Y são variáveis aleatórias conjuntamente absolutamente contínuas com função densidade conjunta $f_{X,Y}$, então

$$\mathbb{P}((X, Y) \in A) = \iint_A f_{X,Y}(x, y) dx dy. \quad (14)$$

O evento $\{(X, Y) \in A\}$ pertence a $\mathcal{F}$. Para justificar essa afirmação, observamos que a pré-imagem de um retângulo $(a, b] \times (c, d]$ é a interseção dos eventos $\{a < X \leq b\}$ e $\{c < Y \leq d\}$ e, portanto, pertence a $\mathcal{F}$. A coleção dos conjuntos do plano cujas pré-imagens pertencem a $\mathcal{F}$ é uma σ -álgebra. Ela contém todos os discos abertos, pois cada um deles é uma união enumerável desses retângulos com extremos racionais. Logo, contém $\mathcal{B}(\mathbb{R}^2)$, o que justifica a afirmação para todo boreliano A .




Figura 2: Quando a densidade varia pouco no retângulo destacado em A , a probabilidade de que (X, Y) pertença a ele é aproximadamente $f_{X,Y}(x, y) \delta x \delta y$.

O Teorema 6 depende de resultados da teoria da integração, e omitimos sua demonstração.

Podemos entender intuitivamente o resultado para uma região limitada A como a da Figura 2. Suponha que sua fronteira tenha área zero e que a densidade seja contínua em

uma vizinhança de seu fecho. A ideia é aproximar A por uniões de pequenos retângulos dois a dois disjuntos. Em cada retângulo, a probabilidade é aproximadamente a densidade em um de seus pontos multiplicada pela área. Somando essas pequenas probabilidades e refinando a divisão, obtemos somas que convergem para a integral da densidade sobre A .

Exemplo 7 (Distribuição uniforme em um retângulo). Uma função Borel-mensurável $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ é a função densidade conjunta de algum par de variáveis aleatórias, em algum espaço de probabilidade, se, e somente se, satisfaz as condições

$$f(x, y) \geq 0 \quad \text{para quaisquer } x, y \in \mathbb{R} \quad \text{e} \quad \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1.$$

Para verificar a suficiência, podemos tomar $\Omega = \mathbb{R}^2$ e $\mathcal{F} = \mathcal{B}(\mathbb{R}^2)$ e definir

$$\mathbb{P}(A) = \iint_A f(x, y) dx dy \quad \text{para todo } A \in \mathcal{F}.$$

Usamos então as variáveis aleatórias $X(x, y) = x$ e $Y(x, y) = y$. A mensurabilidade, a não negatividade e a integral unitária garantem que essa construção define uma medida de probabilidade. A caracterização é análoga à do caso unidimensional.

Fixe agora $a > 0$ e $b > 0$. A função

$$f(x, y) = \begin{cases} \frac{1}{ab}, & \text{se } 0 < x < a \text{ e } 0 < y < b, \\ 0, & \text{caso contrário,} \end{cases}$$

é mensurável, não negativa e satisfaz

$$\int_0^a \int_0^b \frac{1}{ab} dy dx = 1.$$

Portanto, é uma função densidade conjunta. Se X e Y têm densidade conjunta f , dizemos que o vetor (X, Y) é uniformemente distribuído no retângulo $B = (0, a) \times (0, b)$. Para qualquer boreliano A do plano,

$$\mathbb{P}((X, Y) \in A) = \iint_A f(x, y) dx dy = \iint_{A \cap B} \frac{1}{ab} dx dy = \frac{\text{área}(A \cap B)}{\text{área}(B)}.$$




Figura 3: A densidade uniforme tem altura $1/(ab)$ sobre o retângulo $B = (0, a) \times (0, b) \subseteq \mathbb{R}^2$. O prisma representado tem volume 1.

4. As variáveis aleatórias X e Y têm função densidade conjunta dada por

$$f(x, y) = \begin{cases} c\left(x^2 + \frac{1}{2}xy\right), & \text{se } 0 < x < 1 \text{ e } 0 < y < 2, \\ 0, & \text{caso contrário.} \end{cases}$$

Determine o valor da constante c e a função de distribuição conjunta de X e Y .

5. As variáveis aleatórias X e Y têm função densidade conjunta dada por

$$f(x, y) = \begin{cases} e^{-x-y}, & \text{se } x > 0 \text{ e } y > 0, \\ 0, & \text{caso contrário.} \end{cases}$$

Calcule $\mathbb{P}(X + Y \leq 1)$ e $\mathbb{P}(X > Y)$.

3. Densidades marginais e independência

Sempre que o par (X, Y) possui função densidade conjunta $f_{X,Y}$, podemos obter as funções densidade de X e de Y integrando em relação à outra coordenada. Para encontrar uma densidade de X , observamos que

$$\mathbb{P}(X \leq x) = \int_{-\infty}^x \left[\int_{-\infty}^{\infty} f_{X,Y}(u, v) dv \right] du.$$

A integração iterada é válida porque a densidade conjunta é não negativa. Além disso, a função entre colchetes é mensurável, não negativa e tem integral 1 sobre a reta. Assim, uma densidade de X é dada por

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, v) dv \quad \text{para quase todo ponto } x \in \mathbb{R}. \quad (15)$$

De modo análogo,

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(u, y) du \quad \text{para quase todo ponto } y \in \mathbb{R}. \quad (16)$$

Como essas funções têm integral 1, as integrais acima são finitas em quase todo ponto. Se uma delas for infinita em um ponto excepcional, fixamos a densidade marginal igual a zero nesse ponto. O conjunto de tais pontos tem comprimento nulo, de modo que essa modificação não altera as probabilidades.

Essas funções densidade são chamadas de funções densidade *marginais* de X e de Y , pois são obtidas ao “projetar” o vetor aleatório (X, Y) sobre os dois eixos coordenados do plano.

Recorde, pela **Definição 2**, que X e Y são *independentes* se suas funções de distribuição satisfazem

$$F_{X,Y}(x, y) = F_X(x)F_Y(y) \quad \forall (x, y) \in \mathbb{R}^2. \quad (17)$$

Suponha agora que X e Y sejam conjuntamente absolutamente contínuas. O produto $f_X(x)f_Y(y)$ é uma função mensurável não negativa e tem integral 1 sobre o plano. Sua função de distribuição é

$$\int_{-\infty}^x \int_{-\infty}^y f_X(u)f_Y(v) dv du = F_X(x)F_Y(y).$$

Se X e Y são independentes, essa função de distribuição coincide com $F_{X,Y}$. Portanto, $f_{X,Y}$ e o produto das densidades marginais são densidades da mesma distribuição e coincidem quase em todo ponto:

$$f_{X,Y}(x, y) = f_X(x)f_Y(y) \quad \text{para quase todo ponto } (x, y) \in \mathbb{R}^2. \quad (18)$$

Aqui, “quase todo ponto” permite que a igualdade falhe em um conjunto de área nula, pois os valores de uma densidade nesse conjunto não alteram as probabilidades. Reciprocamente, se integrarmos ambos os lados de (18) com x variando em $(-\infty, u]$ e y variando em $(-\infty, v]$, obtemos (17). Assim, variáveis aleatórias conjuntamente absolutamente contínuas são independentes se, e somente se, sua função densidade conjunta se fatora, quase em todo ponto, como o produto das duas funções densidade marginais. Esse resultado é análogo ao caso de variáveis aleatórias discretas, estudado anteriormente. Do mesmo modo que no caso discreto, há um resultado mais geral.

Teorema 8 (Critério de fatoração para independência). Sejam X e Y variáveis aleatórias conjuntamente absolutamente contínuas. Elas são independentes se, e somente se, existem funções Borel-mensuráveis não negativas $g, h : \mathbb{R} \rightarrow [0, \infty)$ tais que

$$f_{X,Y}(x, y) = g(x)h(y) \quad \text{para quase todo ponto } (x, y) \in \mathbb{R}^2.$$

Isto é, a densidade conjunta se fatora como o produto de uma função da primeira coordenada por uma função da segunda.

Não apresentamos a demonstração aqui, mas sugerimos ao leitor que adapte a demonstração correspondente dada para variáveis discretas, substituindo os somatórios por integrais. Para essa adaptação, verifique primeiro que a integral unitária da densidade conjunta implica que as integrais de g e de h são finitas e estritamente positivas. Isso permite normalizar os fatores, dividindo cada um por sua integral, para obter as densidades marginais.

Não vamos nos estender longamente sobre o caso em que há três ou mais variáveis aleatórias. De modo geral, todas as ideias desenvolvidas até aqui possuem análogos em mais de duas dimensões. Em $\mathbb{R}^3$, a σ -álgebra de Borel $\mathcal{B}(\mathbb{R}^3)$ é gerada pelas bolas abertas $\{x \in \mathbb{R}^3 : \|x - a\| < r\}$, com $a \in \mathbb{R}^3$ e $r > 0$. A Borel-mensurabilidade de funções reais é definida pelo mesmo critério de pré-imagens, usando $\mathcal{B}(\mathbb{R}^3)$ no domínio. Volume nulo e propriedades quase em todo ponto são definidos como no plano, substituindo os retângulos e suas áreas por paralelepípedos e seus volumes.

Por exemplo, dizemos que três variáveis aleatórias X, Y e Z são *conjuntamente absolutamente contínuas* se

$$\begin{aligned} F_{X,Y,Z}(x, y, z) &= \mathbb{P}(X \leq x, Y \leq y, Z \leq z) \\ &= \int_{-\infty}^x \int_{-\infty}^y \int_{-\infty}^z f(u, v, w) \, dw \, dv \, du \end{aligned}$$

para todo $(x, y, z) \in \mathbb{R}^3$ e alguma função Borel-mensurável não negativa $f : \mathbb{R}^3 \rightarrow [0, \infty)$ cuja integral sobre $\mathbb{R}^3$ seja 1. Como no caso bidimensional, se $F_{X,Y,Z}$ tem derivadas parciais contínuas até a ordem três em um aberto $H \subseteq \mathbb{R}^3$ cujo complemento tenha volume nulo, podemos obter uma densidade pela fórmula

$$f(x, y, z) = \begin{cases} \frac{\partial^3 F_{X,Y,Z}}{\partial x \partial y \partial z}(x, y, z), & \text{se } (x, y, z) \in H, \\ 0, & \text{caso contrário.} \end{cases}$$

Para qualquer vetor conjuntamente absolutamente contínuo (X, Y, Z) , as três variáveis são *independentes* se, e somente se, a densidade conjunta se fatora como o produto das funções densidade marginais:

$$f(x, y, z) = f_X(x)f_Y(y)f_Z(z) \quad \text{para quase todo ponto } (x, y, z) \in \mathbb{R}^3.$$

Nesse caso, o conjunto excepcional tem volume nulo.

Exemplo 9 (Exponenciais independentes). Suponha que X e Y tenham função densidade conjunta dada por

$$f(x, y) = \begin{cases} e^{-x-y}, & \text{se } x > 0 \text{ e } y > 0, \\ 0, & \text{caso contrário.} \end{cases}$$

Então

$$\begin{aligned} f_X(x) &= \int_{-\infty}^{\infty} f(x, y) dy \\ &= \begin{cases} \int_0^{\infty} e^{-x-y} dy, & \text{se } x > 0, \\ 0, & \text{caso contrário,} \end{cases} \\ &= \begin{cases} e^{-x}, & \text{se } x > 0, \\ 0, & \text{caso contrário,} \end{cases} \end{aligned}$$

o que mostra que X tem distribuição exponencial com parâmetro 1. A variável aleatória Y também possui essa distribuição. Com essas escolhas das densidades marginais, temos

$$f_{X,Y}(x, y) = f_X(x)f_Y(y) \quad \text{para todo } x, y \in \mathbb{R},$$

de modo que X e Y são independentes.

Exemplo 10 (Constante de normalização e dependência). Suponha que X e Y tenham função densidade conjunta dada por

$$f(x, y) = \begin{cases} ce^{-x-y}, & \text{se } 0 < x < y, \\ 0, & \text{caso contrário,} \end{cases} \quad (19)$$

para alguma constante c . Encontre o valor de c e determine se X e Y são independentes.

Solução. A não negatividade da densidade implica $c \geq 0$. Como sua integral deve ser 1, vamos integrar primeiro em relação a y , que varia de x a ∞ na região $0 < x < y$:

$$\begin{aligned} 1 &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dy dx \\ &= c \int_0^{\infty} \int_x^{\infty} e^{-x-y} dy dx \\ &= c \int_0^{\infty} e^{-2x} dx = \frac{c}{2}, \end{aligned}$$

o que fornece $c = 2$.

Para verificar se X e Y são independentes, vamos comparar a probabilidade de $\{X > 2, Y < 1\}$ com o produto das probabilidades de $\{X > 2\}$ e $\{Y < 1\}$. Pela densidade conjunta,

$$\mathbb{P}(X > 2, Y < 1) = \int_2^\infty \int_{-\infty}^1 f(x, y) dy dx = 0,$$

já que $f(x, y) = 0$ quando $y < x$. Por outro lado,

$$\mathbb{P}(X > 2) = \int_2^\infty \int_x^\infty 2e^{-x-y} dy dx = e^{-4} > 0,$$

$$\mathbb{P}(Y < 1) = \int_0^1 \int_0^y 2e^{-x-y} dx dy = (1 - e^{-1})^2 > 0,$$

de modo que

$$\mathbb{P}(X > 2, Y < 1) \neq \mathbb{P}(X > 2)\mathbb{P}(Y < 1),$$

mostrando que X e Y são dependentes.

6. Sejam X e Y variáveis aleatórias com função densidade conjunta dada por

$$f(x, y) = \begin{cases} cx, & \text{se } 0 < y < x < 1, \\ 0, & \text{caso contrário.} \end{cases}$$

Encontre o valor da constante c e as funções densidade marginais de X e Y . As variáveis X e Y são independentes?

7. As variáveis aleatórias X , Y e Z têm função densidade conjunta dada por

$$f(x, y, z) = \begin{cases} 8xyz, & \text{se } 0 < x, y, z < 1, \\ 0, & \text{caso contrário.} \end{cases}$$

As variáveis X , Y e Z são independentes? Calcule $\mathbb{P}(X > Y)$ e $\mathbb{P}(Y > Z)$.

4. Aplicações


Os conceitos de densidade conjunta, marginalização e independência permitem investigar perguntas que aparecem em inteligência artificial. Vamos usá-los para construir:

- sorteios com os pesos da função *softmax*;
- identificar uma informação presente apenas na interação entre duas características;
- examinar como a dimensão influencia a disponibilidade de amostras locais.


Estes exemplos usam apenas as técnicas de probabilidade desenvolvidas até aqui.

4.1. Corridas exponenciais e amostragem softmax

Exemplo 11 (Relógios exponenciais, softmax e sorteios). Considere dois relógios independentes $X \sim \text{Exp}(\lambda)$ e $Y \sim \text{Exp}(\mu)$, com $\lambda, \mu > 0$. O valor de cada uma destas duas variáveis aleatórias representa o tempo que o relógio correspondente leva para tocar.



$$X \sim \text{Exp}(\lambda)$$



$$Y \sim \text{Exp}(\mu)$$

Pela independência e pela forma das densidades exponenciais, uma densidade conjunta é

$$f_{X,Y}(x, y) = \lambda e^{-\lambda x} \mu e^{-\mu y} \mathbf{1}_{(0,\infty)^2}(x, y).$$

De fato, a integral desse produto sobre $(-\infty, x] \times (-\infty, y]$ é $F_X(x)F_Y(y) = F_{X,Y}(x, y)$, como exige a definição de densidade conjunta. Vamos primeiro calcular a probabilidade de que o relógio X toque antes de Y . No plano, o evento $\{X < Y\}$ é a região acima da diagonal $y = x$ no quadrante positivo, como ilustra a Figura 4.




Figura 4: A região sombreada representa $\mathcal{S} \equiv \{(x, y) \in (0, \infty)^2 : x < y\}$.

Para descrever essa região por seções verticais, fixemos $x = x_0 > 0$. A seção indicada em vermelho na figura mostra que, para esse valor de x , a coordenada y varia de x_0 até ∞ . Portanto

$$\begin{aligned} \mathbb{P}(X < Y) &= \mathbb{P}((X, Y) \in \mathcal{S}) = \iint_{\mathcal{S}} f_{X,Y}(x, y) dx dy = \int_0^\infty \int_x^\infty \lambda \mu e^{-\lambda x - \mu y} dy dx \\ &= \int_0^\infty \lambda e^{-\lambda x} e^{-\mu x} dx = \frac{\lambda}{\lambda + \mu}. \end{aligned}$$

Trocando os papéis dos relógios, obtemos $\mathbb{P}(Y < X) = \mu/(\lambda + \mu)$. O empate corresponde à diagonal $\{(x, y) : x = y\}$, que tem área nula no plano. Como (X, Y) tem densidade, segue que $\mathbb{P}(X = Y) = 0$. Assim, quase certamente há um único relógio que toca primeiro.

O cálculo sugere que a taxa de um relógio determina sua chance de vencer. Agora queremos acompanhar também o instante do primeiro toque. Consideremos $n \geq 2$ relógios

independentes $X_1, \dots, X_n$, com $X_i \sim \text{Exp}(\lambda_i)$ e $\lambda_i > 0$. Para registrar o instante e o relógio que toca primeiro, definimos

$$T = \min_{1 \leq j \leq n} X_j, \quad J = \min\{i \in \{1, \dots, n\} : X_i = T\}, \quad \Lambda = \sum_{j=1}^n \lambda_j.$$

Assim, T é o instante do primeiro toque, e J indica qual relógio o produziu. A definição também cobre o caso de empate: escolhemos o menor índice entre os relógios que tocam juntos. Vamos ver que essa convenção só afeta um evento de probabilidade zero. Fixemos um par $i < j$. Pela independência, a densidade conjunta de (X_i, X_j) é $f_{X_i, X_j}(x, y) = \lambda_i \lambda_j e^{-\lambda_i x - \lambda_j y}$, para $x, y > 0$. O empate entre esses relógios corresponde à diagonal $x = y$. Como a probabilidade é a integral da densidade nessa região, e a diagonal tem área nula, temos $\mathbb{P}(X_i = X_j) = 0$. Se houver empate no primeiro toque, algum par de relógios terá tempos iguais. Há apenas finitos pares, e a probabilidade da união dos eventos $\{X_i = X_j\}$ é no máximo a soma das probabilidades individuais; portanto, também é zero.

Para calcular a lei conjunta de T e J , fixemos i e consideremos a probabilidade de o relógio i ser o primeiro a tocar, com esse toque ocorrendo depois de $t \geq 0$. Como os empates têm probabilidade zero, podemos integrar sobre a região em que i toca estritamente antes dos demais. Se esse toque ocorre no instante $u > t$, todas as outras coordenadas x_j devem satisfazer $x_j > u$. Integramos primeiro nessas coordenadas e depois em u :

$$\begin{aligned} \mathbb{P}(T > t, J = i) &= \int_t^\infty \lambda_i e^{-\lambda_i u} \prod_{j \neq i} \left(\int_u^\infty \lambda_j e^{-\lambda_j x_j} dx_j \right) du \\ &= \int_t^\infty \lambda_i e^{-\Lambda u} du = \frac{\lambda_i}{\Lambda} e^{-\Lambda t}. \end{aligned} \quad (20)$$

Cada integral interna integra a densidade do relógio j nos valores $x_j > u$, enquanto a integral externa percorre os instantes $u > t$ em que o relógio i pode tocar primeiro.

Somando sobre i , usando a σ -aditividade de $\mathbb{P}$ ficamos com

$$\mathbb{P}(T > t) = e^{-\Lambda t}, \quad (21)$$

portanto $T \sim \text{Exp}(\Lambda)$. Fazendo $t = 0$ em (20) temos que $\{T > 0\} = \Omega \setminus \{T = 0\}$ e portanto segue do fato de $\mathbb{P}(T = 0) = 0$ que

$$\mathbb{P}(J = i) = \frac{\lambda_i}{\Lambda}. \quad (22)$$

Além disso, segue das identidades (20), (21) e (22) que para todo $t \geq 0$,

$$\mathbb{P}(T > t, J = i) = \mathbb{P}(T > t) \mathbb{P}(J = i). \quad (23)$$

Fixado $s \in \mathbb{R}$ e somando a igualdade acima sobre os índices inteiros não-negativos satisfazendo $i \leq s$, obtemos a seguinte igualdade

$$\mathbb{P}(T > t, J \leq s) = \sum_{i=1}^{\lfloor s \rfloor} \mathbb{P}(T > t, J = i) = \mathbb{P}(T > t) \sum_{i=1}^{\lfloor s \rfloor} \mathbb{P}(J = i) = \mathbb{P}(T > t) \mathbb{P}(J \leq s)$$

Tomando o complementar de $\{T > t\}$, concluímos da identidade acima que

$$F_{T,J}(t, s) = F_T(t) F_J(s), \quad t > 0 \text{ e } s \in \mathbb{R}$$

Para $t < 0$, ambos os lados são zero. Pela definição de independência, T e J são, portanto, independentes. Em particular, saber qual relógio tocou primeiro não altera a distribuição do tempo até o toque, isto é, $\mathbb{P}(T \leq t | J = i) = \mathbb{P}(T \leq t)$. Observe que (21) diz que o tempo mínimo tem taxa total Λ , e a identidade do vencedor, segundo (22), é sorteada com probabilidades proporcionais às taxas individuais.

Podemos agora usar a fórmula do vencedor como um método de amostragem: escolheremos as taxas de modo que o índice vencedor tenha a distribuição *softmax* de uma lista de escores. Consideremos escores (ou pontuações ou log-pesos) $s_1, \dots, s_n \in \mathbb{R}$. Como as taxas na distribuição exponencial precisam ser positivas, então tomamos $\lambda_i = e^{s_i}$. Já que a função exponencial é positiva e estritamente crescente esta transformação fornece taxas e preserva a ordem dos escores. Observe que agora, os valores $\lambda_i \equiv e^{s_i}$ podem ser vistos como pesos não normalizados da distribuição de Gibbs definida pelos escores. Substituindo essas taxas em (22), obtemos

$$\mathbb{P}(J = i) = \frac{\lambda_i}{\Lambda} = \frac{e^{s_i}}{\sum_{j=1}^n e^{s_j}}.$$

Essa é a distribuição *softmax* dos escores. Portanto, para sortear um índice com essas probabilidades, basta gerar, independentemente, $X_i \sim \text{Exp}(e^{s_i})$ e escolher o índice do menor valor.

Essa distribuição conecta a corrida a dois exemplos vistos antes. Nas notas sobre propriedades da probabilidade, ela aparece como a distribuição de Gibbs obtida ao normalizar os pesos e^{s_i} . Nas notas sobre vetores discretos, quando os escores do problema de atenção são s_i , os pesos são $\alpha_i = e^{s_i} / \sum_{j=1}^n e^{s_j}$ e formam a combinação convexa $\sum_i \alpha_i v_i$. A corrida usa esses mesmos pesos para sortear o índice J , de modo que $\mathbb{P}(J = i) = \alpha_i$.

Observação 12 (O truque Gumbel-Max). Há uma forma de fazer o mesmo sorteio usando apenas variáveis uniformes. Para obter uma exponencial de taxa um, procuramos uma transformação cuja probabilidade de exceder t seja e^{-t} . Uma uniforme em $(0, 1)$ fica abaixo de e^{-t} com essa probabilidade; como $-\log$ é decrescente, a transformação $-\log U$ converte essa condição em $-\log U > t$. Depois, reescalamos os tempos para obter as taxas e^{s_i} . Sejam $U_1, \dots, U_n : \Omega \rightarrow (0, 1)$ variáveis aleatórias uniformes e independentes, e defina

$$E_i = -\log U_i.$$

Para $t \geq 0$, a transformação fornece

$$\mathbb{P}(E_i > t) = \mathbb{P}(U_i < e^{-t}) = e^{-t},$$

de modo que $E_i \sim \text{Exp}(1)$. Para verificar a independência, note que, para $t_1, \dots, t_n \geq 0$,

$$\mathbb{P}(E_1 \leq t_1, \dots, E_n \leq t_n) = \mathbb{P}(U_1 \geq e^{-t_1}, \dots, U_n \geq e^{-t_n}) = \prod_{i=1}^n (1 - e^{-t_i}).$$

A segunda igualdade usa a independência das uniformes. Se algum $t_i < 0$, tanto a probabilidade conjunta quanto o produto das marginais são zero. Assim, a função de distribuição conjunta se fatora, e $E_1, \dots, E_n$ são independentes. Ponha

$$T_i = \frac{E_i}{e^{s_i}}.$$

Para $t \geq 0$, temos $\mathbb{P}(T_i > t) = \mathbb{P}(E_i > e^{s_i t}) = e^{-e^{s_i t}}$. Logo T_i tem distribuição exponencial de taxa e^{s_i} . A fatoração da função de distribuição conjunta continua válida após esse reescalonamento de cada limiar, de modo que os tempos permanecem independentes. Pelo **Exemplo 11**, o índice que minimiza os T_i tem a distribuição softmax.

Para escrever essa regra como uma maximização, aplicamos $-\log$, que é estritamente decrescente nos números positivos. Portanto,

$$\operatorname{argmin}_{1 \leq i \leq n} T_i = \operatorname{argmax}_{1 \leq i \leq n} (-\log T_i) = \operatorname{argmax}_{1 \leq i \leq n} (s_i + G_i),$$

onde $G_i = -\log(-\log U_i)$. Aqui, argmin e argmax denotam os índices em que o mínimo e o máximo são atingidos. Como o empate tem probabilidade zero, esses índices são únicos com probabilidade 1. Os ruídos G_i são independentes, pois suas transformações são estritamente crescentes em cada U_i , e a fatoração das funções de distribuição é preservada. Calculamos a distribuição de cada G_i diretamente. Para $g \in \mathbb{R}$,

$$\begin{aligned} F_{G_i}(g) &= \mathbb{P}(-\log(-\log U_i) \leq g) \\ &= \mathbb{P}(U_i \leq e^{-e^{-g}}) = e^{-e^{-g}}. \end{aligned}$$

Essa é a distribuição Gumbel padrão. Assim, gerar ruídos Gumbel independentes, somá-los aos escores e escolher o índice do maior valor é um algoritmo exato para sortear uma posição com probabilidades softmax. Esse procedimento é conhecido como *truque Gumbel-Max*.²

4.2. Informação conjunta na classificação

Exemplo 13 (Duas características e uma informação conjunta). Queremos construir um exemplo em que cada característica, observada sozinha, não ajude a identificar a classe, mas as duas características em conjunto determinem a classe. Isso nos permitirá ver concretamente que as distribuições marginais podem perder a informação sobre a interação entre variáveis.

Considere um rótulo de classe $C \in \{0, 1\}$, com $\mathbb{P}(C = 0) = \mathbb{P}(C = 1) = 1/2$, e duas características reais X e Y . Em ambas as classes, queremos que cada coordenada seja uniforme em $(0, 1)$. Para que o par revele a classe, porém, vamos concentrar a distribuição em quadrantes diferentes do quadrado $Q = (0, 1)^2$.

Escrevemos

$$\begin{aligned} R_0 &= \{(x, y) \in Q : (x - \tfrac{1}{2})(y - \tfrac{1}{2}) > 0\}, \\ R_1 &= \{(x, y) \in Q : (x - \tfrac{1}{2})(y - \tfrac{1}{2}) < 0\}. \end{aligned}$$

Assim, R_0 reúne os dois quadrantes em que as coordenadas ficam do mesmo lado de $1/2$, e R_1 reúne os dois quadrantes em que ficam de lados opostos. As duas linhas divisórias serão excluídas de R_0 e R_1 e isto não é muito importante já que estas linhas têm área nula.

Para descrever a distribuição das características em cada classe, usamos a medida condicional ao evento $\{C = c\}$, que tem probabilidade positiva. Denotamos essa medida por $\mathbb{P}_c(B) = \mathbb{P}(B \mid C = c)$, para eventos $B \in \mathcal{F}$. Sob $\mathbb{P}_c$, vamos atribuir ao par (X, Y) a densidade conjunta h_c , onde

$$h_0(x, y) = 2 \mathbb{1}_{R_0}(x, y), \quad h_1(x, y) = 2 \mathbb{1}_{R_1}(x, y).$$

²Veja C. J. Maddison, *A Poisson process model for Monte Carlo* (2016), para essa ligação entre corridas exponenciais e o truque Gumbel-Max.

Essa escolha dá densidade constante em cada região permitida e nula fora dela. Como R_0 e R_1 são uniões de dois quadrados de lado $1/2$, cada uma tem área $1/2$. As funções h_0 e h_1 são Borel-mensuráveis e não negativas, e

$$\iint_{\mathbb{R}^2} h_c(x, y) dx dy = 2 \text{ área}(R_c) = 2 \cdot \frac{1}{2} = 1, \quad c \in \{0, 1\}.$$

Portanto, cada uma define uma distribuição de probabilidade para (X, Y) dentro da classe correspondente.

A **Figura 5** resume as distribuições em cada classe: em cada painel, os quadrantes sombreados têm densidade 2, e os quadrantes brancos têm densidade zero.




Figura 5: Densidades conjuntas das características (X, Y) em cada classe. Em cada painel, os interiores dos quadrantes sombreados têm densidade 2 e os dos quadrantes brancos têm densidade 0. Os números indicam esses valores.

Vamos agora marginalizar para verificar o que uma única característica revela. Para $x \in (0, 1)$ com $x \neq 1/2$, o corte vertical de cada R_c tem comprimento $1/2$, de modo que

$$\int_{\mathbb{R}} h_c(x, y) dy = 2 \cdot \frac{1}{2} = 1, \quad c \in \{0, 1\}.$$

Fora de $(0, 1)$, essa integral é zero. Para $x = 1/2$, ela também é zero, pois fixamos as densidades conjuntas como zero nas linhas divisórias. Alterar o valor de uma densidade marginal nesse único ponto não muda a distribuição. O mesmo argumento vale para os cortes horizontais. Assim, podemos escolher as versões marginais

$$h_{c,X}(x) = \mathbf{1}_{(0,1)}(x), \quad h_{c,Y}(y) = \mathbf{1}_{(0,1)}(y), \quad c \in \{0, 1\}.$$

Essas versões coincidem com as integrais marginais em quase todo ponto. Em particular, sob ambas as medidas $\mathbb{P}_0$ e $\mathbb{P}_1$, X e Y têm, individualmente, distribuição uniforme em $(0, 1)$. Isoladamente, nenhuma das características distingue as classes.

Para quantificar essa limitação, considere uma regra determinística mensurável que, observando apenas X , prevê a classe 0 nos valores de um boreliano $D \subseteq \mathbb{R}$ e prevê a classe 1 nos demais. Como as distribuições marginais de X nas duas classes são iguais,

$$\begin{aligned} \mathbb{P}(\text{acerto}) &= \frac{1}{2} \mathbb{P}_0(X \in D) + \frac{1}{2} \mathbb{P}_1(X \notin D) \\ &= \frac{1}{2} \mathbb{P}_0(X \in D) + \frac{1}{2} (1 - \mathbb{P}_0(X \in D)) = \frac{1}{2}. \end{aligned}$$

Logo, toda regra determinística mensurável baseada somente em X acerta com probabilidade $1/2$. O mesmo cálculo vale para qualquer regra determinística baseada somente em Y . A

conclusão vem tanto das proporções iguais das classes quanto da igualdade das distribuições marginais.

Com as duas características, a regra pode usar de que lado de $1/2$ cada coordenada está. Ela prevê a classe 0 se $(X - \frac{1}{2})(Y - \frac{1}{2}) > 0$ e a classe 1 se $(X - \frac{1}{2})(Y - \frac{1}{2}) < 0$, atribuindo qualquer previsão sobre as linhas divisórias. Sob a classe c , o par pertence a R_c com probabilidade 1; as linhas divisórias têm probabilidade zero, pois as distribuições têm densidades. Portanto, essa regra conjunta acerta com probabilidade 1. A interação entre as coordenadas contém toda a informação de classe, embora cada marginal, separadamente, não contenha nenhuma.

Essa construção também mostra o que se perde ao substituir, dentro de cada classe, a densidade conjunta pelo produto das densidades marginais. Em ambas as classes esse produto é $h_{c,X}(x)h_{c,Y}(y) = \mathbb{1}_Q(x, y)$, uma densidade uniforme em Q . Ela não depende de c e, portanto, apaga a interação que permitia classificar perfeitamente. O classificador *naive Bayes* supõe que as características sejam independentes dentro de cada classe e usa produtos de densidades marginais para descrever sua distribuição conjunta.³ Neste exemplo, essa hipótese elimina toda a informação que separa as classes.

Há ainda uma consequência para a população sem observar o rótulo. Pela regra da probabilidade total, a densidade conjunta de (X, Y) é

$$h(x, y) = \frac{1}{2}h_0(x, y) + \frac{1}{2}h_1(x, y) = \mathbb{1}_Q(x, y) \quad \text{para quase todo ponto } (x, y) \in \mathbb{R}^2.$$

Assim, na população total, X e Y são independentes e uniformes em $(0, 1)$. Dentro de cada classe, entretanto, elas são dependentes. Por exemplo, tome $A = \{(X, Y) \in (0, \frac{1}{2})^2\}$. Então

$$\mathbb{P}_0(A) = \frac{1}{2}, \quad \mathbb{P}_0(X < \frac{1}{2}) = \mathbb{P}_0(Y < \frac{1}{2}) = \frac{1}{2},$$

de modo que a probabilidade de A não é o produto das probabilidades marginais, que seria $1/4$. Na classe 1, $\mathbb{P}_1(A) = 0$, o que também mostra a dependência.

4.3. Dimensão e escassez de amostras locais

Exemplo 14 (Dimensão e escassez de amostras locais). Em algumas tarefas de inteligência artificial, queremos encontrar amostras que sejam próximas de uma consulta em várias características ao mesmo tempo. Para isolar o efeito do número de características, vamos estudar um modelo simples: cada ponto é escolhido uniformemente no cubo unitário e suas coordenadas são independentes. Perguntamos com que probabilidade um ponto fica na região central em todas as coordenadas.

Fixe $d \in \mathbb{N}$ e sejam $X_1, \dots, X_d$ variáveis aleatórias independentes, cada uma com distribuição uniforme em $(0, 1)$. O vetor $(X_1, \dots, X_d)$ representa um ponto escolhido no cubo $(0, 1)^d$. Consideremos o evento

$$A_d = \left\{ \frac{1}{4} < X_i < \frac{3}{4} \text{ para todo } i = 1, \dots, d \right\}.$$

Assim, em cada coordenada, exigimos que o valor esteja no intervalo central $(1/4, 3/4)$, que tem metade do comprimento do intervalo $(0, 1)$. Aqui, “central” significa que cada coordenada, separadamente, está próxima de $1/2$: exigimos que seu desvio absoluto em relação a $1/2$ seja menor que $1/4$.

³Veja a [documentação do scikit-learn sobre *naive Bayes*](#) para essa hipótese de modelagem.

Para calcular $\mathbb{P}(A_d)$, escrevemos A_d como a interseção dos eventos correspondentes a cada coordenada. Cada um tem probabilidade $1/2$, e a independência permite multiplicar essas probabilidades:

$$\mathbb{P}(A_d) = \prod_{i=1}^d \mathbb{P}\left(\frac{1}{4} < X_i < \frac{3}{4}\right) = \left(\frac{1}{2}\right)^d. \quad (24)$$

O mesmo cálculo pode ser lido geometricamente. A região central é o produto de d intervalos de comprimento $1/2$, logo seu volume é $(1/2)^d$; como o cubo todo tem volume 1, essa também é a fração do volume ocupada pela região. Sob o modelo uniforme com coordenadas independentes, essa fração de volume coincide com a probabilidade calculada.

A escolha de metade do intervalo serve apenas para fixar a escala. Se $0 < \varepsilon < 1/2$ e exigirmos que cada coordenada pertença a $(1/2 - \varepsilon, 1/2 + \varepsilon)$, a probabilidade de uma coordenada satisfazer a condição é 2ε . Pela independência, a probabilidade de todas as d coordenadas satisfazerem a condição é

$$\mathbb{P}\left(\left|X_i - \frac{1}{2}\right| < \varepsilon \text{ para todo } i = 1, \dots, d\right) = (2\varepsilon)^d.$$

Portanto, mesmo um intervalo de comprimento fixo em cada coordenada pode corresponder a uma fração pequena do volume total quando há muitas coordenadas.

Vejam os que isso implica para uma coleção de amostras. Sejam $(X_1^{(k)}, \dots, X_d^{(k)})$, para $k = 1, \dots, N$, pontos gerados de modo que todas as Nd coordenadas sejam independentes e uniformes em $(0, 1)$. Seja $A_d^{(k)}$ o evento de que o ponto de índice k pertence à região central. Cada evento tem probabilidade 2^{-d} . Além disso, os eventos $A_d^{(1)}, \dots, A_d^{(N)}$ são independentes, pois cada um impõe condições apenas às coordenadas de seu próprio vetor. Para qualquer coleção desses eventos, a probabilidade da interseção é o produto das probabilidades, pela independência das coordenadas envolvidas. Assim, a probabilidade de nenhum ponto estar na região é $(1 - 2^{-d})^N$, e obtemos

$$\mathbb{P}\left(\bigcup_{k=1}^N A_d^{(k)}\right) = 1 - (1 - 2^{-d})^N \leq N2^{-d}. \quad (25)$$

A desigualdade também decorre diretamente da desigualdade da união: a probabilidade de pelo menos um dos eventos ocorrer não excede a soma de suas probabilidades.

Por exemplo, para $d = 30$ e $N = 1\,000\,000$, essa estimativa fornece

$$\mathbb{P}\left(\bigcup_{k=1}^N A_{30}^{(k)}\right) \leq \frac{1\,000\,000}{2^{30}} < 0,001 = 0,1\%.$$

Portanto, nesse modelo, um milhão de pontos ainda tem probabilidade menor que um décimo de um por cento de incluir um ponto central em todas as coordenadas.

A mesma estimativa dá uma condição necessária sobre o número de amostras. Se a probabilidade de encontrar ao menos um ponto na região for pelo menos $1/2$, então, por (25),

$$\frac{1}{2} \leq N2^{-d}, \quad \text{e, portanto,} \quad N \geq 2^{d-1}. \quad (26)$$

Trata-se de uma condição necessária obtida por uma cota superior para a probabilidade. Ela, por si só, não afirma que esse número de amostras seja suficiente para atingir a probabilidade desejada.

Este modelo ajuda a entender uma dificuldade possível em métodos que procuram pontos locais comparando várias características simultaneamente: ainda que cada característica

admita um intervalo central relativamente largo, exigir que todas fiquem nesses intervalos pode selecionar uma fração muito pequena do espaço de possibilidades. A conclusão é sobre o modelo uniforme com coordenadas independentes e ilustra um dos fenômenos conhecidos como *maldição da dimensionalidade*: o número de amostras necessário para obter uma chance fixa de encontrar um ponto na região cresce, no mínimo, exponencialmente com d . A distribuição dos dados faz parte desse diagnóstico; dados concentrados em estruturas de menor dimensão exigem uma análise que leve essa estrutura em conta.

Referências

- [1] Geoffrey Grimmett and Dominic Welsh. *Probability—an introduction*. Oxford University Press, Oxford, second edition, 2014.