

Vetores Aleatórios Discretos

L. Cioletti

Agosto de 2026

Resumo

Nestas notas introduzimos o conceito de vetor aleatório discreto e apresentamos algumas de suas propriedades elementares. Introduzimos a função de probabilidade conjunta de um par (X, Y) de variáveis aleatórias discretas, bem como as funções de probabilidade marginais obtidas por soma sobre a variável complementar. Apresentamos o cálculo da esperança de funções $g(X, Y)$ a partir da distribuição conjunta e deduzimos, como caso particular, a linearidade do operador esperança. Concluímos com três aplicações da linearidade da esperança sem hipótese de independência entre as parcelas: cortes aleatórios em grafos, o problema dos chapéus e recordes em permutações aleatórias. Também ilustramos essas ferramentas em contextos contemporâneos de inteligência artificial: modelos de linguagem de bigramas, a marginalização de variáveis latentes na distribuição conjunta e os mecanismos de agrupamento (*pooling*) e de atenção como aplicações da esperança. O texto segue de perto as Seções 3.1 e 3.2 do Capítulo 3 de Grimmett e Welsh [2], com uma aplicação extraída do livro de Alon e Spencer [1].

1. Probabilidade Conjunta e Vetores Aleatórios

Considere, por exemplo, o lançamento de dois dados. O resultado pode ser representado por um par (i, j) , em que i é o resultado do primeiro dado e j é o resultado do segundo. Podemos visualizar esse par como um ponto do plano: a primeira coordenada indica a posição sobre um eixo e a segunda coordenada indica a posição sobre o outro eixo.

Essa ideia pode ser formalizada por meio do conceito de vetor aleatório. Se X e Y são variáveis aleatórias discretas definidas sobre um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$, o par ordenado (X, Y) registra simultaneamente os dois valores observados e pode ser visto como um vetor aleatório com valores em $\mathbb{R}^2$.

Por questão de conveniência, dados um par de números reais x, y , vamos usar a notação $\mathbb{P}(X = x, Y = y)$ para denotar a probabilidade de ocorrência do evento $\{X = x\} \cap \{Y = y\}$, isto é,

$$\mathbb{P}(X = x, Y = y) \equiv \mathbb{P}(\{X = x\} \cap \{Y = y\}).$$



Definição 1 (Função de probabilidade conjunta). Se X e Y são variáveis aleatórias discretas em $(\Omega, \mathcal{F}, \mathbb{P})$, a *função de probabilidade conjunta* $p_{X,Y}$ de X e Y é a função $p_{X,Y} : \mathbb{R}^2 \rightarrow [0, 1]$ definida por

$$p_{X,Y}(x, y) = \mathbb{P}(\{\omega \in \Omega : X(\omega) = x \text{ e } Y(\omega) = y\}), \quad (1)$$

usualmente abreviada como $p_{X,Y}(x, y) = \mathbb{P}(X = x, Y = y)$.




Figura 1: Representação do vetor aleatório $\mathbf{X} \equiv (X, Y) : \Omega \rightarrow \mathbb{R}^2$, com dois pontos distintos do espaço amostral e suas imagens no plano euclidiano.

É claro que

$$p_{X,Y}(x, y) = 0 \quad \text{a menos que } x \in \text{Im } X \text{ e } y \in \text{Im } Y. \quad (2)$$

Além disso, os eventos $\{X = x\} \cap \{Y = y\}$, com $x \in \text{Im } X$ e $y \in \text{Im } Y$, são dois a dois disjuntos e sua união é Ω . Logo, pela σ -aditividade de $\mathbb{P}$, temos a seguinte identidade

$$\begin{aligned} \sum_{x \in \text{Im } X} \sum_{y \in \text{Im } Y} p_{X,Y}(x, y) &= \sum_{x \in \text{Im } X} \sum_{y \in \text{Im } Y} \mathbb{P}(X = x, Y = y) \\ &= \sum_{x \in \text{Im } X} \mathbb{P}\left(\{X = x\} \cap \bigcup_{y \in \text{Im } Y} \{Y = y\}\right) \\ &= \sum_{x \in \text{Im } X} \mathbb{P}(\{X = x\} \cap \Omega) \\ &= \sum_{x \in \text{Im } X} \mathbb{P}(\{X = x\}) \\ &= 1. \end{aligned} \quad (3)$$

As chamadas funções de probabilidade marginais de X e Y podem ser obtidas a partir da função de probabilidade conjunta somando sobre a coordenada complementar. Por exemplo,

para cada $x \in \text{Im } X$,

$$\begin{aligned}
p_X(x) &= \mathbb{P}(X = x) = \mathbb{P}(\{X = x\} \cap \Omega) \\
&= \mathbb{P}\left(\{X = x\} \cap \bigcup_{y \in \text{Im } Y} \{Y = y\}\right) \\
&= \mathbb{P}\left(\bigcup_{y \in \text{Im } Y} \{X = x\} \cap \{Y = y\}\right) \\
&= \sum_{y \in \text{Im } Y} \mathbb{P}(X = x, Y = y) = \sum_{y \in \text{Im } Y} p_{X,Y}(x, y). \tag{4}
\end{aligned}$$

De maneira análoga, para cada $y \in \text{Im } Y$, temos

$$p_Y(y) = \mathbb{P}(Y = y) = \sum_{x \in \text{Im } X} p_{X,Y}(x, y). \tag{5}$$

Se pensarmos em (X, Y) como um ponto escolhido aleatoriamente no plano, então as coordenadas aleatórias X e Y são as projeções desse ponto sobre os eixos coordenados. É nesse sentido que as funções p_X e p_Y são chamadas de funções de probabilidade *marginais*.

Os cálculos acima ficam particularmente transparentes em um exemplo finito.

$p_{X,Y}(x, y)$	$x = 1$	$x = 2$	$x = 3$
$y = 1$	$\frac{1}{12}$	$\frac{3}{18}$	$\frac{1}{6}$
$y = 2$	$\frac{1}{18}$	0	$\frac{5}{18}$
$y = 3$	0	$\frac{3}{18}$	$\frac{1}{12}$

Tabela 1: A função de probabilidade conjunta do par (X, Y) .

Exemplo 2. Suponha que X e Y sejam variáveis aleatórias assumindo, cada uma, os valores 1, 2 ou 3, e que a probabilidade de o par (X, Y) ser igual a (x, y) seja dada pelas entradas da [Tabela 1](#), se $x, y \in \{1, 2, 3\}$ e zero caso contrário.

Então, por exemplo, somando a terceira coluna, concluímos que

$$\begin{aligned}
\mathbb{P}(X = 3) &= \mathbb{P}(X = 3, Y = 1) + \mathbb{P}(X = 3, Y = 2) + \mathbb{P}(X = 3, Y = 3) \\
&= \frac{1}{6} + \frac{5}{18} + \frac{1}{12} = \frac{19}{36}.
\end{aligned}$$

Analogamente, somando a segunda linha,

$$\mathbb{P}(Y = 2) = \frac{1}{18} + 0 + \frac{5}{18} = \frac{1}{3}.$$

A discussão acima e o exemplo mostram claramente como é possível a partir da função de probabilidade conjunta de (X, Y) obter as funções de probabilidade de X e Y , por meio das marginais




Figura 2: Obtenção das funções de probabilidade marginais a partir da função de probabilidade conjunta, somando sobre a coordenada complementar.

É importante observar entretanto que, em geral, dado um vetor aleatório discreto (X, Y) nem sempre é possível reconstruir a função de probabilidade conjunta $p_{(X,Y)}$, utilizando apenas as funções de probabilidade p_X e p_Y . Vamos voltar a este problema em uma outra oportunidade: veremos que é a independência das variáveis X e Y que torna essa reconstrução possível.

Ideias semelhantes aplicam-se a famílias $\mathbf{X} = (X_1, X_2, \dots, X_n)$ de variáveis aleatórias discretas em um espaço de probabilidade, isto é, a um vetor aleatório $\mathbf{X}$ tomando valores em $\mathbb{R}^n$. Por exemplo, a *função de probabilidade conjunta* de $\mathbf{X}$ é a função $p_{\mathbf{X}} : \mathbb{R}^n \rightarrow [0, 1]$ definida por

$$p_{\mathbf{X}}(\mathbf{x}) = \mathbb{P}(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) \quad (6)$$

para $\mathbf{x} = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$. Neste caso, para cada $i = 1, 2, \dots, n$, podemos verificar que a função de probabilidade marginal p_{X_i} é obtida somando $p_{\mathbf{X}}$ sobre todas as demais coordenadas, e vale $\sum_{\mathbf{x}} p_{\mathbf{X}}(\mathbf{x}) = 1$, com a soma estendida aos $\mathbf{x}$ tais que $x_i \in \text{Im } X_i$ para todo i .

Exercício 1. Duas cartas são retiradas ao acaso de um baralho de 52 cartas. Se X denota o número de ases retirados e Y denota o número de reis, exiba a função de probabilidade conjunta de X e Y na forma tabular da [Tabela 1](#).

Exercício 2. O par de variáveis aleatórias discretas (X, Y) tem função de probabilidade conjunta

$$\mathbb{P}(X = i, Y = j) = \begin{cases} \theta^{i+j+1} & \text{se } i, j = 0, 1, 2, \\ 0 & \text{caso contrário,} \end{cases}$$

para algum valor de θ . Mostre que θ satisfaz a equação

$$\theta + 2\theta^2 + 3\theta^3 + 2\theta^4 + \theta^5 = 1,$$

e encontre a função de probabilidade marginal de X em termos de θ .

Encerramos esta seção com uma aplicação direta do maquinário de funções de probabilidade conjuntas e marginais ao processamento de linguagem natural e à inteligência artificial.

Um *modelo de linguagem* (*language model*) é, em sua formulação matemática elementar, uma distribuição de probabilidade sobre sequências de palavras ou símbolos de texto, chamados *tokens*. Para pares de palavras consecutivas, essa distribuição é precisamente a função de probabilidade conjunta de um par de variáveis aleatórias discretas (X_1, X_2) , estimada por contagem a partir de uma coleção de textos (*corpus*). O exemplo a seguir torna essa identificação transparente.

Exemplo 3 (Um modelo de linguagem de bigramas). Considere o seguinte texto de treinamento (o *corpus*):

o gato caça o rato e o gato dorme

Esse texto é formado por uma sequência de $N = 9$ tokens:

$w_1 = \text{o}, \quad w_2 = \text{gato}, \quad w_3 = \text{caça}, \quad w_4 = \text{o}, \quad w_5 = \text{rato},$
 $w_6 = \text{e}, \quad w_7 = \text{o}, \quad w_8 = \text{gato}, \quad w_9 = \text{dorme},$

e o vocabulário V é o conjunto constituído pelas $|V| = 6$ palavras distintas:

$V = \{\text{o}, \text{gato}, \text{caça}, \text{rato}, \text{e}, \text{dorme}\}.$

Um *bigrama* (*bigram*) é qualquer par de tokens consecutivos (w_t, w_{t+1}) . Deslizando uma janela de tamanho 2 ao longo do texto, da posição $t = 1$ até $t = 8$, encontramos $N - 1 = 8$ bigramas:

$t = 1 : (\text{o}, \text{gato}) \quad t = 2 : (\text{gato}, \text{caça}) \quad t = 3 : (\text{caça}, \text{o}) \quad t = 4 : (\text{o}, \text{rato})$
 $t = 5 : (\text{rato}, \text{e}) \quad t = 6 : (\text{e}, \text{o}) \quad t = 7 : (\text{o}, \text{gato}) \quad t = 8 : (\text{gato}, \text{dorme}).$

O experimento aleatório. Imagine que sorteamos uniformemente ao acaso uma das 8 posições de bigrama, isto é, tomamos o espaço amostral $\Omega = \{1, 2, \dots, 8\}$ com probabilidade uniforme $\mathbb{P}(\{t\}) = 1/8$ para cada posição t .

A rigor, uma variável aleatória toma valores reais em $\mathbb{R}$. Para representar palavras matematicamente, associamos cada token do vocabulário V a um identificador numérico em $\{1, \dots, 6\}$ (exatamente como fazem os *tokenizadores* na prática de inteligência artificial ao atribuir um *token ID* a cada palavra):

$\text{o} \leftrightarrow 1, \quad \text{gato} \leftrightarrow 2, \quad \text{caça} \leftrightarrow 3, \quad \text{rato} \leftrightarrow 4, \quad \text{e} \leftrightarrow 5, \quad \text{dorme} \leftrightarrow 6.$

Definimos então duas variáveis aleatórias discretas $X_1, X_2 : \Omega \rightarrow \mathbb{R}$:

- X_1 : o identificador numérico do **primeiro token** do bigrama sorteado (w_t);
- X_2 : o identificador numérico do **segundo token** do bigrama sorteado (w_{t+1}).

Por comodidade de notação e clareza de leitura, continuaremos nos referindo aos valores assumidos por X_1 e X_2 diretamente pelos seus rótulos textuais (isto é, escrevemos $X_1 = \text{gato}$ como abreviação de $X_1 = 2$). A função de probabilidade conjunta

$$p_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 = x_1, X_2 = x_2)$$

é simplesmente a frequência relativa com que o par (x_1, x_2) ocorre no corpus. Por exemplo:

- $\mathbb{P}(X_1 = \text{o}, X_2 = \text{gato}) = \frac{2}{8} = \frac{1}{4}$, pois o par (o, gato) aparece duas vezes (nas posições $t = 1$ e $t = 7$);
- $\mathbb{P}(X_1 = \text{gato}, X_2 = \text{caça}) = \frac{1}{8}$, pois ocorre uma única vez ($t = 2$);
- $\mathbb{P}(X_1 = \text{gato}, X_2 = \text{rato}) = 0$, pois a palavra **gato** nunca é imediatamente seguida por **rato** no texto.

A **Tabela 2** apresenta a tabela de probabilidade conjunta completa do par (X_1, X_2) , acompanhada das somas marginais.

$p_{X_1, X_2}(x_1, x_2)$	$x_2 = \text{o}$	$x_2 = \text{gato}$	$x_2 = \text{caça}$	$x_2 = \text{rato}$	$x_2 = \text{e}$	$x_2 = \text{dorme}$	$p_{X_1}(x_1)$
$x_1 = \text{o}$	0	$\frac{2}{8}$	0	$\frac{1}{8}$	0	0	$\frac{3}{8}$
$x_1 = \text{gato}$	0	0	$\frac{1}{8}$	0	0	$\frac{1}{8}$	$\frac{2}{8}$
$x_1 = \text{caça}$	$\frac{1}{8}$	0	0	0	0	0	$\frac{1}{8}$
$x_1 = \text{rato}$	0	0	0	0	$\frac{1}{8}$	0	$\frac{1}{8}$
$x_1 = \text{e}$	$\frac{1}{8}$	0	0	0	0	0	$\frac{1}{8}$
$x_1 = \text{dorme}$	0	0	0	0	0	0	0
$p_{X_2}(x_2)$	$\frac{2}{8}$	$\frac{2}{8}$	$\frac{1}{8}$	$\frac{1}{8}$	$\frac{1}{8}$	$\frac{1}{8}$	1

Tabela 2: Função de probabilidade conjunta dos bigramas (X_1, X_2) e suas respectivas distribuições marginais p_{X_1} (soma das linhas) e p_{X_2} (soma das colunas).

A soma de todas as entradas da tabela é 1, como exige a equação (3). Somando as linhas, recuperamos a distribuição marginal de X_1 ; somando as colunas, a marginal de X_2 . Note que $p_{X_1}(\text{dorme}) = 0$, pois a palavra **dorme** é o último token do corpus e, portanto, nunca inicia um bigrama.

As marginais descrevem a distribuição de palavras individuais (*unigramas* ou *unigrams*), sem guardar qualquer informação sobre quais palavras aparecem juntas. A representação clássica em *sacola de palavras* (*bag-of-words*) armazena apenas essas frequências marginais. Mas, como vimos, as marginais não determinam a conjunta. De fato, as frases

o gato caçou o rato e o rato caçou o gato

possuem as mesmíssimas contagens marginais (duas ocorrências de **o** e uma ocorrência de cada uma das palavras **gato**, **caçou** e **rato**), mas têm sentidos completamente distintos: na primeira ocorre o bigrama (**gato**, **caçou**), enquanto na segunda ocorre o bigrama (**rato**, **caçou**). É a função de probabilidade conjunta que preserva a estrutura sequencial e a semântica do texto.

O modelo de *n-gramas* (*n-grams*) generaliza essa construção para vetores aleatórios $\mathbf{X} = (X_1, \dots, X_n)$ de comprimento n . Para um vocabulário padrão em inteligência artificial de $|V| = 50000$ tokens (5×10^4) e sequências curtas de apenas três palavras consecutivas (*trigramas*, com $n = 3$), o número de entradas necessárias em uma tabela conjunta tridimensional é

$$|V|^n = (5 \times 10^4)^3 = 5^3 \times 10^{12} = 125 \times 10^{12} = 1,25 \times 10^{14}.$$

Por extenso, são 125.000.000.000.000 (125 trilhões) de probabilidades. Armazenar essa tabela em memória, mesmo em precisão simples de 4 bytes por número, exigiria cerca de 500 terabytes de memória RAM. Se avançássemos para sequências de apenas quatro palavras ($n = 4$), o tamanho saltaria para $|V|^4 = 6,25 \times 10^{18}$ entradas, um número astronômico.

Essa explosão combinatória colossal tornou tabelas explícitas de contagem inviáveis para sequências longas e forçou a inteligência artificial a migrar para redes neurais (como os *Transformers*). Neles, a tabela é substituída por uma função parametrizada no contínuo, mas em essência o objeto probabilístico fundamental continua sendo uma função de probabilidade conjunta sobre sequências de tokens; veja [3]. Mais à frente, quando estivermos tratando com a esperança condicional de uma variável aleatória com respeito a outra variável aleatória, veremos como usar essa conjunta para calcular a probabilidade da próxima palavra dada a sequência anterior ($\mathbb{P}(X_{t+1} \mid X_1, \dots, X_t)$), precisamente o mecanismo autorregressivo que permite aos modelos de linguagem gerar texto de forma coerente.

Observação 4 (Variáveis latentes e identificabilidade). Em muitas aplicações, os dados observados são governados por uma variável que não observamos diretamente, chamada *variável latente* (ou oculta). O princípio matemático subjacente é a identidade

$$p_X(x) = \sum_{z \in \text{Im } Z} p_{Z,X}(z, x),$$

isto é, a igualdade (5) aplicada ao par (Z, X) . Somando sobre todos os valores possíveis da variável latente Z , marginalizamos a conjunta e obtemos a distribuição dos dados observados. A variável latente Z pode ser o estilo do texto, o tópico do documento ou o especialista sorteado, e cada valor de Z induz uma distribuição diferente sobre o token observado X . A **Tabela 3** ilustra o caso em que X assume valores em $\{a, b, c\}$ (identificados com $\{1, 2, 3\} \subset \mathbb{R}$) e a latente Z em $\{1, 2\}$.

$p_{Z,X}(z, x)$	$x = a$	$x = b$	$x = c$
$z = 1$	$\frac{1}{6}$	$\frac{1}{12}$	$\frac{1}{12}$
$z = 2$	$\frac{1}{6}$	$\frac{1}{2}$	0
$p_X(x)$	$\frac{1}{3}$	$\frac{7}{12}$	$\frac{1}{12}$

Tabela 3: A distribuição observada é a marginal p_X , soma por coluna da conjunta $p_{Z,X}$.

Essa construção é a essência dos modelos de *mistura de especialistas* (*mixture of experts*, ou MoE): um mecanismo roteador (*router*) seleciona o especialista Z e, em seguida, o token X é produzido conforme a distribuição daquele especialista. O que observamos é apenas a mistura, exatamente a marginal p_X obtida somando-se sobre os especialistas; veja [4].

Vale registrar, contudo, que a marginal não preserva a estrutura latente. O modelo alternativo em que o especialista 1 emite apenas o token a (com massa total $1/3$) e o especialista 2 emite apenas os tokens b e c (com massas $7/12$ e $1/12$) tem exatamente a mesma marginal p_X , embora a estrutura latente seja completamente diferente. Como as marginais não determinam a conjunta, em geral há infinitas estruturas latentes compatíveis com os mesmos dados observados, e recuperar a estrutura latente exige hipóteses estruturais adicionais. Este é o problema da *identificabilidade* de modelos com variáveis latentes, tema central em aprendizado não supervisionado (*unsupervised learning*).

2. Esperança de Funções de Vetores Aleatórios

A discussão da seção anterior mostrou como a função de probabilidade conjunta organiza toda a informação sobre um par de variáveis aleatórias, inclusive em modelos com variáveis latentes, nos quais só observamos a marginal. A mesma descrição conjunta torna possível agora ir além das probabilidades de eventos como $\{X = x\}$ e $\{Y = y\}$: podemos também calcular a esperança de expressões que dependem simultaneamente das variáveis aleatórias X e Y .

Antes de calcular a esperança de $g(X, Y)$, precisamos verificar que essa expressão define, de fato, uma variável aleatória. Há duas propriedades a serem verificadas: primeiro, que a imagem de $g(X, Y)$ é enumerável; segundo, que a função $g(X, Y)$ é mensurável. A segunda verificação é especialmente importante porque não estamos supondo que g seja contínua ou mensurável.

Exercício 3. Sejam X e Y variáveis aleatórias discretas no espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$. Defina $Z : \Omega \rightarrow \mathbb{R}$ por

$$Z(\omega) = X(\omega)Y(\omega), \quad \omega \in \Omega.$$

Mostre que o produto $X \cdot Y$, isto é, a função Z , é uma variável aleatória discreta. Para isso, verifique que $\text{Im } Z$ é enumerável e que, para cada $z \in \mathbb{R}$, o conjunto $\{Z = z\}$ pertence a $\mathcal{F}$.

Proposição 5 (Mensurabilidade de uma função de duas variáveis discretas). Se X e Y são variáveis aleatórias discretas em $(\Omega, \mathcal{F}, \mathbb{P})$ e $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ é uma função arbitrária, então a função $Z : \Omega \rightarrow \mathbb{R}$ dada por

$$Z(\omega) = g(X(\omega), Y(\omega)), \quad \omega \in \Omega$$

é uma função mensurável e consequentemente Z é uma variável aleatória. Além disso, sua imagem é enumerável e, portanto, Z é uma variável aleatória discreta.

Prova. Vamos dividir a demonstração em três etapas. Na primeira, verificaremos que Z assume apenas uma quantidade enumerável de valores. Na segunda, mostraremos que cada conjunto da forma $\{Z = z\}$ é um evento mensurável. Por fim, usaremos esses conjuntos para verificar diretamente a mensurabilidade de Z .

Parte 1: A imagem de Z é enumerável.


Como X e Y são variáveis aleatórias discretas, os conjuntos $\text{Im } X$ e $\text{Im } Y$ são enumeráveis. Consequentemente, o produto cartesiano

$$\text{Im } X \times \text{Im } Y$$

também é enumerável. Com efeito, se escrevermos $\text{Im } X = \{x_1, x_2, \dots\}$ e $\text{Im } Y = \{y_1, y_2, \dots\}$, seus pares ordenados podem ser organizados em uma lista

$$(x_1, y_1), (x_1, y_2), (x_2, y_1), (x_1, y_3), (x_2, y_2), (x_3, y_1), \dots$$

obtida da forma mostrada na figura abaixo



É claro que se $\text{Im } X$ é um conjunto finito, por exemplo, então a tabela acima possui um número finito de linhas. Observação completamente análoga aplica-se ao número de colunas, caso o conjunto $\text{Im } Y$ seja finito.

Observe que para cada $\omega \in \Omega$, temos $X(\omega) \in \text{Im } X$ e $Y(\omega) \in \text{Im } Y$. Logo,

$$\begin{aligned} \text{Im } Z &= \{Z(\omega) : \omega \in \Omega\} \\ &= \{g(X(\omega), Y(\omega)) : \omega \in \Omega\} \\ &\subseteq \{g(x, y) : x \in \text{Im } X, y \in \text{Im } Y\}. \end{aligned}$$

Já que a imagem do conjunto enumerável $\text{Im } X \times \text{Im } Y$ pela função g é um conjunto enumerável, então o subconjunto que aparece mais a direita na expressão acima é um conjunto enumerável. Portanto, concluímos que $\text{Im } Z$ é enumerável.

Parte 2: Os conjuntos $\{Z = z\}$ são mensuráveis.

Fixe $z \in \mathbb{R}$. Vamos identificar exatamente quais pontos $\omega \in \Omega$ pertencem ao conjunto

$$\{Z = z\} \equiv \{\omega \in \Omega : Z(\omega) = z\}.$$

Para organizar a união que aparecerá, considere o conjunto de pares

$$I_z = \{(x, y) \in \text{Im } X \times \text{Im } Y : g(x, y) = z\}.$$

Como I_z é um subconjunto de um conjunto enumerável $\text{Im } X \times \text{Im } Y$, então ele também é um conjunto enumerável.

Observe que para cada $(x, y) \in \mathbb{R}^2$, temos

$$\begin{aligned} \{X = x, Y = y\} &= \{\omega \in \Omega : X(\omega) = x \text{ e } Y(\omega) = y\} \\ &= \{\omega \in \Omega : X(\omega) = x\} \cap \{\omega \in \Omega : Y(\omega) = y\} \\ &= \{X = x\} \cap \{Y = y\} \in \mathcal{F}. \end{aligned}$$

Em particular, para cada $(x, y) \in I_z$ temos que $\{X = x, Y = y\} \in \mathcal{F}$.

Próximo passo é mostrar que vale a seguinte igualdade

$$\{Z = z\} = \bigcup_{(x,y) \in I_z} \{X = x, Y = y\}. \quad (7)$$

De fato, se $\omega \in \{Z = z\}$, então segue da definição de Z que

$$g(X(\omega), Y(\omega)) = Z(\omega) = z.$$

Já que $X(\omega) \in \text{Im } X$ e $Y(\omega) \in \text{Im } Y$ e portanto pela definição de I_z temos

$$(X(\omega), Y(\omega)) \in I_z.$$

Naturalmente, $X(\omega) = X(\omega)$ e $Y(\omega) = Y(\omega)$, de modo que $\omega \in \{X = X(\omega), Y = Y(\omega)\}$. Logo, ω pertence à união no lado direito de (7).

Agora, para provar a inclusão contrária, tome

$$\omega \in \bigcup_{(x,y) \in I_z} \{X = x, Y = y\}.$$

Então existe algum par $(x, y) \in I_z$ tal que $X(\omega) = x$ e $Y(\omega) = y$. Como $(x, y) \in I_z$, temos da definição de I_z que $g(x, y) = z$. Consequentemente,

$$Z(\omega) = g(X(\omega), Y(\omega)) = g(x, y) = z$$

o que mostra que $\omega \in \{Z = z\}$. Isso prova (7).

Já que cada conjunto que aparece na união do lado direito de (7) pertence a $\mathcal{F}$ e I_z é enumerável e $\mathcal{F}$ é uma σ -álgebra, então podemos concluir que

$$\{Z = z\} \in \mathcal{F} \quad \text{para todo } z \in \mathbb{R}.$$

Se I_z for vazio, a união em (7) é o conjunto vazio, que também pertence a $\mathcal{F}$.

Parte 3: Z é mensurável.

Para que Z seja uma variável aleatória, precisamos verificar que o conjunto

$$\{Z \in B\} \equiv \{\omega \in \Omega : Z(\omega) \in B\}$$

é mensurável para todo conjunto de Borel $B \subseteq \mathbb{R}$. Pela Parte 1, o conjunto $\text{Im } Z$ é enumerável. Logo, $B \cap \text{Im } Z$, sendo um subconjunto de um conjunto enumerável, também é enumerável, e vale a decomposição

$$\{Z \in B\} = \bigcup_{z \in B \cap \text{Im } Z} \{Z = z\}. \quad (8)$$

Com efeito, $\omega \in \{Z \in B\}$ se, e somente se, $Z(\omega) \in B$; como $Z(\omega) \in \text{Im } Z$, isso equivale a $Z(\omega) \in B \cap \text{Im } Z$, ou seja, ω pertence a $\{Z = z\}$ para algum $z \in B \cap \text{Im } Z$. Pela Parte 2, cada conjunto $\{Z = z\}$ pertence a $\mathcal{F}$, e a união em (8) é enumerável. Como $\mathcal{F}$ é fechada por uniões enumeráveis, segue que $\{Z \in B\} \in \mathcal{F}$ para todo conjunto de Borel B , o que mostra que Z é mensurável e, portanto, uma variável aleatória. Isso encerra a prova da proposição. ■

Observe que em nenhum momento usamos uma propriedade especial de g , como continuidade ou mensurabilidade. O ponto decisivo é que X e Y assumem valores em conjuntos enumeráveis; por isso, só precisamos considerar os valores de g no conjunto enumerável $\text{Im } X \times \text{Im } Y$.

Exercício 4. Sejam X e Y variáveis aleatórias discretas definidas sobre o espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$. Usando a [Proposição 5](#), mostre que

$$Z \equiv \frac{\cos(X)}{1 + e^Y}$$

também define uma variável aleatória discreta sobre $(\Omega, \mathcal{F}, \mathbb{P})$.

Pela [Proposição 5](#), $Z \equiv g(X, Y)$ é uma variável aleatória discreta. Como veremos abaixo, sua esperança pode ser calculada diretamente a partir da função de probabilidade conjunta $p_{X,Y}(x, y) = \mathbb{P}(X = x, Y = y)$, como é mostrado no [Teorema 6](#). A demonstração é análoga à do teorema correspondente para funções de uma única variável aleatória discreta; vamos reproduzi-la aqui, por questão de completude, repetindo com calma cada uma de suas etapas.

Teorema 6 (Teorema da Mudança de Variáveis). Sejam $(\Omega, \mathcal{F}, \mathbb{P})$ um espaço de probabilidade, X e Y variáveis aleatórias discretas sobre este espaço. Para qualquer função $g : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$ temos

$$\mathbb{E}[g(X, Y)] = \sum_{x \in \text{Im } X} \sum_{y \in \text{Im } Y} g(x, y) \mathbb{P}(X = x, Y = y), \quad (9)$$

sempre que a soma do lado direito da igualdade acima convergir absolutamente, isto é,

$$\sum_{x \in \text{Im } X} \sum_{y \in \text{Im } Y} |g(x, y)| \mathbb{P}(X = x, Y = y) < \infty.$$

Prova. Vamos seguir o mesmo roteiro usado na demonstração do Teorema da Mudança de Variáveis para funções de uma única variável aleatória. Primeiro agruparemos os pares (x, y) de acordo com o valor que g assume neles. Esse agrupamento permitirá verificar que $Z = g(X, Y)$ possui esperança bem definida e, depois, calcular essa esperança diretamente pela sua definição.

Parte 1: Uma partição do conjunto D .

Para facilitar a exposição vamos introduzir as seguintes notações:

$$D = \text{Im } X \times \text{Im } Y, \quad J = g(D), \quad Z = g(X, Y).$$

Como D é enumerável, pela primeira parte da demonstração da [Proposição 5](#), o conjunto J também é enumerável.

Antes de prosseguir registramos uma informação importante. Usamos $J = g(D)$, e não apenas $\text{Im } Z$, porque queremos agrupar todos os pares que aparecem na soma do enunciado. De fato, pode ocorrer que $\text{Im } Z$ seja um subconjunto próprio de J . A razão é a seguinte: um par $(x, y) \in D$ significa apenas que x é um valor possível de X e que y é um valor possível de Y , considerados separadamente. Pode não existir nenhum $\omega \in \Omega$ que realize esses dois valores *simultaneamente*, isto é, podemos ter $\{X = x, Y = y\} = \emptyset$, o que é o mesmo que $\mathbb{P}(X = x, Y = y) = 0$. Nesse caso, o valor $g(x, y)$ pode não ser assumido por Z , ainda que o par (x, y) participe da soma do enunciado com peso nulo.

Um exemplo concreto esclarece a distinção. Seja X o resultado de um lançamento de uma moeda justa, com valores em $\{0, 1\}$, e tome $Y = X$. Então $D = \{0, 1\} \times \{0, 1\}$, mas os pares $(0, 1)$ e $(1, 0)$ têm probabilidade zero, pois Y coincide com X . Para $g(x, y) = x + y$, temos $J = g(D) = \{0, 1, 2\}$, enquanto $Z = g(X, Y) = 2X$ só assume os valores $\text{Im } Z = \{0, 2\}$. Assim, $1 \in J \setminus \text{Im } Z$: o valor 1 só seria atingido pelos pares $(0, 1)$ e $(1, 0)$, que nunca ocorrem simultaneamente, e por isso não contribui para a esperança.

Para cada $z \in J$, considere “a fibra” (veja [Figura 3](#))

$$D_z = D \cap g^{-1}(\{z\}) = \{(x, y) \in D : g(x, y) = z\},$$

formada por todos os pares $(x, y) \in D$ que a função g envia no valor z . Esses conjuntos formam uma partição de D , isto é,

$$D = \bigcup_{z \in J} D_z, \quad (10)$$

e são dois a dois disjuntos. De fato, cada par $(x, y) \in D$ pertence exatamente à fibra correspondente ao valor $z = g(x, y)$. A [Figura 3](#) representa esse agrupamento, com uma das fibras destacada.




Figura 3: As fibras de g formam uma partição de D . Todos os pares que pertencem à fibra destacada D_z são enviados por g no mesmo valor $z \in J$. Neste esquema, as fibras exibidas têm, respectivamente, dois, três e quatro pontos, pois a quantidade de pontos de uma fibra não precisa coincidir com a das demais.

Pela hipótese do teorema, a soma no lado direito de (9) converge absolutamente, isto é,

$$\sum_{x \in \text{Im } X} \sum_{y \in \text{Im } Y} |g(x, y)| \mathbb{P}(X = x, Y = y) < \infty. \quad (11)$$

Parte 2: A função de probabilidade de Z .

O próximo passo é expressar a função de probabilidade de Z em termos da função de probabilidade conjunta de (X, Y) . Para cada $z \in J$, temos

$$\mathbb{P}(Z = z) = \sum_{(x,y) \in D_z} \mathbb{P}(X = x, Y = y). \quad (12)$$

De fato, a identidade (7), demonstrada na **Proposição 5**, fornece

$$\{Z = z\} = \bigcup_{(x,y) \in D_z} \{X = x, Y = y\}.$$

Os eventos dessa união são dois a dois disjuntos. Logo, (12) segue da σ -aditividade de $\mathbb{P}$.

Parte 3: Existência da esperança de Z .

Para verificar que Z possui esperança bem definida, precisamos controlar a série dos valores absolutos que aparece na definição de esperança. Como suas parcelas são não negativas, podemos agrupá-las segundo a partição (10) e reindexá-las sem alterar o valor da soma. Essa é a mesma propriedade das séries de termos não-negativos usada na demonstração do Teorema da Mudança de Variáveis. Usando também (12) e o fato de que $|g(x, y)| = |z|$ para todo $(x, y) \in D_z$, obtemos

$$\begin{aligned} \sum_{z \in J} |z| \mathbb{P}(Z = z) &= \sum_{z \in J} |z| \sum_{(x,y) \in D_z} \mathbb{P}(X = x, Y = y) \\ &= \sum_{z \in J} \sum_{(x,y) \in D_z} |z| \mathbb{P}(X = x, Y = y) \\ &= \sum_{z \in J} \sum_{(x,y) \in D_z} |g(x, y)| \mathbb{P}(X = x, Y = y) \\ &= \sum_{(x,y) \in D} |g(x, y)| \mathbb{P}(X = x, Y = y) \\ &= \sum_{x \in \text{Im } X} \sum_{y \in \text{Im } Y} |g(x, y)| \mathbb{P}(X = x, Y = y) \\ &< \infty \end{aligned}$$

onde na desigualdade acima usamos exatamente a hipótese (11). Como $\text{Im } Z \subseteq J$, a soma dos mesmos termos sobre $\text{Im } Z$ também é finita. Portanto, $Z = g(X, Y)$ possui esperança bem definida.

Parte 4: Cálculo de $\mathbb{E}[g(X, Y)]$.

A etapa anterior fornece precisamente o controle necessário para reagrupar a série que define a esperança de Z . Além disso, se $z \in J \setminus \text{Im } Z$, então $\{Z = z\} = \emptyset$ e, portanto, $\mathbb{P}(Z = z) = 0$. Podemos, assim, estender a soma da definição de $\mathbb{E}[Z]$ de $\text{Im } Z$ a J . Usando

novamente (12) e a partição (10), concluímos que

$$\begin{aligned}
\mathbb{E}[g(X, Y)] &= \mathbb{E}[Z] \\
&= \sum_{z \in J} z \mathbb{P}(Z = z) \\
&= \sum_{z \in J} z \sum_{(x, y) \in D_z} \mathbb{P}(X = x, Y = y) \\
&= \sum_{z \in J} \sum_{(x, y) \in D_z} g(x, y) \mathbb{P}(X = x, Y = y) \\
&= \sum_{(x, y) \in D} g(x, y) \mathbb{P}(X = x, Y = y) \\
&= \sum_{x \in \text{Im } X} \sum_{y \in \text{Im } Y} g(x, y) \mathbb{P}(X = x, Y = y),
\end{aligned}$$

que é exatamente a identidade (9). ■

O exemplo a seguir mostra o **Teorema 6** em ação em uma das operações mais onipresentes das arquiteturas contemporâneas de redes neurais.

Exemplo 7 (Agrupamento (*pooling*) e Atenção como Esperanças).

1. **Motivação.** Ao analisar um texto composto por uma sequência de n *tokens* (como as n palavras de uma sentença), modelos de inteligência artificial representam cada palavra por um vetor numérico $v_i \in \mathbb{R}^d$, chamado *embedding* (vetor de representação), onde d é a dimensão do espaço vetorial (como $d = 768$). Em diversas tarefas, como na classificação de um texto ou na geração de um resumo da sentença, é necessário condensar a sequência de n vetores $(v_1, \dots, v_n)$ em um único vetor em $\mathbb{R}^d$. A forma mais direta de realizar essa síntese é calcular a média aritmética

$$\frac{1}{n} \sum_{i=1}^n v_i,$$

operação conhecida como *agrupamento por média* (*average pooling*).

2. **Reformulação probabilística.** Podemos formular essa operação diretamente na linguagem de probabilidade. Considere o espaço amostral de posições $\Omega = \{1, \dots, n\}$ munido de uma probabilidade $\mathbb{P}$, e defina duas variáveis aleatórias:

- $X : \Omega \rightarrow \{1, \dots, n\}$ dada por $X(\omega) = \omega$, que registra a **posição sorteada** na sequência;
- $Y : \Omega \rightarrow \mathbb{R}^d$ dada por $Y(\omega) = v_\omega$, que registra o **vetor de embedding** correspondente à posição sorteada.

Como o vetor Y é determinado unicamente pela posição X , a função de probabilidade conjunta do par (X, Y) assume valores não nulos exclusivamente nos n pares da forma (i, v_i) , isto é,

$$p_{X,Y}(i, v) = \begin{cases} \mathbb{P}(X = i), & \text{se } v = v_i, \\ 0, & \text{caso contrário.} \end{cases}$$

Quando a posição é sorteada uniformemente ao acaso na sequência, temos $\mathbb{P}(X = i) = 1/n$ para cada $i \in \{1, \dots, n\}$.

3. **Agrupamento como esperança.** Como $Y = (Y_1, \dots, Y_d)$ assume valores em $\mathbb{R}^d$, definimos seu vetor de esperanças coordenada a coordenada por $\mathbb{E}[Y] \equiv \sum_{j=1}^d \mathbb{E}[Y_j] e_j$, onde $\{e_1, \dots, e_d\}$ denota a base canônica de $\mathbb{R}^d$. Para cada componente $j \in \{1, \dots, d\}$, a função projeção $g_j(x, v) = \langle e_j, v \rangle$ assume valores reais, e o **Teorema 6** fornece

$$\begin{aligned} \mathbb{E}[Y] &= \sum_{j=1}^d \mathbb{E}[Y_j] e_j \\ &= \sum_{j=1}^d e_j \sum_{i=1}^n \sum_v \langle e_j, v \rangle p_{X,Y}(i, v) \\ &= \sum_{i=1}^n \left(\sum_{j=1}^d \langle e_j, v_i \rangle e_j \right) \mathbb{P}(X = i) \\ &= \sum_{i=1}^n v_i \mathbb{P}(X = i) \\ &= \frac{1}{n} \sum_{i=1}^n v_i. \end{aligned}$$

Portanto, o agrupamento por média (*average pooling*) é rigorosamente a esperança do vetor aleatório Y sob a distribuição uniforme de posições.

4. **Mecanismo de Atenção e Medidas de Gibbs.** O mecanismo de *atenção* (*attention mechanism*), introduzido em [5] e central na arquitetura dos modelos baseados em *Transformers*, opera sob este mesmo princípio, substituindo a distribuição uniforme sobre as posições por uma *medida de Gibbs*, exatamente como apresentada nas notas anteriores sobre propriedades da probabilidade.

Em vez de resumir os tokens por uma média uniforme, a atenção realiza uma busca orientada: fixado um vetor de consulta $q \in \mathbb{R}^d$ (*query*, que representa a informação procurada), cada token $i \in \{1, \dots, n\}$ da sequência possui um **vetor de chave** $k_i \in \mathbb{R}^d$ (*key*, que atua como rótulo identificador do conteúdo do token) e um **vetor de valor** $v_i \in \mathbb{R}^d$ (*value*, que contém a representação semântica a ser transmitida). Os produtos escalares

$$s_i = q \cdot k_i$$

medem a afinidade entre a consulta q e a chave do i -ésimo token. Definindo a função de energia (o *Hamiltoniano*) sobre o espaço de posições $\Omega = \{1, \dots, n\}$ por

$$H(i) = -s_i = -q \cdot k_i,$$

onde posições com chaves de maior similaridade correspondem a menor energia, a função *softmax* define a medida de Gibbs $\mathbb{P}_\beta$ com parâmetro inverso de temperatura $\beta = 1$:

$$\alpha_i = \mathbb{P}_{\beta=1}(X = i) = \frac{e^{-H(i)}}{Z(1)} = \frac{e^{s_i}}{\sum_{j=1}^n e^{s_j}},$$

onde $Z(1) = \sum_{j=1}^n e^{s_j}$ é a *função de partição*. A saída da camada de atenção é, então, nada mais do que a esperança do vetor Y sob essa medida de Gibbs:

$$\sum_{i=1}^n \alpha_i v_i = \mathbb{E}_{\beta=1}[Y].$$

Em vez de atribuir o mesmo peso $1/n$ a todas as posições, a atenção concentra a probabilidade nas posições de menor energia (maior afinidade entre a consulta q e a chave k_i).




Figura 4: A atenção associa uma medida de Gibbs α às posições $\{1, \dots, n\}$ e devolve a esperança de Y sob essa distribuição; no regime de altas temperaturas, recupera-se o agrupamento por média (*average pooling*).

5. **Temperatura e limites termodinâmicos.** A introdução do parâmetro de *temperatura* $T = 1/\beta > 0$ (*temperature*) nos pesos de atenção,

$$\alpha_i(T) = \mathbb{P}_\beta(X = i) = \frac{e^{-\beta H(i)}}{Z(\beta)} = \frac{e^{s_i/T}}{\sum_{j=1}^n e^{s_j/T}},$$

reproduz exatamente os comportamentos assintóticos das medidas de Gibbs:

- **Limite de altas temperaturas** ($T \rightarrow \infty$, ou $\beta \downarrow 0$): como visto no exercício correspondente das notas anteriores, a medida de Gibbs converge para a distribuição uniforme ($\alpha_i(T) \rightarrow 1/n$). Assim, a atenção se reduz ao agrupamento por média (*average pooling*);
- **Limite de baixas temperaturas** ($T \rightarrow 0$, ou $\beta \rightarrow \infty$): como também demonstrado nas notas anteriores, a medida concentra toda a sua massa nos estados de energia mínima (isto é, na posição de maior escore $s_{i^*} = \max_j s_j$), e a esperança $\mathbb{E}[Y]$ converge para o vetor v_{i^*} , recuperando o agrupamento por máximo (*max pooling*).

A esperança $\mathbb{E}[Y]$ sob a família de medidas de Gibbs unifica, portanto, toda a escala contínua entre a média aritmética e o máximo.

O leitor mais atento deve ter notado que a demonstração do **Teorema 6** usou apenas a definição de esperança, a σ -aditividade de $\mathbb{P}$ e os fatos sobre reindexação de séries de termos não negativos ou absolutamente convergentes já empregados no Teorema da Mudança de Variáveis. Em particular, ela não depende da linearidade da esperança, que será deduzida a seguir como consequência do teorema.

Antes de enunciar a linearidade, precisamos registrar que a combinação linear de duas variáveis aleatórias discretas é novamente uma variável aleatória discreta. Essa verificação é necessária, pois ainda não havíamos estabelecido que operações entre variáveis aleatórias preservam essa propriedade.

Corolário 8 (Combinação linear de variáveis aleatórias discretas). Se X e Y são variáveis aleatórias discretas em $(\Omega, \mathcal{F}, \mathbb{P})$ e $a, b \in \mathbb{R}$, então $aX + bY$ é uma variável aleatória discreta.

Prova. Considere a função $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ dada por $g(x, y) = ax + by$. A **Proposição 5** vale para qualquer função g e, portanto, garante que $g(X, Y)$ é uma variável aleatória discreta. Como $g(X, Y) = aX + bY$, concluímos o resultado. ■

Já temos quase todo terreno preparado para mostrar a validade da propriedade de linearidade da esperança. O único preparativo que falta é o seguinte. Embora o **Corolário 8** garanta que $aX + bY$ seja uma variável aleatória é necessário mostrar que a série associada a sua esperança é uma série absolutamente convergente. Feito isto, podemos, em seguida, aplicar o **Teorema 6**.

Teorema 9 (Linearidade da esperança). Se X e Y são variáveis aleatórias discretas sobre um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbb{P})$ e $a, b \in \mathbb{R}$, então

$$\mathbb{E}[aX + bY] = a \mathbb{E}[X] + b \mathbb{E}[Y], \quad (13)$$

sempre que $\mathbb{E}[X]$ e $\mathbb{E}[Y]$ existirem, isto é, sempre que as séries que definem essas esperanças convergirem absolutamente.

Prova. Pelo **Corolário 8**, $aX + bY$ é uma variável aleatória discreta. Para aplicar o **Teorema 6** com $g(x, y) = ax + by$, precisamos verificar a convergência absoluta da soma correspondente. Para isso, aplicamos a desigualdade triangular termo a termo:

$$|ax + by| \leq |a| |x| + |b| |y|.$$

Como as parcelas do lado direito são não negativas, podemos distribuir e trocar a ordem das somas, obtendo

$$\begin{aligned} & \sum_{x \in \text{Im } X} \sum_{y \in \text{Im } Y} |ax + by| \mathbb{P}(X = x, Y = y) \\ & \leq \sum_{x \in \text{Im } X} \sum_{y \in \text{Im } Y} (|a| |x| + |b| |y|) \mathbb{P}(X = x, Y = y) \\ & = |a| \sum_{x \in \text{Im } X} |x| \sum_{y \in \text{Im } Y} \mathbb{P}(X = x, Y = y) + |b| \sum_{y \in \text{Im } Y} |y| \sum_{x \in \text{Im } X} \mathbb{P}(X = x, Y = y) \\ & = |a| \sum_{x \in \text{Im } X} |x| \mathbb{P}(X = x) + |b| \sum_{y \in \text{Im } Y} |y| \mathbb{P}(Y = y) < \infty, \end{aligned}$$

onde usamos (4) e (5) nas duas últimas igualdades. Note que a finitude das últimas somas no lado direito acima é precisamente a hipótese de que $\mathbb{E}[X]$ e $\mathbb{E}[Y]$ existem. Assim, o **Teorema 6** e a convergência absoluta das séries fornecem

$$\begin{aligned}
\mathbb{E}[aX + bY] &= \sum_{x \in \text{Im } X} \sum_{y \in \text{Im } Y} (ax + by) \mathbb{P}(X = x, Y = y) \\
&= a \sum_{x \in \text{Im } X} x \sum_{y \in \text{Im } Y} \mathbb{P}(X = x, Y = y) + b \sum_{y \in \text{Im } Y} y \sum_{x \in \text{Im } X} \mathbb{P}(X = x, Y = y) \\
&= a \sum_{x \in \text{Im } X} x \mathbb{P}(X = x) + b \sum_{y \in \text{Im } Y} y \mathbb{P}(Y = y) \\
&= a \mathbb{E}[X] + b \mathbb{E}[Y],
\end{aligned}$$

onde usamos novamente as identidades marginais. Distribuir as constantes nos somatórios e reagrupar as parcelas são operações com séries numéricas, justificadas pela convergência absoluta já verificada, e não propriedades anteriores da esperança. ■

Exercício 5. Suponha que (X, Y) tenha função de probabilidade conjunta

$$\mathbb{P}(X = i, Y = j) = \theta^{i+j+1} \quad \text{para } i, j = 0, 1, 2,$$

com θ como no **Exercício 2**. Mostre que

$$\mathbb{E}[XY] = \theta^3 + 4\theta^4 + 4\theta^5$$

e que

$$\mathbb{E}[X] = \theta^2 + 3\theta^3 + 3\theta^4 + 2\theta^5.$$

Observação 10. A linearidade (13) estende-se de imediato, por indução, a qualquer combinação linear finita: se $X_1, \dots, X_n$ são variáveis aleatórias discretas com esperança finita e $a_1, \dots, a_n \in \mathbb{R}$, então

$$\mathbb{E} \left[\sum_{i=1}^n a_i X_i \right] = \sum_{i=1}^n a_i \mathbb{E}[X_i].$$

Este fato será usado repetidamente em aplicações posteriores.

3. Aplicações da Linearidade da Esperança

A linearidade é a propriedade mais versátil dentre as que demonstramos até aqui, e nesta seção vamos explorar um roteiro de uso que se repete em inúmeras aplicações: quando uma variável aleatória Y conta quantos objetos satisfazem uma determinada condição, escrevemos Y como soma de indicadoras, uma para cada objeto, calculamos a esperança de cada indicadora por contagem direta no espaço amostral e deixamos que a linearidade some os resultados. O ponto central do roteiro é que ele não exige qualquer noção de independência entre as parcelas.

As três aplicações a seguir ilustram esse roteiro em cenários clássicos: cortes aleatórios em grafos, o problema dos chapéus e recordes em permutações aleatórias. No primeiro deles, a esperança de uma variável aleatória convenientemente construída prova um resultado de existência puramente determinístico, uma primeira amostra do chamado método probabilístico, cuja exposição sistemática é o objeto do livro de Alon e Spencer [1].

3.1. Cortes aleatórios em grafos

Convém introduzir brevemente a noção de *grafo*, que é a estrutura matemática padrão para representar redes e conexões entre objetos.

Intuitivamente, um grafo é formado por dois blocos fundamentais:

- um conjunto de pontos, chamados de **vértices** (ou nós), que representam os objetos de interesse;
- um conjunto de linhas conectando pares de vértices, chamadas de **arestas** (ou ligações), que indicam uma relação direta entre eles.

Essa representação surge de modo ubíquo: em redes sociais, os vértices representam pessoas e as arestas representam amizades; na malha aérea, os vértices são aeroportos e as arestas são voos diretos; na internet, os vértices são roteadores e as arestas são cabos de fibra óptica.

Formalmente, um *grafo simples não-direcionado* é um par $G = (V, E)$, em que V é um conjunto não-vazio de vértices e E é um conjunto de arestas, onde cada aresta $e \in E$ é um par não-ordenado $\{u, v\}$ de vértices distintos ($u, v \in V$ com $u \neq v$). Os vértices u e v são denominados *extremos* (ou extremidades) da aresta e .

Em muitas situações práticas, contudo, os elementos do sistema não pertencem todos a uma mesma categoria homogênea, mas dividem-se naturalmente em duas classes distintas, e as conexões só fazem sentido entre elementos de classes opostas, nunca entre elementos da mesma classe. Por exemplo:

- em plataformas de comércio ou *streaming*, as arestas ligam *usuários* aos *produtos* ou filmes que eles avaliaram (não há conexões diretas de usuário a usuário ou de produto a produto nesse nível de interação);
- na alocação de recursos, associamos *estudantes* a *disciplinas*, ou *candidatos* a *vagas de emprego*;
- em redes acadêmicas, conectamos *pesquisadores* aos *artigos científicos* que eles publicaram.

Em todos esses cenários, os vértices do grafo estão divididos em dois grupos disjuntos e cada aresta existente conecta obrigatoriamente um vértice do primeiro grupo a um do segundo grupo. Essa propriedade estrutural motiva a seguinte definição:

Definição 11 (Grafo bipartido). Dizemos que um grafo $G = (V, E)$ é *bipartido* se o seu conjunto de vértices V puder ser particionado em dois subconjuntos disjuntos V_0 e V_1 (isto é, $V = V_0 \cup V_1$ com $V_0 \cap V_1 = \emptyset$) de tal modo que toda aresta $\{u, v\} \in E$ possua uma extremidade em V_0 e a outra em V_1 . Os subconjuntos V_0 e V_1 são chamados de as *partes* (ou classes) da bipartição.

Vale destacar que a restrição da definição incide exclusivamente sobre as **arestas** existentes, e não sobre os vértices: não é necessário que saia ao menos uma aresta de cada vértice. Em particular, vértices *isolados* (isto é, sem qualquer aresta incidente) são perfeitamente permitidos, pois não geram qualquer conflito com a condição de bipartição.

Podemos visualizar essa propriedade colorindo os vértices com duas cores, digamos preto para os elementos de V_0 e vermelho para os de V_1 . Em um grafo bipartido, toda aresta conecta necessariamente um vértice preto a um vermelho, inexistindo arestas entre vértices

de mesma cor. A **Figura 5** ilustra três exemplos clássicos: o grafo bipartido completo $K_{2,2}$, o caminho P_4 e a estrela $K_{1,3}$.




Figura 5: Três exemplos de grafos bipartidos.

Em contrapartida, em redes gerais complexas (como redes de relacionamentos ou grafos densos), a estrutura global raramente é bipartida, pois a presença de triângulos e outros ciclos de comprimento ímpar inviabiliza uma bipartição perfeita de todos os vértices.

Surge então uma pergunta natural: *mesmo que um grafo $G = (V, E)$ arbitrário não seja bipartido, será que podemos extrair dele um subgrafo bipartido que conserve uma fração substancial de suas arestas?*

Para responder a essa pergunta, podemos impor uma divisão aos vértices de G . Uma forma sistemática de descrever essa divisão é atribuir a cada vértice $v \in V$ um **rótulo** (ou etiqueta ou cor) binário, 0 ou 1, o que particiona V nos grupos $V_0 = \{v \in V : \text{rótulo}(v) = 0\}$ e $V_1 = \{v \in V : \text{rótulo}(v) = 1\}$. Uma vez fixada essa atribuição de rótulos:

- as arestas cujos extremos possuem o **mesmo rótulo** (ambos 0 ou ambos 1) são descartadas;
- as arestas cujos extremos possuem **rótulos distintos** (um em V_0 e outro em V_1) são preservadas.

O conjunto dessas arestas preservadas, isto é, daquelas cujos extremos pertencem a grupos distintos, é chamado de um *corte* (ou *cut*) no grafo G , e cada uma delas é dita uma *aresta cortada*. Ao mantermos todos os vértices de G e apenas as arestas do corte, obtemos um subgrafo gerador $H \subseteq G$ (ou seja, um subgrafo com o mesmo conjunto de vértices de G) que é, por construção, bipartido. A **Figura 6** ilustra essa ideia.




Figura 6: Motivação geométrica para a noção de corte: à esquerda, um grafo G com $n = 5$ vértices e $m = 7$ arestas. À direita, a linha tracejada vertical divide os vértices em duas partes, $V_1 = \{v_1, v_4\}$ e $V_0 = \{v_2, v_3, v_5\}$. As 5 arestas em destaque verde atravessam a linha divisória e formam o corte, constituindo o subgrafo gerador bipartido $H \subseteq G$. As 2 arestas internas a V_0 (tracejadas em cinza) foram descartadas.

Exemplo 12. Vamos provar que todo grafo finito com m arestas contém um subgrafo bipartido com pelo menos $\frac{m}{2}$ arestas.

Note que a afirmação sobre a existência desse subgrafo é puramente determinística: nada nela envolve aleatoriedade. Contudo, encontrar explicitamente uma partição dos vértices que maximize o número de arestas cortadas (o célebre problema do *corte máximo* ou *Max-Cut*) é um problema computacionalmente difícil (NP-difícil).

Surpreendentemente, a probabilidade e a linearidade da esperança fornecem uma demonstração de existência simples e elegante: em vez de procurar deterministicamente a melhor partição, sorteamos a atribuição de rótulos aos vértices jogando uma moeda justa para cada vértice, de maneira independente. Mostraremos que, em média, esse sorteio corta metade das arestas ($m/2$); como a média é $m/2$, deve existir ao menos um corte específico que atinja ou supere esse valor.

Sejam $v_1, \dots, v_n$ os vértices de um grafo G com m arestas. Suponha $n \geq 2$, pois com um único vértice não há arestas e a afirmação é trivial. O experimento aleatório consiste em sortear, para cada vértice, um dos dois rótulos, 0 ou 1. Assim, os vértices com rótulo 0 e os vértices com rótulo 1 formarão os dois conjuntos da bipartição do grafo G . Podemos associar o seguinte espaço de probabilidade a este experimento aleatório

$$\Omega = \{0, 1\}^n, \quad \mathcal{F} = \mathcal{P}(\Omega), \quad \mathbb{P}(\{\omega\}) = \frac{1}{2^n}, \quad \forall \omega \in \Omega.$$

Observe que a aplicação $X_i(\omega) = \omega_i$, a i -ésima coordenada de ω , define uma variável aleatória discreta sobre $(\Omega, \mathcal{F}, \mathbb{P})$. O vetor $\mathbf{X} = (X_1, \dots, X_n)$ é um vetor aleatório discreto com função de probabilidade conjunta dada por

$$p_{\mathbf{X}}(x) \equiv \mathbb{P}(\mathbf{X} = x) = \frac{1}{2^n} \quad \text{para todo } x \in \{0, 1\}^n,$$

e $p_{\mathbf{X}}(x) = 0$ para os demais vetores $x \in \mathbb{R}^n$. Neste caso todos os vetores de rótulos são igualmente prováveis, e X_i é o rótulo atribuído ao vértice v_i .

Dizemos que uma aresta $e = \{v_a, v_b\}$ é *cortada* pelo vetor de rótulos quando seus extremos recebem rótulos distintos, isto é, quando $X_a \neq X_b$.



Figura 7: Uma aresta é cortada quando os rótulos de seus extremos são distintos. Aqui, $X_a = 0$ e $X_b = 1$, portanto $X_a \neq X_b$.

Considere uma enumeração arbitrária do conjunto das arestas de G , digamos, $e_1, \dots, e_m$, onde cada aresta $e_j = \{v_{a_j}, v_{b_j}\}$. Para cada $j = 1, \dots, m$, considere o evento

$$E_j = \{\omega \in \Omega : \omega_{a_j} \neq \omega_{b_j}\}$$

que corresponde ao evento a aresta e_j é cortada. O número de arestas cortadas pode ser representado pela seguinte variável aleatória

$$Y \equiv \sum_{j=1}^m \mathbb{1}_{E_j}.$$

A vantagem dessa escrita é decompor um objeto difícil de analisar em bloco, o número total de arestas cortadas, em parcelas tratáveis individualmente, já que cada indicadora dirige a atenção para uma única aresta.

A probabilidade de cada E_j vem de uma contagem direta. Dos 2^n vetores de rótulos, aqueles em que $\omega_{a_j} \neq \omega_{b_j}$ podem ser contados da seguinte forma: as demais $n-2$ coordenadas são livres e admitem 2^{n-2} escolhas e, para cada uma dessas escolhas, o par $(\omega_{a_j}, \omega_{b_j}) \in \{0, 1\}^2$ admite 4 valores, dos quais exatamente 2 têm entradas distintas. Logo

$$\mathbb{P}(E_j) = \frac{2 \cdot 2^{n-2}}{2^n} = \frac{1}{2}.$$

Chega o momento de somar. Como cada $\mathbb{1}_{E_j}$ só assume os valores 0 e 1, sua esperança existe e vale $\mathbb{E}[\mathbb{1}_{E_j}] = \mathbb{P}(E_j)$. Pela propriedade de linearidade da esperança, concluímos que

$$\mathbb{E}[Y] = \sum_{j=1}^m \mathbb{E}[\mathbb{1}_{E_j}] = \sum_{j=1}^m \mathbb{P}(E_j) = m \cdot \frac{1}{2} = \frac{m}{2}.$$

Resta converter o valor esperado em existência, e aqui usamos que Ω é finito. A esperança $\mathbb{E}[Y]$ é a média dos valores $Y(\omega)$ com pesos uniformes 2^{-n} . Suponhamos, por contradição, que todo corte tenha menos de $m/2$ arestas, isto é, que $Y(\omega) < m/2$ para todo $\omega \in \Omega$. Como Ω é finito, o máximo $M = \max_{\omega \in \Omega} Y(\omega)$ é assumido por algum ponto do espaço e satisfaz $M < m/2$; conseqüentemente,

$$\mathbb{E}[Y] \leq M < \frac{m}{2},$$

em contradição com $\mathbb{E}[Y] = m/2$. Portanto existe $\omega^* \in \Omega$ com $Y(\omega^*) \geq m/2$. A finitude é essencial neste passo: em um conjunto infinito de valores todos estritamente menores que $m/2$, o supremo poderia ser o próprio $m/2$, e a desigualdade estrita não se manteria sem um argumento adicional.

Para concluir, observamos que as arestas cortadas por ω^* formam um subgrafo bipartido de G . Com efeito, se B é o conjunto dos vértices com rótulo 1 em ω^* , então toda aresta cortada tem um extremo em B e o outro no complementar. Como há pelo menos $m/2$ arestas cortadas, o grafo formado por elas é um subgrafo bipartido de G com pelo menos $m/2$ arestas, e a afirmação está provada. No caso do grafo com $n = 5$ vértices e $m = 7$ arestas da [Figura 6](#), a esperança garante a existência de um corte com pelo menos $7/2 = 3,5$ arestas, e a partição ilustrada atinge 5 arestas cortadas.

Observação 13. Quatro observações sobre o [Exemplo 12](#) merecem registro.

Primeira: em nenhum momento usamos independência. A probabilidade $1/2$ de cada aresta ser cortada veio de uma contagem direta no espaço finito $\{0, 1\}^n$, e a linearidade da esperança não exige qualquer hipótese sobre a interação entre as parcelas da soma.

Segunda: a esperança não precisa ser um valor assumido. No triângulo, isto é, no grafo completo com três vértices e $m = 3$ arestas, o número de arestas cortadas só pode ser 0 ou 2: com apenas dois rótulos, dois vértices necessariamente compartilham o rótulo, e exatamente as duas arestas que saem do terceiro vértice cruzam o corte; se os três rótulos coincidem, nenhuma aresta é cortada. Assim Y nunca assume o valor $\mathbb{E}[Y] = 3/2$: a esperança é uma média dos valores possíveis, e não um valor típico que a variável precise realizar.


Terceira: as indicadoras estão longe de se comportar de maneira isolada. Ainda no triângulo, os eventos E_1 , E_2 e E_3 não podem ocorrer simultaneamente, pois três vértices não podem receber rótulos dois a dois distintos usando apenas dois rótulos; em particular, $E_1 \cap E_2 \cap E_3 = \emptyset$, embora cada E_j tenha probabilidade $1/2$. A linearidade da esperança permanece válida sem qualquer restrição.

Quarta: o espaço $\{0, 1\}^n$ do corte aleatório reaparece em mecanismos onipresentes nas arquiteturas de redes neurais modernas. Na regularização por desativação aleatória (*dropout*), cada neurônio ou unidade de uma camada é mantido ativo ou desligado a cada passo de treinamento, e o conjunto dessas decisões é um vetor em $\{0, 1\}^n$; nos modelos de linguagem com mascaramento aleatório de tokens durante o pré-treinamento (*masked language modeling*), a máscara aplicada é igualmente um vetor binário. O corte aleatório é, nesse sentido, uma primeira introdução aos modelos baseados em máscaras binárias aleatórias.

3.2. Permutações

Assim como no corte aleatório, as duas próximas aplicações da linearidade usam um espaço amostral finito e a decomposição em indicadoras; a diferença é que agora o objeto sorteado não é um vetor binário, mas uma ordenação dos elementos de um conjunto. Convém, portanto, recordar a noção de permutação.

Uma permutação de $\{1, 2, \dots, n\}$ é uma função bijetiva $\sigma : \{1, 2, \dots, n\} \rightarrow \{1, 2, \dots, n\}$. Há várias maneiras de se representar uma permutação. Por exemplo, uma permutação do conjunto $\{1, 2, 3, 4\}$ pode ser dada pela função σ definida por $\sigma(1) = 2$, $\sigma(2) = 4$, $\sigma(3) = 3$ e $\sigma(4) = 1$. Esta permutação também pode ser representada pela notação em uma linha $(2, 4, 3, 1)$, que nada mais é do que a lista das imagens $\sigma(1) \sigma(2) \sigma(3) \sigma(4)$, como mostra a figura abaixo:



Por exemplo, a primeira seta lê-se $1 \mapsto \sigma(1) = 2$; a segunda, $2 \mapsto \sigma(2) = 4$, e assim por diante.

Uma maneira familiar de visualizar uma função é desenhar seu gráfico no plano cartesiano. Colocamos a entrada x no eixo horizontal e a saída $y = \sigma(x)$ no eixo vertical. Para a permutação acima, obtemos os pontos $(1, 2)$, $(2, 4)$, $(3, 3)$ e $(4, 1)$:




Figura 8: Gráfico da função discreta $y = \sigma(x)$ associada à permutação $(2, 4, 3, 1)$. Como o domínio é discreto, o gráfico é formado por pontos isolados; por isso, não os ligamos por segmentos.

A coleção de todas as permutações do conjunto $\{1, 2, \dots, n\}$ será denotada por S_n , isto é,

$$S_n \equiv \left\{ \sigma : \{1, 2, \dots, n\} \rightarrow \{1, 2, \dots, n\} : \sigma \text{ é uma bijeção} \right\}.$$

Além do mais, o número de elementos desta coleção satisfaz

$$\#S_n = n!$$

3.3. O Problema dos Chapéus

O problema dos chapéus é um clássico da modelagem probabilística, no qual a linearidade produz uma resposta notavelmente estável: o valor esperado não depende do tamanho do problema.

Exemplo 14. Um grupo de n convidados deixa seus chapéus no guarda-volumes de um restaurante e, na saída, os chapéus são devolvidos em uma ordem aleatória. Quantos convidados recebem o próprio chapéu, em média? Vamos mostrar que a resposta é exatamente 1, qualquer que seja n .

O primeiro passo é especificar o modelo. Para $\sigma \in S_n$, interpretamos o valor $\sigma(i)$ como sendo o número do convidado que recebeu o chapéu do convidado i . A hipótese de devolução

aleatória será modelada pela distribuição uniforme. Assim, nosso problema pode ser tratado no seguinte espaço de probabilidade:

$$\Omega = S_n, \quad \mathcal{F} = \mathcal{P}(\Omega), \quad \mathbb{P}(\{\sigma\}) = \frac{1}{n!} \text{ para todo } \sigma \in S_n,$$

Essa escolha da medida de probabilidade é feita de modo que qualquer uma das maneiras de realizar a devolução dos chapéus é igualmente provável.

A variável aleatória de interesse é

$$X(\sigma) = \#\{i : \sigma(i) = i\},$$

o número de convidados que recebem o próprio chapéu, isto é, o número de pontos fixos da permutação σ . Contar de uma só vez quantos acertos ocorrem parece exigir o estudo de toda a permutação. Entretanto, contar de quantas maneiras um convidado específico recebe de volta seu próprio chapéu é imediato. Isso sugere decompor

$$X = \sum_{i=1}^n X_i, \quad X_i = \mathbb{1}_{D_i}, \quad D_i = \{\sigma \in S_n : \sigma(i) = i\}.$$

As permutações que fixam i são obtidas permutando livremente os demais $n-1$ elementos, de modo que $\#D_i = (n-1)!$ e

$$\mathbb{P}(X_i = 1) = \mathbb{P}(D_i) = \frac{(n-1)!}{n!} = \frac{1}{n}.$$

Pela linearidade da esperança concluímos que

$$\mathbb{E}[X] = \sum_{i=1}^n \mathbb{E}[X_i] = \sum_{i=1}^n \mathbb{P}(D_i) = n \cdot \frac{1}{n} = 1,$$

para todo $n \geq 1$. Em média, exatamente um convidado é beneficiado, haja 10 convidados ou um milhão: o número esperado de acertos não cresce com n . A [Figura 9](#) exibe uma devolução possível.




Figura 9: A devolução de chapéus correspondente à permutação $\sigma = (2, 5, 3, 1, 4)$: apenas o convidado 3 recebe o próprio chapéu, de modo que $X(\sigma) = 1$, exatamente o valor esperado.

Observação 15. O caso $n = 2$ expõe com nitidez o quanto a linearidade é robusta. Nesse caso, $S_2 = \{\text{id}, (1\ 2)\}$ e $D_1 = D_2 = \{\text{id}\}$, de modo que X_1 e X_2 são literalmente a mesma variável aleatória. Ainda assim,

$$\mathbb{E}[X_1 + X_2] = \mathbb{E}[X] = 1 = \frac{1}{2} + \frac{1}{2},$$

pois a linearidade lida sem qualquer restrição com parcelas repetidas. Este é o exemplo mais simples de que a igualdade (13) nada exige sobre a interação entre as parcelas da soma.

O evento $\{X = 0\}$, em que nenhum convidado recebe o próprio chapéu, corresponde às permutações sem pontos fixos, os chamados *desarranjos*. Pode-se mostrar que $\mathbb{P}(X = 0)$ tende a $1/e \approx 0,37$ quando n cresce, mas a demonstração usa inclusão-exclusão, ferramenta que ainda não introduzimos nestas notas. Registramos o fato como motivação para retornarmos a este problema mais adiante no curso.

3.4. Recordes em uma permutação aleatória

Estudaremos agora a frequência com que recordes aparecem em uma sequência de observações. A resposta, o número harmônico H_n , quantifica uma intuição familiar: recordes se tornam cada vez mais raros.

Exemplo 16. Considere n observações com valores dois a dois distintos, como as marcas sucessivas registradas em uma competição. Como a decisão de que o instante i é ou não um recorde envolve apenas comparações entre os valores observados, somente a ordem relativa deles importa. Codificamos essa ordem por uma permutação $\sigma \in S_n$: o número $\sigma(i)$ indica a posição relativa do valor observado no instante i . Assim, $\sigma(i) = 1$ corresponde ao menor valor e $\sigma(i) = n$ ao maior.

O roteiro será curto: primeiro visualizamos uma permutação, depois calculamos a chance de recorde em um instante fixo e, por fim, somamos essas chances para obter o número esperado de recordes.

Para começar com um caso concreto, suponha que $n = 5$ e que

$$\sigma = (2, 5, 1, 4, 3).$$

Isto significa que a segunda observação foi a maior das cinco, a primeira foi a segunda menor, e assim por diante. A permutação pode ser lida também geometricamente: o ponto $(i, \sigma(i))$ é o valor da função discreta $i \mapsto \sigma(i)$ no instante i . A Figura 10 mostra três possibilidades. Em cada gráfico, os pontos em teal são os recordes, enquanto os pontos vermelhos não são recordes.




Figura 10: Três gráficos de funções discretas $i \mapsto \sigma(i)$ para permutações de $\{1, 2, 3, 4, 5\}$. Cada linha e cada coluna contém exatamente um ponto. Os pontos em teal são recordes e os pontos vermelhos não são recordes; portanto, da esquerda para a direita, os números de recordes são 2, 2 e 1.

A hipótese de ordem aleatória corresponde ao espaço de probabilidade

$$\Omega = S_n, \quad \mathcal{F} = \mathcal{P}(\Omega), \quad \mathbb{P}(\{\sigma\}) = \frac{1}{n!} \text{ para todo } \sigma \in S_n.$$

Depois de observar os primeiros i valores, dizemos que o instante i é um *recorde* quando o valor atual é o maior observado até aquele momento. Como os valores são distintos, isto equivale a $\sigma(i) > \sigma(j)$ para todo $j < i$. Denote por E_i o evento correspondente:

$$E_i = \left\{ \sigma \in S_n : \sigma(i) = \max\{\sigma(1), \dots, \sigma(i)\} \right\}$$

Sua indicadora $R_i = \mathbf{1}_{E_i}$ vale 1 quando há recorde no instante i e vale 0 caso contrário. Assim, o número total de recordes é

$$R = \sum_{i=1}^n R_i.$$

Note que o evento E_1 é igual a todo o espaço amostral S_n , porque a primeira observação, de qualquer permutação, não tem antecessoras a superar e será sempre um recorde. Portanto $R_1 \equiv 1$. A Figura 11 acompanha todas essas definições em um único exemplo.

	A permutação $\sigma = (2, 5, 1, 4, 3)$				
	$i = 1$	$i = 2$	$i = 3$	$i = 4$	$i = 5$
valor de $\sigma(i)$	2	5	1	4	3
máximo até i	2	5	5	5	5
R_i	1	1	0	0	0

recorde quando
o valor atual
é o máximo
até aqui

Figura 11: Leitura da permutação $\sigma = (2, 5, 1, 4, 3)$. A primeira linha mostra a posição relativa de cada observação na ordem crescente (1 = menor e 5 = maior). A linha central guarda o máximo acumulado; por isso, os dois primeiros instantes são recordes e $R(\sigma) = 1 + 1 + 0 + 0 + 0 = 2$.

O núcleo do exemplo é calcular $\mathbb{P}(E_i)$ para cada instante i . Uma tentativa direta teria de acompanhar simultaneamente as $i - 1$ comparações $\sigma(i) > \sigma(j)$. Para tornar a contagem manejável, usamos a seguinte ideia: como o recorde depende apenas dos primeiros i valores, primeiro fixamos quais são esses valores e só depois contamos suas possíveis ordens. Para cada $A \subseteq \{1, \dots, n\}$ com $\#A = i$, defina

$$B_A = \left\{ \sigma \in S_n : \{\sigma(1), \dots, \sigma(i)\} = A \right\}.$$

Os conjuntos B_A são blocos disjuntos que cobrem S_n : cada permutação pertence exatamente ao bloco determinado pelo conjunto de valores que ocupam suas primeiras i posições. A Figura 12 mostra o que acontece em um bloco pequeno.

as três primeiras posições recebem os valores de A

$$\begin{array}{ccccc} & 1 & & 3 & \\ 1 & & & & \\ & 2 & & & 3 \end{array}$$

1	3	5
1	5	3
3	1	5
3	5	1
5	1	3
5	3	1

$$\#(B_A \cap E_3) = 2! = 2$$

$$\frac{2}{6} = \frac{1}{3}$$

Figura 12: Dentro do bloco correspondente a $A = \{1, 3, 5\}$, há 3! ordens possíveis para as primeiras três posições. O recorde em $i = 3$ ocorre exatamente nas duas linhas em que o maior valor, 5, aparece na posição 3.

$$\#(B_A \cap E_i) = (i-1)!(n-i)!.$$
$$\begin{aligned}\#E_i &= \binom{n}{i} (i-1)! (n-i)! \\ &= \frac{n!}{i! (n-i)!} (i-1)! (n-i)! \\ &= \frac{n!}{i}.\end{aligned}$$
$$\mathbb{P}(R_i = 1) = \mathbb{P}(E_i) = \frac{\#E_i}{n!} = \frac{1}{i}.$$

Agora o papel das indicadoras fica completo: cada R_i responde a uma única pergunta local, e R soma essas respostas. Pela identidade $\mathbb{E}[\mathbf{1}_E] = \mathbb{P}(E)$ e pela **Teorema 9**, aplicada a

uma soma finita,


$$\begin{aligned}\mathbb{E}[R] &= \sum_{i=1}^n \mathbb{E}[R_i] \\ &= \sum_{i=1}^n \mathbb{P}(R_i = 1) \\ &= \sum_{i=1}^n \frac{1}{i} \equiv H_n,\end{aligned}$$

o n -ésimo *número harmônico*.

Essa é a resposta exata. Para interpretar seu tamanho, resta entender quão rápido H_n cresce. A soma é formada pelos valores de $1/x$ nos inteiros; por isso, comparamos seus termos com a área sob a curva $y = 1/x$. Como a função $x \mapsto 1/x$ é decrescente, para cada $k \geq 1$ vale

$$\frac{1}{k+1} \leq \int_k^{k+1} \frac{dx}{x} \leq \frac{1}{k}.$$

A figura abaixo destaca apenas a cota inferior, que será usada para comparar a soma com a integral: em cada intervalo $[k, k+1]$, o retângulo sombreado de altura $1/(k+1)$ fica inteiramente sob o gráfico da curva. A cota superior é análoga e, para não sobrecarregar o desenho, não a repetimos. Para tornar a ideia concreta, destacamos o que acontece no intervalo $[1, 2]$, como representante de um intervalo genérico da forma $[k, k+1]$.



Somando a desigualdade à direita em $k = 1, \dots, n$ e a desigualdade à esquerda em $k = 1, \dots, n-1$, obtemos

$$\ln(n+1) = \int_1^{n+1} \frac{dx}{x} \leq \sum_{k=1}^n \frac{1}{k} = H_n, \quad H_n - 1 = \sum_{k=1}^{n-1} \frac{1}{k+1} \leq \int_1^n \frac{dx}{x} = \ln n,$$

donde

$$\ln(n+1) \leq H_n \leq 1 + \ln n.$$

Portanto $\mathbb{E}[R]$ cresce como o logaritmo de n . Em números: $H_{10} \approx 2,93$, $H_{100} \approx 5,19$ e, com um milhão de observações, esperamos cerca de 14 recordes. Multiplicar por dez o número de

observações eleva o valor esperado de aproximadamente 3 para aproximadamente 5 recordes; a cada instante i a chance de recorde é $1/i$, e os recordes tornam-se progressivamente raros. Uma realização concreta com $n = 10$, na qual se pode comparar o número efetivo de recordes com o valor médio H_{10} , aparece na **Figura 13**.




Figura 13: A permutação $\sigma = (3, 1, 2, 7, 4, 9, 6, 5, 10, 8)$ vista como uma sequência de observações: os instantes 1, 4, 6 e 9, destacados, são recordes. Aqui $R(\sigma) = 4$, um pouco acima do valor esperado $H_{10} \approx 2,93$.

Observação 17. A identidade $\mathbb{P}(R_i = 1) = 1/i$ quantifica a raridade crescente dos recordes: no instante i , a nova observação precisa superar $i - 1$ antecessoras, e a chance de que isso ocorra é a chance de o máximo parcial cair justamente na posição i , uma entre i posições igualmente prováveis. Note que essa probabilidade não depende de n : o destino do instante i é decidido apenas pelos instantes que o precedem.

Vale registrar, por fim, o que o cálculo de $\mathbb{E}[R]$ não precisou saber: em nenhum momento calculamos probabilidades conjuntas como $\mathbb{P}(R_i = 1, R_j = 1)$. Bastaram as probabilidades individuais das parcelas, ainda que seu comportamento conjunto seja não trivial; R_1 , por exemplo, é constante igual a 1. Curiosamente, pode-se provar que os eventos $E_1, \dots, E_n$ são de fato independentes, no sentido que introduziremos em nota futura, mas esse fato não tornaria o cálculo de $\mathbb{E}[R]$ mais curto: a linearidade já dá tudo o que precisamos. Registramos ainda, sem demonstração, que a sequência $H_n - \ln n$ converge para a constante de Euler, $\gamma \approx 0,5772$.

Observação 18 (Recordes e pontos de salvamento de treinamento). O **Exemplo 16** tem interpretação direta no treinamento de modelos em aprendizado de máquina. Ao treinar uma rede neural por n épocas (*epochs*), registramos a perda de validação L_i ao fim de cada época e salvamos um novo ponto de salvamento (*checkpoint*) exatamente quando L_i é estritamente menor que todas as perdas anteriores, isto é, quando o instante i estabelece um novo recorde (de mínimo) da sequência $L_1, \dots, L_n$.

Sob a hipótese simplificada de que a ordem das perdas de validação seja uma permutação aleatória uniforme, o número esperado de atualizações do melhor modelo ao longo de n épocas é $H_n \approx \ln n$, e a probabilidade de a época i registrar o melhor resultado até então é $1/i$. A grande maioria dos recordes ocorre no início do treinamento, tornando novos avanços progressivamente raros à medida que as épocas avançam. Esse fato fundamenta a intuição teórica para a técnica de *parada antecipada* (*early stopping*), na qual o treinamento é interrompido quando a perda de validação passa muitas épocas sem estabelecer novos recordes.

Essa modelagem teórica requer uma ressalva importante: durante um treinamento real guiado por otimização via gradiente descendente, a função de perda possui uma tendência decrescente sistemática e as observações não são identicamente distribuídas ou estritamente intercambiáveis, de modo que a permutação uniforme atua como uma aproximação de referência.

Os três exemplos desta seção seguiram o mesmo roteiro: definir um experimento aleatório uniforme, decompor a grandeza de interesse em soma de indicadoras, calcular cada probabilidade por contagem direta e somar os resultados pela linearidade. Quando a média obtida garante a existência de uma configuração com as propriedades desejadas, como no **Exemplo 12**, temos o método probabilístico em sua forma mais simples. A hipótese de independência, que não foi necessária em nenhum dos três casos, será introduzida em nota futura e permitirá estimativas mais refinadas.

Exercício 6. No contexto do **Exemplo 14**, denote por $T(\sigma)$ o número de índices $i \in \{1, \dots, n\}$ tais que $\sigma(i) \equiv i + 1 \pmod{n}$, isto é, o número de convidados que recebem o chapéu do próximo convidado na ordem cíclica. Calcule $\mathbb{E}[T]$.

Exercício 7. Seja σ escolhida uniformemente em S_n . Dizemos que um par (i, j) , com $1 \leq i < j \leq n$, é uma *inversão* de σ quando $\sigma(i) > \sigma(j)$. Denotando por $I(\sigma)$ o número de inversões de σ , mostre que

$$\mathbb{E}[I] = \frac{n(n-1)}{4}.$$

Sugestão: para cada par (i, j) , a operação que troca os valores de $\sigma(i)$ e $\sigma(j)$ é uma bijeção de S_n em S_n que leva o conjunto $\{\sigma : \sigma(i) > \sigma(j)\}$ no conjunto $\{\sigma : \sigma(i) < \sigma(j)\}$.

Exercício 8. Seja G um grafo com n vértices e m arestas. Atribua a cada vértice um rótulo sorteando-se um vetor uniformemente em $\{0, 1, 2\}^n$, e diga que uma aresta é *separada* quando seus extremos recebem rótulos distintos. Mostre que o número esperado de arestas separadas é $2m/3$ e conclua que os vértices de G podem ser divididos em três grupos de modo que pelo menos $2m/3$ das arestas conectam vértices de grupos distintos.

Exercício 9 (Comitês de preditores (*ensembles*)). Sejam $X_1, \dots, X_n$ as predições de n modelos distintos para uma mesma grandeza numérica. Suponha que existam constantes $\mu \in \mathbb{R}$, $\sigma^2 > 0$ e $\rho \in [-1, 1]$ tais que, para todo i e todo $j \neq i$,

$$\mathbb{E}[X_i] = \mu, \quad \mathbb{E}[X_i^2] = \mu^2 + \sigma^2, \quad \mathbb{E}[X_i X_j] = \mu^2 + \rho\sigma^2.$$

A última condição diz que cada par de preditores tem o mesmo grau de correlação, medido por ρ . Considere a predição combinada do comitê (*ensemble*), dada pela média

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

(a) Mostre que $\mathbb{E}[\bar{X}] = \mu$.

(b) Mostre que

$$\mathbb{E}[(\bar{X} - \mu)^2] = \frac{\sigma^2}{n} + \left(1 - \frac{1}{n}\right) \rho\sigma^2.$$

Sugestão: expanda o quadrado, use a linearidade da esperança (**Teorema 9**) e calcule $\mathbb{E}[X_i X_j]$, para $i \neq j$, aplicando o **Teorema 6** com $g(x, y) = xy$ à função de probabilidade conjunta do par (X_i, X_j) .

(c) Interprete: o que acontece com o erro quadrático médio do comitê quando $\rho = 0$ e n cresce? E quando $\rho = 1$? À luz da fórmula obtida, por que é vantajoso combinar modelos cujos erros sejam descorrelacionados?

Este é o princípio estatístico por trás de métodos de combinação de modelos como agregação por *bootstrap* (*bagging*) e florestas aleatórias (*random forests*).

Referências

- [1] Noga Alon and Joel H. Spencer. *The probabilistic method*. Wiley Series in Discrete Mathematics and Optimization. John Wiley & Sons, Inc., Hoboken, NJ, fourth edition, 2016.
- [2] Geoffrey Grimmett and Dominic Welsh. *Probability—an introduction*. Oxford University Press, Oxford, second edition, 2014.
- [3] Daniel Jurafsky and James H. Martin. Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition, 2025. Terceira edição (rascunho em revisão contínua, disponível online).
- [4] Noam Shazeer, Azalia Mirhoseini, Krzysztof Maziarczyk, Andy Davis, Quoc V. Le, Geoffrey E. Hinton, and Jeff Dean. Outrageously large neural networks: the sparsely-gated mixture-of-experts layer. In *International Conference on Learning Representations*, 2017.
- [5] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems 30*, pages 5998–6008, 2017.